

PerCorsi di Studio

Statistica con 

Collana diretta da Giuseppe Espa e Rocco Micciolo

Rocco Micciolo, Luisa Canal, Giuseppe Espa

Probabilità e modelli

Teoria e pratica con R

Presentazione di Alan Agresti

Probabilità e modelli
Teoria e pratica con R

Autori: **Rocco Micciolo, Luisa Canal, Giuseppe Espa**
Impaginazione $\text{\LaTeX}$: Compomat s.r.l.

© Copyright 2021 by Maggioli S.p.A.
Maggioli Editore è un marchio di Maggioli S.p.A.
Azienda con sistema qualità certificato ISO 9001: 2015

47822 Santarcangelo di Romagna (RN) • Via del Carpino, 8
Tel. 0541/628111 • Fax 0541/622595
www.maggiolieditore.it
e-mail: clienti.editore@maggioli.it

*Diritti di traduzione, di memorizzazione elettronica, di riproduzione
e di adattamento, totale o parziale con qualsiasi mezzo sono riservati per tutti i Paesi.*

Finito di stampare nel mese di aprile 2021
nello stabilimento Maggioli S.p.A.
Santarcangelo di Romagna (RN)

Sommario

Presentazione	vii
----------------------	------------

Prefazione	ix
-------------------	-----------

1 Probabilità e calcolo delle probabilità

1.1	Probabilità e giochi d'azzardo	
1.1.1	Permutazioni semplici	4
1.1.2	Disposizioni semplici	6
1.1.3	Combinazioni semplici	7
1.1.4	Permutazioni con ripetizione	8
1.1.5	Disposizioni con ripetizione	9
1.1.6	Combinazioni con ripetizione	10
1.1.7	Modelli di occupazione	10
1.1.8	Estrazione di un campione da una popolazione	14
1.1.9	Alcuni esempi	16
1.2	Oltre il gioco d'azzardo: probabilità e fisica	28
1.2.1	Cose che succedono quando i numeri sono molto, molto grandi	30
1.3	Oltre la definizione classica: le definizioni frequentista, soggettivista e assiomatica	35
1.4	La probabilità condizionata	40
1.4.1	Il teorema di Bayes	46
1.4.2	Teorema di Bayes e test diagnostici	50
1.4.3	Teorema di Bayes e ricerca scientifica	54
1.5	Probabilità, odds e scommesse	55
1.5.1	Dalla teoria alla pratica: le scommesse nel mondo reale	60

2 Variabili casuali discrete **69**

2.1	Valore atteso e varianza di una variabile casuale discreta	72
2.2	La variabile casuale uniforme discreta	78
2.3	La variabile casuale triangolare discreta	82
2.4	La variabile casuale di Bernoulli	86
2.5	La variabile casuale geometrica	87
2.6	La variabile casuale binomiale	90
2.7	La variabile casuale ipergeometrica	102
2.8	La variabile casuale di Poisson	105

2.9	La variabile casuale binomiale negativa	113
3	Variabili casuali continue	121
3.1	La variabile casuale uniforme continua	124
3.2	La variabile casuale esponenziale	132
3.2.1	La funzione azzardo	138
3.3	La variabile casuale normale	143
3.3.1	Approssimazioni alla normale e “correzione per la continuità”	153
3.3.2	La variabile casuale log-normale	159
3.4	Altre variabili casuali continue	164
3.4.1	La variabile casuale chi quadrato	164
3.4.2	La variabile casuale t di Student	164
3.4.3	La variabile casuale F	167
3.5	La “famiglia esponenziale” e i modelli lineari generalizzati	168
4	Distribuzioni campionarie	187
4.1	La media campionaria	187
4.1.1	Alcune simulazioni sulla “bontà” del teorema centrale	195
4.2	Precisione e accuratezza	201
4.3	Errore standard e dimensione del campione	203
4.4	La proporzione campionaria	205
4.5	La varianza campionaria	208
4.6	Distribuzioni campionarie di differenze di medie e di rapporti di varianze	214
4.7	La mediana campionaria	215
4.8	L’odds ratio campionario	217
4.9	Il rischio relativo campionario	224
4.10	La distribuzione campionaria di un coefficiente di regressione	229
4.11	Il bootstrap	233
	Bibliografia	243
	Indice analitico	247
	Indice delle funzioni e dei termini di R	251
	Indice dei nomi	253

Presentazione

Professors Micciolo, Canal, and Espa have written an interesting and informative book about probability and its relevance to models. Reading it, we learn not only about the foundations of probability and the use of R software for finding probabilities, but we also gain perspective on the history of the subject. So, while learning how to find probabilities in a variety of settings, we also read anecdotes about personalities as diverse as Dante, Galileo, Bayes, and many others who wrote about some aspects of probability. We also learn about contributions of people from this past century whose writings have helped our understanding of probability and its history, such F. N. David, William Feller, and Stephen Stigler.

The first chapter of the book focuses on the basics of probability and its formulation through frequentist, subjective, and axiomatic approaches. Besides its use in games of chance and gambling, we learn about connections in physics regarding the behavior of particles and molecules. The exposition of R software is very helpful both for new users and those with some experience. For instance, do you know about the `pbirthday()` and `qbirthday()` functions relating to the probability that at least two of a certain number of people have the same birthday? Interesting examples include a surprising probability of false positives in diagnostic tests even when sensitivity and specificity may be very high, and true probabilities associated with bookmaker-stated odds of various teams winning the Series A championship in soccer. Chapter 2 presents the most important probability distributions for discrete random variables. Related topics include probability inequalities and random walks. Chapter 3, which deals with continuous probability distributions, also presents an introduction to linear and generalized linear models, including various link functions for binary data. Chapter 4 presents results about sampling from probability distributions. It pays special attention to the Central Limit Theorem, including simulations to investigate how well it works for various sample sizes and shapes of distributions.

Although this book focuses mainly on probability and R software, I think that the historical focus and the variety of interesting examples will encourage many readers to want to learn more about the topic and to find out the relevance of these topics to statistical inference and the burgeoning field of data science. Congratulations to professors Micciolo, Canal, and Espa!

Alan Agresti
Gainesville, Florida USA

8 marzo 2021

Prefazione

Nella quasi totalità dei corsi di Statistica impartiti presso le università italiane, agli studenti vengono proposti argomenti di Inferenza statistica. In particolare, sia nei corsi di base che in quelli avanzati, i docenti mostrano i fondamenti teorici e l'utilizzo di tecniche che si basano sul metodo induttivo. Tali tecniche costituiscono un bagaglio fondamentale per chi voglia dedicarsi alla ricerca empirica in quanto consentono di trarre inferenze da un insieme relativamente esiguo di osservazioni (il campione) riguardo ad un insieme più grande di osservazioni (la popolazione): conoscendo le caratteristiche di un campione si vuole risalire alle caratteristiche (sconosciute) della popolazione. Non si deve, però, trascurare che alle fondamenta dell'Inferenza statistica c'è il calcolo delle probabilità e i concetti di variabile casuale e di distribuzione campionaria. Una buona conoscenza di tali argomenti è, quindi, un requisito necessario per comprendere compiutamente le tematiche affrontate nella maggior parte dei corsi di Statistica che è possibile frequentare all'università. Questo volume è dedicato, senza alcuna pretesa di essere esaustivo, proprio al calcolo delle probabilità, alle variabili casuali (discrete e continue) e alle distribuzioni campionarie. Gli argomenti trattati nel volume vengono affrontati, secondo lo stile della collana che lo ospita e senza rinunciare al rigore metodologico ed ai necessari formalismi, dalla prospettiva di chi deve utilizzare tali strumenti nelle applicazioni pratiche mediante il software R.

Il testo “chiude” in qualche modo un percorso iniziato con il volume *Analisi esplorativa dei dati con R* e proseguito con il manuale *Ricerca con R - Metodi di inferenza statistica*, entrambi pubblicati dagli autori nella medesima collana, e colma il *gap* che li separa giocando il ruolo di “anello mancante” di una, ora sì, armoniosa catena didattica il cui *file rouge* è proprio R.

Al di là dei contenuti, per noi il volume che state sfogliando ha una valenza importante. In questo periodo di pandemia e di restrizioni che hanno confinato a distanza la didattica che eroghiamo, esserci potuti dedicare a pieno agli strumenti per l'insegnamento rappresenta il modo migliore per dimostrare la nostra volontà di tornare presto in aula e la nostra speranza di poter nuovamente interagire in presenza con i nostri studenti. Questo è stato lo spirito che ci ha, più di ogni altro stimolo, invogliato a scrivere un nuovo volume per la nostra collana *Statistica con R*.

Nel dare il libro alle stampe, cogliamo l'occasione per ringraziare chi ha collaborato, in vario modo, alla sua realizzazione. Per primo ringraziamo l'amico Alan Agresti che non ha certo bisogno di presentazioni né tanto meno di note biografiche e bibliografiche. Da vero “gigante” della Statistica qual è, ha letto con estrema attenzione il nostro lavoro (in italiano!), ci ha fornito utili suggerimenti per migliorarlo

in alcuni punti e, soprattutto, ha voluto scrivere la Presentazione che avete letto in apertura del volume e che rende superflua ogni nostra parola introduttiva.

Esprimiamo, poi, la nostra gratitudine agli amici e colleghi Maria Michela Dickson, Diego Giuliani (Università di Trento) e Flavio Santi (Università di Verona) che, con i loro preziosi consigli, ci hanno consentito di affinare una prima versione di questo manuale che hanno letto con molta pazienza.

Ringraziamo, inoltre, l'Editore Maggioli e, in particolare, Alberto Kratter Thaler e Patrizia Villani che credono nei nostri progetti e che ci seguono sempre con grande professionalità in ogni fase della stesura di un volume.

Da ultima, ma non certo in ordine di importanza, ringraziamo Silvia Maschio (CompoMat s.r.l.). Il suo lavoro editoriale dietro le quinte in ogni progetto che intraprendiamo le è valso l'appellativo di "quinto Beatle"; non abbiamo incontrato problema, in particolare connesso all'uso di $\text{\LaTeX}$, che lei non abbia risolto con la simpatia, il garbo e i modi rassicuranti che la rendono unica e la contraddistinguono.

Questo libro è alla prima edizione e potrebbe contenere refusi, imperfezioni o errori sfuggiti al processo di revisione. Ci scusiamo in anticipo per questo e saremo grati a chi volesse segnalarceli all'indirizzo e-mail giuseppe.espa@unitn.it. In questo modo potremo predisporre un'eventuale errata corrige da depositare sul sito web dedicato al manuale,¹ sito che conterrà anche tutti gli script R usati, una appendice metodologica e eventuale altro materiale integrativo.

Infine, un dettaglio tecnico. Questo libro, come i precedenti nella stessa collana, si basa sulle straordinarie potenzialità di R come strumento didattico basato sulla simulazione. A questo proposito, un aspetto non secondario riguarda la possibilità che ha il lettore di riprodurre esattamente i risultati che abbiamo ottenuto, per poi verificare che questi non dipendono dal particolare "innesco" con cui è iniziata la simulazione. Occorre ricordare che dalla versione 3.6.0 di R (aprile 2019), il metodo con il quale la funzione `sample` (in particolare) produce numeri pseudo-casuali è stato modificato. Rimandiamo all'appendice *online* per una descrizione più dettagliata riguardante questo argomento. Qui ci preme soltanto segnalare che i lettori che volessero riprodurre esattamente i nostri risultati con versioni di R dalla 3.6.0 in poi (attualmente siamo alla 4.0.5) dovranno premettere negli *script* che impiegano la funzione `sample` l'istruzione `RNGkind(sample.kind="Rounding")`.

Questo libro è dedicato a Annamaria, Eleonora, Matias e Daniel (Rocco Micciolo), a mia figlia Giulia, giovane scienziata (Luisa Canal) e a mio figlio Guido, fresco di laurea in Matematica (Giuseppe Espa).

Rocco Micciolo

Luisa Canal

Giuseppe Espa

Trento, 29 marzo 2021

¹<http://hostingwin.unitn.it/micciolo/PeM/home.html>

1

Probabilità e calcolo delle probabilità

“The true logic of this world is in the calculus of probabilities.” Con queste parole di Maxwell¹ inizia il capitolo 6 (dedicato alla probabilità) del primo volume delle leggendarie *“The Feynman Lectures on Physics”*² scritte da Richard Feynman, premio Nobel per la fisica nel 1965.³

Per un fisico conoscere (ed impiegare) il calcolo delle probabilità è fondamentale; tuttavia, la probabilità pervade tutti i campi della conoscenza scientifica e, anche, la vita di tutti i giorni. Eppure, la probabilità è uno degli argomenti più controintuitivi che esistano, quasi che il cervello umano non sia “costruito” in modo adeguato per afferrare pienamente questo tipo di concetto, che si rivela straordinariamente sfuggente. Basata su un numero limitato di “regole” e su una matematica in larga misura “elementare”, la probabilità offre paradossi logici in quantità.⁴ Gli psicologi che studiano il comportamento, più o meno “razionale”, degli esseri umani conducono veri e propri esperimenti esponendo i soggetti a diversi tipi di *stress probabilistici*.⁵

In particolare, Tversky e Kahneman negli anni '70 del 900 studiarono gli errori di ragionamento probabilistico evidenziando come le persone non ragionino secondo le norme della teoria della probabilità.⁶ Conducendo ricerche sperimentali, individuarono tendenze di ragionamento che portano a errori sistematici nella valutazione della

¹James Clerk Maxwell è famoso soprattutto per le sue *equazioni* con le quali unificò elettricità e magnetismo. Inoltre, insieme a Boltzmann e a Gibbs, può essere considerato il “padre” della meccanica statistica. La frase prosegue poco più avanti nel modo seguente: *“This branch of Math., which is generally thought to favour gambling, dicing, and wagering, and therefore highly immoral, is the only ‘Mathematics for Practical Men, as we ought to be.’* Letter to Lewis Campbell; reproduced in L. Campbell and W. Garrett, *The Life of James Clerk Maxwell*, Macmillan, 1881.

²https://www.feynmanlectures.caltech.edu/I_06.html

³Feynman ha fatto anche parte del comitato che indagò sul disastro dello Space Shuttle Challenger; a lui si deve in gran parte la scoperta della causa del disastro.

⁴Uno dei più noti è il *paradosso di Monty Hall*, che abbiamo trattato diffusamente nel libro *Problemi ed esperimenti di statistica con R*.

⁵A chi fosse interessato alla “storia” dell’impiego della probabilità e della statistica in psicologia, consigliamo la lettura dell’articolo di Stigler (1992).

⁶Si veda, ad esempio, Tversky e Kahneman (1974).

probabilità. Questi errori sistematici, indicati spesso con il termine di *illusioni probabilistiche*, sono particolarmente diffusi nell'ambito dei giochi d'azzardo, dove le leggi della probabilità trovano spesso una applicazione quasi "elementare" (come vedremo fra breve). Forse l'illusione più frequente è quella dei "numeri ritardatari" nel gioco del lotto dove molti giocatori sono convinti che un numero abbia più probabilità di essere estratto quanto più lontana è stata la sua ultima estrazione. È assodato che queste illusioni probabilistiche svolgono un ruolo importante nella diffusione del gioco d'azzardo e della patologia ad esso associata.⁷

La difficoltà emersa è soprattutto di tipo logico, quasi che l'essere umano non si trovi a suo agio nel ragionare in condizioni di incertezza. In fondo, probabilità è (può essere considerata) sinonimo di incertezza riferendosi a qualcosa che non si è ancora verificato, ma che potrebbe verificarsi, oppure no. E quindi si deve abbandonare il regno delle certezze e del determinismo per avventurarsi in quello, molto meno sicuro, delle *possibilità*.

La divergenza fra i risultati ottenuti da osservazioni eseguite sotto condizioni sperimentali del tutto equivalenti può essere attribuita ad un ente astratto, il *caso*. Un *esperimento casuale* è un esperimento che, ripetuto sotto condizioni equivalenti, produce risultati differenti. Nonostante la variabilità dei risultati e l'imprevedibilità del singolo risultato, esistono regole, fondate sul calcolo delle probabilità che, opportunamente impiegate, permettono di interpretare i risultati degli esperimenti, separando ciò che è davvero casuale da ciò che può essere invece attribuito ad una componente sistematica (una "causa"); in questo modo, passo dopo passo, si realizza il progresso della conoscenza scientifica non solo nel campo di discipline "hard" quali la fisica e la chimica, ma anche nel campo delle scienze della vita, delle scienze naturali, economiche e sociali.

1.1 Probabilità e giochi d'azzardo

I *giochi di sorte* (in particolare come quelli che oggi chiameremmo gioco dei dadi⁸) sono stati praticati dall'uomo forse già in epoca preistorica,⁹ ma i primi tentativi di analizzare gli esiti dei giochi di sorte con idee probabilistiche sembrano risalire al XVI secolo ad opera del matematico italiano Girolamo Cardano (che scrisse il *Liber*

⁷Chi fosse interessato può consultare il sito www.fateilnostrogioco.it/

⁸Il Canto VI del Purgatorio si apre con il verso: *Quando si parte il gioco de la zara*. Dante fa riferimento ad un gioco (d'azzardo) diffuso nel Medioevo: il "gioco della zara". Questa parola (zara) deriverebbe dall'arabo *zahr*, che significa "dado"; da qui sarebbe derivato in italiano il termine "gioco d'azzardo".

⁹"When man first started to play games of chance is a time problem we shall never clearly resolve...Some time between prehistoric man of four hundred centuries ago and the beginning of the third millennium before Christ *Homo sapiens* invented games and among these games, games of chance." (David, 1955).

de ludo aleae, pubblicato postumo). A circa un secolo dopo risalgono i contributi di Blaise Pascal, di Pierre de Fermat e di Christian Huygens;¹⁰ anche Galileo si occupò, tra il 1613 e il 1623, di problemi analoghi. Veri e propri trattati sulla probabilità sono stati pubblicati, nella decade che va dal 1708 al 1718, da Pierre Rémond de Montmort (*Essay d'analyse sur les jeux de hazard*, 1713), da Jakob Bernoulli (*Ars conjectandi*, 1713) e da Abraham de Moivre (*The doctrine of chances*, 1718). Circa un secolo dopo (nel 1812) Pierre Simon Laplace scrive la *Théorie analytique des probabilités* nella quale enuncia la definizione “classica” di probabilità di un *evento*, che è data dal rapporto fra il numero dei casi favorevoli e il numero dei casi possibili, assumendo che siano tutti ugualmente possibili.¹¹

Naturalmente questa non può essere considerata una vera definizione di probabilità, dal momento che essa è palesemente “circolare” (ugualmente possibile = ugualmente probabile). Tuttavia può essere considerata una maniera “operativa” per calcolare la probabilità, enumerando (ovvero contando) i “casi favorevoli” e i “casi possibili” e facendone il rapporto. Questa regola funziona molto bene nei giochi d'azzardo. Ma non solo. Essa si è dimostrata valida anche in un campo molto diverso da quello dei giochi di sorte: in fisica! Infatti, verso la fine del XIX secolo, le proprietà statistiche dei gas (in particolare la temperatura) vennero spiegate da Ludwig Boltzmann e da Josiah Willard Gibbs proprio in termini di probabilità, dando il via alla meccanica statistica, il cui assunto chiave è il seguente: “In an isolated system in thermal equilibrium, all accessible (i.e. possible) microstates are equally probable”.¹²

Che si voglia vederla come una definizione (classica) di probabilità o piuttosto come una regola operativa (da applicare in situazioni specifiche), risulta fondamentale riuscire ad enumerare, ovvero contare, i casi favorevoli e i casi possibili per farne il rapporto. Quantificare i casi favorevoli e quelli possibili è compito del *calcolo combinatorio*. Senza alcuna pretesa di essere esaustivi, considereremo di seguito solo quanto ci servirà nelle pagine successive: permutazioni, disposizioni e combinazioni (semplici e con ripetizione).

¹⁰Stigler (1988) riferisce che a Huygens si può far risalire il primo lavoro scritto relativo alla teoria della probabilità. Si trattava di 15 pagine, scritte in latino, in appendice a un testo matematico di Frans van Schooten, tradotte in tedesco due anni dopo. Scrive Stigler: “Ironically, Huygens launched the subject in a most uncertain way: its title was given as *De Ratiociniis in Aleae Ludo* on the volume's title page, and as *De Ratiociniis in Ludo Aleae* on the tract's first page.”

¹¹“...la probabilité d'un événement est le rapport du nombre de cas qui lui sont favorables, au nombre de cas possibles, lorsque rien ne porte à croire que l'un de ces cas doit arriver plutôt que les autres, ce qui les rend pour nous également possibles.” *Théorie analytique des probabilités*, P. S. Laplace (1812).

¹²J. Kaplan. Lecture Notes on Statistical Mechanics & Thermodynamics, pag. 15. <https://sites.krieger.jhu.edu/jared-kaplan/files/2018/11/StatisticalMechanicsNotes.pdf>
Vedi più avanti per la definizione di “microstato”.

1.1.1 Permutazioni semplici

Consideriamo le quattro lettere *A, M, O, R*. Quante “parole” di 4 lettere (non necessariamente di senso compiuto) possiamo costruire usando ciascuna di queste 4 lettere una sola volta (*AMOR, AMRO, AROM, AOMR, ...*)? La risposta è data dal numero delle *permutazioni*: $4!$. Si legge *quattro fattoriale* e si calcola moltiplicando fra loro tutti i numeri interi da 1 a 4: $4! = 1 \times 2 \times 3 \times 4 = 24$.

In generale, se abbiamo *n simboli distinti* (nessuno dei quali si ripete), il numero delle permutazioni è dato da $n!$ (ricordiamo che, per convenzione, $0! = 1$). Il fattoriale è un numero che cresce molto rapidamente ed eccede altrettanto rapidamente la capacità di calcolo (esatto) di molti *computer*.

Una permutazione equivale, ad esempio, a mescolare un mazzo di 52 carte. Il numero di possibili “mazzi” è quindi dato da $52!$. È un numero davvero grande, al di fuori della portata di R che ci restituisce una risposta approssimata

```
> factorial(52)
[1] 8.065818e+67
```

vale a dire un numero composto da 68 cifre!

Un programma come *Mathematica*® è invece in grado di calcolarlo esattamente:

```
80658175170943878571660636856403766975289505440883277824000000000000
```

ma è un numero sostanzialmente illeggibile! Quello di cui possiamo essere certi è che sarà molto, molto difficile che, mescolando in modo casuale un mazzo di 52 carte, si possa riprodurre una certa sequenza data (per esempio ottenere le carte ordinate, così come quando le avevamo acquistate). Infatti, in questo caso esisterebbe un solo caso “favorevole”, mentre il numero dei casi possibili sarebbe $52!$ e la probabilità dell’evento “carte ordinate così come quando le avevamo acquistate” sarebbe pari a $1/52!$ (cioè a circa 10^{-68}).

La scozzata perfetta. Facciamo una breve digressione per far vedere come sia possibile ottenere nella realtà un risultato assolutamente improbabile: basta *barare*. Abbiamo visto appena adesso che mescolando a caso più volte un mazzo di carte è sostanzialmente impossibile riprodurre l’ordinamento iniziale presente nel mazzo. Ma i prestigiatori non mescolano le carte a caso! La loro abilità consiste nell’ eseguire la *scozzata perfetta* (*perfect shuffle*). Dopo aver diviso il mazzo in due metà esatte (26 carte nella mano destra e 26 nella sinistra), le mescolano in modo che le carte si alternino: la prima nella mano destra, seguita dalla prima nella mano sinistra, poi la seconda nella mano destra, seguita dalla seconda nella mano sinistra e così via. Chi scrive non possiede questa abilità, ma R sì! Prendiamo (virtualmente) un mazzo di 52 carte, identifichiamo ogni carta con un numero progressivo da 1 a 52 ed eseguiamo (facciamo eseguire a R) la scozzata perfetta:

```
> (x <- c(1:52))
[1] 1 2 3 4 5 6 7 8 9 10 11 12 13 14 15 16 17 18 19 20 21 22 23 24 25 26
[27] 27 28 29 30 31 32 33 34 35 36 37 38 39 40 41 42 43 44 45 46 47 48 49 50 51 52
> destra <- x[1:26]
> sinistra <- x[27:52]
> y <- numeric(0)
> for (i in 1:26) y <- c(y,destra[i],sinistra[i])
> y
[1] 1 27 2 28 3 29 4 30 5 31 6 32 7 33 8 34 9 35 10 36 11 37 12 38 13 39
[27] 14 40 15 41 16 42 17 43 18 44 19 45 20 46 21 47 22 48 23 49 24 50 25 51 26 52
```

Vedete come le carte si alternano? Ebbene, dopo 8 scozzate perfette, il mazzo ritornerà nello stesso ordine in cui si trovava all'inizio! Facciamo eseguire questo gioco di prestigio a R:

```
> x <- c(1:52)
> cat("Ordinamento iniziale del mazzo\n")
Ordinamento iniziale del mazzo
> x
[1] 1 2 3 4 5 6 7 8 9 10 11 12 13 14 15 16 17 18 19 20 21 22 23 24 25 26
[27] 27 28 29 30 31 32 33 34 35 36 37 38 39 40 41 42 43 44 45 46 47 48 49 50 51 52
>
> for (k in 1:8)
+ {
+   a <- x[1:26]
+   b <- x[27:52]
+   y <- numeric(0)
+   for (i in 1:26) y <- c(y,a[i],b[i])
+   x <- y
+   cat("Scozzata numero",k,"\n")
+   print(x)
+ }
Scozzata numero 1
[1] 1 27 2 28 3 29 4 30 5 31 6 32 7 33 8 34 9 35 10 36 11 37 12 38 13 39
[27] 14 40 15 41 16 42 17 43 18 44 19 45 20 46 21 47 22 48 23 49 24 50 25 51 26 52
Scozzata numero 2
[1] 1 14 27 40 2 15 28 41 3 16 29 42 4 17 30 43 5 18 31 44 6 19 32 45 7 20
[27] 33 46 8 21 34 47 9 22 35 48 10 23 36 49 11 24 37 50 12 25 38 51 13 26 39 52
Scozzata numero 3
[1] 1 33 14 46 27 8 40 21 2 34 15 47 28 9 41 22 3 35 16 48 29 10 42 23 4 36
[27] 17 49 30 11 43 24 5 37 18 50 31 12 44 25 6 38 19 51 32 13 45 26 7 39 20 52
Scozzata numero 4
[1] 1 17 33 49 14 30 46 11 27 43 8 24 40 5 21 37 2 18 34 50 15 31 47 12 28 44
[27] 9 25 41 6 22 38 3 19 35 51 16 32 48 13 29 45 10 26 42 7 23 39 4 20 36 52
Scozzata numero 5
[1] 1 9 17 25 33 41 49 6 14 22 30 38 46 3 11 19 27 35 43 51 8 16 24 32 40 48
[27] 5 13 21 29 37 45 2 10 18 26 34 42 50 7 15 23 31 39 47 4 12 20 28 36 44 52
Scozzata numero 6
[1] 1 5 9 13 17 21 25 29 33 37 41 45 49 2 6 10 14 18 22 26 30 34 38 42 46 50
[27] 3 7 11 15 19 23 27 31 35 39 43 47 51 4 8 12 16 20 24 28 32 36 40 44 48 52
Scozzata numero 7
[1] 1 3 5 7 9 11 13 15 17 19 21 23 25 27 29 31 33 35 37 39 41 43 45 47 49 51
[27] 2 4 6 8 10 12 14 16 18 20 22 24 26 28 30 32 34 36 38 40 42 44 46 48 50 52
Scozzata numero 8
[1] 1 2 3 4 5 6 7 8 9 10 11 12 13 14 15 16 17 18 19 20 21 22 23 24 25 26
[27] 27 28 29 30 31 32 33 34 35 36 37 38 39 40 41 42 43 44 45 46 47 48 49 50 51 52
```

e *voilà*, il gioco è fatto. In questo caso non si è verificato un evento altissimamente improbabile, ma è la grandissima abilità del prestigiatore a garantire il risultato.

Riprendiamo ora il percorso interrotto. Parlavamo di permutazioni e di come mescolare, a caso, un mazzo di carte equivalga a una permutazione. Con R è semplicissimo ottenere una permutazione. Consideriamo un mazzo di 52 carte che individuiamo, per comodità, con i numeri da 1 a 52. Mescoliamo le carte (cioè eseguiamo una permutazione):

```
> mazzo <- c(1:52)
> mano <- sample(mazzo, size=52, replace=FALSE)
> mano
[1] 30 20 39 49 51 6 12 8 9 33 10 26 7
```

[14] 22 47 38 3 1 31 19 25 29 37 46 16 23
 [27] 17 2 48 50 24 40 34 4 11 18 5 32 43
 [40] 21 15 14 35 52 42 27 36 28 44 41 13 45

Abbiamo impiegato la funzione `sample`. Il primo argomento rappresenta l'insieme degli elementi da permutare, il secondo argomento (`size`) deve essere uguale al numero di elementi dell'insieme da permutare (se si vuole ottenere una permutazione) e il terzo argomento (`replace`) impostato su `FALSE` garantisce che lo stesso elemento non può essere estratto più volte (di *default* l'argomento `replace` è impostato su `FALSE`, per cui avremmo potuto anche ometterlo).

1.1.2 Disposizioni semplici

Consideriamo un insieme costituito da n oggetti distinti, da prendere k alla volta (con $k \leq n$). Il numero di tutte le possibili *disposizioni semplici* di n oggetti distinti presi a k a k (o di classe k) è dato da

$$D_{n,k} = \frac{n!}{(n-k)!}.$$

La formula precedente può anche essere scritta come prodotto di k fattori:

$$D_{n,k} = n \times (n-1) \times (n-2) \times \dots \times (n-k+1),$$

per cui $D_{n,k}$ è detto anche *fattoriale discendente*. La permutazione può essere vista come un caso particolare di disposizione semplice in cui $k = n$.

Ad esempio, supponiamo che si giochino 2 sole partite di calcio e che i due risultati siano diversi (cioè che non vincano, pareggino o perdano entrambe le squadre che giocano in casa). Quante sono le possibili "schedine"? Si tratta di scegliere dall'insieme costituito dai 3 simboli $\{1, X, 2\}$ due simboli distinti. Il numero delle disposizioni è quindi dato da

$$D_{3,2} = \frac{3!}{(3-2)!} = 6.$$

Infatti, le possibili schedine sono: $(1, X)$, $(1, 2)$, $(X, 1)$, $(X, 2)$, $(2, 1)$, $(2, X)$.

Analogamente, considerando le cifre 1, 3, 5, 7, quanti sono i numeri distinti costituiti da 2 cifre (non identiche)? Dobbiamo scegliere dall'insieme $\{1, 3, 5, 7\}$ due numeri distinti. Il numero delle disposizioni è quindi dato da

$$D_{4,2} = \frac{4!}{(4-2)!} = 12.$$

Lasciamo al lettore individuare i 12 numeri in parola. Facciamo soltanto notare che in una disposizione, l'*ordine* con cui compaiono gli elementi è importante. Infatti, la coppia (il numero) 13 è certamente diversa dalla coppia (dal numero) 31.

1.1.3 Combinazioni semplici

Supponiamo che, lanciando una moneta 5 volte, si sia ottenuto per 3 volte testa (T) e per 2 volte croce (C). Quante sono le possibili *sequenze* che producono questo risultato? La risposta è data dal numero delle *combinazioni semplici* di n oggetti distinti presi a k a k (o di classe k)

$$C_{n,k} = \binom{n}{k} = \frac{n!}{k!(n-k)!},$$

dove, nella formula precedente, $n = 5$ (il numero dei lanci), $k = 3$ (il numero di teste) e $n - k = 2$ (il numero di croci). Abbiamo quindi

$$C_{5,3} = \binom{5}{3} = \frac{5!}{3!2!} = \frac{120}{6 \times 2} = 10.$$

Il numero di combinazioni può essere calcolato direttamente con R impiegando la funzione `choose`:

```
> choose(5,3)
[1] 10
```

Analogamente, supponiamo di dover eleggere un comitato di 6 membri a partire da un insieme di 21 persone. Quanti sono i possibili “comitati”? La risposta è data dal numero delle combinazioni:

$$C_{21,6} = \binom{21}{6} = \frac{21!}{6!15!},$$

ovvero

```
> choose(21,6)
[1] 54264
```

Per finire, calcoliamo quante sono le possibili “mani” nel gioco del poker:

$$C_{52,5} = \binom{52}{5} = \frac{52!}{5!47!},$$

ovvero

```
> choose(52,5)
[1] 2598960
```

Facciamo notare che nel caso delle combinazioni, l'ordine non conta. Ad esempio, se giocando a poker ci vengono date (nell'ordine) le carte 2, 4, 5, 6, 9 la “mano” 2, 6, 5, 9, 4 è esattamente la stessa, ai fini del gioco.

Vediamo due esempi dove dovrebbe risultare ben evidente quando l'ordine è importante e quando invece non lo è.

Esempio 1.1 In una finale olimpica dei 100 metri piani ci sono 8 concorrenti e ci sono 3 medaglie in palio. In quanti modi si possono distribuire le 3 medaglie agli 8 atleti (cioè qual è il numero di *podì* differenti)?

In questo caso riteniamo che sia evidente che dare la medaglia d'oro a Bolt, quella d'argento a Gatlin e quella di bronzo a De Grasse¹³ sia ben diverso che dare, ad esempio, la medaglia d'oro a Gatlin, quella d'argento a De Grasse e quella di bronzo a Bolt! Pertanto, il numero di podì differenti è dato dalle disposizioni semplici

$$D_{8,3} = \frac{8!}{(8-3)!} = 6 \times 7 \times 8 = 336.$$

Esempio 1.2 In una classe di 20 studenti, si devono scegliere 3 rappresentanti. Quanti sono i possibili “terzetti” di studenti?

In questo caso il “terzetto” costituito, ad esempio da Maria, da Giovanna e da Paolo e quello costituito da Paolo, da Maria e da Giovanna rappresentano la stessa terna di rappresentanti (e di queste terne ce ne sono, evidentemente, $3! = 6$).

In un caso come questo, quindi, l'ordine non è importante e il numero di possibili “terzetti” di studenti è dato dalle combinazioni semplici

$$C_{8,3} = \binom{8}{3} = \frac{8!}{(8-3)! \times 3!} = 7 \times 8 = 56.$$

Facciamo notare che il risultato è equivalente a calcolare le disposizioni semplici ($6 \times 7 \times 8$) (come se l'ordine fosse importante) e a dividere poi il risultato per $3! = 6$, rimuovendo quindi le terne costituite dagli stessi elementi (e rimuovendo, quindi, l'ordinamento).

1.1.4 Permutazioni con ripetizione

Ci chiediamo quante “parole” di 5 lettere (non necessariamente di senso compiuto) possiamo costruire usando ciascuna delle seguenti 5 lettere una sola volta: H, A, R, R, Y . In altre parole, quanti sono i possibili *anagrammi* di “Harry”?

È una domanda analoga a quella proposta introducendo il concetto di permutazione semplice, ma questa volta la lettera R si ripete 2 volte. La risposta è data dal numero delle *permutazioni con ripetizione*. Se le 5 lettere fossero tutte distinte, allora la risposta sarebbe $5! = 120$. Dal momento però che 2 lettere si ripetono, dobbiamo dividere il risultato precedente per 2 (o meglio per $2!$, che numericamente è lo stesso), quindi la risposta è 60.

Più in generale, se un insieme è formato da N elementi distinti, ciascuno dei quali si ripete $k_1, k_2, \dots, k_N$ volte (con $k \geq 1$), allora, se $n = k_1 + k_2 + \dots + k_N$, il numero

¹³Stiamo evidentemente facendo riferimento alla finale olimpica del 2016 di Rio de Janeiro.

delle *permutazioni con ripetizione* è dato da

$$P_{k_1, k_2, \dots, k_N} = \frac{n!}{k_1! \times k_2! \times \dots \times k_N!}.$$

Esercizio. Trovare tutti i possibili anagrammi della parola “zuzzurellone”. In questo caso $N = 7$, mentre $n = 12$. La risposta è 9979200. Per lo svolgimento di questo esercizio (così come di altri) rimandiamo al nostro *Problemi ed esperimenti di statistica con R*.

1.1.5 Disposizioni con ripetizione

Consideriamo un insieme costituito da n oggetti distinti, da prendere k alla volta (ma questa volta k può anche essere maggiore di n dal momento che gli elementi possono essere ripetuti). Il numero delle *disposizioni con ripetizione* di n oggetti distinti presi a k a k (o di classe k) è dato da

$$D'_{n,k} = n^k.$$

Ecco due esempi al riguardo.

Esempio 1.3 Un dado ha le facce contrassegnate con i numeri 1, 2, 3, 4, 5, 6. Se lanciamo il dado due volte, quanti sono i possibili risultati, tenendo conto dell'ordine in cui si presentano (cioè il risultato 1, 2 è diverso dal risultato 2, 1)? In questo caso $n = 6$ e $k = 2$, per cui i possibili risultati sono $6^2 = 36$. Potremmo lanciare il dado 10 volte; i possibili risultati sono 6^{10} :

> 6^10

[1] 60466176

cioè oltre 60 milioni di risultati distinti (ricordiamo che in questo esempio l'ordine conta). Quindi, lanciando un dado k volte (con $k \geq 1$), i risultati possibili sono 6^k .

Esempio 1.4 Consideriamo una schedina costituita da $k = 13$ partite e supponiamo che ciascuna partita termini o con la vittoria della squadra che gioca in casa o con un pareggio o con la vittoria della squadra che gioca in trasferta, esito rappresentato con i simboli {1, X, 2} (quindi, in questo esempio, $n = 3$). Quante sono le possibili “schede”?

$$D'_{3,13} = 3^{13} = 1594323.$$

Attualmente le partite in schedina sono 14 (e non più 13), ragion per cui il numero delle possibili “colonne” passa a $D'_{3,14}$, cioè

> 3^14

[1] 4782969

1.1.6 Combinazioni con ripetizione

Supponiamo di avere un'urna che contiene n palline distinguibili e di volerne estrarre k “in blocco”, quindi senza rimettere la pallina nell'urna. In quanti modi possiamo estrarre k palline dall'urna che ne contiene n ? La risposta è data dalle *combinazioni semplici* $C_{n,k}$ di n oggetti di classe k .

Se però supponiamo di estrarre le k palline con rimessa (reinserendo quindi ogni volta nell'urna la pallina estratta) senza annotare in quale ordine le palline sono state estratte, allora il numero di modi in cui possiamo estrarre k palline da un'urna che ne contiene n è dato dalle *combinazioni con ripetizione* di n oggetti distinti presi a k a k (o di classe k):

$$C'_{n,k} = \binom{n+k-1}{k}.$$

Osserviamo che in questo caso, essendo l'estrazione con rimessa, k può anche essere maggiore di n .

L'esempio “standard” proposto in questo caso è quello cosiddetto “della pasticceria”. Supponiamo che in una pasticceria ci siano 3 tipi differenti di pasticcini, A , B e C (quindi $n = 3$); tuttavia, per ciascun tipo, il numero di pasticcini disponibile è *ad libitum*. Supponiamo di voler acquistare 5 pasticcini (quindi $k = 5$). In quanti modi diversi possiamo scegliere 5 pasticcini fra le 3 tipologie diverse? La risposta è data dalle *combinazioni con ripetizione*:

$$C'_{3,5} = \binom{3+5-1}{5} = \binom{7}{5} = 6 \times 7 = 42.$$

Ricordiamo che, dal momento che l'estrazione (la scelta dei pasticcini) è fatta con ripetizione, potremmo scegliere 5 pasticcini tutti del tipo A oppure tutti del tipo B , oppure tutti del tipo C e così via.

1.1.7 Modelli di occupazione

Vogliamo ora ripassare quanto visto in precedenza facendo riferimento ad una situazione in cui abbiamo a disposizione k biglie che vogliamo mettere in n scatole rispettando di volta in volta differenti condizioni.

- Supponiamo che le biglie (così come le scatole) siano numerate (quindi siano *distinguibili*) e che una scatola non possa contenere più di una biglia (perciò dovrà essere $k \leq n$). In quanti modi si possono disporre k biglie in n scatole rispettando queste condizioni? Dobbiamo calcolare il numero delle *disposizioni semplici* $D_{n,k}$.
- Supponiamo che le biglie (così come le scatole) siano numerate (quindi siano *distinguibili*) e che una scatola possa contenere anche più di una biglia (al limite, anche tutte). In quanti modi si possono disporre k biglie in n scatole rispettando queste condizioni? Dobbiamo calcolare il numero delle *disposizioni con ripetizione* $D'_{n,k}$.

- Supponiamo che le biglie non siano numerate (quindi non siano *distinguibili*) e che una scatola non possa contenere più di una biglia (perciò dovrà essere $k \leq n$). In quanti modi si possono disporre k biglie in n scatole rispettando queste condizioni? Dobbiamo calcolare il numero delle *combinazioni semplici* $C_{n,k}$.
- Supponiamo che le biglie non siano numerate (quindi non siano *distinguibili*) e che una scatola possa contenere più di una biglia (perciò k potrebbe anche essere maggiore di n). In quanti modi si possono disporre k biglie in n scatole rispettando queste condizioni? Dobbiamo calcolare il numero delle *combinazioni con ripetizione* $C'_{n,k}$.

A nostro avviso un riferimento bibliografico irrinunciabile relativo a questi “problemi di occupazione” (*occupancy problems*) è lo splendido libro di Feller (1968). Facendo riferimento in particolare all’ultimo caso, Feller puntualizza che ci sono molte situazioni in cui, ai fini pratici, risulta conveniente (se non addirittura necessario) trattare le biglie come indistinguibili. Un possibile esempio riguarda la distribuzione del numero di nascite in base al giorno della settimana (l’interesse del ricercatore è rivolto alla frequenza delle nascite in un determinato giorno e non all’identità di chi è nato quel giorno). Sempre Feller scrive che lanciare k dadi può essere considerato equivalente a mettere k biglie in $n = 6$ scatole (potrebbe essere possibile distinguere il risultato ottenuto su ciascuno dei k dadi lanciati, ma generalmente questa informazione non viene considerata). Infine, ci sembra utile riportare un ulteriore esempio proposto da Feller per fare vedere come parlare di “biglie” e di “scatole” è solo un modo puramente convenzionale (così come parlare di urne, palline, dadi, carte da gioco, ecc.) e che le applicazioni pratiche possono essere molto più “pregnanti”.

L’esempio proposto da Feller è il seguente. Le *derivate parziali* di ordine k di una funzione analitica di n variabili non dipendono dall’ordine di differenziazione, ma solo dal numero di volte che ciascuna variabile viene differenziata. Pertanto, ogni variabile corrisponde ad una “scatola” e quindi esistono $C'_{n,k}$ differenti derivate parziali di ordine k .

In Fisica le particelle sono generalmente indistinguibili e lo spazio delle fasi viene suddiviso in un (gran) numero di piccole regioni (celle). In Meccanica Statistica si può quindi pensare a calcolare in quanti modi k particelle (le “biglie”) possono occupare le n celle (le “scatole”) in cui è diviso lo spazio delle fasi.¹⁴ Nel caso di particelle come i *fotoni* vale la seconda regola, mentre nel caso di particelle come gli *elettroni* vale la terza regola (dal momento che obbediscono ad un “principio di esclusione”).

Microstati e macrostati. Consideriamo il seguente problema. Abbiamo una scatola divisa a metà da una parete e n palline numerate (quindi distinguibili). In quanti modi possiamo mettere le n palline nelle due “sottoscatole”?

¹⁴Si tratta di uno spazio astratto impiegato per descrivere matematicamente l’evoluzione nel tempo di un sistema fisico.

È evidente che con una sola pallina ($n = 1$), ci sono solo due modi. Se le palline sono due ($n = 2$), le possibilità diventano 4, se sono tre ($n = 3$) diventano 8 e, in generale, ci sono 2^n modi per mettere le n palline nelle due “sottoscatole” (quindi le disposizioni con ripetizione). Diciamo che ciascuna di queste disposizioni rappresenta un *microstato* distinto.

Immaginiamo ora che venga rimosso il numero che permette di distinguere le palline fra loro. In questo caso tutto quello che si può fare è contare quante palline sono nella metà destra della scatola e quante nella metà sinistra. Sotto questa condizione il numero di modi in cui possiamo mettere le n palline (indistinguibili) nelle due “sottoscatole” si riduce in maniera drastica. Se indichiamo con n_A il numero di palline presenti nella metà sinistra della scatola, allora è evidente che n_A potrà assumere tutti i valori interi da 0 a n ; abbiamo quindi soltanto $n + 1$ casi possibili. Ognuno di questi casi rappresenta un *macrostato*.

In generale un macrostato corrisponde a più microstati. Ad esempio, se $n = 3$, il macrostato rappresentato da $n_A = 2$ è formato da 3 microstati, quelli con le coppie di palline (1, 2), (1, 3) e (2, 3) nella metà sinistra della scatola. Se $n = 5$, il macrostato rappresentato da $n_A = 2$ è formato da 10 microstati. In generale se le palline sono n , il macrostato rappresentato da n_A palline nella metà sinistra è formato da $\binom{n}{n_A}$ microstati, vale a dire dalle combinazioni semplici di n oggetti di classe n_A .

Consideriamo ora il caso in cui il numero n di palline sia pari. Il macrostato in cui $n_A = n/2$ corrisponde alla situazione di perfetto equilibrio, essendo uguale il numero di palline nelle due metà in cui è divisa la scatola. Questo particolare macrostato è formato da

$$\binom{n}{n/2} = \frac{n!}{(n/2)!(n/2)!} \quad (1.1)$$

microstati. Ad esempio, facendo variare n fra 2 e 20 (considerando solo i valori pari), il numero di microstati corrispondenti al macrostato di perfetto equilibrio è

```
> n <- seq(2,20,2)
> y <- choose(n,n/2)
> rbind(n,y)
n      2      4      6      8     10     12     14     16     18     20
y      2      6     20     70    252    924   3432  12870  48620 184756
```

Come varia, al crescere di n (essendo n un numero pari), la proporzione di microstati corrispondenti alla situazione di equilibrio perfetto rispetto al numero totale di macrostati? Questa proporzione è data dal rapporto fra i “casi favorevoli”, cioè $\binom{n}{n/2}$ e i “casi possibili”, cioè 2^n :

```
> n <- seq(2,20,2)
> cfav <- choose(n,n/2)
> cpos <- 2^n
> p <- cfav/cpos
> rbind(n,round(p,3))
```

n	2	4	6	8	10	12	14	16	18	20
p	0.5	0.375	0.312	0.273	0.246	0.226	0.209	0.196	0.185	0.176

Contare il numero di microstati corrispondenti alla situazione di perfetto equilibrio diventa sempre più difficile al crescere di n , per lo meno se si impiega la formula precedente. Ad esempio, se $n = 1000$ abbiamo

```
> n <- 1000
> choose(n,n/2)/(2^n)
[1] 0.02522502
```

Però, se poniamo $n = 1030$,

```
> n <- 1030
> choose(n,n/2)/(2^n)
[1] NaN
```

otteniamo come risposta un NaN (*Not a Number*), il che significa che R non riesce a fare il calcolo. Un modo per ovviare a questo è sfruttare la funzione `lchoose`, che restituisce il logaritmo naturale del numero delle combinazioni semplici e calcolare il logaritmo (naturale) del numero dei casi possibili, cioè $n \log(2)$. La proporzione di microstati corrispondenti all'equilibrio perfetto è quindi data dall'esponenziale della *differenza* fra i due valori ottenuti:

```
> n <- 1030
> (lnum <- lchoose(n,n/2))
[1] 710.2469
> (lden <- n*log(2))
[1] 713.9416
> exp(lnum - lden)
[1] 0.02485513
```

Può essere però utile ricorrere ad un calcolo approssimato, che risulta efficace quando n è molto grande. Il calcolo si basa sulla *formula di Stirling*

$$n! \sim \sqrt{2\pi n} \times n^n \times e^{-n} \quad (1.2)$$

che ha la seguente proprietà

$$\lim_{n \rightarrow \infty} \frac{\sqrt{2\pi n} \times n^n \times e^{-n}}{n!} = 1$$

ed è quindi in grado di approssimare efficacemente il fattoriale (quando n è grande).

Usando la (1.2) all'interno della (1.1), la proporzione di microstati corrispondenti all'equilibrio perfetto diventa:

$$\frac{\sqrt{2\pi n} \times n^n \times e^{-n}}{\left(\sqrt{2\pi n/2} (n/2)^{n/2} e^{-n/2}\right)^2 \times 2^n},$$

ovvero, dopo opportune semplificazioni,

$$\frac{2}{\sqrt{2\pi n}}.$$

Ritroveremo nei capitoli successivi questa dipendenza dall'inverso della radice quadrata di n (nel caso che abbiamo appena affrontato n è il numero di particelle; in generale sarà il *numero di osservazioni*).

1.1.8 Estrazione di un campione da una popolazione

Consideriamo una *popolazione* composta da N elementi. Potrebbe trattarsi di un mazzo di 52 carte, di una moneta (2 possibilità, testa o croce), dei simboli 1, X , 2 nel gioco del totocalcio, di un'urna contenente 10 palline numerate da 0 a 9 o anche di una popolazione reale.

Vogliamo estrarre da questa popolazione un *campione* di n elementi. Esistono due modalità fondamentalmente diverse di procedere all'estrazione: con o senza *rimessa* (o *ripetizione*).

Con rimessa. In questo caso, l'elemento estratto fa sempre parte della popolazione e, quindi, può essere estratto più volte. Dal momento che la composizione della popolazione è la stessa ad ogni estrazione, ciascun elemento ha sempre la stessa probabilità di essere estratto; in questo caso le estrazioni successive sono fra loro *indipendenti* (il risultato di una estrazione non influenza la successiva). In una situazione di questo tipo, la dimensione n del campione può anche essere superiore ad N (la dimensione della popolazione) e il numero dei possibili campioni è dato da N^n (il numero delle disposizioni con ripetizione). Nell'esempio visto in precedenza, una schedina composta da una colonna di 13 risultati può essere assimilabile ad una estrazione di $n = 13$ elementi da una popolazione di $N = 3$ elementi (i simboli 1, X , 2). Estraiamo una colonna con R impiegando la funzione `sample` e specificando `replace=TRUE` per eseguire un campionamento con rimessa.¹⁵

```
> set.seed(123456)
> sample(c("1", "X", "2"), size=13, replace=TRUE)
[1] "2" "2" "X" "X" "X" "1" "X" "1" "2" "1" "2" "X" "2"
```

La funzione `sample` permette anche di specificare per ciascun elemento della popolazione una diversa probabilità di estrazione. Ad esempio, se riteniamo che le probabilità associate ai simboli “1”, “X” e “2” siano, rispettivamente 0.5, 0.4 e 0.1, possiamo ottenere un campione (con rimessa) mediante l'istruzione

¹⁵La funzione `set.seed`, “innescata” con lo stesso valore, permette di riprodurre il risultato della simulazione successiva.

```
> set.seed(123456)
> sample(c("1", "X", "2"), size=13, replace=TRUE, prob=c(0.5, 0.4, 0.1))
[1] "X" "X" "1" "1" "1" "1" "X" "1" "2" "1" "X" "X" "2"
```

specificando le probabilità di estrazione mediante l'argomento `prob`.

L'estrazione con rimessa permette di simulare l'estrazione di un campione da una *popolazione infinita*. Un campione di questo tipo si dice *bernoulliano* (o, anche, *casuale semplice*).

Senza rimessa (o “in blocco”). In questo caso, l'elemento estratto non viene rimesso nella popolazione e, quindi, può essere estratto al più una sola volta. Dal momento che la composizione della popolazione cambia ad ogni estrazione, la probabilità di estrazione per gli elementi della popolazione non è costante e, quindi, le estrazioni successive non possono più considerarsi fra loro indipendenti. In una situazione di questo tipo, la dimensione n del campione non può evidentemente superare quella della popolazione (N). Se $n = N$ tutti gli elementi della popolazione vengono estratti e quella che si ottiene è una *permutazione* degli elementi della popolazione. Se invece $n < N$, allora da una popolazione di N elementi si possono estrarre (senza rimessa) un numero di differenti campioni, ciascuno di dimensione n , non ordinati nella successione dei loro elementi, pari al numero delle *combinazioni semplici*. Se, invece, si volesse tener conto dell'ordine, allora il numero dei possibili campioni è dato dalle *disposizioni semplici*. Riproponiamo di seguito, affiancate, per comodità di confronto, le formule relative al calcolo del numero delle combinazioni semplici e delle disposizioni semplici.

$$\begin{array}{cc} \text{Disposizioni semplici } (D_{N,n}) & \text{Combinazioni semplici } (C_{N,n}) \\ \frac{N!}{(N-n)!} & \frac{N!}{n!(N-n)!} \end{array}$$

Per chiarire una volta di più cosa vuol dire tenere o meno conto “dell'ordine”, consideriamo il seguente esempio. Prendiamo una popolazione costituita da 5 elementi (E_1, E_2, E_3, E_4, E_5) ed estraiamo un campione, senza rimessa, di 3 elementi. In base alle formule precedenti, se *teniamo conto* dell'ordine di estrazione, il numero dei campioni possibili è

$$\frac{5!}{(5-3)!} = 60,$$

mentre se *non teniamo conto* dell'ordine di estrazione, il numero dei campioni possibili è

$$\frac{5!}{3!(5-3)!} = 10.$$

Enumeriamo ora tutti i possibili campioni, considerando l'ordine di estrazione (quindi la terna (E_1, E_2, E_3) sta ad indicare che E_1 è stato estratto per primo, E_2 per secondo e E_3 per terzo).

(E_1, E_2, E_3)	(E_1, E_3, E_2)	(E_2, E_1, E_3)	(E_2, E_3, E_1)	(E_3, E_1, E_2)	(E_3, E_2, E_1)
(E_1, E_2, E_4)	(E_1, E_4, E_2)	(E_2, E_1, E_4)	(E_2, E_4, E_1)	(E_4, E_1, E_2)	(E_4, E_2, E_1)
(E_1, E_2, E_5)	(E_1, E_5, E_2)	(E_2, E_1, E_5)	(E_2, E_5, E_1)	(E_5, E_1, E_2)	(E_5, E_2, E_1)
(E_1, E_2, E_6)	(E_1, E_6, E_2)	(E_2, E_1, E_6)	(E_2, E_6, E_1)	(E_6, E_1, E_2)	(E_6, E_2, E_1)
(E_2, E_3, E_4)	(E_2, E_4, E_3)	(E_3, E_2, E_4)	(E_3, E_4, E_2)	(E_4, E_2, E_3)	(E_4, E_3, E_2)
(E_2, E_3, E_5)	(E_2, E_5, E_3)	(E_3, E_2, E_5)	(E_3, E_5, E_2)	(E_5, E_2, E_3)	(E_5, E_3, E_2)
(E_2, E_3, E_6)	(E_2, E_6, E_3)	(E_3, E_2, E_6)	(E_3, E_6, E_2)	(E_6, E_2, E_3)	(E_6, E_3, E_2)
(E_3, E_4, E_5)	(E_3, E_5, E_4)	(E_4, E_3, E_5)	(E_4, E_5, E_3)	(E_5, E_3, E_4)	(E_5, E_4, E_3)
(E_3, E_4, E_6)	(E_3, E_6, E_4)	(E_4, E_3, E_6)	(E_4, E_6, E_3)	(E_6, E_3, E_4)	(E_6, E_4, E_3)
(E_4, E_5, E_6)	(E_4, E_6, E_5)	(E_5, E_4, E_6)	(E_5, E_6, E_4)	(E_6, E_4, E_5)	(E_6, E_5, E_4)

I campioni che si trovano su ciascuna riga sono formati dagli stessi elementi e l'unica differenza è il diverso ordine in cui sono stati estratti. Dal momento che ogni campione è formato da 3 elementi, il numero dei possibili differenti ordini di estrazione sarà $3!$ (cioè 6); per questo la tabella ha 6 colonne (in generale, per un campione di n elementi sarà $n!$). Le righe, invece, identificano campioni i cui elementi sono differenti (non sono tutti uguali).

1.1.9 Alcuni esempi

Vediamo di seguito alcuni esempi¹⁶ in cui le probabilità possono essere calcolate impiegando la regola del rapporto fra casi favorevoli e casi possibili. Iniziamo con tre “problemi storici”.

Il problema della divisione della posta. Si tratta forse del primo problema che può essere associato al calcolo delle probabilità. Risalirebbe alla fine del 1400 nella versione proposta da Luca Pacioli, ma forse la sua origine può essere ancora anteriore (fine del XIV secolo). Questa è la descrizione che ne dà Kendall (1956): “Fra Luca dal Borgo, or Paccioli, was an itinerant teacher of mathematics whose *Summa de Arithmetica, Geometria, Proportioni et Proportionalità*, published in 1494, was widely studied in Italy. He considers a simple version of what later became known as the problem of points: *A* and *B*, playing at a fair game (not dice, but *balla*, presumably a ball game) agree to continue until one has won six rounds; but the match has to stop when *A* has won five and *B* has won three. How should the stakes be divided?”

Pacioli propone di suddividere la posta sulla base dei punti raggiunti al momento della sospensione, ma questa non sembra essere la soluzione corretta (ovvero equa). Se ad esempio *A* avesse vinto i primi due turni e *B* nessuno, tutta la posta dovrebbe andare ad *A* (lo stesso avverrebbe se il gioco si interrompesse dopo il primo turno: tutta la posta andrebbe al vincitore di quell'unico turno). In effetti, come scrive Cardano,¹⁷ non sono i punti ottenuti, bensì quelli che mancano per conseguire il successo finale ad essere essenziali nella suddivisione della posta.

¹⁶Alcuni degli esempi sono tratti dal capitolo 3 del nostro *Problemi ed esperimenti di statistica con R*, al quale rimandiamo per una soluzione dettagliata.

¹⁷*Practica Arithmeticae et misurandi singularis* (1539).

Proviamo ad affrontare questo problema in maniera empirica, eseguendo una simulazione con R. Sappiamo che *A* ha vinto 5 turni e *B* ne ha vinti 3. Deve giocare *A* che, quindi, ha una probabilità 0.5 di vincere il nono turno e, con esso, la partita (conquistando così tutta la posta) e una probabilità 0.5 di non vincere il turno. In questo caso sarà *B* a vincere, totalizzando complessivamente 4 punti, per cui il gioco dovrà proseguire con un nuovo turno (il decimo). Ecco uno dei possibili risultati simulato con R.

```
> set.seed(123456)
> a <- 5; b <- 3
> repeat {
+   x <- sample(c("A","B"),1)
+   cat(x)
+   ifelse (x == "A", a <- a + 1, b <- b + 1)
+   if ((a==6) | (b==6)) {
+     cat("\n")
+     break
+   }
+ }
BBA
> c(a,b)
[1] 6 5
```

Impiegando la funzione `sample` il turno viene vinto dal giocatore *A* (se viene estratta la stringa "A") oppure dal giocatore *B* (se viene estratta la stringa "B"). Attraverso la funzione `ifelse` viene aggiornato il punteggio dei due giocatori (il numero di turni vinti), mentre l'ultimo `if` verifica se uno dei due giocatori ha raggiunto un punteggio totale di 6 (cioè se ha vinto 6 turni). Se non è così, si gioca un altro turno (impiegando la funzione `repeat`), altrimenti il ciclo ha termine (`break`). Nella simulazione proposta, i primi due turni giocati (se non si fosse dovuto interrompere il gioco) sono stati vinti da *B*, che quindi ha totalizzato un punteggio complessivo di 5 punti (pareggiando quindi i punti di *A*), ma poi l'ultimo turno è stato vinto da *A*. In questa particolare simulazione, quindi, tutta la posta sarebbe andata ad *A*.

La simulazione "completa" consiste nel ripetere questo procedimento un grandissimo numero di volte (100000), assegnando ogni volta 100 euro al vincitore.

```
> nrep <- 100000
> A <- 0; B <- 0
> set.seed(135246)
> for\index[funr]{for} (i in 1:nrep)\index[funr]{nrep} {
+   a <- 5; b <- 3
+   repeat {
+     x <- sample(c(1,2),1)
+     ifelse (x == 1, a <- a + 1, b <- b + 1)
```

```

+      if ((a==6) | (b==6)) break
+ }
+   if(a == 6) A <- A + 100
+   if(b == 6) B <- B + 100
+ }
>
> (c(A,B)/100)
[1] 87607 12393
> c(A,B)/nrep
[1] 87.607 12.393

```

Osserviamo come A ha vinto 87607 partite, mentre B ne ha vinte 12393; in altre parole A ha una probabilità molto elevata (molto più elevata di B) di vincere la partita partendo da un punteggio di 5. Questo non vuol dire che B non possa vincere (accade circa il 12% delle volte). Se avessimo assegnato 100 euro per ogni partita vinta, A avrebbe vinto (complessivamente) 8760700 euro, mentre B ne avrebbe vinto 1239300. Pertanto, in base ai risultati di questa simulazione, quando il gioco viene interrotto dopo 8 turni sul punteggio di 5 a 3 a favore di A , andrebbero assegnati (circa) 88 euro ad A e 12 euro a B essendo, al momento dell'interruzione, 0.876 la *stima* della probabilità che ha A di vincere, mentre la stima corrispondente per B è 0.124.

Forse non è del tutto ovvio come calcolare in modo analitico le probabilità che hanno, rispettivamente, A e B di vincere la partita sulla base del numero dei casi favorevoli e di quelli possibili. Dal momento che A ha vinto 5 turni, è sufficiente che ne vinca 1 soltanto, mentre B ne deve vincere 3 senza perderne nessuno. I casi (cioè le “sequenze di successo”) possibili sono quindi quattro:

A
 BA
 BBA
 BBB

dei quali 3 sono favorevoli ad A e 1 solo a B ; il fatto è che queste quattro “sequenze di successo” non sono tutte ugualmente probabili. La prima sequenza (che corrisponde ad un unico turno, il nono, vinto da A), infatti, ha una probabilità uguale a 0.5 (come abbiamo detto poco sopra), mentre la probabilità associata a ciascuna delle tre sequenze rimanenti deve essere necessariamente inferiore a 0.5 (altrimenti la probabilità totale sarebbe superiore ad 1).

Nella sezione 1.4 impareremo che, in una condizione come questa, dove A e B hanno la stessa probabilità (cioè 0.5 ciascuno) di vincere un turno, la probabilità di una sequenza si calcola moltiplicando le probabilità di vittoria nei singoli turni giocati. Quindi, la sequenza BA ha una probabilità pari a 0.25 (0.5^2), mentre le sequenze BBA e BBB hanno ciascuna una probabilità pari a 0.125 (0.5^3). Se sommiamo le probabilità associate alle quattro sequenze, otteniamo 1 ($0.5 + 0.25 + 0.125 + 0.125$).

Questo procedimento però non segue la regola che dice di calcolare la probabilità dividendo il numero dei casi favorevoli per il numero dei casi possibili (dal momento

che in questa situazione i casi non sono tutti ugualmente possibili) e può essere visto come una “evoluzione” del concetto di probabilità. Possiamo tuttavia ancora impiegare la “vecchia” regola se modifichiamo il “gioco” in un modo che non influenza il risultato finale, ma che permette di avere sequenze tutte con la stessa probabilità.

Data la situazione (A sta vincendo per 5 a 3) è evidente che sono necessari al massimo tre turni per dichiarare il vincitore. Infatti, se B vince il nono e il decimo turno la situazione è di parità: A ha 5 punti e B ha 5 punti. Dal momento che vince chi per primo si aggiudica 6 punti, è evidente che il turno numero 11 sarà l'ultimo. Possiamo allora modificare il gioco chiedendo che comunque si disputino 3 turni (il nono, il decimo e l'undicesimo), dichiarando comunque (alla fine) vincitore chi per primo ha ottenuto 6 punti.

In questo modo il numero dei casi (cioè delle sequenze) possibili diventa 8 (cioè 2^3 , perché 2 sono i giocatori e 3 sono i turni da giocare). Possiamo scrivere (o, meglio, far scrivere ad R) esplicitamente tutte le 8 sequenze possibili:

```
> for (i1 in (c("A","B"))){
+   for (i2 in (c("A","B"))){
+     for (i3 in (c("A","B"))){
+       cat(i1,i2,i3,"\n",sep="")
+     }}
AAA
AAB
ABA
ABB
BAA
BAB
BBA
BBB
```

Tutte queste sequenze sono ugualmente probabili (dal momento che ciascuna di esse è il risultato di tre turni). Quelle favorevoli ad A sono le prime 7: nelle prime 4 A vincerebbe già al nono turno, nelle due successive A vincerebbe al decimo turno, mentre se si realizza la settima sequenza A vincerebbe all'undicesimo turno. Quindi la probabilità che vinca A (partendo da una situazione di 5 a 3) è 7 (i casi favorevoli) diviso 8 (i casi possibili), quindi 0.875. B può vincere solo se si realizza l'ultima sequenza (vincendo tutti i tre turni che si devono giocare) e, quindi, la sua probabilità di vittoria è 1 diviso 8, quindi 0.125. La posta di 100 euro andrebbe quindi suddivisa assegnando ad A 87 euro e 50 centesimi e a B l'importo rimanente.

Naturalmente se fosse necessario conquistare 60 punti per vincere tutta la posta in palio e se A avesse conquistato 50 punti e B 30, non sarebbe così immediato calcolare come andrebbe suddivisa la posta se il gioco si interrompesse su questo punteggio. Per conquistare 60 punti sono necessari al massimo 119 turni (A e B potrebbero alternarsi nel vincere 1 turno a testa, arrivando sul punteggio di 59 pari, ma poi il turno successivo sarebbe quello decisivo). Più in generale, se P sono i punti da conquista-

re complessivamente, il massimo numero di turni da giocare sarà $2(P-1)+1$. Se il gioco si interrompe quando ad A mancano a punti per vincere tutta la posta e a B ne mancano b , il numero massimo di turni che resta da giocare è pari a $a+b-1$ e il numero dei “casi” (cioè delle sequenze) possibili è 2^{a+b-1} .

Quindi, nell'esempio discusso abbiamo $P=6$, $a=1$ e $b=3$; pertanto il numero massimo di turni che resta da giocare è pari a 8 e il numero delle sequenze possibili è $2^3=8$. Se invece fosse necessario conquistare $P=60$ punti per vincere tutta la posta in palio e se A avesse conquistato 50 punti e B 30, avremmo $a=10$, $b=30$; in questo caso il numero massimo di turni che resta da giocare è pari a $10+30-1=39$ e il numero delle sequenze possibili è $2^{39} \simeq 5.50 \times 10^{11}$, cioè quasi 550 miliardi,¹⁸ un po' troppi per enumerarli tutti! Possiamo però ricorrere a R per arrivare ad un risultato approssimato, modificando soltanto alcuni valori nello *script* precedente:

```
> A <- 0; B <- 0
> set.seed(135246)
> for (i in 1:nrep) {
+   a <- 50; b <- 30
+   repeat {
+     x <- sample(c(1,2),1)
+     ifelse (x == 1, a <- a + 1, b <- b + 1)
+     if ((a==60) | (b==60)) break
+   }
+   if(a == 60) A <- A + 100
+   if(b == 60) B <- B + 100
+ }
>
> (c(A,B)/100)
[1] 99939    61
> c(A,B)/nrep
[1] 99.939  0.061
```

In questo caso è estremamente più probabile che vinca A e, quindi, a lui dovrebbe andare quasi tutta la posta, mentre a B andrebbero soltanto 6 centesimi.

Può sembrare strano, ma non è necessaria una simulazione dal momento che è possibile calcolare analiticamente il risultato. Ricorrendo alla *distribuzione binomiale* (che incontreremo nel capitolo 2, quando parleremo di *variabili casuali*) possiamo calcolare le probabilità che hanno A e B di vincere tutta la posta partendo da un punteggio di 50 a 30 a favore di A . Modificando il gioco come fatto in precedenza,¹⁹ la vittoria

¹⁸Il valore “preciso” è 549755813888.

¹⁹Chiedendo cioè di giocare comunque 39 turni, ma assegnando la vittoria a chi raggiunge per primo 60 punti.

andrebbe ad A se questi si aggiudicasse 10 o più turni (quindi fino a 39), mentre la vittoria andrebbe a B se questi si aggiudicasse 30 o più turni. Le due probabilità sono

```
> sum(dbinom(c(10:39), 39, 0.5))
[1] 0.9994675
> sum(dbinom(c(30:39), 39, 0.5))
[1] 0.0005325098
```

due valori molto vicini a quelli trovati nella nostra simulazione.²⁰

Il problema di Galileo (ovvero del Granduca di Toscana). Nel XVII secolo in Italia i giocatori d'azzardo scommettevano sui punteggi ottenuti lanciando 3 dadi. Detta S la somma dei numeri presenti sulle tre facce, i giocatori sostenevano che le probabilità di ottenere una somma pari a 9 oppure a 10 fossero uguali ($P(S=9) = P(S=10)$) e scommettevano indifferentemente su una delle due alternative. Galileo Galilei nel suo libro *Sopra le scoperte de i dadi*, su richiesta del Granduca di Toscana, dimostra che invece le due probabilità non coincidono²¹ calcolandone il valore esatto come rapporto fra numero di casi favorevoli e numero di casi possibili.

Lanciando 3 dadi il numero dei casi possibili è dato dalle disposizioni con ripetizione $D'_{6,3} = 6^3 = 216$. È un numero davvero limitato di possibilità, che è immediato enumerare con R impiegando 3 cicli `for` annidati uno nell'altro:

```
for (d1 in 1:6){
  for (d2 in 1:6){
    for (d3 in 1:6){
      cat(d1,d2,d3,"\n")
    }
  }
}
```

Non riportiamo l'*output* di questo *script*, dal momento che porterebbe via 216 righe di testo; il lettore curioso può comunque visualizzare l'*output*.

L'essenza del “problema di Galileo” consiste nel calcolare il numero dei casi favorevoli alle due possibilità ($S=9$ e $S=10$); con R (impiegando lo *script* precedente con poche modifiche) è facile enumerarli:

```
for (d1 in 1:6){
  for (d2 in 1:6){
    for (d3 in 1:6){
      S <- d1+ d2 + d3
      if (S==9 | S==10) cat(d1,d2,d3,S,"\n")
    }
  }
}
```

²⁰Per calcolare le due probabilità abbiamo impiegato la distribuzione binomiale e la funzione `dbinom` di R, che vedremo nel prossimo capitolo.

²¹“Che nel gioco de' dadi alcuni punti sieno più vantaggiosi di altri, vi ha la sua ragione assai manifesta, la quale è il poter quelli più facilmene e più frequentemente scoprirsi che questi.”

Lo *script* calcola la somma S e, qualora essa sia uguale a 9 oppure a 10, stampa il punteggio osservato sul primo, sul secondo e sul terzo dado (oltre al totale). Anche in questo caso preferiamo non riportare l'*output* dello *script* (52 righe), lasciando al lettore la possibilità di visualizzarlo.

- Si ottiene un totale S pari a 9 se compare una delle seguenti 6 terne: (1, 2, 6), (1, 3, 5), (1, 4, 4), (2, 3, 4), (2, 2, 5), (3, 3, 3).
- Si ottiene un totale S pari a 10 se compare una delle seguenti 6 terne: (1, 4, 5), (1, 3, 6), (2, 2, 6), (2, 3, 5), (2, 4, 4), (3, 3, 4).

Quindi le terne (che Galileo chiama *triplicità*) sono 6 in entrambi i casi, ma questo non vuol dire che il numero dei casi favorevoli sia lo stesso. Infatti, guardando l'*output* dello *script*, il lettore potrà verificare che un totale $S = 9$ si verifica in 25 modi diversi, mentre un totale $S = 10$ si verifica in 27 modi diversi. Perché?

Il fatto è che una terna come, ad esempio, (1, 2, 6) oppure (1, 4, 5), si può presentare in 6 modi ($3!$) diversi (permutazioni semplici), mentre una terna come, ad esempio, (1, 4, 4) oppure (2, 2, 6), si può presentare in 3 modi ($3!/2!$) diversi (permutazioni con ripetizione). Nel caso in cui $S = 9$ c'è addirittura una terna (3, 3, 3) che si può presentare in un solo modo. Ecco quindi che i casi favorevoli a $S = 9$ sono in tutto 25, mentre quelli favorevoli a $S = 10$ sono 27. Pertanto $P(S = 9) = 25/216 \simeq 0.1157$, mentre $P(S = 10) = 27/216 = 0.125$.

Lanciando tre dadi, è quindi un po' più facile ottenere un totale di 10 che un totale di 9. Su *Problemi ed esperimenti di statistica con R* si trova uno *script* per affrontare il "problema di Galileo" impiegando R e il metodo Monte Carlo.

Il problema del cavalier de Méré. Nel XVII secolo in Francia, presso i giocatori d'azzardo erano molto diffusi due giochi. Il primo consisteva nello scommettere sull'uscita almeno una volta della faccia contrassegnata dal numero 6 in quattro lanci di un dado. Nel secondo gioco si scommetteva, invece, sull'uscita almeno una volta del doppio 6 in ventiquattro lanci di due dadi. Il Cavalier de Méré sosteneva che i due eventi avessero la stessa probabilità, ma non aveva ragione.

Infatti, l'esperienza empirica, che mostrava come il primo evento si verificasse più frequentemente del secondo, non confortava la dimostrazione analitica proposta dal nobiluomo francese. Questi, per fare chiarezza sulla questione, si rivolse al filosofo Blaise Pascal il quale chiamò in suo soccorso l'amico matematico Pierre de Fermat. Dal carteggio fra i due alcuni ritengono sia nata la moderna teoria della probabilità.²²

È immediato calcolare il numero dei casi possibili che si possono ottenere lanciando un dado 4 volte; si tratta infatti di calcolare le disposizioni con ripetizione $D'_{6,4} = 6^4 = 1296$. Può essere un po' più complesso calcolare il numero dei casi favorevoli (l'uscita di almeno un 6); infatti, dovremmo calcolare il numero di modi in cui

²²“The first article in this series by Dr F. N. David (1955) has reviewed the development of dicing and gaming up to the time of Fermat and Pascal, who are popularly but erroneously supposed to have founded the calculus of probability.” Evidentemente Kendall (1956) non è d'accordo.

il 6 può uscire 1, 2, 3 o 4 volte. In un caso come questo è certamente più semplice calcolare il numero dei casi “sfavorevoli”, cioè il numero dei modi in cui, lanciando un dado 4 volte, il 6 non esce mai: basta fare $5^4 = 625$ (il numero dei casi che si possono ottenere lanciando 4 volte un “dado” con 5 facce). A questo punto, il numero dei casi favorevoli si calcola per differenza fra il numero dei casi possibili e il numero dei casi sfavorevoli: $1296 - 625 = 671$. La probabilità cercata è quindi $671/1296 \simeq 0.5177$.

Possiamo verificare facilmente con R la correttezza del calcolo del numero dei casi favorevoli e dei casi possibili (e il loro rapporto) con il seguente *script*:

```
> cfav <- 0; cpos <- 0
> for (d1 in 1:6){
+   for (d2 in 1:6){
+     for (d3 in 1:6){
+       for (d4 in 1:6){
+         cpos <- cpos + 1
+         if (d1==6 | d2==6 | d3==6 | d4==6) cfav <- cfav + 1
+       }}}
> c(cfav, cpos)
[1] 671 1296
> cfav/cpos
[1] 0.5177469
```

Lo *script* impiega 4 cicli *for* annidati uno nell'altro per enumerare tutti i casi possibili (volendo si potrebbero anche stampare a video, ma lo sconsigliamo...), mentre l'istruzione *if* conta i casi in cui è uscito almeno un 6.

Seguendo un ragionamento analogo possiamo calcolare il numero dei casi che si possono ottenere lanciando due dadi 24 volte: i risultati possibili derivanti dal lancio di due dadi sono 36 (6^2) e, quindi, il valore cercato è $D'_{36,24} = 36^{24}$ (ovvero circa 2.245×10^{37}).²³ Il numero dei casi “sfavorevoli” è dato da 35^{24} (ovvero 1.142×10^{37});²⁴ quindi il numero dei casi favorevoli è dato da $36^{24} - 35^{24}$. Si tratta davvero di un numero molto grande,²⁵ difficile da calcolare se non impiegando programmi come, ad esempio, Maxima.²⁶

È evidente che non potremmo usare R per enumerare tutti i casi possibili; questo non tanto per la lunghezza dello *script* (basterebbero 24 cicli *for*, ciascuno con una sequenza da 1 a 36), quanto per la (inutile) durata dell'elaborazione.²⁷ Tuttavia, se non

²³Il valore “preciso” è 22452257707354557240087211123792674816.

²⁴Il valore “preciso” è 11419131242070580387175083160400390625.

²⁵Il valore “preciso” è 11033126465283976852912127963392284191.

²⁶<http://maxima.sourceforge.net/>

²⁷I risultati possibili sono dell'ordine di 10^{37} . Se in un secondo si potessero ottenere un miliardo (10^9) di questi risultati (cosa molto più che ottimistica), ci vorrebbero (circa) $10^{37}/10^9 = 10^{28}$ secondi. Dal momento che in un giorno ci sono 86400 secondi e che in un anno (di 365 giorni) ce

possiamo usare in questo caso la “forza bruta” del computer, possiamo usare invece alcune (semplici) conoscenze matematiche.

Infatti, se è vero che il numero dei casi favorevoli è quello dei casi possibili è straordinariamente grande (dell'ordine di 10^{37}), è altrettanto vero che il loro rapporto è un numero “piccolo” (compreso fra 0 e 1). Possiamo allora calcolarlo nel modo seguente:

$$\frac{36^{24} - 35^{24}}{36^{24}} = 1 - \frac{35^{24}}{36^{24}} = 1 - \left(\frac{35}{36}\right)^{24}.$$

Il risultato calcolato con R è

```
> 1 - (35/36)^24
[1] 0.4914039
```

Ecco quindi che continuando a scommettere sull'uscita della faccia contrassegnata dal numero 6 almeno una volta in quattro lanci di un dado, il Cavalier de Méré poteva aspettarsi di ottenere un guadagno, mentre scommettendo sull'uscita del doppio 6 almeno una volta in ventiquattro lanci di due dadi non poteva attendersi lo stesso risultato.

Anche in questo caso, su *Problemi ed esperimenti di statistica con R* si trova uno script per affrontare il “problema del cavalier De Méré” impiegando R e il metodo Monte Carlo.

Esempio 1.5 Consideriamo un mazzo di carte da *poker* e chiediamoci quale è la probabilità che, estraendo a caso una carta dal mazzo, questa sia una carta di cuori.

Il numero dei casi possibili è 52 (il numero delle carte del mazzo), il numero dei casi favorevoli è 13 (il numero delle carte di cuori). La probabilità cercata è $13/52$.

Esempio 1.6 Consideriamo sempre un mazzo di carte da *poker* e chiediamoci quale è la probabilità che, estraendo a caso una carta dal mazzo, questa sia un asso.

Il numero dei casi possibili è sempre 52, il numero dei casi favorevoli è 4 (il numero di assi). La probabilità cercata è $4/52$.

Esempio 1.7 Consideriamo sempre un mazzo di carte da *poker* e chiediamoci quale è la probabilità che, estraendo a caso una carta dal mazzo, questa sia o una carta di cuori o un asso.

Il numero dei casi possibili è sempre 52, il numero dei casi favorevoli è 16 (il numero delle carte di cuori è 13, il numero di assi è 4, ma bisogna considerare che esiste l'asso di cuori, già contato o fra le carte di cuori o fra gli assi). La probabilità cercata è $16/52$.

ne sono quindi 31536000, ci vorrebbe un tempo superiore all'età attuale dell'universo per portare a termine l'elaborazione!

Esempio 1.8 Da un mazzo di 52 carte da *poker* ne vengono estratte 2. Calcolare la probabilità che entrambe le carte siano carte di fiori.

Se l'estrazione fosse fatta *con reinserimento* (si prende una carta, la si guarda, la si reinserisce nel mazzo, si rimescola il mazzo, si estrae una seconda carta), i casi possibili sarebbero 52^2 , mentre quelli favorevoli sarebbero 13^2 (si tratterebbe delle *disposizioni con ripetizione* $D'_{52,2}$ e $D'_{13,2}$). La risposta è $1/16$.

Se, però, si prendessero 2 carte contemporaneamente (ovvero l'una dopo l'altra senza reinserimento), dovremmo sottrarre sia dal numero dei casi possibili, sia da quello dei casi favorevoli, le situazioni in cui la stessa carta compare due volte. Quindi i casi favorevoli diventano $52^2 - 52$ e quelli favorevoli $13^2 - 13$. Si tratta, in termini "tecnici", delle *disposizioni semplici* $D_{52,2}$ e $D_{13,2}$. Raccogliendo e semplificando, la risposta è $3/51$.

Esempio 1.9 Si lanci una moneta per 10 volte. Calcolare la probabilità di ottenere più croci che teste.

Il numero dei casi possibili è costituito dalle sequenze di $k = 10$ simboli presi dall'insieme di $n = 2$ elementi $\{T, C\}$, ossia dalle *disposizioni con ripetizione* $D'_{2,10} = 2^{10} = 1024$.

Se indichiamo con A l'evento *si ottengono più croci che teste in 10 lanci di una moneta*, A è uno di questi "sottoeventi": escono 6 croci (su 10 lanci), escono 7 croci, escono 8 croci, escono 9 croci, escono 10 croci. Il numero di modi in cui può avvenire ciascuno dei "sottoeventi" è dato dalle *combinazioni* corrispondenti che, quindi, vanno sommate insieme:

$$\binom{10}{6} + \binom{10}{7} + \binom{10}{8} + \binom{10}{9} + \binom{10}{10} = 386.$$

La probabilità cercata è quindi $386/1024$.

Il problema del compleanno. Vediamo ora un esempio "classico", non riguardante il gioco d'azzardo, che si affronta impiegando il calcolo combinatorio. È il cosiddetto *problema del compleanno*.

Supponiamo che ci siano n persone in una stanza. Quale è la probabilità che almeno due di loro abbiano lo stesso compleanno? Per affrontare questo problema conviene introdurre una semplificazione, assumendo che in un anno vi siano sempre 365 giorni, ignorando gli anni bisestili.

Il numero di casi possibili è dato da 365^n , cioè il numero delle disposizioni con ripetizione.

Per quanto riguarda il calcolo del numero dei casi favorevoli, è più opportuno modificare (temporaneamente) la domanda, calcolando la probabilità (complementare) che *nessuno abbia lo stesso compleanno*. È questa una tecnica "standard" che trova impiego per rispondere a domande nelle quali compare il termine "almeno". Indichiamo con B l'evento "almeno due persone hanno lo stesso compleanno" e con $\bar{B}$ l'evento complementare "compleanni tutti diversi". Calcoliamo ora il numero dei casi favorevoli relativi all'evento $\bar{B}$.

Se $n = 2$, allora il numero di casi favorevoli è dato da 365×364 (perché la prima persona può essere nata in un giorno qualsiasi, mentre la seconda può “scegliere” fra uno dei 364 giorni rimanenti). Facciamo osservare che 365×364 può essere scritto come rapporto fra due fattoriali; infatti,

$$\frac{365!}{(365-2)!} = \frac{365!}{363!} = \frac{1 \times 2 \times 3 \times \dots \times 363 \times 364 \times 365}{1 \times 2 \times 3 \times \dots \times 363} = 365 \times 364.$$

Re-iterando il ragionamento precedente, troviamo che, quando $n = 3$, il numero dei casi favorevoli è dato da $365 \times 364 \times 363$, ovvero da

$$\frac{365!}{(365-3)!} = \frac{365!}{362!} = \frac{1 \times 2 \times \dots \times 362 \times 363 \times 364 \times 365}{1 \times 2 \times 3 \times \dots \times 362} = 365 \times 364 \times 363.$$

Pertanto, se il numero di persone è n , il numero dei casi favorevoli (relativamente all'evento $\bar{B}$) è dato da

$$\frac{365!}{(365-n)!} = 365 \times 364 \times \dots \times (365-n+1), \quad (1.3)$$

cioè dal numero delle *disposizioni semplici* di 365 oggetti distinti di classe n .

Osserviamo che se $n = 365$, il denominatore della (1.3) diventa $0!$ che, per definizione, è uguale a 1. Il numero dei casi favorevoli è quindi $365!$. Se, invece, $n \geq 366$, la (1.3) non vale più (se $n = 366$ vale ancora la parte a destra del segno $=$) e il numero dei casi favorevoli diventa zero (cioè la probabilità che nessuno abbia lo stesso compleanno vale 0 e, quindi, la probabilità che almeno due abbiano lo stesso compleanno è uguale a 1).

Supponiamo $n = 3$. Allora per ottenere il numero dei casi favorevoli dobbiamo calcolare $365 \times 364 \times 363$ (che fa 48228180). Il numero dei casi possibili è 365^3 (che fa 48627125). Pertanto, abbiamo che $P(\bar{B}) = 48228180/48627125$ e, quindi, $P(B) = 1 - 48228180/48627125 = 398945/48627125 \simeq 0.0082$.

Può essere interessante calcolare il valore di $P(B)$ per diversi valori di n . Potremmo implementare la (1.3) in una funzione che calcola il rapporto fra due fattoriali.²⁸ Tuttavia, R possiede già la funzione `pbirthday` che risponde alla nostra richiesta.

```
> n <- c(2:5, 10, 15, 20, 25, 30, 40, 50)
> for (i in n) {
+   cat(i, pbirthday(i), "\n")
+ }
2 0.002739726
```

²⁸Dal momento che, come abbiamo già visto, il fattoriale di un numero “grande” è un numero “molto, molto più grande”, è opportuno lavorare con i logaritmi dei fattoriali (sfruttando la funzione `lfactorial`) e solo alla fine convertire il risultato in probabilità.


```

3 0.008204166
4 0.01635591
5 0.02713557
10 0.1169482
15 0.2529013
20 0.4114384
25 0.5686997
30 0.7063162
40 0.8912318
50 0.9703736

```

Abbiamo calcolato la probabilità p dell'evento B (almeno due persone hanno lo stesso compleanno) per alcuni valori di n compresi fra 2 e 50. L'andamento di p in funzione di n viene rappresentato graficamente nel pannello di sinistra della Figura 1.1. È abbastanza controintuitivo il risultato che con sole 15 persone la probabilità sia pari al 25% e che, come si vede dalla Figura 1.1, con 23 persone si raggiunga il 50%.




Figura 1.1: A sinistra: Probabilità che in un gruppo di n persone, almeno due abbiano lo stesso compleanno, in funzione del numero n di persone. A destra: Numero n di persone necessarie affinché la probabilità che almeno due di esse abbiano lo stesso compleanno sia almeno uguale a p in funzione di p .

Grazie alla funzione `qbirthday` è immediato calcolare quante debbano essere le persone nella stanza affinché la probabilità che almeno due di esse abbiano lo stesso compleanno sia uguale (o superiore) al 99%:

```

> qbirthday(0.99)
[1] 57

```

Possiamo “verificare” con il metodo Monte Carlo quanto abbiamo appena trovato con $n = 23$. Lo *script* che segue può essere adattato modificando il valore di n (ed eventualmente quello di $nrep$).

```

> set.seed(654321)
> nrep <- 100000
> n <- 23
> x <- sample(anno,nrep*n,replace=TRUE)
> X <- matrix(x,nrow=nrep,byrow=TRUE)
> dum <- function(y) ifelse(sum(duplicated(y))>0,1,0)
> ris <- apply(X,1,dum)
> sum(ris)/nrep
[1] 0.5077

```

Lo *script* è molto “compatto” e sfrutta la funzione logica *duplicated* per verificare se esistono elementi che si ripetono in un vettore. La funzione *dum* (“applicata” alle righe della matrice *X* che contiene i dati estratti) restituisce 1 in caso di “successo” (almeno due persone in un gruppo di *n* hanno lo stesso compleanno) e 0 in caso di “insuccesso”. Il risultato è vicinissimo a quello esatto (0.5073).

La funzione *pbirthday* è in grado di rispondere ad una domanda più generale: “Computes answers to a generalised birthday paradox problem. *pbirthday* computes the probability of a coincidence and *qbirthday* computes the smallest number of observations needed to have at least a specified probability of coincidence.”

Quindi, ad esempio, la probabilità che in un gruppo di 50 persone ce ne siano 3 (o più) con lo stesso compleanno è

```

> pbirthday(50,classes = 365, coincident = 3)
[1] 0.1316786

```

mentre il più piccolo numero di persone necessario affinché la probabilità che almeno 3 di esse abbiano lo stesso compleanno sia uguale o superiore a 0.9 è

```

> qbirthday(0.9,classes = 365, coincident = 3)
[1] 135

```

1.2 Oltre il gioco d’azzardo: probabilità e fisica

La definizione “classica” di probabilità trova applicazione nella soluzione di problemi riguardanti i giochi d’azzardo dove un assunto di equiprobabilità sembra sostanzialmente ragionevole, almeno in linea di principio. Può forse apparire in qualche modo sconcertante che la probabilità (in particolare definita in modo “classico”) abbia trovato un fertile campo di applicazione nella disciplina che più di ogni altra appare non averne bisogno, essendo fondata su leggi rigidamente deterministiche: la fisica.²⁹ In

²⁹Dovremmo aggiungere l’aggettivo “classica”. Infatti, ad un livello più profondo e più fondamentale, quello atomico e subatomico, le leggi fisiche sembrerebbero essere basate sulla probabilità

questo ambito l'assunto di equiprobabilità può basarsi sull'esistenza di simmetrie fisiche, motivo per cui il calcolo matematico si può eseguire in termini di disposizioni, combinazioni e permutazioni.

Un primo successo della “fisica del caso” può essere considerato quello raggiunto da Maxwell per spiegare la pressione e la viscosità dei gas attraverso il movimento delle particelle costituenti. Non potendo conoscere con precisione le posizioni e le velocità di queste particelle, Maxwell impiegò il calcolo delle probabilità per ricavare la distribuzione di probabilità delle velocità delle molecole di un gas perfetto.

Alcuni anni dopo Boltzmann postulò che un gas si evolva spontaneamente dalla situazione meno probabile alla situazione più probabile, rappresentata da una distribuzione “equilibrata” delle molecole. Si tratta di una sorta di “determinismo statistico” che passa attraverso la rinuncia al “determinismo individuale”.

Nel menzionare questi “trionfi” dell'applicazione del calcolo delle probabilità alla fisica non bisogna dimenticare che un corpo materiale (solido, liquido o gassoso) è costituito, ad un livello microscopico, da un numero di atomi/molecole straordinariamente grande. Sappiamo che una *mole* di qualsiasi sostanza contiene 6.022×10^{23} atomi/molecole di quella sostanza.³⁰ Ad esempio, in 18 grammi di acqua (cioè in una mole di acqua) sono contenute 6.022×10^{23} molecole di acqua e in una stanza (del volume di circa 50 m^3) il numero di molecole di gas è dell'ordine di 10^{27} . Da un punto di vista della fisica classica, sarebbe necessario conoscere le posizioni e le velocità di ogni molecola per poterne seguire l'evoluzione temporale. Al contrario, ad un livello macroscopico, le proprietà termodinamiche sono descritte da un numero molto limitato di variabili, come la pressione, la temperatura e il volume.

Basandosi su idee probabilistiche (che avevano una controparte fisica),³¹ Boltzmann trovò una relazione che legava le quantità del mondo macroscopico (descritte in termini termodinamici) e quelle del mondo microscopico (descritte secondo le leggi della dinamica classica).

Dal momento che un singolo corpo macroscopico è (generalmente) costituito da un numero di molecole straordinariamente grande (virtualmente infinito, sotto molti punti di vista), è possibile impiegare il calcolo delle probabilità per ottenere risultati validi su questo singolo corpo. In altre parole, il comportamento collettivo di un numero straordinariamente grande di componenti (ciascuno dei quali sembra comportarsi in modo del tutto aleatorio) è in grado di generare (il più delle volte) un comportamento del tutto regolare (e prevedibile). Questa stessa regolarità e prevedibilità è in grado di spiegare l'irreversibilità termodinamica (a livello macroscopico), mentre le leggi della dinamica sono reversibili (a livello microscopico).

e sull'indeterminismo. In questo contesto, le probabilità avrebbero un carattere *non epistemico*, non sarebbero cioè espressione di una situazione di “ignoranza”, superabile con l'avanzamento della conoscenza, ma esisterebbero “primitivamente” (probabilità *ontologica*).

³⁰Questo è il *numero di Avogadro*.

³¹Che potevano cioè essere interpretate in termini fisici.

1.2.1 Cose che succedono quando i numeri sono molto, molto grandi

Il peso atomico dell'ossigeno è (circa) 16 uma,³² mentre quello dell'idrogeno è (circa) 1 uma. Quindi il peso molecolare dell'acqua è 18 uma. Se prendiamo 18 grammi di acqua (cioè una mole di acqua) sappiamo che contiene 6.022×10^{23} molecole di acqua. Se un bicchiere contiene 100 ml di acqua, arrotondando un po' possiamo dire che contiene 3×10^{24} molecole d'acqua. Seguendo un ragionamento per i cui dettagli rimandiamo al libro di Vulpiani (2014, pagg. 62–63), si può ritenere che la parte mescolante di tutti i mari della Terra contenga circa 3×10^{20} bicchieri di acqua. Se si versa il contenuto di un bicchiere d'acqua nel mare e si aspetta un tempo sufficiente affinché esso si mescoli adeguatamente, alla fine, prendendo un nuovo bicchiere d'acqua in esso ci saranno, in media $3 \times 10^{24} / 3 \times 10^{20} = 10^4$ molecole originariamente contenute nel bicchiere. Insomma, ci sono molte più molecole in un bicchiere d'acqua che bicchieri d'acqua in tutti i mari della Terra.

Cosa c'entra questo con il calcolo delle probabilità? Ebbene, la probabilità che nel secondo bicchiere d'acqua sia presente almeno una molecola già presente nel primo è sostanzialmente uguale a 1! Vediamo perché.

Il modello di riferimento è quello di un'urna contenente (circa) 10^{44} palline,³³ delle quali 10^{24} sono, ad esempio, bianche. Quindi la probabilità di estrarre una pallina bianca è $10^{24} / 10^{44} = 10^{-20}$. A questo punto estraiamo 10^{24} palline (il secondo bicchiere d'acqua). Qual è la probabilità che *almeno una* pallina sia bianca?

Per rispondere conviene (come abbiamo visto in altri esempi) rispondere prima ad un'altra domanda: Qual è la probabilità q che *nessuna* pallina sia bianca? La probabilità che una pallina non sia bianca è $(1 - 10^{-20})$. La probabilità che nessuna delle 10^{24} palline estratte sia bianca è, quindi,³⁴ $q = (1 - 10^{-20})^{10^{24}}$.

Non conviene fare questo calcolo con R (e nemmeno con altri programmi); infatti $(1 - 10^{-20})$ viene considerato uguale a 1 e il risultato finale risulta sbagliato. Conviene passare ai logaritmi, per cui dobbiamo vedere quanto fa $\log(q) = 10^{24} \times \log(1 - 10^{-20})$. Il logaritmo (naturale) di $(1 - 10^{-20})$ fa circa -10^{-20} e, quindi, $\log(q) = -10^{-20} \times 10^{24} = -10^4$. Ora, per trovare q dobbiamo fare l'esponenziale, cioè $q = e^{-10000}$, che è un numero praticamente uguale a zero (è circa 10^{-4343}). In generale, se le palline estratte sono n (con n molto grande), la probabilità q che *nessuna* pallina sia bianca è circa e^{-n} . Pertanto, la probabilità che *almeno una* delle palline estratte sia bianca è $1 - e^{-n} \simeq 1$.

³²Unità di massa atomica.

³³Un bicchiere contiene circa 10^{24} molecole (tralasciando il 3, che è ininfluenza per il ragionamento), mentre l'acqua di tutti i mari contiene 10^{20} bicchieri, quindi $10^{24} \times 10^{20} = 10^{44}$ molecole.

³⁴Stiamo usando ancora una volta il concetto di indipendenza, che chiariremo successivamente.

A questo punto possiamo anche ridurre di due ordini di grandezza il nostro risultato iniziale (dicendo cioè che, in media, nel secondo bicchiere ci sono 100, invece di 10000, delle molecole contenute nel primo bicchiere). La probabilità q che nessuna delle molecole contenute nel primo bicchiere sia presente anche nel secondo è e^{-100} :

```
> exp(-100)
[1] 3.720076e-44
```

quindi circa 10^{-44} , per cui la probabilità $p = (1 - q)$ che almeno una delle molecole contenute nel primo bicchiere sia presente anche nel secondo può essere considerata, a tutti gli effetti, l'equivalente di una certezza.

Il modello di Ehrenfest. Il secondo principio della termodinamica,³⁵ che comporta la sostanziale irreversibilità di molti fenomeni macroscopici, sembra in contrasto con la reversibilità dei fenomeni microscopici. Questa (apparente) contraddizione fra (reversibilità della) Meccanica e (irreversibilità della) Termodinamica fu inizialmente oggetto di critiche feroci (in particolare da parte di Mach e di Zermelo). Alcune di queste critiche si basavano sul *teorema di ricorrenza di Poincaré* il quale afferma che, a patto di aspettare un tempo sufficientemente lungo, un sistema dinamico ritorna sempre in uno stato arbitrariamente vicino a quello di partenza. È però importante quantificare quanto “lungo” debba essere questo tempo. Infatti, il secondo principio della termodinamica si basa su considerazioni probabilistiche le quali, applicate ad oggetti macroscopici costituiti da un enorme numero di atomi/molecole, producono risultati praticamente certi.

Il *modello di Ehrenfest* può aiutarci in questo senso. In questo modello possiamo considerare n palline contenute in due scatole (A e B); ad esempio, tutte le n palline potrebbero trovarsi nella scatola A . Si sceglie a caso una pallina e la si sposta dalla scatola in cui si trova mettendola nell'altra scatola. Il teorema di ricorrenza di Poincaré ci dice che *prima o poi* tutte le n palline ritorneranno nella scatola A .

Non è difficile preparare uno *script* per simulare il modello di Ehrenfest; possiamo anzi scrivere una *funzione* di R che lo faccia.

```
Ehr <- function(n,nmax=500000) {
  x <- c(1:n)
  y <- rep("A",n)
  out <- numeric(nmax)
  nest <- 0
  repeat {
    k <- sample(x,size=1)
    nest <- nest + 1
```

³⁵Si tratta di un principio di natura sostanzialmente statistica, che, almeno a livello concettuale, ammette la possibilità di violazioni, perdendo così lo *status* di legge assoluta.

```

if (nest > nmax) stop("Numero massimo di passi raggiunto.")
ifelse((y[k] == "A"), y[k] <- "B", y[k] <- "A")
chk <- sum(y == "A")
out[nest] <- chk
if (chk == n) break
}
cat("Numero di estrazioni eseguite:",nest,"\n")
out <- out[1:nest]
return(out)
}

```

La funzione ha un unico parametro obbligatorio, il numero n di palline da mettere nella scatola A ; l'altro parametro è il numero massimo di estrazioni (fissato a 500000). Possiamo usare la funzione `Ehr` come una “scatola nera” che riceve il numero n di palline e restituisce un vettore con il numero di palline contenute nella scatola A ad ogni estrazione (oltre al numero delle estrazioni necessarie per tornare alla situazione di partenza). Ad esempio, se scriviamo

```
set.seed(123); out <- Ehr(4); out
```

otteniamo come risultato

```
Numero di estrazioni eseguite: 4
[1] 3 2 3 4
```

ad indicare che la prima pallina estratta era (necessariamente) nella scatola A , che quindi ora contiene 3 palline; anche la seconda pallina scelta era nella scatola A (che quindi ha 2 palline); le due palline successive sono state scelte dalla scatola B , per cui, dopo 4 estrazioni complessive, le 4 palline sono tutte ritornate nella scatola A . Si può raffigurare graficamente il risultato mediante l'istruzione `plot(out, type="l", lty=3)`, cosa che lasciamo fare al lettore.

Passiamo a considerare altri 4 casi, in cui $n = 5, 10, 14, 20$:

```

> set.seed(456); out <- Ehr(5); out
Numero di estrazioni eseguite: 34
[1] 4 3 2 1 2 3 4 3 4 3 4 3 2 3 2 3 2 3
[21] 2 3 4 3 2 1 2 3 4 3 2 3 4 5
> set.seed(567); out <- Ehr(10)
Numero di estrazioni eseguite: 1500
> set.seed(678); out <- Ehr(14)
Numero di estrazioni eseguite: 33478
> set.seed(789); out <- Ehr(20,10000000)
Numero di estrazioni eseguite: 1635856

```

Nell'ultimo caso, abbiamo dovuto aumentare il numero massimo di estrazioni, portandolo a 10 milioni; infatti, 500000 estrazioni sarebbero in generale poche per aspettarsi di ritornare alla situazione iniziale. Rappresentare graficamente l'andamento “nel tempo” (cioè estrazione dopo estrazione) del numero delle palline nella scatola A quando

$n = 10, 14, 20$ è piuttosto difficile, dato il numero delle estrazioni eseguite.³⁶ Possiamo però rappresentare la distribuzione di frequenza del numero delle palline nella scatola A (Figura 1.2).




Figura 1.2: Distribuzione di frequenza del numero di palline nella scatola A quando il numero di palline totali è 14 (pannello di sinistra) o 20 (pannello di destra).

Come ci si poteva aspettare, per la maggior parte del “tempo” si osserva una situazione di equilibrio, con lo stesso numero di palline in entrambe le scatole; questo accade in circa il 21% dei casi quando $n = 14$ e in circa il 18% dei casi quando $n = 20$. Se consideriamo indicativi di una situazione di “equilibrio” anche i due valori adiacenti (quindi l’intervallo 6 – 8 quando $n = 14$ e l’intervallo 9 – 11 quando $n = 20$, allora una situazione di equilibrio si osserva in circa il 57% dei casi quando $n = 14$ e in circa il 50% dei casi quando $n = 20$. Inoltre, i grafici delle due distribuzioni sono quasi perfettamente simmetrici, ad indicare che scostamenti dalla situazione di equilibrio ideale di una fissata entità x sono ugualmente probabili in entrambe le direzioni; osserviamo inoltre che maggiore è lo scostamento dalla situazione di equilibrio ideale, minore è la probabilità che questo si realizzi.

Tuttavia, anche se la situazione di equilibrio si realizza per la maggior parte del tempo (essendo la più probabile), ciononostante ad un certo punto tutte le palline ritornano nella scatola A. Considerazioni teoriche che sono al di là degli scopi di questo libro permettono di dire che, in media, il “tempo” (cioè il numero delle estrazioni) necessario per tornare allo stato iniziale è circa 2^n . Il tempo, quindi, aumenta esponenzialmente all’aumentare di n .

Le osservazioni attuali suggeriscono che l’età dell’Universo (il tempo passato a partire dal Big Bang) sia di circa 13.8 miliardi di anni, che possiamo pure arrotondare a

³⁶Naturalmente il lettore dovrebbe provare a ripetere quanto abbiamo fatto, usando un “seme” diverso dal nostro, per valutare la variabilità del risultato (il numero delle estrazioni).

14 (miliardi di anni). Un anno (365 giorni) è formato da circa 3×10^7 secondi. Quindi, espressa in secondi, l'età dell'Universo è circa 4.4×10^{17} ; facciamo pure 10^{18} , arrotondando per eccesso. Ebbene, se provate a scrivere Ehr (60) dovreste essere pronti ad aspettare un tempo superiore a 14 miliardi di anni (in realtà R si fermerebbe prima, perché raggiungerebbe il numero massimo di estrazioni). Infatti:

> 2^60

[1] 1.152922e+18

Il lettore attento potrebbe obiettare che R è certamente in grado di fare ben più di una estrazione al secondo. In effetti quanto abbiamo scritto prima vale nel caso in cui si impieghi un secondo per fare una estrazione. Ma questo non cambia, ovviamente, la sproporzione fra il piccolo valore di n (60) e l'immensità del "tempo" impiegato a tornare alla situazione iniziale. Se, ad esempio, R riuscisse a fare 10 milioni (10^7) di estrazioni al secondo, allora il tempo sarebbe 10 milioni di volte più piccolo, quindi "soltanto" $10^{18} \times 10^{-7} = 10^{11}$ secondi, cioè oltre 3000 anni. Insomma, non conviene provare a scrivere Ehr (60)! E basterebbe portare a 84 il numero di palline nell'urna A per dover comunque aspettare (in media) un tempo superiore all'età dell'Universo.

Ma il numero di "palline" (atomi o molecole) contenute in pochi grammi di qualsiasi sostanza è ben superiore a 84! Ad esempio, in una stanza del volume di 50 m^3 si può pensare che ci sia un numero di molecole di gas dell'ordine di 10^{27} . È pertanto davvero sostanzialmente impossibile osservare empiricamente violazioni del secondo principio della termodinamica quando si ha a che fare con oggetti macroscopici.

Il moto browniano. Il calcolo delle probabilità ha rivestito un ruolo molto importante nella "dimostrazione" (indiretta) dell'esistenza degli atomi prodotta da Einstein in uno dei quattro articoli scritti nel suo *annus mirabilis* (il 1905): quello sul *moto browniano*.³⁷ Questo fenomeno fu osservato (al microscopio) nel 1827 dal botanico Robert Brown: si tratta di movimenti in tutte le direzioni, continui, rapidi ed irregolari esibiti da piccoli granuli di varie sostanze (come ad esempio il polline) immersi nell'acqua. Bisogna però aspettare Einstein (e il 1905) perché questo fenomeno, da semplice curiosità si trasformi in una vera e propria scoperta scientifica.

Come scrive molto lucidamente Vulpiani (2014), Einstein partì da due ipotesi:

- rispetto alle molecole del fluido in cui è immerso, un granello di polline si comporta come un corpo macroscopico che quando si muove sente una forza di attrito;
- a causa degli urti casuali con le molecole, dopo un certo tempo, il granulo avrà la stessa energia cinetica media di ogni molecola.

³⁷Über die von der molekularkinetischen Theorie der Wärme geforderte Bewegung von in ruhenden Flüssigkeiten suspendierten Teilchen. Annalen der Physik, 17, 549–560, 1905.

Scrive Vulpiani (2014): “La seconda assunzione è veramente ardita, tanto per dare un’idea è come supporre che una mongolfiera su cui urtano moscerini alla fine avrà la stessa energia cinetica media di un moscerino.” A partire da questi due assunti Einstein riuscì a calcolare lo spostamento quadratico medio compiuto dalla particella rispetto a una posizione originale in un tempo t , collegando lo spostamento medio con una costante (il coefficiente di diffusione) che tiene conto sia di quantità legate al mondo macroscopico (la costante dei gas, la viscosità del fluido, la sua temperatura e il raggio del granello) sia di una quantità propria del mondo microscopico, vale a dire il numero di Avogadro. In questo modo, grazie all’impiego della probabilità, è stato possibile “contare” gli atomi pur non potendoli vedere.

1.3 Oltre la definizione classica: le definizioni frequentista, soggettivista e assiomatica

La definizione “classica” di probabilità appare certamente limitante, dal momento che le situazioni che si presentano nella vita di tutti i giorni non rispettano il principio della equiprobabilità. Guardando un cielo nuvoloso possiamo pensare che nella prossima ora piovcherà oppure no, ma questo non vuol dire certamente che la probabilità di pioggia sia 0.5; allo stesso modo un farmaco, somministrato ad un paziente, può essere o non essere efficace, ma, ancora una volta, questo non vuol dire che la probabilità che quel paziente tragga giovamento dalla terapia sia 0.5.

Quando un assunto di equiprobabilità appare poco verosimile, si può ricorrere ad un’impostazione legata alla possibilità di poter ripetere, almeno in via teorica, uno stesso “esperimento” sostanzialmente sotto le stesse condizioni.³⁸ Quello che si osserva in questi casi è che il risultato (l’*evento* osservato) non è sempre esattamente lo stesso, ma presenta un certo grado (più o meno elevato) di variabilità: la teoria della probabilità può essere impiegata per definire un modello matematico di queste fluttuazioni.

Si può pertanto definire probabilità di un particolare evento *la frazione di volte in cui esso si presenta in una sequenza casuale, molto lunga, di prove ripetute sotto condizioni simili*. La probabilità di un evento è quindi un numero compreso fra zero (quando un evento non si verifica mai) ed uno (quando un evento si verifica in ogni prova). Questa definizione, detta anche *frequentista*, è correntemente impiegata nel campo delle scienze empiriche. La probabilità (induttivamente stimata) si basa sulle frequenze relative osservate nel passato. La proprietà delle frequenze a stabilizzarsi all’aumentare delle prove ha tuttavia una natura squisitamente empirica (induttiva) e non può quindi essere dimostrata.

³⁸La riproducibilità di un esperimento è uno dei requisiti essenziali del metodo scientifico.

Jakob Bernoulli nella sua *Ars conjectandi*, apparsa postuma nel 1713, stabilisce un primo teorema *limite* della teoria della probabilità. Per esporlo, seguiamo quanto scrive Hacking (2013) nel suo libro *The emergence of probability*. Bernoulli prese in considerazione la possibilità di eseguire ripetute prove, ciascuna con la stessa, sconosciuta, probabilità p di “successo”. Dopo aver eseguito n prove, si osserva una proporzione s_n di successi. Bernoulli dimostra quella che ora viene chiamata la “legge debole dei grandi numeri”: la probabilità che $|p - s_n| < \varepsilon$ tende a 1 al tendere di n all’infinito. Inoltre, qualsiasi sia il valore di ε , Bernoulli fa vedere come sia possibile calcolare un valore di n in modo tale che la probabilità di ottenere una proporzione s_n di successi che cada nell’intervallo $[p - \varepsilon, p + \varepsilon]$, sia maggiore di una data probabilità $1 - \delta$. In particolare, se $1 - \delta = 0.999$ abbiamo una “certezza morale” (*moral certainty*)³⁹ che s_n cadrà in quell’intervallo. Se, ad esempio, $p = 3/5$, allora una certezza morale che l’errore sia inferiore a $1/50$ è garantita quando n è superiore a 25550.

Il lettore potrebbe eseguire il semplicissimo *script* che segue⁴⁰ ed essere “moralmente certo” che il risultato che otterrà sarà compreso fra 0.58 e 0.62 (vale a dire 0.6 ± 0.02).

```
p <- 3/5
n <- 25551
x <- rbinom(1,n,p)
x/n
```

Notate che questa volta non abbiamo eseguito lo *script* e non abbiamo nemmeno innescato il generatore di numeri pseudo-casuali con la funzione `set.seed`. Questo perché ogni lettore dovrebbe ottenere il suo risultato indipendentemente dagli altri. Attenzione però: se i lettori saranno 1000, (almeno) uno potrebbe benissimo ottenere un valore al di fuori dell’intervallo e se i lettori saranno 100000, sarà praticamente certo che almeno uno otterrà un valore al di fuori dell’intervallo; lo stesso ci aspettiamo che accada se un lettore volesse ripetere il nostro *script* 100000 volte. Questa è la vera “essenza” del metodo frequentista.

La “certezza morale” può essere considerata alla base della definizione frequentista, grazie alla quale, soprattutto nel periodo che intercorse fra le due guerre mondiali, il campo di applicazione della teoria della probabilità si allargò alle scienze naturali, biologiche e sociali. In quel periodo probabilità e statistica formarono un connubio grazie ai lavori sulla “verifica d’ipotesi”⁴¹ ad opera principalmente di K. Pearson, R.A.

³⁹*Moraliter certum est, cujus probabilitas fere aequatur integrae certitudini, sic un defectus sentire non possit.*

⁴⁰Abbiamo impiegato la funzione `dbinom`, che illustreremo nel Capitolo 2 quando parleremo della variabile casuale binomiale.

⁴¹La traduzione abituale italiana dell’inglese *hypothesis test* è in qualche misura fuorviante, dal momento che non è possibile “provare” un’ipotesi (per lo meno non è possibile impiegando strumenti statistici). Una traduzione più fedele potrebbe essere “saggio d’ipotesi”.

Fisher, J. Neyman e E. Pearson. Questo tipo di procedura⁴² viene abitualmente impiegata per analizzare i risultati di studi osservazionali o sperimentali eseguiti nell'ambito della biologia, della medicina, della psicologia, delle scienze naturali, delle scienze sociali.

Per completezza, è poi necessario menzionare anche che alcuni autori sostengono una definizione di probabilità più ampia della precedente, interpretandola come *misura del grado di credibilità personale nei confronti di un'osservazione* (probabilità *soggettiva*) ovvero come uno strumento per rappresentare e comunicare l'incertezza. Probabilità ed informazione disponibile divengono pertanto intimamente connesse. Il termine "informazione" si riferisce a tutte le conoscenze che si posseggono nel momento in cui si debbano fare considerazioni su avvenimenti sconosciuti.

I limiti impliciti in ciascuna delle impostazioni appena illustrate possono essere, in parte, aggirati se non proprio superati, attraverso una *impostazione assiomatica* dovuta al matematico russo Kolmogorov, cioè mediante una consistente formalizzazione matematica di regole basate su un numero limitato di *assiomi*. Prima di enunciarli, è bene introdurre una terminologia adeguata.

La teoria matematica della probabilità viene definita per gli *esperimenti casuali* (concettuali o reali) ossia quegli esperimenti il cui *risultato* è *incerto*: lanciare una moneta, tirare un dado, osservare la durata di vita di un pezzo meccanico, eseguire un test diagnostico, somministrare un farmaco.

Un *evento* è uno dei possibili risultati di un esperimento (ideale). Gli *eventi elementari* (o *eventi semplici*) che costituiscono, ad esempio, i possibili risultati derivanti dal lancio di un dado sono rappresentati dall'uscita dei numeri 1, 2, 3, 4, 5, 6 che il dado porta sulle sue facce.

Un esperimento (ideale) è definito dai possibili risultati elementari. Facendo ricorso ad alcuni elementi di *teoria degli insiemi*, individuiamo l'insieme di tutti gli esiti possibili di un esperimento casuale, vale a dire l'*insieme degli eventi elementari*, che prende il nome di *spazio campionario* (o *universo*), che indichiamo con la lettera greca Ω . Un evento elementare può essere quindi indicato con la lettera ω . A partire da questi è possibile costruire altri eventi (impiegando operazioni quali l'unione, l'intersezione, la complementazione).

Un possibile risultato a seguito del lancio di un dado (quindi, un *evento*) è anche rappresentato dall'uscita di un numero pari (2, 4, 6); in questo caso il risultato (l'evento A) è un *evento composto* (cioè un *insieme* di eventi semplici): $A \subset \Omega$. Si può quindi dare una definizione più generale di *evento casuale* come un *sottoinsieme* di Ω . Per motivi di completezza, fra i possibili risultati di un esperimento vanno sempre considerati anche l'*evento certo* (ad esempio l'uscita di un numero minore di 7), rappresentato dallo stesso Ω e l'*evento impossibile* (per esempio, l'uscita di un numero maggiore di 6), rappresentato dall'*insieme vuoto* ($\emptyset$).

⁴²Ad essa è dedicato il libro *Ricerca con R*.

Ciascun evento casuale può essere visto come un elemento di un insieme “più grande”. Se il numero degli eventi elementari è finito e uguale a k , il massimo numero complessivo di eventi casuali è 2^k . Questo insieme (chiamato anche *insieme potenza* o *spazio degli eventi*) non è altro che l’insieme di tutti i possibili sottoinsiemi di Ω . Quindi, in questo caso, un evento A è un qualsiasi sottoinsieme di Ω ($A \subseteq \Omega$). Lo stesso non si può dire (rigorosamente) se, ad esempio, Ω fosse l’insieme $\mathbb{R}$ dei numeri reali. Il motivo è troppo complesso per essere affrontato qui. Tuttavia questa limitazione può essere aggirata se ci limitiamo a considerare un sottoinsieme di $\mathbb{R}$ costituito da un numero (anche infinito, ma numerabile) di intervalli di ampiezza opportuna.

Se indichiamo con $\mathcal{S}$ lo spazio degli eventi⁴³ (l’insieme di tutti i sottoinsiemi di Ω , con l’“accortezza” sopra indicata nel definire Ω), allora è possibile associare ad ogni elemento di $\mathcal{S}$ (cioè ad ogni evento) un numero reale *compreso fra 0 e 1* che chiamiamo la *probabilità dell’evento*. Da questo punto di vista, la probabilità è una *funzione di insieme* a valori reali che “prende” un evento e ne restituisce la sua probabilità: $P: \mathcal{S} \rightarrow [0, 1]$.

Se indichiamo con A un qualsiasi elemento dello spazio degli eventi $\mathcal{S}$, la probabilità è *definita* come una funzione P che soddisfa i seguenti assiomi:

1. $P(A) \geq 0$ (assioma del limite inferiore);
2. la probabilità dell’evento certo è uguale ad uno (assioma del limite superiore)

$$P(\Omega) = 1;$$

3. se A_1 e A_2 sono due eventi tali che $A_1 \cap A_2 = \emptyset$ (ovvero sono due eventi fra loro *incompatibili* o *disgiunti*), allora la probabilità dell’evento costituito dall’unione di A_1 e A_2 è data dalla somma delle probabilità dei due eventi (assioma della sommabilità finita):

$$P(A_1 \cup A_2) = P(A_1) + P(A_2).$$

Questo assioma (della sommabilità finita) si generalizza subito al caso di una famiglia *finita* $A_1, A_2, \dots, A_n$ di eventi a due a due disgiunti:

$$P\left(\bigcup_{i=1}^n A_i\right) = \sum_{i=1}^n P(A_i).$$

Non è possibile dimostrare che la formula precedente può essere estesa ad un’infinità numerabile di eventi a due a due disgiunti, motivo per cui questa proprietà va introdotta con un assioma “a parte” (assioma della continuità o della sommabilità completa):

⁴³Tecnicamente $\mathcal{S}$ deve essere una σ -algebra.

4. Se A_i è una successione infinita (ma numerabile) di eventi di $\mathcal{S}$ a due a due disgiunti, la probabilità dell'evento costituito dall'unione degli A_i è data dalla somma (infinita) delle probabilità dei singoli eventi A_i :

$$P\left(\bigcup_{i=1}^{\infty} A_i\right) = \sum_{i=1}^{\infty} P(A_i).$$

Per quanto ci riguarda, noi considereremo valido questo assioma, anche se, a differenza degli altri, esiste una discussione ancora aperta sulla sua validità.

A partire da questi assiomi si possono dimostrare numerosi teoremi, i più utili dei quali dal punto di vista operativo sono elencati (senza dimostrazione) di seguito. La dimostrazione di alcuni di essi è proposta nel capitolo 3 di *Problemi ed esperimenti di statistica con R*. In quanto segue, con $\bar{A}$ indichiamo il *complementare* dell'insieme A rispetto a Ω . Ricordiamo che $A \cup \bar{A} = \Omega$ e che $A \cap \bar{A} = \emptyset$.

- $\forall A, B \subseteq \Omega, P(B \cap \bar{A}) = P(B) - P(A \cap B)$.
- $\forall A \subseteq \Omega, P(\bar{A}) = 1 - P(A)$.
- $P(\emptyset) = 0$; l'evento $\emptyset$ si dice “evento impossibile”.⁴⁴
- Se $A \subseteq B$, allora $P(A) \leq P(B)$.
- Se $A, B \subseteq \Omega$, allora $P(A \cup B) = P(A) + P(B) - P(A \cap B)$.

L'ultimo teorema è anche noto come “principio della somma”.⁴⁵ Lo abbiamo applicato, implicitamente, in precedenza quando avevamo calcolato la probabilità di estrarre, da un mazzo di 52 carte, o un asso o una carta di cuori. Rispondiamo ora alla stessa domanda in modo più “formale”. Sia A l'evento “viene estratto un asso” e B l'evento “viene estratta una carta di cuori”. Quindi l'evento $A \cup B$ corrisponde all'evento “viene estratto un asso o una carta di cuori”. I due eventi A e B *non* sono fra loro incompatibili, in quanto l'evento $A \cap B$ corrisponde all'estrazione di un asso di cuori (si tratta di un *evento congiunto*). Quindi

$$P(A \cup B) = P(A) + P(B) - P(A \cap B) = \frac{4}{52} + \frac{13}{52} - \frac{1}{52} = \frac{16}{52}.$$

Si lancia un dado le cui facce riportano i numeri da 1 a 6. Calcolare la probabilità che esca un numero dispari o un numero primo (1 è un numero primo).

Sia A l'evento $\{1, 3, 5\}$ e B l'evento $\{1, 2, 3, 5\}$. Quindi $A \cup B = \{1, 2, 3, 5\}$ e $A \cap B = \{1, 3, 5\}$. Quindi

$$P(A \cup B) = P(A) + P(B) - P(A \cap B) = \frac{3}{6} + \frac{4}{6} - \frac{3}{6} = \frac{4}{6}.$$

⁴⁴Facciamo notare subito che se $P(A) = 0$, non è detto che A sia necessariamente l'evento impossibile. In altre parole l'evento impossibile non è l'unico evento ad avere probabilità uguale a zero.

⁴⁵La versione più generale di questo teorema, relativa alla probabilità dell'unione di più di due eventi è piuttosto “pesante” e non la riportiamo, rimandando a testi specialistici.

1.4 La probabilità condizionata

Le regole enunciate fino ad ora non sono in generale tali da portare a gravi paradossi logici (anche se abbiamo visto che già applicando la definizione classica di probabilità alcuni risultati sembrano andare contro il “buon senso”). Questi sopravvengono (e in abbondanza) quando si introduce un nuovo “tipo” di probabilità: la *probabilità condizionata*, che ora andiamo a definire (perchè di una definizione si tratta).

Definizione. Dati due eventi A e B (con B tale che $P(B) > 0$), si definisce *probabilità condizionata di A dato B* l'espressione seguente:

$$P(A|B) = \frac{P(A \cap B)}{P(B)}. \quad (1.4)$$

La (1.4) produce subito una nuova definizione.

Definizione. Dati due eventi A e B (con B tale che $P(B) > 0$), se $P(A|B) = P(A)$, allora A e B si definiscono *eventi stocasticamente indipendenti*.⁴⁶

Dalla (1.4) si ottiene immediatamente la “regola del prodotto”(o “principio delle probabilità composte”) per *eventi congiunti*:

$$P(A \cap B) = P(B) \times P(A|B), \quad (1.5)$$

regola che può essere “semplificata” nel caso di eventi indipendenti:

$$P(A \cap B) = P(B) \times P(A). \quad (1.6)$$

Una conseguenza assolutamente ovvia⁴⁷ della (1.5) è che $P(A \cap B) \leq P(A|B)$, dal momento che per ottenere $P(A \cap B)$ dobbiamo moltiplicare $P(A|B)$ per un numero, $P(B)$, che al massimo può essere uguale a 1 e che, in generale, è minore di 1.

La (1.6) si estende immediatamente al caso di k eventi indipendenti $A_1, \dots, A_k$:

$$P(A_1 \cap \dots \cap A_k) = P(A_1) \times \dots \times P(A_k). \quad (1.7)$$

La formula precedente è in realtà la definizione di eventi indipendenti, nel senso che, dato un numero qualunque di eventi, diciamo che essi sono indipendenti se e solo se vale la (1.7).

⁴⁶Attenzione a non confondere eventi mutuamente esclusivi (la cui intersezione è l'insieme vuoto) con eventi indipendenti.

⁴⁷Forse, però, non così tanto ovvia se diverse illusioni cognitive sono basate proprio sulla mancata percezione di tale conseguenza.

Dal momento che l'operazione di intersezione è commutativa, la (1.5) può essere scritta come segue:

$$P(A \cap B) = P(B \cap A) = P(A) \times P(B|A)$$

(con $P(A) > 0$).

In qualche modo, la probabilità condizionata ridefinisce lo spazio campionario Ω , eliminando da questo ciò che sappiamo non essersi verificato. Questo costringe a “rifare i conti”. Infatti, in base agli assiomi $P(\Omega) = 1$, ma ora, dal momento che ad alcuni eventi (che sappiamo non essersi verificati) è stata assegnata probabilità zero, avremmo $P(\Omega) < 1$! Si tratta quindi di definire un nuovo spazio campionario Ω' tale che $P(\Omega') = 1$. Se non vi sembra chiaro, capirete forse perché quando è in ballo la probabilità condizionata il rischio di incorrere in paradossi logici è sempre dietro l'angolo.

Consideriamo la seguente variante di un esercizio già visto. Da un mazzo di 52 carte ne vengono estratte (senza rimessa) 2. Calcolare la probabilità che la seconda carta sia di fiori, dato che la prima è di fiori.

Indichiamo con B l'evento “la seconda carta è di fiori” e con A l'evento “la prima carta è di fiori”. L'esercizio chiede di calcolare $P(B|A)$. In base alla definizione dobbiamo trovare quanto valgono $P(B \cap A)$ e $P(A)$. È immediato trovare $P(A) = 13/52$, mentre l'evento congiunto $B \cap A$ corrisponde all'estrazione di due carte di fiori. Avevamo già calcolato in precedenza la probabilità di questo evento, che vale $3/51$. Quindi

$$P(B|A) = \frac{3}{51} \times \frac{52}{13} = \frac{12}{51}.$$

In questo esercizio Ω è rappresentato dalle 52 carte del mazzo “completo”, mentre Ω' è rappresentato dalle 13 carte del mazzo “ridotto”, costituito da sole carte di fiori.

Per risolvere problemi di questo tipo (che coinvolgono probabilità condizionate e/o eventi congiunti) esiste un approccio equivalente, ma molto meno formale: quello dell'*albero degli eventi*. In questo tipo di approccio si tratta di “descrivere” l'esperimento, costruendo una sorta di albero decisionale. Sui rami dell'albero degli eventi vanno poste le probabilità corrispondenti, mentre le probabilità associate ai rami terminali si ottengono moltiplicando fra loro le probabilità che si incontrano durante il cammino. Vediamo l'esercizio precedente risolto in quattro passi costruendo un “albero degli eventi”, rappresentato nella Figura 1.3.

Primo passo. Alla prima estrazione può uscire una carta di fiori, risultato indicato con F oppure una carta di un altro seme, risultato indicato con $\bar{F}$. L'albero degli eventi ha quindi due rami “principali”. Sul ramo corrispondente a F abbiamo segnato $13/52$ (cioè $P(F)$), mentre sull'altro abbiamo segnato $39/52$ (cioè $P(\bar{F})$).

Secondo passo. Passiamo ora alla seconda estrazione, disegnando due rami, analoghi ai precedenti per ciascuno dei due risultati (rami) considerati in precedenza. Abbiamo quindi a questo punto 4 rami e dobbiamo segnare, su ciascuno di essi, la probabilità corrispondente.




Figura 1.3: Albero degli eventi relativo all'esempio descritto nel testo.

Procedendo dall'alto verso il basso abbiamo messo:

- $12/51$ dal momento che le carte rimaste nel mazzo sono 51, di cui 12 sono di fiori (alla prima estrazione è uscita una carta di fiori);
- $39/51$ dal momento che le carte rimaste nel mazzo sono 51, di cui 39 sono di un seme diverso da fiori (alla prima estrazione è uscita una carta di fiori);
- $13/51$ dal momento che le carte rimaste nel mazzo sono 51, di cui 13 sono di fiori (alla prima estrazione è uscita una carta che non è di fiori);
- $38/51$ dal momento che le carte rimaste nel mazzo sono 51, di cui 38 sono di un seme diverso da fiori (alla prima estrazione è uscita una carta che non è di fiori)

Terzo passo. Calcoliamo le probabilità associate agli estremi dei quattro rami, moltiplicando fra loro i valori che incontriamo lungo il percorso. Ancora una volta, procedendo dall'alto verso il basso, abbiamo

- $p_1 = \frac{13}{52} \times \frac{12}{51} = \frac{1}{17}$
- $p_2 = \frac{13}{52} \times \frac{39}{51} = \frac{13}{68}$
- $p_3 = \frac{39}{52} \times \frac{13}{51} = \frac{13}{68}$
- $p_4 = \frac{39}{52} \times \frac{38}{51} = \frac{19}{34}$

La prima probabilità (p_1) corrisponde alla probabilità di estrarre due carte di fiori, probabilità che avevamo già calcolato in precedenza.

Quarto (e ultimo) passo. Abbiamo però un'informazione ulteriore che fino ad ora abbiamo ignorato: la prima carta estratta è una carta di fiori. Quindi, sugli estremi dei due rami più in basso dovremmo scrivere $p_3 = 0$ e $p_4 = 0$, perché sappiamo che l'evento "prima carta non di fiori" non si è verificato. Ma a questo punto

$$P(\Omega) = p_1 + p_2 + 0 + 0 < 1$$

e questo non è possibile (dal momento che violerebbe l'assioma numero 2).

Si tratta quindi di definire un nuovo spazio degli eventi Ω' (rappresentato dai primi due rami finali dell'albero degli eventi) riscalandolo p_1 e p_2 in modo tale che la loro somma faccia 1. Per ottenere questo basta dividere p_1 e p_2 per la loro somma: $p'_1 = p_1/(p_1 + p_2)$ e $p'_2 = p_2/(p_1 + p_2)$, di modo che $P(\Omega') = p'_1 + p'_2 = 1$. La probabilità cercata è quindi proprio p'_1 . Se il lettore avrà la pazienza di confrontare i passaggi che abbiamo eseguito, si accorgerà che essi sono esattamente gli stessi che avevamo impiegato per risolvere l'esercizio in modo "formale".

Vediamo qualche altro esempio che impiega l'albero degli eventi. Si lancia una moneta truccata: $P(T) = 2/3$ e $P(C) = 1/3$. Se esce T viene scelto a caso un numero tra 1 e 9; se esce C viene scelto a caso un numero tra 1 e 5. Si determini la probabilità che venga scelto un numero pari.

La Figura 1.4 riporta l'albero degli eventi e la soluzione dell'esempio. Anche in questo caso possiamo considerare uno svolgimento in 4 passi.

Primo passo. Si lancia la moneta. Il risultato può essere T o C . L'albero degli eventi ha quindi due rami iniziali. Sul ramo corrispondente a T abbiamo segnato $2/3$ (cioè $P(T)$), mentre sull'altro abbiamo segnato $1/3$ (cioè $P(C)$).

Secondo passo. Estraiamo un numero, che può risultare pari (P) o dispari (D). Disegniamo due rami per ciascuno dei due risultati considerati in precedenza. Abbiamo quindi a questo punto 4 rami e dobbiamo segnare, su ciascuno di essi, la probabilità corrispondente. Procedendo dal basso verso l'alto abbiamo messo:

- $5/9$ dal momento che è uscito T e quindi abbiamo estratto a caso un numero tra 1 e 9 (i numeri dispari in questo insieme sono 5);
- $4/9$ cioè il complemento a 1 del valore precedente;
- $3/5$ dal momento che è uscito C e quindi abbiamo estratto a caso un numero tra 1 e 5 (i numeri dispari in questo insieme sono 3);
- $2/9$ cioè il complemento a 1 del valore precedente.

Terzo passo. Calcoliamo le probabilità associate agli estremi dei quattro rami, moltiplicando fra loro i valori che incontriamo lungo il percorso. Ancora una volta, procedendo dall'alto verso il basso, abbiamo




Figura 1.4: Albero degli eventi relativo all'esempio descritto nel testo.

- $p_1 = \frac{2}{3} \times \frac{5}{9}$
- $p_2 = \frac{2}{3} \times \frac{4}{9}$
- $p_3 = \frac{1}{3} \times \frac{3}{5}$
- $p_4 = \frac{1}{3} \times \frac{2}{5}$

Lasciamo al lettore la verifica che $p_1 + p_2 + p_3 + p_4 = 1$, dal momento che abbiamo descritto tutti i possibili risultati.

Quarto (e ultimo) passo. L'estrazione di un numero pari corrisponde o all'evento $T \cap P$, riportato sul secondo ramo finale dell'albero degli eventi (procedendo dall'alto) o all'evento $C \cap P$, riportato sul quarto ramo finale dell'albero degli eventi. Quindi la risposta (la probabilità che esca un numero pari) è $p_1 + p_3 = 58/135$.

Siamo ora pronti per affrontare alcuni paradossi legati alla probabilità o, come spesso vengono chiamati dagli psicologi,⁴⁸ dei *tunnel mentali*.

Si lancia una moneta (bilanciata) 7 volte. Su quale di queste sequenze scommettete (ovvero, quale è, secondo voi, la più probabile)?

1. T T T T C C C

⁴⁸Si veda in particolare il libro di Kahneman, Slovic, Tversky (1982).

2. C T T C T C C

3. C C C C C C C

Gli psicologi hanno posto questa domanda a un gran numero di persone. L'ordine di preferenza è per la risposta (2), seguita dalla (1) e, a distanza, dalla (3). Voi cosa rispondete? Attendete un attimo prima di leggere la soluzione.

La domanda riguarda la particolare *sequenza* di teste e di croci, non il numero di teste e di croci. Pertanto, per la regola del prodotto fra eventi indipendenti, la probabilità è *la stessa* per tutte e tre le sequenze, cioè $(1/2)^7$. Se non avete dato questa risposta, siete stati vittime di un *tunnel mentale*.

Vediamo ora un secondo esempio di (possibile) *tunnel mentale*. Un dado ha quattro facce verdi (V) e due rosse (R). Su quale di queste sequenze scommettete?

1. R V R R R

2. V R V R R R

3. V R R R R R

Anche in questo caso gli psicologi hanno posto questa domanda a un gran numero di persone. L'ordine di preferenza è per la risposta (2), seguita dalla (1) e dalla (3). Voi cosa rispondete?

Tutte le sequenze proposte sono sbilanciate sul rosso. La sequenza (2) (con 4 rossi e 2 verdi) appare più bilanciata (o meno sbilanciata) e, quindi (?) più probabile. Sarà così?

Calcoliamo la probabilità associata alla sequenza (1) impiegando il metodo dell'albero degli eventi come illustrato nel pannello in alto a sinistra della Figura 1.5. Essendo uscito R quattro volte e V una volta, la probabilità della sequenza è data da $(1/3)^4 \times 2/3$.

Consideriamo ora la sequenza (2) (pannello in alto a destra della Figura 1.5). La faccia R si è presentata quattro volte, mentre quella V due volte. Se pensate che questa sequenza sia più probabile della precedente, avete imboccato un *tunnel mentale*. Infatti, la probabilità della sequenza è data da $(1/3)^4 \times (2/3)^2$. Anche senza fare i calcoli, si tratta del valore calcolato per la sequenza (1) *moltiplicato* poi per $2/3$. Poiché $2/3$ è minore di 1, il valore che otterremo sarà, necessariamente *più piccolo* (quindi meno probabile) di quello ottenuto per la sequenza (1).

Un discorso analogo vale per la sequenza (3), illustrata nel pannello in basso a sinistra della Figura 1.5. La probabilità della sequenza è data da $(1/3)^5 \times 2/3$. Anche in questo caso, senza fare i calcoli, osserviamo che si tratta del valore calcolato per la sequenza (1) *moltiplicato* poi per $1/3$. Poiché $1/3$ è minore di 1, il valore che otterremo sarà, necessariamente *più piccolo* (quindi meno probabile) di quello ottenuto per la sequenza (1).

È interessante notare che è possibile individuare la sequenza più probabile *senza* che sia necessario eseguire materialmente i calcoli. Basta solo accorgersi che le sequenze (2) e (3) “contengono”, al loro interno, la sequenza (1) e, quindi, avranno una probabilità inferiore rispetto a questa.




Figura 1.5: Alberi degli eventi relativi alle tre sequenze proposte nel testo.

E non è ancora tutto... Adesso dobbiamo affrontare il *teorema di Bayes*.

1.4.1 Il teorema di Bayes

Thomas Bayes è stato un ministro presbiteriano inglese noto soprattutto per il teorema che porta il suo nome. Tuttavia Bayes non pubblicò mai il suo teorema, che fu invece reso noto, dopo la sua morte, da Richard Price.⁴⁹

Il *teorema di Bayes* è una fonte pressoché inesauribile di paradossi logici e di *tunnel mentali*. Eppure si tratta di un teorema così “elementare” che spesso i matematici lo chiamano “formula di Bayes” o “regola di Bayes”, quasi che non avesse la “dignità” di un teorema. In effetti derivarlo è molto semplice. Riprendiamo in esame la formula (1.4) che qui riportiamo per comodità:

$$P(A|B) = \frac{P(A \cap B)}{P(B)}.$$

⁴⁹An Essay towards solving a Problem in the Doctrine of Chances. By the late Rev. Mr. Bayes, communicated by Mr. Price, in a letter to John Canton, M. A. and F. R. S. Philosophical Transactions of the Royal Society of London 53 (1763), 370–418. Anche se questo è il titolo originale, forse il “vero” titolo potrebbe essere un altro. Il lettore interessato può leggere l’articolo di Stigler (2013).

Una formulazione alternativa è data da

$$P(B|A) = \frac{P(A \cap B)}{P(A)},$$

dove $P(A) > 0$.

Possiamo a questo punto ricavare $P(A \cap B)$ dalla seconda formula:

$$P(A \cap B) = P(A) \times P(B|A)$$

sostituendo (al numeratore) il risultato nella prima:

$$P(A|B) = \frac{P(A) \times P(B|A)}{P(B)}$$


e, *voilà*, ecco il teorema di Bayes. $P(A|B)$ è detta *probabilità a posteriori*, mentre $P(A)$ è detta *probabilità a priori*; infine $P(B|A)$ è detta *verosimiglianza*.

Vediamo un primo esempio di applicazione del teorema di Bayes.

La scatola A contiene nove carte numerate da 1 a 9, la scatola B cinque carte numerate da 1 a 5. Viene scelta una scatola a caso (cioè $P(A) = P(B) = 0.5$) e da questa si estrae una carta. Il numero è pari. Calcolare la probabilità che la carta venga dalla scatola A .

Prima di affrontare l'esercizio in modo formale, costruiamo l'albero degli eventi corrispondente (dal momento che sappiamo che è uscito un numero pari, abbiamo calcolato soltanto le due probabilità relative a questa circostanza).

Indichiamo con p_1 la probabilità di osservare un numero pari estratto dalla scatola A (cioè l'evento $A \cap P$) e con p_2 la probabilità di osservare un numero pari estratto dalla scatola B (cioè l'evento $B \cap P$).



La probabilità di osservare un numero pari è quindi data da $p_1 + p_2$ e la probabilità che, *avendo osservato un numero pari*, questo venga dalla scatola A è data dal rapporto fra p_1 e il totale $p_1 + p_2$, vale a dire

$$\frac{\frac{2}{9}}{\frac{2}{9} + \frac{1}{5}} = \frac{10}{19}.$$

Vediamo ora di risolvere l'esercizio in modo più formale, applicando la formula di Bayes che riscriviamo indicando con A la scelta della scatola A e con P l'estrazione di un numero pari:

$$P(A|P) = \frac{P(A) \times P(P|A)}{P(P)}$$

Quello che ci viene chiesto è calcolare la probabilità *a posteriori* che la scatola scelta sia la A , sapendo che è uscito un numero pari, cioè calcolare $P(A|P)$.

Al numeratore della formula di Bayes compaiono la probabilità *a priori* che la scatola scelta sia la A (vale a dire $P(A)$ che, in base al testo dell'esercizio sappiamo essere 0.5) e la *verosimiglianza* (*likelihood*) associata al risultato, vale a dire $P(P|A)$ (se è stata scelta la scatola A , quale è la probabilità di estrarre un numero pari?). Facciamo notare che il numeratore vale proprio p_1 , ovvero $1/2 \times 4/9$.

Al denominatore della formula di Bayes compare la probabilità di estrarre un numero pari. Dal momento che un numero pari può essere estratto o dalla scatola A o dalla scatola B , tale probabilità è data da $p_1 + p_2$. Quindi la risposta è (come prima) $p_1/(p_1 + p_2)$.

Se 0.5 era la probabilità *a priori* che la scatola scelta fosse la A , l'informazione che è stato estratto un numero pari ha modificato tale probabilità aumentandola leggermente ($10/19 \simeq 0.526 > 0.5$). Vedremo fra poco esempi in cui la probabilità *a priori* viene modificata in modo più sostanziale.

Enunciamo adesso il teorema di Bayes in modo un po' più formale di quanto fatto fino ad ora.

Teorema delle probabilità totali. Se $\{C_j : j = 1, 2, \dots, k\}$ è una *partizione* dello spazio campionario Ω (vale a dire, un insieme di eventi mutuamente disgiunti la cui unione è lo spazio campionario) e $P(C_j) > 0$ per $j = 1, \dots, k$, allora per ogni evento A appartenente allo spazio degli eventi $\mathcal{S}$

$$P(A) = \sum_{j=1}^k P(C_j)P(A|C_j) \quad (1.8)$$

Teorema di Bayes. Sia A un evento appartenente allo spazio degli eventi $\mathcal{S}$. Se $C_1, \dots, C_k$ costituiscono una *partizione* di Ω , allora

$$P(C_i|A) = \frac{P(C_i)P(A|C_i)}{\sum_{j=1}^k P(C_j)P(A|C_j)}, \quad (1.9)$$

dove le probabilità $P(C_i|A)$, $P(C_i)$ e $P(A|C_i)$ prendono rispettivamente il nome di probabilità *a posteriori*, probabilità *a priori* e *verosimiglianze*.

Il denominatore della (1.9) rappresenta $P(A)$ e la formula per calcolare in questo modo $P(A)$, cioè la (1.8), è il teorema delle probabilità totali. Naturalmente la (1.9) vale solo se $P(A) > 0$.

Consideriamo il seguente esercizio.

In un sacco ci sono 100 monete. Una ha due teste (M_{2T}), mentre le altre 99 hanno una testa e una croce (M_{1T}) e sono bilanciate (la probabilità che esca testa è pari a 0.5). Si estrae a caso una moneta e la si lancia per 10 volte. Il risultato è sempre testa (T_{10}). Quale è la probabilità che la moneta estratta fosse quella con due teste, ovvero, in simboli, $P(M_{2T}|T_{10})$?

Lasciamo al lettore risolvere l'esercizio impiegando l'albero degli eventi. Noi lo affrontiamo in modo un po' più formale. Per rispondere alla domanda abbiamo bisogno

...della probabilità a priori. L'esercizio chiede di trovare la probabilità a posteriori $P(M_{2T}|T_{10})$. La probabilità a priori $P(M_{2T})$ che la moneta estratta sia quella con due teste è pari a $1/100$.

...della verosimiglianza. Il secondo "ingrediente" è la verosimiglianza, vale a dire $P(T_{10}|M_{2T})$, cioè la probabilità che si osservino 10 teste su 10 lanci nel caso in cui la moneta estratta è quella con due teste. In questo caso, ovviamente, tale probabilità vale 1 (se la moneta ha due teste uscirà sempre testa).

...della probabilità totale (da mettere al denominatore). L'ultimo "ingrediente" è $P(T_{10})$, la "probabilità del risultato osservato" (10 teste su 10 lanci). Se la moneta estratta è quella con due teste (evento che accade con probabilità $1/100$), questa probabilità è, come abbiamo visto, 1. Se invece è stata estratta una moneta regolare (evento che accade con probabilità $99/100$), allora la probabilità di osservare 10 teste su 10 lanci è (per il principio del prodotto per eventi indipendenti) $(1/2)^{10}$, vale a dire, $1/1024$. Quindi, mettendo insieme le due possibilità, abbiamo

$$P(T_{10}) = P(M_{2T})P(T_{10}|M_{2T}) + P(M_{1T})P(T_{10}|M_{1T});$$

$P(T_{10})$ è la *probabilità totale* ottenuta impiegando la (1.8).

A questo punto abbiamo tutto e non ci resta che trovare il risultato:

$$P(M_{2T}|T_{10}) = \frac{P(M_{2T})P(T_{10}|M_{2T})}{P(T_{10})} = \frac{0.01 \times 1}{0.01 \times 1 + 0.99 \times 1/1024},$$

che fa (circa) 0.912. In questo caso il risultato ha modificato in modo sostanziale la probabilità che la moneta avesse due teste: il suo valore è passato da 0.01 a 0.912!

Facciamo una variante all'esercizio, modificando la composizione del sacco. Esso contiene 1000 monete, di cui una con due teste, mentre le altre 999 sono monete "regolari". Manteniamo il resto inalterato.

In questo caso la probabilità a priori che la moneta estratta abbia due teste è $1/1000$, la verosimiglianza non cambia (rimane 1), mentre il denominatore si modifica in conseguenza della diversa composizione del sacco. La probabilità a posteriori risulta quindi

$$P(M_{2T}|T_{10}) = \frac{0.001 \times 1}{0.001 \times 1 + 0.999 \times 1/1024},$$

cioè 0.506. Ancora una volta il risultato osservato ha modificato la probabilità a priori, ma, data la bassa probabilità a priori, il "livello di certezza" (che la moneta sia quella con due teste) è solo di poco superiore al 50%.


Possiamo allora porci la seguente domanda. Quante volte (n) si dovrebbe lanciare la moneta estratta (ottenendo, ovviamente, sempre testa) per portare la probabilità a posteriori a un "livello di certezza" pari almeno al 90%?

In questo caso l’“incognita” è n , il numero dei lanci, mentre abbiamo fissato una soglia per la probabilità a posteriori. Possiamo allora scrivere

$$P(M_{2T}|T_n) = \frac{0.001 \times 1}{0.001 \times 1 + 0.999 \times (1/2)^n} \geq 0.9.$$

Lasciamo al lettore la soluzione analitica. Noi sfruttiamo la “potenza di calcolo” di R cercando la soluzione per tentativi.

```
> n <- c(1:25)
> den <- 0.001+0.999*0.5^n
> p <- 0.001/den
> plot(n,p)
> cbind(n[13:14],p[13:14])
[,1]      [,2]
[1,]    13 0.8913067
[2,]    14 0.9425301
```



La figura a fianco dello *script* mostra come varia la probabilità a posteriori $P(M_{2T}|T_n)$ al variare del numero dei lanci (il cui risultato è sempre testa). Se ci fermiamo a 13 lanci non raggiungiamo una probabilità del 90%, ma con 14 la superiamo abbondantemente.

Il teorema di Bayes è noto anche come “probabilità delle cause”. Infatti, riprendendo l’esempio introduttivo, in cui prima veniva scelta a caso una fra due scatole e poi veniva estratta una carta dalla scatola scelta, possiamo pensare alla scatola come alla “causa” e alla carta scelta come all’“effetto”. Il teorema di Bayes si propone di risalire (ovviamente in termini probabilistici) dall’effetto (il numero scelto è pari) alla causa che lo ha “provocato” (la scatola da cui è stata estratta la carta).

1.4.2 Teorema di Bayes e test diagnostici

Un campo in cui il teorema di Bayes trova larga applicazione è quello dei *test diagnostici* in medicina.

Un test diagnostico è una qualunque procedura utile all’identificazione di uno stato di malattia. Ammettiamo che un test diagnostico possa esitare soltanto in due risultati possibili, che chiamiamo, per convenzione, “positivo” e “negativo”. L’esito di un test è positivo se induce a sospettare la presenza della malattia. L’esito di un test è negativo se induce ad escludere la presenza della malattia.

Un buon test diagnostico tende a fornire esiti positivi in soggetti che presentano la malattia e, al contempo, a fornire esiti negativi in soggetti che non presentano la malattia.

Occorre prestare attenzione al fatto che un risultato positivo ad un test diagnostico non equivale ad affermare che la malattia è presente, così come un risultato negativo ad un test diagnostico non equivale ad affermare che la malattia è assente. In qualunque test esiste la possibilità di avere dei *falsi negativi* (soggetti malati, ma con esito negativo al test) e dei *falsi positivi* (soggetti non malati, ma con esito positivo al test). Esiste una terminologia tecnica che è opportuno conoscere. Nel prosieguo indicheremo con M l'evento "malattia presente" e con $\bar{M}$ l'evento "malattia assente". Indicheremo inoltre con T_+ l'esito positivo di un test diagnostico e con T_- l'esito negativo di un test diagnostico.

Si definisce *sensibilità* di un test diagnostico la probabilità che il test risulti positivo nei pazienti in cui la malattia è presente; in simboli è $P(T_+|M)$.

Si definisce *specificità* di un test diagnostico la probabilità che il test risulti negativo nei pazienti in cui la malattia non è presente; in simboli è $P(T_-|\bar{M})$.

Si definisce *valore predittivo positivo* di un test diagnostico la probabilità che un soggetto con il test positivo abbia la malattia; in simboli è $P(M|T_+)$.

Si definisce *valore predittivo negativo* di un test diagnostico la probabilità che un soggetto con il test negativo non abbia la malattia; in simboli è $P(\bar{M}|T_-)$.

Facciamo notare che sensibilità e specificità sono delle verosimiglianze, mentre valore predittivo positivo e valore predittivo negativo sono probabilità a posteriori.

Una domanda che si pone il medico (e il paziente) di fronte, ad esempio, ad un test con esito positivo è "quale sarà la probabilità che, essendo il test risultato positivo, il paziente abbia davvero la malattia?" La risposta può essere data impiegando il teorema di Bayes.

Il fatto è che molto spesso medico e paziente hanno una percezione distorta (un vero e proprio *tunnel mentale*) dell'interpretazione da dare al risultato di un test diagnostico, non sapendo interpretare correttamente le probabilità (a volte con esiti drammatici, come vedremo fra poco). Anche in questo caso gli psicologi hanno condotto diversi studi su medici per verificare la loro capacità di interpretare correttamente il risultato di un test diagnostico. Il libro di Gigerenzer (2003) tratta a fondo questo argomento ed è una lettura utilissima e illuminante non solo per la chiarezza espositiva, ma anche perché gli esempi trattati sono tutti reali, come quello che segue.

Nella popolazione generale la probabilità che una donna abbia un tumore al seno è dello 0.8% (8/1000). Se una donna ha un tumore al seno, la probabilità che la mammografia risulti positiva è del 90% (questa è la sensibilità). Se una donna non ha un tumore al seno vi è comunque la probabilità che la mammografia sia positiva per tumore nel 7% dei casi (quindi la specificità è del 93%). Se una donna (appartenente alla popolazione generale) ha una mammografia positiva, quale è la probabilità che abbia effettivamente un tumore?

Il lettore dovrebbe avere tutti gli elementi per rispondere alla domanda impiegando il teorema di Bayes. Noi, seguendo Gigerenzer, impiegheremo il metodo delle "fre-

quenze naturali”, che non è altro che una versione lievemente modificata dell’albero degli eventi (Figura 1.6).




Figura 1.6: Albero degli eventi relativo all’esempio proposto nel testo.

Prendiamo in considerazione 1000 donne appartenenti alla popolazione generale. Di queste 8 avranno un tumore al seno e le rimanenti 992 no. Scriviamo questi due valori sui primi due rami dell’albero degli eventi. A questo punto sottoponiamo alla mammografia *tutte* le 1000 donne. Cosa accadrà?

Il test eseguito sulle 8 donne con tumore al seno risulterà positivo in circa 7 casi ($8 \times 0.9 = 7.2$). Scriviamo 7 per mantenerci “agganciati” ad una situazione potenzialmente reale (i medici non amano pensare a 7.2 pazienti). Pertanto il test risulterà negativo in 1 delle 8 donne con la malattia.

Passiamo ora ad esaminare l’esito del test eseguito sulle 992 donne senza tumore al seno. Come detto sopra, qualche volta (7 volte su 100) il test risulterà (falsamente) positivo; precisamente ci aspettiamo circa 70 casi di questo tipo, cioè falsi positivi ($992 \times 0.07 = 69.44$). Nelle rimanenti 922 donne senza la malattia il test risulterà negativo.

Adesso possiamo rispondere alla domanda (cioè calcolare il valore predittivo positivo del test). Il numero di donne con test positivo è pari a 77 ($7 + 70$). Di queste, sono 7 quelle che hanno davvero un tumore al seno. Quindi, se una donna (appartenente alla popolazione generale) ha una mammografia positiva, la probabilità che abbia effettivamente un tumore al seno è inferiore al 10% ($7/77 \simeq 0.091$).

È un risultato assolutamente contro-intuitivo (per molti, medici e non). Accade di frequente che la risposta data alla domanda precedente (quale è la probabilità che una donna con mammografia positiva abbia davvero un tumore al seno) sia 0.90, vale a dire si scambia la sensibilità del test $P(T_+|M)$ con il valore predittivo positivo $P(M|T_+)$. Eppure, guardando la Figura 1.6 non dovrebbe essere difficile convincersi della veridicità del risultato ottenuto. Nella popolazione generale le donne senza la malattia sono la stragrande maggioranza e la mammografia, applicata indiscriminatamente, dà in questo caso 7 risultati (falsamente) positivi ogni 100 donne esaminate.

Ma vediamo, sempre prendendolo dal Gigerenzer, un caso ancora più “incredibile” (e drammatico).

Negli anni 80 del secolo scorso è stata identificata una nuova patologia, l'AIDS (*Acquired Immune Deficiency Syndrome*), ad eziologia virale (causata dal virus HIV *Human Immunodeficiency Virus*). Per questa malattia non si conosceva alcun tipo di cura e, data la modalità di trasmissione, la sua diagnosi era vissuta in molti casi come un vero e proprio “stigma” sociale. L'introduzione dei primi test diagnostici per individuare gli anticorpi anti-HIV ha, se possibile, reso più drammatica la situazione.

I primi test avevano una sensibilità del 99.9% e una specificità del 99.99%. In altre parole solo una persona sana su 10000 aveva un test (falsamente) positivo. Sembra un valore del tutto rassicurante, assai prossimo a zero. Ma è proprio così?

Gigerenzer riferisce che in un Dipartimento di salute pubblica dell'Illinois era esposto il seguente cartello:

Un risultato positivo significa che nel suo sangue sono stati trovati gli anticorpi dell'HIV, e questo vuol dire che Lei ha un'infezione da HIV. È infetto per il resto della vita, e può trasmettere l'HIV ad altre persone.


Poche righe più sotto Gigerenzer riferisce che
...nel decennio 1980-1990 in Florida, su 22 donatori di sangue a cui era stato comunicato che il test ELISA (il più semplice per l'HIV) era risultato positivo, 7 si sono suicidati.

Notate bene che Gigerenzer parla di donatori di sangue, cioè persone appartenenti alla popolazione generale che non avrebbero avuto alcun motivo per sottoporsi al test per l'HIV; lo hanno fatto in quanto, essendo donatori di sangue, la legge (giustamente) lo prescriveva.

Gigerenzer scrive che nella popolazione generale si può pensare che circa 1 maschio su 10000 sia affetto da AIDS. Costruiamo l'albero degli eventi che riporta quello che ci si deve aspettare se il test per l'HIV viene applicato indiscriminatamente a tutti i maschi appartenenti a questa popolazione.

Partiamo con 10 000 maschi; 1 sarà affetto da AIDS, mentre i rimanenti 9999 saranno sani. Quando eseguiamo il test sull'unica persona malata possiamo essere sostanzialmente certi che risulterà (correttamente) positivo.


Quando eseguiamo il test sulle 9999 persone che non hanno l'AIDS, avremo 1 falso positivo; infatti, data la specificità del test, abbiamo: $9999 \times 0.0001 = 0.9999$ che arrotondiamo a 1. L'esito del test nelle altre 9998 persone sarà (correttamente) negativo.



Tiriamo ora le conclusioni. Ci sono due maschi positivi al test, ma uno è malato e l'altro no. Quindi la probabilità che, avendo avuto un test positivo, un maschio abbia in realtà l'AIDS è del 50%. Assolutamente (e drammaticamente) contro-intuitivo. Altro che “...questo vuol dire che Lei ha un'infezione da HIV”.

Allora non dobbiamo più credere ai test diagnostici? Ovviamente no. Il fatto è che l'interpretazione da dare al risultato di un test diagnostico dipende dal motivo per cui il test è stato eseguito. Sempre Gigerenzer propone la seguente variante all'esempio precedente.

Supponiamo che un maschio appartenente ad una delle categorie a rischio per AIDS (ad esempio un omosessuale) si sottoponga allo stesso test. Gigerenzer riferisce che fra i maschi omosessuali 150 persone su 10 000 risultano affetti dalla patologia in parola. Costruiamo l'albero degli eventi corrispondente a questa situazione.



Partiamo ancora con 10 000 maschi. Di questi 150 saranno malati e 9850 saranno sani. Eseguendo il test sui 150 malati ci aspettiamo di osservare 150 test positivi ($150 \times 0.999 = 149.85$, che arrotondiamo a 150).

Eseguendo il test sui 9850 maschi sani ci aspettiamo di osservare

1 test (falsamente) positivo ($9850 \times 0.0001 = 0.985$, che arrotondiamo a 1).

A questo punto tiriamo le conclusioni. Ci sono 151 maschi in cui il test è risultato positivo; uno non è malato, ma gli altri 150 sì. Quindi la probabilità che, avendo avuto un test positivo, un maschio omosessuale abbia in realtà l'AIDS è superiore al 99% ($150/151 \simeq 0.993$).

Cosa è cambiato rispetto al caso discusso in precedenza? È cambiata la *prevalenza* della malattia (quella che abbiamo chiamato probabilità *a priori*), che è passata da 1 ogni 10000 a 150 ogni 10000.

1.4.3 Teorema di Bayes e ricerca scientifica

Per quanto riguarda il modo con cui i risultati di un esperimento devono essere interpretati, occorre ricordare che accanto all'impostazione frequentista (secondo la quale devono essere soltanto i risultati sperimentali a determinare le conclusioni), ve n'è un'altra, detta *bayesiana*, secondo la quale le conclusioni (quantitative) che si debbono trarre da un esperimento non dipendono solo dal particolare risultato ottenuto, ma anche dalla diversa credibilità delle ipotesi poste a confronto. È cioè possibile (anzi è necessario) dare un peso iniziale alle diverse ipotesi (probabilità *a priori*), integrandole successivamente con le informazioni sperimentali (la verosimiglianza), per calcolare, mediante il teorema di Bayes, la probabilità finale (*a posteriori*) che spetta a ciascuna ipotesi. L'esperimento diviene pertanto un aggiornamento continuo della conoscenza, non soltanto in modo empirico, ma anche in misura più formale.

È ovvio che la probabilità *a posteriori* dipende da quella *a priori*, e che la prima non può essere calcolata se la seconda non viene specificata. Il problema principale è rappresentato quindi dalla scelta delle probabilità *a priori*, la cui soggettività è apparsa a molti ricercatori inaccettabile nel campo scientifico, per cui tali probabilità

o sono state ignorate o, impiegando una cosiddetta regola di indifferenza, sono state distribuite uniformemente fra le diverse ipotesi a confronto. È tuttavia da far rilevare che, all'aumentare del numero delle osservazioni, il valore della probabilità *a posteriori* sembra tendere, il più delle volte, a coincidere, qualunque sia il valore assegnato alla probabilità *a priori* (zero escluso). I fautori dell'impostazione soggettivista sostengono che la teoria statistica derivata dall'impostazione frequentista (in particolare quella della verifica delle ipotesi) sia uno strumento troppo rigido al quale si debbono conformare le esigenze del ricercatore. Resta a questo punto da vedere, affermano i soggettivisti, se la metodologia frequentista generalmente adottata soddisfa pienamente la domanda posta dal ricercatore stesso o piuttosto non ne eluda le reali esigenze offrendo risposte tortuose ed indirette (Piccinato, 1979).

D'accordo con Pesarin (1979), la condotta migliore potrebbe essere quella di mantenere una pluralità di approcci inferenziali. Infatti, "per quanto una stessa teoria possa soddisfare contemporaneamente anche più di uno scopo, due o più di esse potranno anche essere non riducibili ad una teoria più comprensiva. Nel qual caso il chiedersi quali tra esse sia la migliore o meglio quale sia preferibile, va visto propriamente come un falso problema" (Pesarin, 1979).

Rinviamo il lettore interessato agli articoli di Bradley Efron proposti in bibliografia e alla sezione *The Bayesian approach to statistical inference* del libro di Agresti e Kateri (2022) di prossima pubblicazione.

1.5 Probabilità, odds e scommesse

C'è un modo alternativo di pensare alla probabilità che fa ricorso al concetto di *odds*, un termine che è sostanzialmente in traducibile in italiano e che fa riferimento al mondo delle scommesse.

La definizione di *odds* è molto semplice. Se p è la probabilità che si verifichi l'evento A , allora l'*odds* corrispondente è

$$odds = \frac{p}{1-p}. \quad (1.10)$$

Se, per esempio, l'evento A è la vittoria della squadra di casa in un incontro di calcio e pensiamo che la probabilità che si verifichi questo evento sia 0.4, allora l'*odds* corrispondente è $\frac{0.4}{1-0.4}$, cioè circa 0.67. Il *reciproco* di questo valore, cioè 1.5, è la *quota* di una corrispondente scommessa *equa*. In altre parole, dovremmo essere disposti a scommettere sulla vittoria della squadra di casa 1 euro contro 1 euro e 50 centesimi: se la squadra di casa vince (cioè se si realizza l'evento A) guadagniamo 1 euro e 50 centesimi; se la squadra di casa non vince (cioè se si realizza l'evento complementare $\bar{A}$) perdiamo 1 euro. Ribadiamo che la scommessa *deve essere equa*, vale a dire che, immaginando che la partita si possa giocare sotto le stesse condizioni un numero elevatissimo di volte, non dovremmo guadagnare né noi né chi ci offre la contropartita (il *bookmaker*). Infatti, ripetendo la scommessa 100000 volte, dovremmo vincere 1 euro e 50 centesimi 40000 volte (il 40% di 100000) e perdere 1 euro 60000 volte. Quindi, vincite e perdite si bilancerebbero perfettamente.

Abbiamo simulato due volte questa scommessa con R impiegando la funzione `sample` nel seguente *script*:

```
> p <- 0.4
> odds <- p/(1-p)
> quota <- 1/odds
> x <- c(quota,-1)
> nrep <- 100000
> set.seed(123456)
> #
> a <- sample(x,nrep,prob=c(p,(1-p)),replace=TRUE)
> (tbl <- table(a))
a
-1    1.5
60084 39916
> 1.5*tbl[2] - tbl[1]
1.5
-210
> #
> a <- sample(x,nrep,prob=c(p,(1-p)),replace=TRUE)
> (tbl <- table(a))
a
-1    1.5
59848 40152
> 1.5*tbl[2] - tbl[1]
1.5
380
```

Se volete ottenere i nostri stessi risultati è importante innescare il generatore di numeri pseudo-casuali di R con lo stesso *seme*: `set.seed(123456)`. Abbiamo definito la probabilità dell'evento *A* sul quale scommettiamo (`p <- 0.4`) e R ha calcolato l'*odds* (`odds <- p/(1-p)`) e la quota corrispondenti (`quota <- 1/odds`), vale a dire 1.5 euro, nel nostro esempio. La vincita (1.5 euro) e la perdita (1 euro, col segno meno davanti) sono state inserite nel vettore *x* (`x <- c(quota,-1)`). Infine abbiamo definito quante volte vogliamo replicare la scommessa (`nrep <- 100000`).

La riga principale dello *script* è l'ottava

```
a <- sample(x,nrep,prob=c(p,(1-p)),replace=TRUE)
```

nella quale abbiamo detto a R di estrarre (impiegando la funzione `sample`), con rimessa (`replace=TRUE`) dal vettore *x* (che contiene i valori 1.5 e -1) un campione di 100000 osservazioni con probabilità *p* per l'evento "vincita" e con probabilità $1 - p$ per l'evento "perdita".

La funzione `table` ci dice che su 100000 repliche abbiamo perso 60084 volte (invece di 60000) e abbiamo vinto 39916 volte (invece di 40000). I valori osservati sono molto vicini a quelli attesi e, come abbiamo visto più volte, non possiamo pre-

tendere che una simulazione produca risultati “esatti”. Complessivamente, in questa simulazione, abbiamo perso 60084 euro e vinto 59874 euro (con una perdita totale di 210 euro, molto vicina al valore 0, che è quello atteso).

D’altro canto, facendo una seconda simulazione, con gli stessi parametri, vediamo come abbiamo perso 59848 volte e vinto 40152 volte. Complessivamente, in questa seconda simulazione, abbiamo perso 59848 euro e vinto 60228 euro, con una vincita totale di 380 euro.

Il pannello di sinistra della Figura 1.7 mostra come varia l’*odds* in funzione della probabilità. Il grafico è stato prodotto facendo ricorso alla funzione `curve`:

```
curve(x/(1-x),0,0.9,xlab="Probabilità",ylab="Odds",
      cex.lab=1.25,cex.axis=1.25)
abline(v=0.5,h=1,lty=3)
```

La funzione `abline`, disegna una retta; l’argomento `v` chiede di disegnare una retta verticale passante per il punto di ascissa 0.5, mentre l’argomento `h` chiede di disegnare una retta orizzontale passante per il punto di ordinata 1; infine il valore 3 assegnato all’argomento `lty` chiede che le ‘rette’ siano punteggiate (abbiamo in questo modo voluto evidenziare una coppia di valori ben definita, quella in cui p vale 0.5 e l’*odds* vale 1).




Figura 1.7: Andamento dell’*odds* (a sinistra) e del *logit* (a destra) in funzione della probabilità.

Al crescere della probabilità cresce anche l’*odds* corrispondente; se $p = 0$ l’*odds* è zero (il valore minimo che può assumere un *odds*). Quando $p = 1/2$ allora l’*odds* è 1. Quando p varia fra 0 e $1/2$ l’*odds* varia fra 0 e 1. Quando p è superiore a $1/2$, l’*odds* diventa maggiore di 1 e cresce sempre di più al crescere di p . Ad esempio, se $p = 0.9$ l’*odds* vale 9 ($0.9/0.1$), se $p = 0.99$ l’*odds* vale 99 ($0.99/0.01$), se $p = 0.999$ l’*odds* vale 999 ($0.999/0.001$) e così via. Se dessimo a p il suo valore massimo ($p = 1$), l’*odds* non sarebbe calcolabile; infatti in questo caso il denominatore $1 - p$ diventerebbe zero e, come ci è stato insegnato nei corsi di Matematica, non è

possibile dividere un numero per zero. Tuttavia, dal momento che p non può superare il valore 1, con un po' di abuso di linguaggio, potremmo dire che quando $p = 1$, l'*odds* diventa *infinito*.

Possiamo chiedere a R di calcolare i valori degli *odds* corrispondenti ad alcune probabilità:

```
> (p <- seq(0,1,by=0.1))
[1] 0.0 0.1 0.2 0.3 0.4 0.5 0.6 0.7 0.8 0.9 1.0
> round(p/(1-p),3)
[1] 0.000 0.111 0.250 0.429 0.667 1.000 1.500
[8] 2.333 4.000 9.000    Inf
```

La funzione `seq` è impiegata per generare *sequenze* regolari e attraverso l'argomento `by` viene definito l'incremento.

Come si può osservare dal grafico, la relazione fra probabilità e *odds* è *biunivoca*; questo vuol dire che se si conosce il valore dell'*odds*, è possibile ricavare il valore della probabilità corrispondente (ad esempio sappiamo già che se l'*odds* è 1, la probabilità non può essere che 0.5). La formula che permette di ricavare la probabilità p a partire dall'*odds* è

$$p = \frac{odds}{1 + odds}. \quad (1.11)$$

Ci si può chiedere perché si debba lavorare con gli *odds* e non impiegare direttamente le probabilità. Uno dei (molti) motivi è che le probabilità non possono essere moltiplicate “impunemente”. Supponiamo, ad esempio, che la probabilità di successo ad un esame sia 0.1; possiamo rendere l'esame più “semplice”, raddoppiando la probabilità di successo e portandola a 0.2 e proseguire in questo modo portandola a 0.4 e a 0.8, ma, a questo punto, non possiamo certo raddoppiarla portandola a 1.6!

Lavoriamo adesso con gli *odds*. Se la probabilità di successo è 0.1, l'*odds* di successo è $1/9$. Possiamo raddoppiare questo valore, portandolo a $2/9$ (che corrisponde ad una probabilità di circa 0.18). Proseguiamo raddoppiando ogni volta l'*odds* di successo: otterremo $4/9$, $8/9$, $16/9$. In questo ultimo caso l'*odds* di successo ha superato il valore 1, ma questo non è assolutamente un problema; vuol dire solo che la probabilità corrispondente è maggiore di 0.5 (e infatti è 0.64). Continuiamo a raddoppiare: $32/9$, $64/9$, $128/9$, ... Fino a quando possiamo andare avanti? Fino a quando vogliamo! La probabilità sarà sempre minore di 1; magari arriverà molto vicina a 1, ma sarà sempre inferiore a 1. Ad esempio, se l'*odds* è $1024/9$, la probabilità è circa 0.991. Gli *odds* si possono raddoppiare (o triplicare, quadruplicare, ...), le probabilità no.

C'è poi un altro tipo di trasformazione della probabilità, legata all'*odds*, di particolare importanza in probabilità e statistica: la *trasformazione logit*, illustrata graficamente nel pannello di destra della Figura 1.7.

Lo *script* usato per disegnare la figura è il seguente:

```
curve(log(x/(1-x)),0.001,0.999,xlab="Probabilità",
ylab="Logit",cex.lab=1.25,cex.axis=1.25)
abline(v=0.5,h=0,lty=3)
```


Il *logit* associato ad una probabilità non è altro che il logaritmo naturale dell'*odds* ed è quindi così definito:

$$\text{logit} = \ln \left(\frac{p}{1-p} \right).$$

La trasformazione *logit* permette di mappare l'intervallo $(0, 1)$ su tutta la retta reale. In altre parole, usando un linguaggio certamente non rigoroso, ma “colorito”, ci sono altrettanti “punti” nell'intervallo $(0, 1)$ quanti ce ne sono su tutta la retta reale (da “meno infinito” a “più infinito”). Quando $p = 0.5$ (e, quindi, quando l'*odds* è uguale a 1) il *logit* vale 0; quando $p < 0.5$ il *logit* è minore di zero, mentre quando $p > 0.5$ il *logit* è maggiore di zero. Quando $p = 0$, l'*odds* vale 0 e il logaritmo di zero non è definito; usando lo stesso linguaggio non rigoroso impiegato in precedenza diciamo che, in questo caso, il *logit* è “meno infinito”. Analogamente, quando $p = 1$, l'*odds* vale “più infinito” e il logaritmo di “più infinito” (cioè il *logit*) vale “più infinito”.

Anticipando un argomento di cui parleremo nel Capitolo 3, la trasformazione *logit* trova impiego nel *modello logistico*; questo modello permette di valutare in che modo una o più variabili (indipendenti) influenzano la probabilità di un evento. Infatti, anche la relazione tra *logit* e probabilità è una relazione biunivoca, e la relazione inversa (quella che permette di trovare p conoscendo il *logit* corrispondente) è data da:

$$p = \frac{e^l}{1 + e^l},$$

dove con l abbiamo indicato il *logit* (e ricordiamo che l può essere qualsiasi numero reale). La curva che descrive come varia p al variare di l è una curva *logistica*.

Per fare un esempio di applicazione di un modello logistico, consideriamo il caso in cui la probabilità di avere un attacco di panico dipenda dal livello di stress psico-fisico, misurato attraverso una opportuna scala che va da 0 (nessuno stress) a 100 (stress massimo). Più precisamente, supponiamo che il *logit* della probabilità di avere un attacco di panico (y , la variabile dipendente) sia legato al livello di stress (x , la variabile indipendente) dalla seguente relazione lineare: $y = -7 + 0.14x$. In questo caso, la probabilità p di avere un attacco di panico in funzione del livello di stress psico-fisico x è data da

$$p = \frac{e^{-7+0.14x}}{1 + e^{-7+0.14x}}$$

e il grafico corrispondente è riportato nel pannello di destra della Figura 1.8.

Come si può osservare dalla Figura 1.8, mentre y (cioè il *logit* della probabilità di avere un attacco di panico) è legato linearmente al livello di stress psico-fisico (quando il livello di stress psico-fisico aumenta di 1 punto il *logit* aumenta di 0.14), il grafico del corrispondente modello logistico (riportato nel pannello di destra) è una curva a forma di *S italica*. La probabilità cresce al crescere del valore di x (dal momento che il coefficiente angolare della retta è maggiore di zero), dapprima lentamente, poi più rapidamente in una zona “centrale” dei valori di x e infine ancora lentamente, raggiungendo (asintoticamente) il valore 1 per valori “elevati” di x .




Figura 1.8: Andamento del *logit* (a sinistra) e della probabilità (a destra) di avere un attacco di panico in funzione del livello di stress psico-fisico.

Un punto generalmente interessante del grafico di un modello logistico è quello in cui la probabilità vale 0.5. Dal momento che il *logit* di 0.5 vale zero, possiamo ricavare il valore di x risolvendo, nel nostro esempio, l'equazione $0 = -7 + 0.14x$ (o, in generale, $0 = b_0 + b_1x$). Il valore di x cercato è quindi $7/0.14$, cioè 50 (e, in generale, è $-b_0/b_1$). Quindi, quando il livello di stress psico-fisico è 50, la probabilità di avere un attacco di panico è 0.5. Naturalmente potremmo essere interessati a conoscere quale deve essere il livello di stress psico-fisico affinché la probabilità di avere un attacco di panico sia, ad esempio, 0.95. La risposta si ottiene risolvendo l'equazione $\text{logit}(0.95) = -7 + 0.14x$ che è verificata quando x è (approssimativamente) 71. Infatti, quando $x = 71$, $y = 2.94$ (ricordiamo che y rappresenta il *logit* della probabilità cercata) e, quindi,

$$p = \frac{e^{2.94}}{1 + e^{2.94}} = 0.9498.$$

1.5.1 Dalla teoria alla pratica: le scommesse nel mondo reale

Abbiamo detto (e qui lo ribadiamo) che l'*odds* può essere visto come il reciproco della *quota* di una *scommessa equa* (e, come vedremo, l'aggettivo “equa” è fondamentale in questo contesto). Ad esempio, se la probabilità che un certo cavallo vinca una certa corsa è $p = 0.2$, un *bookmaker* “onesto” dovrebbe dare quel cavallo vincente 4 : 1 (l'*odds* in questo caso è $0.2/0.8$ e il reciproco è 4). In altre parole, chi scommette punta 1 euro e il *bookmaker* ne punta 4. Se quel cavallo vince, lo scommettitore ritira 5 euro ($1 + 4$), guadagnandone 4; se invece quel cavallo perde, lo scommettitore perde l'euro che aveva puntato, che diventa il guadagno del *bookmaker*. Dovrebbe essere altrettanto vero (ma vedremo che nella vita reale non è così) che se lo scommettitore volesse puntare sul fatto che quel cavallo non vincerà quella corsa, il *bookmaker* dovrebbe offrire questo risultato 1 : 4 (lo scommettitore punta 4 euro e il *bookmaker* ne punta 1). Lasciamo al lettore verificare che in entrambi i casi, ripetendo la scom-

messa “infinite” volte, nè chi scommette, nè chi “offre” la scommessa (il *bookmaker*) guadagnerebbero nulla.

Nel mondo reale delle scommesse, però, le cose non vanno così. Vediamo un esempio preso (il giorno 16 agosto 2020) da un sito di scommesse *online* (che non nomineremo, perché non è importante e perché non vogliamo fare pubblicità ai siti dove si offrono scommesse, per quanto legali). La scommessa è relativa al fatto che entrambe le squadre che giocheranno una semifinale della *Champions League* del 2020 segneranno (o non segneranno) e le “vincite” offerte sono riportate nella Tabella 1.1 (parliamo di “vincite” e non di “quote”; fra breve diremo perché).

Tabella 1.1: Alcune vincite proposte da un sito *online* di scommesse relative a risultati delle due partite di semifinale della *Champions League* del 2020.

	Risultato			Segneranno entrambe?	
	1	X		Sì	No
Martedì 18/08/20					
RB Lipsia					
PSG	4.25	3.90	1.80	1.60	2.20
Mercoledì 19/08/20					
Lione					
Bayern Monaco	11.50	7.00	1.22	1.80	1.91

È evidente che l’evento “segneranno entrambe” o si realizzerà o non si realizzerà (nel momento in cui scriviamo; nel momento in cui leggerete il libro o si sarà realizzato o non si sarà realizzato). Se il *bookmaker* fosse “onesto” (vale a dire, se la scommessa fosse equa) dovrebbe offrire le due quote in modo tale che una sia il reciproco dell’altra (così che il loro prodotto sia uguale a 1; vedi l’esempio precedente relativo alla scommessa sulla vittoria/sconfitta di un cavallo). Vediamo se è così nella Tabella 1.1.

Prima di iniziare questa verifica è importante sottolineare che quelle che sono riportate nella Tabella 1.1 non sono quelle che noi abbiamo chiamato “quote”; le chiameremo, come abbiamo scritto sopra, “vincite”. Per ottenere quelle che noi abbiamo chiamato “quote” dobbiamo sottrarre 1 euro da ciascuna “vincita”.⁵⁰ La quota relativa alla scommessa “segneranno entrambe” nella partita RB Lipsia – PSG è quindi 0.60, mentre la quota relativa alla scommessa “non segneranno entrambe” nella stessa partita è 1.20; gli *odds* corrispondenti sono quindi 1.667 e 0.833. Si vede subito

⁵⁰L’idea è che quello che si legge nella Tabella 1.1 è quello che “ci si porta via”, se si vince, puntando 1 euro.

che “qualcosa non va”, per lo meno dal nostro punto di vista (teorico): entrambi gli *odds* sono maggiori di 1, quindi entrambe le probabilità sono maggiori di 0.5 e, quindi, la loro somma è più grande di 1! Calcoliamo le due probabilità, ricorrendo alla formula (1.11).

La probabilità p_1 relativa alla scommessa “segneranno entrambe” è $1.667/2.667$, cioè 0.625,⁵¹ mentre la probabilità p_2 relativa alla scommessa “non segneranno entrambe” è $0.833/1.833$, cioè circa 0.455; pertanto $p_1 + p_2 \simeq 1.080 > 1$. Da notare che, sia pure con “vincite” diverse, anche nel caso della partita Lione – Bayern Monaco abbiamo $p_1 + p_2 \simeq 1.079 > 1$, essendo $p_1 = 1.25/2.25$ e $p_2 = 1.099/2.099$.

Questo risultato paradossale (la somma della probabilità di un evento e quella del suo complementare è diversa da 1) si spiega con il fatto che questo tipo di scommesse non è equo, nel senso che il “banco” (ovvero il *bookmaker* o la società che offre le scommesse) deve realizzare un guadagno. Se volessimo conoscere quali sono le probabilità “vere” in base alle quali sono state definite le quote (e le “vincite”), dovremmo normalizzare i due risultati p_1 e p_2 in modo che la loro somma faccia 1. Quindi, $p'_1 = p_1/(p_1 + p_2)$ e $p'_2 = p_2/(p_1 + p_2)$. Avremmo quindi, nel caso della partita Lipsia – PSG, $p'_1 = 0.579$ e $p'_2 = 0.421$, mentre in quella Lione – Bayern Monaco $p'_1 = 0.515$ e $p'_2 = 0.485$.

Il secondo esempio che proponiamo riguarda queste stesse due partite, ma questa volta le scommesse sono relative ai risultati $(1, X, 2)$ delle due semifinali; le “vincite” offerte sono riportate sempre nella Tabella 1.1.

Guardiamo la partita più “sbilanciata” (Lione – Bayern Monaco). Puntando 1 euro sulla vittoria del Lione se ne guadagnano 10 e 50 centesimi (naturalmente se dovesse vincere il Lione); puntando 1 euro sul pareggio se ne guadagnano 6 (qualora si realizzasse questo risultato); puntando 1 euro sulla vittoria del Bayern Monaco si guadagnano soltanto 22 centesimi (se dovesse vincere il Bayern Monaco). È evidente che il Bayern Monaco viene considerato dai *bookmaker* come un grande favorito. Passiamo dalle quote alle probabilità: la probabilità p_1 che vinca il Lione è 0.087; la probabilità p_X che le due squadre pareggino è 0.143; la probabilità p_2 che vinca il Bayern Monaco è 0.820; la somma di queste tre probabilità è 1.049 (quindi p_1 , p_X e p_2 non possono essere considerate delle “vere” probabilità). Le probabilità corrispondenti sono: $p_1 = 0.083$, $p_X = 0.136$ e $p_2 = 0.781$ e si ottengono moltiplicando i valori precedenti p_1 , p_X e p_2 per una costante K , data dal reciproco della loro somma ($K = \frac{1}{1.0495} \simeq 0.9528$). Vediamo i passaggi con R, iniziando con il definire le tre vincite:

```
> x <- c(11.5, 7, 1.22)
```

⁵¹Facciamo notare che questo stesso valore si può ottenere, più rapidamente, calcolando il reciproco della vincita: $1/1.60 = 0.625$. Infatti, $\frac{1-p}{p} - 1 = \frac{1}{p}$. A noi interessa però sviluppare tutto il ragionamento che porta dalle quote agli *odds* alle probabilità e, quindi, non ricorreremo a questa “scorciatoia”.

calcolando poi le quote

```
> (quote <- x - 1)
[1] 10.50  6.00  0.22
```

gli *odds*

```
> odds <- 1/quote
> round(odds,3)
[1] 0.095 0.167 4.545
```

e le “probabilità”

```
> prob <- odds/(1 + odds)
> round(prob,3)
[1] 0.087 0.143 0.820
```

Verifichiamo che la somma è maggiore di 1 e calcoliamo la costante di normalizzazione K

```
> sum(prob)
[1] 1.049486
> (K <- 1/sum(prob))
[1] 0.9528476
```

Calcoliamo infine le probabilità “vere” (verificando che la loro somma sia proprio 1)

```
> round(prob*K,3)
[1] 0.083 0.136 0.781
> sum(prob*K)
[1] 1
```

Lasciamo verificare al lettore (ripetendo i passaggi illustrati nello *script* precedente) che, nel caso della partita RB Lipsia – PSG, le “probabilità” p_1 , p_X e p_2 sono, rispettivamente, 0.235, 0.256, 0.556 (la cui somma S è 1.047 e $K = \frac{1}{S} \simeq 0.953$) e che le probabilità “vere” sono (circa) 0.225, 0.245 e 0.530.

Cosa succede se tre persone A , B e C si mettono d’accordo per scommettere ciascuna 100 euro sui tre risultati (A punta sul risultato 1, B punta sul risultato X , C punta sul risultato 2) dividendo alla fine quello che complessivamente “guadagnano”. È forse questa una strategia per vincere con certezza?

In base alle probabilità calcolate in precedenza

- A guadagna 1050 euro con probabilità 0.083 e perde 100 euro con probabilità $(1 - 0.083)$; quindi $1050 \times 0.083 - 100 \times 0.917 = -4.55$.
- B guadagna 600 euro con probabilità 0.136 e perde 100 euro con probabilità $(1 - 0.136)$; quindi $600 \times 0.136 - 100 \times 0.864 = -4.80$.

- *C* guadagna 22 euro con probabilità 0.781 e perde 100 euro con probabilità $(1 - 0.781)$; quindi $22 \times 0.781 - 100 \times 0.219 = -4.718$.

Come si può vedere tutti e tre i giocatori si aspettano di perdere e per di più la stessa cifra; infatti i tre valori appena ottenuti sono approssimati. Facciamo i conti con R.

```
> x <- c(11.5, 7.00, 1.22)
> quote <- x - 1
> odds <- 1/quote
> prob <- odds/(1 + odds)
> K <- 1/sum(prob)
> p <- prob*K
> #
> (X <- cbind(quote*100, p, quote*100*p, -100, (1-p), -100*(1-p)))
p
[1,] 1050 0.08285631 86.99913 -100 0.9171437 -91.71437
[2,] 600 0.13612108 81.67265 -100 0.8638789 -86.38789
[3,] 22 0.78102261 17.18250 -100 0.2189774 -21.89774
> Y <- X[,c(3,6)]
> rowSums(Y)
[1] -4.715242 -4.715242 -4.715242
```

Ciascuna riga della matrice *X* è relativa ad uno dei tre giocatori (*A*, *B* e *C*, nell'ordine); le colonne hanno il seguente significato:

1. guadagno corrispondente ad una puntata di 100 euro;
2. probabilità associata al guadagno;
3. prodotto fra i valori riportati nelle colonne 1 e 2;
4. perdita se non si realizza il risultato su cui si è puntato (100 euro, nel nostro esempio)
5. probabilità associata alla perdita (ottenuta facendo il complemento a 1 del valore nella seconda colonna;)
6. prodotto fra i valori riportati nelle colonne 4 e 5;

La penultima riga, calcola, impiegando la funzione `rowSums`, la somma dei valori riportati nelle colonne 3 e 6 (guadagno + perdita pesata) di ciascuna riga; tutti i giocatori devono aspettarsi di perdere, in media, la stessa cifra (quasi 5 euro). Vediamo la stessa cosa da un altro punto di vista.

- Se vince il Leone, *A* guadagna 1050 euro, mentre *B* e *C* ne perdono 100 ciascuno; in totale un guadagno di 850 euro.
- Se le due squadre pareggiano, *B* guadagna 600 euro, mentre *A* e *C* ne perdono 100 ciascuno; in totale un guadagno di 400 euro.
- Se vince il Bayern Monaco, *C* guadagna 22 euro, mentre *A* e *B* ne perdono 100 ciascuno; in totale una perdita di 178 euro.

Quindi in due casi su tre A , B e C avrebbero un guadagno complessivo da spartire fra loro. Però i tre risultati non sono ugualmente probabili, anzi uno (quello in cui si ha una perdita) è quello di gran lunga più probabile. E allora, inserendo nel calcolo le probabilità corrispondenti (tenendo conto di tutti i decimali e non solo di quelli mostrati di seguito) abbiamo che $850 \times 0.083 + 400 \times 0.136 - 178 \times 0.781 = -14.14573$, cioè *mediamente* c'è una perdita da spartire (e non un guadagno) che ammonta a $-14.14573/3 = -4.715242$ (lo stesso importo trovato in precedenza). Se dividiamo questo valore per 100 (riferendoci così ad 1 euro di puntata) vediamo che coincide con il valore della costante K diminuita di 1.

```
> x <- c(11.5, 7.00, 1.22)
> quote <- x - 1
> odds <- 1/quote
> prob <- odds/(1 + odds)
> (K <- 1/sum(prob))
[1] 0.9528476
> K - 1
[1] -0.04715242
```

Per ogni euro puntato, in media, si perdono circa 5 centesimi. Pertanto, K può essere vista come una misura di quanto il gioco non sia equo. Se fosse $K = 1$, il gioco sarebbe equo ($K - 1 = 0$), mentre se fosse $K > 1$ il gioco non sarebbe equo, ma sarebbe a favore di chi scommette (e non del banco). Nella realtà K è sempre minore di 1 e quanto più piccolo è il suo valore, tanto più il gioco non è equo (tanto maggiore è il guadagno che si aspetta il banco per ogni euro puntato).

Siamo ora pronti a tirare le conclusioni. Le “probabilità vere” (per lo meno riconosciute soggettivamente come tali dal *bookmaker* ovvero dal banco) associate alle “vincite” sono “gonfiate” in modo tale che la loro somma S sia maggiore di 1. Il reciproco di tale valore $K = 1/S$ rappresenta il fattore di normalizzazione che permette di trovare le “probabilità vere” a partire dalle “vincite”, secondo il procedimento che abbiamo appena illustrato. Tuttavia il valore di K è legato anche alla perdita “media” di un giocatore; tale perdita ammonta a $K - 1$ per ogni euro puntato. Dal momento che la perdita di un giocatore è il guadagno del banco, $1 - K$ è anche il guadagno “medio” del banco. Anzi, si potrebbe pensare che la strategia usata per fissare quelle che abbiamo chiamato “vincite” consista nel percorrere a ritroso i passaggi che abbiamo appena eseguito. Facciamo un esempio, supponendo che il banco voglia un guadagno medio del 10%:

1. Fissiamo $K = 0.9$, per cui $S = \frac{1}{K} = \frac{1}{0.9} \simeq 1.111$.
2. Stabiliamo, soggettivamente, le probabilità dei tre risultati 1, X , 2; ad esempio, poniamo $p'_1 = 0.10$, $p'_X = 0.15$, $p'_2 = 0.75$.
3. “Gonfiamo” questi tre valori, moltiplicando ciascuna probabilità per $S = \frac{1}{0.9}$: $p_1 = 0.1111$, $p_X = 0.1667$, $p_2 = 0.8333$ (la loro somma è S).
4. Passiamo dalle probabilità agli *odds*: 0.125, 0.200, 5.000.

5. Calcoliamo le quote: 8, 5, 0.2.
6. Calcoliamo le “vincite” da offrire agli scommettitori: 9, 6, 1.2.

Lasciamo al lettore verificare che a partire da questi 3 valori si ottengono le probabilità dichiarate al punto 2 e che $K = 0.9$ (quindi, in media, il banco guadagna 10 centesimi per ogni euro puntato).

Come ultimo esempio, prendiamo in esame la scommessa relativa alla squadra che vincerà il prossimo campionato italiano di Serie A (2020–2021); le “vincite” che il banco offriva il 16/8/2020 (quindi a circa 1 mese dal fischio di inizio della prima partita) sono riportate nella Tabella 1.2.

Tabella 1.2: Vincite proposte il 16 agosto 2020 da un sito *online* di scommesse relative alla squadra prima classificata del prossimo campionato italiano di Serie A (2020-2021).

Vincitore		
Juventus 1.75	Inter 3.00	Napoli 12.00
Atalanta 13.00	Lazio 17.00	Milan 21.00
Roma 51.00		Fiorentina 251.00
Hellas V. 501.00	Sassuolo 501.00	Torino 501.00
Parma 751.00	Cagliari 751.00	Bologna 751.00
Sampdoria 751.00	Udinese 751.00	Benevento 1001.00
Crotone 1001.00		

Eseguiamo con R i passaggi visti in precedenza, in modo da visualizzare le quote, gli *odds*, le probabilità “gonfiate”, la loro somma S e, infine, le probabilità “vere”. Iniziamo inserendo le vincite nel vettore x (rispettando l’ordinamento delle squadre proposto nella Tabella 1.2):

```
x <- c(1.75, 3, 12, 13, 17, 21, 51, 251, 501, 501, 501,
751, 751, 751, 751, 751, 1001, 1001)
```

Calcoliamo (e visualizziamo) le quote:

```
> quote <- x - 1
> quote
[1] 0.75 2.00 11.00 12.00 16.00 20.00 50.00
[8] 250.00 500.00 500.00 500.00 750.00 750.00 750.00
[15] 750.00 750.00 1000.00 1000.00
```


Passiamo agli *odds*:

```
> odds <- 1/quote
> round(odds,3)
[1] 1.333 0.500 0.091 0.083 0.062 0.050 0.020 0.004 0.002
[10] 0.002 0.002 0.001 0.001 0.001 0.001 0.001 0.001 0.001
```

e, quindi, alle “probabilità gonfiate”

```
> round(prob,3)
[1] 0.571 0.333 0.083 0.077 0.059 0.048 0.020 0.004 0.002
[10] 0.002 0.002 0.001 0.001 0.001 0.001 0.001 0.001 0.001
```

la cui somma S è maggiore di 1:

```
> sum(prob)
[1] 1.209697
```

Calcoliamo infine le probabilità “vere” dividendo ciascun valore per S :

```
> round(prob/sum(prob),3)
[1] 0.472 0.276 0.069 0.064 0.049 0.039 0.016 0.003 0.002
[10] 0.002 0.002 0.001 0.001 0.001 0.001 0.001 0.001 0.001
```

In questo caso il fattore di normalizzazione K è alquanto più piccolo di quelli visti in precedenza e vale circa 0.827, dal momento che il suo reciproco S (il fattore che “gonfia” le probabilità) è circa 1.21 (ogni probabilità viene aumentata di oltre il 20%). In un caso come questo, in cui la distanza temporale fra la scommessa (agosto 2020) e l’esito (maggio 2021, quando dovrebbe terminare il prossimo campionato italiano di Serie A) è molto grande, il banco vuole evidentemente “garantirsi” fissando (per sé) un guadagno (atteso) maggiore, pari a circa 17 centesimi per ogni euro puntato.

Quando si parla di scommesse si fa sempre riferimento ad eventi “singoli”, non ripetibili, per cui le probabilità sono evidentemente soggettive (quindi diverse da sito a sito), anche se i *bookmaker* cercano di tener conto di tutto quello che, al momento in cui vengono proposte le quote, può influenzare in misura più o meno diretta l’esito dell’evento oggetto di scommessa. Proprio per questo le quote sono soggette a modificarsi nel corso del tempo sulla base di nuove informazioni (campagna acquisti/cessioni, infortuni, ...nei nostri esempi “calcistici”).

2 Variabili casuali discrete

Uno degli aspetti più “ostici” a proposito di probabilità (e ce ne sono molti) riguarda la sua caratteristica di *funzione di insieme*. Abbiamo visto, infatti, come la probabilità “prenda” un evento (l'*argomento* della funzione) e restituisca un numero compreso fra 0 e 1 (la probabilità di quell'evento).

La maggior parte dei lettori sarà (stata) abituata a prendere in esame funzioni il cui argomento è un numero reale. Ad esempio la funzione $f(x) = 2x^2 + 3x + 4$, che descrive una parabola, restituisce il valore 4 quando $x = 0$ (perché $2 \times 0^2 + 3 \times 0 + 4 = 4$), il valore 9 quando $x = 1$ (perché $2 \times 1^2 + 3 \times 1 + 4 = 9$) e così via. In R è immediato farlo:

```
> f <- function(x) 2*x^2 + 3*x + 4
> x\index[funr]{x} <- c(0,1)
> f(x)
[1] 4 9
```

e così per qualsiasi valore di x .

Sarebbe quindi “bello” se fosse possibile “trasformare gli eventi in numeri”, in modo da poterci ricondurre alla situazione più familiare di una “funzione di variabile reale”. Questo è possibile facendo ricorso al concetto di *variabile casuale* (o *variabile aleatoria*). Vediamo un esempio.

È il 9 luglio 2006. La finale fra Italia e Francia che assegna la coppa del mondo di calcio è terminata con un pareggio anche dopo i tempi supplementari. La coppa sarà quindi assegnata a una delle due contendenti mediante i “tiri di rigore”. Si comincia con 5 tiri per squadra. I calciatori delle due squadre si alterneranno e alla fine si vedrà chi ne ha segnati di più (l'Italia!).

In questo caso, l'*evento elementare* è rappresentato dall'esito di un tiro di rigore e ci sono soltanto due eventualità possibili: il tiro di rigore viene segnato oppure no. Potremmo indicare il primo evento con un pallino verde e il secondo con un pallino rosso (come spesso si vede in televisione) oppure, più prosaicamente, il primo evento con la lettera *S* (segnato) e il secondo con la lettera *P* (parato). Un possibile evento composto è quindi rappresentato dalla *sequenza* *SSSSP*, mentre un secondo evento composto, diverso dal primo è rappresentato dalla *sequenza* *PSSSS*. Ma da un punto

di vista calcistico (ma, forse, non dal punto di vista emotivo) i due eventi precedenti sono del tutto analoghi: sono stati segnati 4 tiri di rigore su 5.

Possiamo quindi definire una variabile casuale (che indichiamo con la lettera X) che indica (conta) il numero di tiri di rigore che sono entrati in porta (indipendentemente dalla sequenza). Nell'esempio precedente la *realizzazione* x della variabile casuale X ¹ è stata pari a 4 in entrambi i casi.

Potremmo fare molti altri esempi in cui un insieme di eventi è “trasformato” in un numero: i crediti conseguiti da uno studente in un anno, i casi di malattia osservati in una certa area geografica in una settimana, i pezzi difettosi prodotti in un giorno da una macchina, il tempo intercorso da quando è stata accesa una lampadina a quando si è bruciata, l'altezza di una persona e così via.

Le variabili casuali rappresentano uno strumento molto potente non solo perché, come vedremo, semplificano il calcolo delle probabilità associate agli eventi di uno spazio campionario (lasciando tale spazio in larga misura sullo sfondo), ma anche perché rappresentano dei *modelli* applicabili a situazioni concrete che si presentano nel mondo della ricerca empirica. Per un concreto approccio alla probabilità è quindi basilare pensare in termini di variabili casuali piuttosto che di eventi: “*La potenza del ragionamento probabilistico ... è che si può calcolare la distribuzione di una variabile aleatoria senza riferirsi ad uno spazio campione o ad eventi. La distribuzione è definita in termini fenomenologici, cioè soltanto in termini di fenomeni osservati.*” (Baclawski, Cerasoli, Rota, 1990)

Nel prosieguo descriveremo quindi gli eventi in termini di variabili casuali, senza fare esplicito riferimento a uno spazio campionario. Prenderemo in considerazione soltanto alcune variabili casuali, che “descriveremo” in termini di *funzione di probabilità* (o *distribuzione di probabilità*), di *funzione di ripartizione*, di *valore atteso* (ovvero di *media*) e di *varianza*.

Iniziamo prendendo in esame le variabili casuali *discrete*, cioè quelle variabili casuali che possono assumere solo un numero *finito* (o, al più, una *infinità numerabile*) di valori. Le più importanti sono dei veri e propri *modelli probabilistici* e sono rappresentate mediante opportune formule. Prima, però, prendiamo in considerazione attraverso alcuni esempi alcune variabili casuali basate su dati empirici.

Esempio 2.1 La tabella che segue riporta la distribuzione di frequenza del numero x di fratelli e/o sorelle dei 24 bambini dell'Aula Rosa della Scuola di Infanzia “Torrione” di Trento in un determinato Anno Scolastico.

x	0	1	2	3
n	6	13	4	1

¹La simbologia adottata è quella “standard”: la variabile casuale (l'entità astratta) è indicata con una lettera *maiuscola*, mentre la sua realizzazione osservata (il particolare valore numerico ottenuto) è indicata con una lettera *minuscola*. Talvolta questa simbologia può ingenerare un po' di confusione nel lettore.

In questo esempio ci sono 6 bambini/e che non hanno fratelli/sorelle ($x = 0$), 13 bambini/e che ne hanno uno/a ($x = 1$), 4 che ne hanno 2 ($x = 2$) e, infine, c'è un bambino/a che ha 3 fratelli/sorelle ($x = 3$). Non ci sono bambini/e che hanno più di 3 tra fratelli e sorelle. Possiamo allora definire una variabile casuale X che assume i valori 0, 1, 2, 3, con probabilità, rispettivamente, $6/24$, $13/24$, $4/24$, $1/24$, come illustrato nella tabella che segue.

x	0	1	2	3
$f(x)$	$6/24$	$13/24$	$4/24$	$1/24$

La variabile casuale X appena definita, permette di conoscere la probabilità che, estraendo a caso uno/a dei 24 bambini/e considerati/e, questo/a abbia esattamente x tra fratelli e sorelle.

Esempio 2.2 In questo esempio prenderemo in considerazione addirittura la *Divina Commedia*. Facendo una ricerca in rete è facile trovare e scaricare il testo della *Divina Commedia* in formato txt. Leggere con R questo file è immediato se si impiega la funzione `readLines`: `dc <- readLines("divina_commedia.txt")`. Dopo un po' di lavoro per sistemare i vari segni di interpunzione abbiamo a disposizione il testo del capolavoro di Dante per fare qualsiasi tipo di ricerca.

Il numero totale di versi è 14233, divisi in modo sostanzialmente uniforme fra le tre cantiche (4720, 4755, 4758). Se isoliamo l'ultima parola di ciascun verso (la parola, cioè, che definisce la rima), osserviamo che quella più frequente è “parte”, che compare 35 volte (10 volte nell'*Inferno*, 14 volte nel *Purgatorio* e 11 volte nel *Paradiso*). Se consideriamo i 100 canti che compongono la *Divina Commedia*, otteniamo la distribuzione di frequenza che segue:

x	0	1	2
n	70	25	5

In 70 dei 100 canti la parola “parte” non compare mai alla fine di un verso, in 25 canti compare una volta e in 5 canti compare due volte (tre o più volte non compare mai). Possiamo allora definire una variabile casuale X che assume i valori 0, 1, 2, con probabilità, rispettivamente, 0.7, 0.25, 0.05, come illustrato nella tabella che segue.

x	0	1	2
$f(x)$	0.7	0.25	0.05

La variabile casuale X così definita, permette di conoscere la probabilità che, estraendo a caso uno dei 100 canti che compongono la *Divina Commedia*, in questo canto la parola “parte” compaia esattamente x volte ($x = 0, 1, 2$) alla fine di un verso.

Esempio 2.3 Consideriamo una lotteria nella quale sono stati venduti 1000 biglietti (a 1000 persone diverse), ciascuno al prezzo di 1 euro. La lotteria prevede l'estrazione di

3 premi, rispettivamente di 500, 250 e 125 euro. Possiamo allora definire una variabile casuale X che assume i valori -1 , 124, 249 e 499, con probabilità, rispettivamente, 0.997, 0.001, 0.001, 0.001, come illustrato nella tabella che segue.

x	-1	124	249	499
$f(x)$	0.997	0.001	0.001	0.001

La probabilità di non vincere nulla è 0.997, dal momento che dopo l'estrazione dei 3 premi, ci saranno 997 persone “perdenti”; queste persone hanno tutte comprato 1 biglietto del prezzo di 1 euro e, quindi, hanno perso 1 euro; per loro la variabile casuale X assume valore -1 . Poiché i biglietti vincenti estratti sono 3, la probabilità di vincere uno dei 3 premi in palio è, complessivamente, 0.003; questa probabilità si suddivide uniformemente fra i 3 diversi premi. I premi sono da 500, 250 e 125 euro, ma, avendo ogni soggetto dovuto acquistare il biglietto, la vincita sarà di 499, 249 e 124 euro, rispettivamente.

Cosa hanno in comune gli esempi proposti? In ciascun esempio abbiamo individuato una variabile casuale X indicando i valori che questa poteva assumere e la corrispondente *funzione di probabilità* $f(x)$.² La funzione di probabilità associa ad ogni valore della variabile casuale X la probabilità corrispondente, con il vincolo fondamentale che la somma di tutte le probabilità sia esattamente uguale a 1. In modo più formale, la definizione della funzione di probabilità $f(x)$ per una variabile casuale discreta X è:

$$f(x) = P(X = x),$$

dove, come da consuetudine, abbiamo indicato con la lettera maiuscola (X) la variabile casuale (cioè l'oggetto astratto) e con la lettera minuscola (x) la sua realizzazione concreta.

Per poter essere considerata una *variabile casuale discreta*, X deve soddisfare due requisiti necessari e sufficienti, vale a dire

- $\forall x, f(x) \geq 0$
- $\sum f(x) = 1$.

2.1 Valore atteso e varianza di una variabile casuale discreta

Due concetti fondamentali associati ad una qualsiasi variabile casuale X sono quelli di *valore atteso* e di *varianza*.

²In alcuni testi $f(x)$ nel caso discreto è chiamata *funzione di massa di probabilità* per distinguerla dall'analoga $f(x)$ relativa al caso continuo, che è chiamata *funzione di densità di probabilità*. Noi ometteremo sempre le parole “di massa”, parlando soltanto di funzione di probabilità.

Per calcolare il valore atteso μ di una variabile casuale X basta moltiplicare i singoli valori di x per il corrispondente valore $f(x)$ e farne la somma:

$$E(X) = \mu = \sum_x x f(x) \quad (2.1)$$

(con il simbolo $E(X)$ abbiamo indicato il valore atteso di X).³

Nel primo esempio, la variabile casuale X descriveva il numero di fratelli/sorelle dei 24 bambini dell'Aula Rosa della Scuola di Infanzia "Torrione" di Trento in un determinato Anno Scolastico. I valori assunti da questa variabile casuale erano $x = \{0, 1, 2, 3\}$, rispettivamente con probabilità $f(x) = \{6/24, 13/24, 4/24, 1/24\}$. Il valore atteso è quindi

$$E(X) = 0 \times \frac{6}{24} + 1 \times \frac{13}{24} + 2 \times \frac{4}{24} + 3 \times \frac{1}{24} = 1$$

Riflettiamo sul significato di quanto abbiamo fatto. Abbiamo calcolato il *numero medio* di fratelli/sorelle, tenendo però conto del fatto che alcuni valori (ad esempio, 1) sono più rappresentati di altri (ad esempio, 3). Se non tenessimo conto di questo diremmo che il numero medio di fratelli/sorelle è $(0 + 1 + 2 + 3)/4$, cioè 1.5, ma questo risultato sarebbe sbagliato.

Pertanto, nell'esempio appena proposto, il valore atteso della variabile casuale X non è altro che la *media ponderata* del numero di fratelli/sorelle, impiegando come *pesi* le probabilità corrispondenti.

Analogamente, nel caso della *Divina Commedia*, il valore atteso della variabile casuale X considerata non è altro che il numero medio di volte che la parola "parte" compare, in un canto, alla fine di un verso:

$$E(X) = 0 \times 0.7 + 1 \times 0.25 + 2 \times 0.05 = 0.35$$

Prendiamo ora in esame l'ultimo esempio, quello della lotteria. Calcoliamo con R il valore atteso della variabile casuale X considerata:

```
> x <- c(-1, 124, 249, 499)
> f <- c(0.997, 0.001, 0.001, 0.001)
> sum(x*f)
[1] -0.125
```

Si tratta di un valore negativo. Qual è il suo significato? La variabile casuale che stiamo considerando è il "guadagno". Chi vince il primo premio, da 500 euro, guadagna 499 euro (perché il costo del biglietto, 1 euro, non viene rimborsato), chi vince il secondo premio, da 250 euro, guadagna 249 euro, chi vince il terzo premio, da 125 euro, guadagna 124 euro. Chi non vince nessun premio "guadagna" -1 euro; un guadagno

³In alcuni testi italiani $E(X)$ è indicata con il nome di "speranza matematica" o "valore di aspettazione".

negativo è, in realtà, una perdita e, quindi, potremmo dire che perde 1 euro. Il fatto che il valore atteso sia negativo sta a significare che, in media, in questa lotteria si perde. È quello che succede generalmente, anche perché ci sono dei costi di allestimento che chi gestisce la lotteria deve ammortizzare. Nell'esempio proposto, sottratto il valore complessivo del premio (875 euro) dall'incasso realizzato (1000 euro), agli organizzatori rimangono 125 euro, che forse non è molto.

Se i tre premi fossero stati, rispettivamente, $4000/7$ euro (circa 571 euro), $2000/7$ euro (circa 286 euro) e $1000/7$ euro (circa 143 euro), allora il valore atteso sarebbe stato esattamente zero e la lotteria sarebbe stata "equa"; controlliamolo con R :

```
> x <- c(-1, 1000/7-1, 2000/7-1, 4000/7-1)
> f <- c(0.997, 0.001, 0.001, 0.001)
> sum(x*f)
[1] 1.387779e-16
```

Il valore che ci restituisce R è a tutti gli effetti zero (errori di arrotondamento a parte).

Prendiamo in esame un esempio più concreto, ma in qualche misura analogo a quello precedente. Nella roulette (francese) ci sono 37 settori numerati da 0 a 36. Se la roulette è affidabile, allora la probabilità che esca un qualsiasi numero fra i 37 possibili è $1/37$. Una possibile puntata è sull'uscita del "rosso" o del "nero"; i numeri (a parte lo zero) sono colorati in rosso oppure in nero: 18 numeri sono colorati in rosso e 18 numeri sono colorati in nero. Se puntiamo 1 euro sull'uscita del rosso ed esce proprio il rosso vinciamo 2 euro (quindi guadagniamo 1 euro), se invece esce il nero oppure lo zero, perdiamo 1 euro (quello che avevamo puntato). Individuiamo la distribuzione di probabilità associata a questo gioco. I valori possibili sono $+1$ (quando esce il rosso) e -1 quando non esce il rosso. Le probabilità corrispondenti sono $18/37$ e $19/37$, cioè $f(1) = 18/37$ e $f(-1) = 19/37$. Il valore atteso sarà quindi

```
> x <- c(1, -1)
> f <- c(18/37, 19/37)
> sum(x*f)
[1] -0.02702703
```

che è un valore negativo; quindi, in media, puntando 1 euro sul rosso si perdono circa 27 centesimi (naturalmente lo stesso vale se si punta sul nero).

Se invece puntiamo 1 euro sull'uscita di un numero particolare, ad esempio il 5, allora se esce proprio il 5 vinciamo (guadagniamo) 35 euro, altrimenti non vinciamo nulla (e perdiamo 1 euro). In questo caso la variabile casuale X può assumere i valori 35 (se vinciamo) e -1 (se perdiamo) e le probabilità sono $f(35) = 1/37$ e $f(-1) = 36/37$. Il valore atteso sarà quindi

```
> x <- c(35, -1)
> f <- c(1/37, 36/37)
> sum(x*f)
[1] -0.02702703
```

cioè lo stesso che avevamo ottenuto prima, puntando sul rosso (o sul nero).

Altre puntate possibili sono *Cheval* (una coppia di numeri) con cui si vince 17 volte la somma puntata, *Transversale Pleine* (terzina) con cui si vince 11 volte la somma puntata, *Carré* (quartina) con cui si vince 8 volte la somma puntata, *Transversale Simple* (sestina) con cui si vince 5 volte la somma puntata, *Colonne* (colonna: prima, seconda o terza) con cui si vince 2 volte la somma puntata. Lasciamo al lettore verificare che il valore atteso del guadagno corrispondente a ciascuna di queste giocate coincide con quello trovato in precedenza.

Abbiamo quindi visto che, qualsiasi sia la giocata alla roulette, il valore atteso del guadagno è sempre lo stesso. Eppure il *rischio* associato alle diverse giocate non può essere lo stesso. Giocando sul rosso o sul nero si vince quasi una volta su due, mentre giocando su un numero particolare si vince molto più raramente (in media 1 volta ogni 37, che corrisponde, a parte il segno, al valore atteso costante calcolato prima). Vogliamo quindi definire un indicatore capace di catturare questo diverso *rischio* sotto forma di *variabilità* associata al risultato. Questo indicatore è la *varianza*.

La varianza σ^2 di una variabile casuale discreta X non è altro che la media (il valore atteso) dei *quadrati*⁴ delle differenze $(x - \mu)$ (ovvero degli *scarti* dalla media):

$$\text{Var}(X) = E(X - \mu)^2 = \sigma^2 = \sum_x (x - \mu)^2 f(x). \quad (2.2)$$

Calcoliamo la varianza nel caso in cui puntiamo sul rosso. Il valore atteso è uguale a $-1/37$; le differenze $(x - \mu)$ saranno, nel nostro caso, $1 + 1/37 = 38/37$ quando $x = 1$ (abbiamo messo il segno '+' perché il valore atteso è negativo) e $-1 + 1/37 = -36/37$ quando $x = -1$. Elevando al quadrato questi due valori otteniamo $1444/1369$ e $1296/1369$. Per calcolare la varianza dobbiamo moltiplicare il primo valore per $f(1)$, cioè per $18/37$ e il secondo valore per $f(-1)$, cioè per $19/37$:

$$\frac{38^2}{37^2} \times \frac{18}{37} + \frac{36^2}{37^2} \times \frac{19}{37} = \frac{50616}{50653}$$

cioè quasi 1. Con R si ottiene immediatamente:

```
> x <- c(1, -1)
> f <- c(18/37, 19/37)
> m <- sum(x*f)
> sum((x-m)^2*f)
[1] 0.9992695
```

Lasciando al lettore la ripetizione di tutti i passaggi, calcoliamo la varianza del guadagno nel caso in cui si punti sull'uscita di un numero particolare:

⁴Perché eleviamo al quadrato invece di considerare semplicemente le differenze $(x - \mu)$? Perché la media delle differenze è sempre zero. Questa è la proprietà principale della media aritmetica.

```
> x <- c(35,-1)
> f <- c(1/37,36/37)
> m <- sum(x*f)
> sum((x-m)^2*f)
[1] 34.08035
```

cioè una varianza molto più grande.

C'è però un problema di “dimensionalità” sul quale vogliamo far riflettere il lettore. Nell'esempio della roulette la media del “guadagno” è espressa in euro (circa -0.027 euro). Prendiamo ora la varianza appena calcolata, relativa al “guadagno” quando si punta su un numero particolare; abbiamo visto che è circa 34, ma qual è l'unità di misura associata; sono forse euro? La risposta è no. Infatti, la varianza è la media del *quadrato* delle differenze fra ciascun valore assunto da X e la media. Quindi, euro meno euro “fanno” euro, ma poi, elevando la differenza al quadrato otteniamo *euro al quadrato*. Quindi la varianza della variabile casuale X considerata in precedenza è (circa) 34 *euro al quadrato*. Questa sembra davvero una stranezza, ma in realtà è solo la conseguenza del fatto che per “togliere il segno” alle differenze abbiamo “deciso” di farne il quadrato.⁵ Tuttavia, se volessimo definire degli intervalli centrati sulla media (come faremo più avanti, soprattutto con le variabili casuali continue) non potremmo certo considerare intervalli del tipo $\mu \pm \sigma^2$, perché commetteremmo un errore “dimensionale” (non possiamo sommare euro e euro al quadrato, così come non ha senso sommare, ad esempio, metri e metri quadrati). Per definire intervalli “sensati”, basta considerare la radice quadrata della varianza, ottenendo così una quantità che ha la stessa unità di misura della media. La radice quadrata della varianza prende il nome di *deviazione standard* (dall'inglese *standard deviation*)⁶ e un intervallo “tipico” potrebbe essere indicato come $\mu \pm \sigma$, indicando con questo l'intervallo di valori di X compresi fra $\mu - \sigma$ e $\mu + \sigma$.

La disuguaglianza di Bienaymé-Čebyšëv

Uno dei motivi per cui la varianza è un parametro importante per una variabile casuale X è legato al fatto che conoscendo soltanto la media μ e la deviazione standard σ di X (senza conoscere nulla della sua distribuzione) è possibile stabilire un limite inferiore alla probabilità che X possa assumere valori esterni a un intervallo simmetrico rispetto a μ espresso in termini di σ , cioè un intervallo del tipo $(\mu - k\sigma, \mu + k\sigma)$, essendo $k > 0$. Più precisamente la disuguaglianza afferma che

$$\Pr(\mu - k\sigma \leq X \leq \mu + k\sigma) \geq 1 - \frac{1}{k^2}.$$

⁵Esistono indici di variabilità che considerano ad esempio, il valore assoluto della differenza $(X - \mu)$, ma noi non li considereremo.

⁶In italiano il termine generalmente adottato è *scarto quadratico medio*, ma noi impiegheremo sempre la traduzione letterale del termine inglese.

Diciamo subito che se poniamo $k = 1$, la disuguaglianza è poco informativa. Infatti, se $k = 1$ la disuguaglianza ci informa che la probabilità che X assuma valori nell'intervallo $(X \pm \sigma)$ è maggiore di (o uguale a) zero. La disuguaglianza diventa più informativa se k assume valori maggiori di 1. Ad esempio, possiamo essere certi che nell'intervallo $(\mu \pm 2\sigma)$ cadranno almeno il 75% dei valori. Facciamo calcolare ad R le probabilità corrispondenti ad alcuni valori di k :

```
> k <- c(seq(1.5,5,0.5),6)
> p <- 1 - 1/k^2
> rbind(k,round(p,3))
k 1.500 2.00 2.50 3.000 3.500 4.000 4.500 5.00 6.000
p 0.556 0.75 0.84 0.889 0.918 0.938 0.951 0.96 0.972
```

È un risultato notevole, perché prescinde dalla distribuzione di probabilità seguita dalla variabile casuale. Si può fare di meglio soltanto conoscendo la distribuzione di probabilità, come vedremo, in particolare, parlando della variabile casuale normale.

Proprietà del valore atteso e della varianza

Valore atteso e varianza di una variabile casuale (discreta o continua) presentano delle proprietà che è utile conoscere perché permettono di semplificare i calcoli in alcuni dei casi che vedremo successivamente. In quanto segue X indica una variabile casuale e k è un valore costante (analogamente a k_1 e k_2).

- $E(k) = k$: il valore atteso di una costante è uguale alla costante.
- $Var(k) = 0$: la varianza di una costante è zero.
- $E(X + k) = E(X) + k$: il valore atteso di una variabile casuale più una costante è uguale al valore atteso della variabile casuale più la costante.
- $Var(X + k) = Var(X)$: la varianza di una variabile casuale più una costante è uguale alla varianza della variabile casuale.
- $E(kX) = kE(X)$: il valore atteso del prodotto fra una variabile casuale e una costante è uguale al prodotto del valore atteso della variabile casuale per la costante.
- $Var(kX) = k^2Var(X)$: la varianza del prodotto fra una variabile casuale e una costante è uguale al prodotto della varianza della variabile casuale per il quadrato della costante.
- $E(k_1X + k_2) = k_1E(X) + k_2$
- $Var(k_1X + k_2) = k_1^2Var(X)$

Sfruttando le proprietà del valore atteso è facile far vedere che $E(X - \mu) = 0$. Infatti, essendo μ una costante, avremo $E(X - \mu) = E(X) - \mu$, ma, essendo $\mu = E(X)$, la differenza è zero. Poiché il valore atteso di una variabile casuale discreta è una somma (pesata), il risultato precedente implica che anche la somma (pesata) degli scarti dalla media è nulla.

Prima di passare a considerare i principali *modelli probabilistici* discreti e le variabili casuali ad essi associate è opportuno ricordare che la varianza non è altro che un valore atteso (il valore atteso degli scarti dalla media elevati al quadrato). Possiamo allora definire, analogamente, il valore atteso del *quadrato* di una variabile casuale modificando opportunamente la formula (2.1):

$$E(X^2) = \sum_x x^2 f(x);$$

in altre parole, basta elevare al quadrato i valori assunti dalla variabile casuale prima di moltiplicarli per il corrispondente valore dato da $f(x)$. Ad esempio, il valore atteso del quadrato del numero di fratelli/sorelle dei 24 bambini dell'Aula Rosa della Scuola di Infanzia "Torrione" di Trento in un determinato Anno Scolastico è

$$E(X^2) = 0^2 \times \frac{6}{24} + 1^2 \times \frac{13}{24} + 2^2 \times \frac{4}{24} + 3^2 \times \frac{1}{24} = \frac{38}{24}.$$

Analogamente, il valore atteso del quadrato del "guadagno" relativo alla puntata sul rosso (o sul nero) è

$$E(X^2) = 1^2 \times \frac{18}{37} + (-1)^2 \times \frac{19}{37} = 1.$$

Il valore atteso del quadrato di una variabile casuale è particolarmente importante perché permette spesso di calcolare in modo più agevole la varianza di una variabile casuale ricorrendo alla seguente formula alternativa (che vale sia nel caso discreto sia nel caso continuo):

$$\text{Var}(X) = E(X^2) - [E(X)]^2 \quad (2.3)$$

Invitiamo il lettore a verificarlo negli esempi precedenti.

2.2 La variabile casuale uniforme discreta

Quando una variabile casuale può assumere n valori distinti, ciascuno con probabilità $1/n$ abbiamo il modello *uniforme discreto*. A questo modello si conformano (almeno in linea di principio) il risultato del lancio di un dado le cui facce sono numerate da 1 a 6 (così che la probabilità di uscita di ciascuna faccia è $1/6$) oppure il settore in cui si ferma la pallina di una roulette (in questo caso se la roulette ha 37 settori, numerati da 0 a 36, la probabilità che la pallina si fermi in uno qualsiasi dei settori è $1/37$).

Prendendo in esame il primo caso (l'esito del lancio di un dado), la variabile casuale X può assumere i valori $1, 2, 3, 4, 5, 6$ e la funzione di probabilità di X vale $f(x) = 1/6$ quando $X = \{1, 2, 3, 4, 5, 6\}$ e vale $f(x) = 0$ per qualsiasi altro valore di X . Il valore atteso μ di questa variabile casuale è

$$1 \times 1/6 + 2 \times 1/6 + 3 \times 1/6 + 4 \times 1/6 + 5 \times 1/6 + 6 \times 1/6 = 3.5$$

e la varianza (calcolata con R) è

```
> x <- c(1:6)
> f <- rep(1/6,6)
> (mu <- sum(x*f))
[1] 3.5
> (sigma2 <- sum((x-mu)^2*f))
[1] 2.916667
```

(questo è un risultato approssimato; il valore esatto è $35/12$).

Prendiamo ora in esame un altro esempio di variabile casuale uniforme discreta, che impiegheremo più avanti (quando parleremo di distribuzioni campionarie); prendiamo un'urna e inseriamo nell'urna 10 palline numerate con i numeri interi da 0 a 9. La probabilità di ottenere come risultato di una singola estrazione un particolare valore $(0, 1, 2, 3, 4, 5, 6, 7, 8, 9)$ varrà $1/10$. Quindi $X = \{0, 1, 2, 3, 4, 5, 6, 7, 8, 9\}$ e $f(x) = 1/10$.⁷ La media e la varianza di X valgono in questo caso, rispettivamente, 4.5 e 8.25:

```
> x <- c(0:9)
> f <- rep(1/10,10)
> (mu <- sum(x*f))
[1] 4.5
> (sigma2 <- sum((x-mu)^2*f))
[1] 8.25
```

Quelli che abbiamo appena visto sono degli esempi particolari. Più in generale, se X è una *variabile casuale uniforme discreta* che può assumere i valori $X = \{1, 2, \dots, n\}$, allora $f(x) = 1/n$ e la media μ e la varianza σ^2 sono:

$$E(X) = \sum_{x=1}^n \frac{x}{n} = \frac{n+1}{2} \quad (2.4)$$

$$Var(X) = \sum_{x=1}^n \frac{(x-\mu)^2}{n} = \frac{n^2-1}{12}. \quad (2.5)$$

Introduciamo ora la *funzione di ripartizione*. Questa funzione fa corrispondere alle realizzazioni di X le corrispondenti *probabilità cumulate*. In altre parole la funzione di ripartizione della variabile casuale discreta X , che indichiamo con $F(x)$, è definita come segue:

$$F(x) = P(X \leq x) = \sum_{u \leq x} f(u). \quad (2.6)$$

⁷Per completezza dovremmo aggiungere $f(x) = 0$ per valori di x al di fuori di quelli indicati specificamente. Non sempre aggiungeremo questa specificazione, che diamo d'ora in avanti per sottintesa.

Consideriamo ancora l'esito del lancio di un dado. Cosa rappresenta $F(3)$? È la probabilità che, lanciando un dado, si ottenga come risultato un numero *minore o uguale* a 3 (cioè che si ottenga o 1 o 2 o 3). La risposta a questa domanda si ottiene sommando (*cumulando*) le probabilità corrispondenti: $F(3) = f(1) + f(2) + f(3)$, cioè $F(3) = 1/6 + 1/6 + 1/6 = 3/6$. La funzione *cumsum* di R fa esattamente questo. Calcoliamo la funzione di ripartizione della variabile casuale X (esito del lancio di un dado):

```
> x <- c(1:6)
> f <- rep(1/6,6)
> F <- cumsum(f)
> data.frame(x,f,F)
  x      f      F
1 1 0.1666667 0.1666667
2 2 0.1666667 0.3333333
3 3 0.1666667 0.5000000
4 4 0.1666667 0.6666667
5 5 0.1666667 0.8333333
6 6 0.1666667 1.0000000
```

mentre nel caso dell'esempio dell'estrazione di una pallina dall'urna abbiamo

```
> x <- c(0:9)
> f <- rep(1/10,10)
> F <- cumsum(f)
> data.frame(x,f,F)
  x  f  F
1 0 0.1 0.1
2 1 0.1 0.2
3 2 0.1 0.3
4 3 0.1 0.4
5 4 0.1 0.5
6 5 0.1 0.6
7 6 0.1 0.7
8 7 0.1 0.8
9 8 0.1 0.9
10 9 0.1 1.0
```

Forse è più efficace osservare la rappresentazione grafica delle funzioni di probabilità e di ripartizione delle due variabili casuali considerate (Figura 2.1).

Il grafico della funzione di probabilità f è rappresentato da una serie di segmenti verticali, tutti della stessa lunghezza; la lunghezza corrisponde alla probabilità (che è, appunto, costante). Il grafico della funzione di ripartizione è *a gradini*. L'altezza di ogni gradino è costante e pari a $1/6$ nel caso del lancio di un dado e a $1/10$ nel caso dell'esempio dell'estrazione di una pallina.




Figura 2.1: Grafico della funzione di probabilità (f) e della funzione di ripartizione (F) per due variabili casuali uniformi discrete.

Più formalmente si dice che la funzione di ripartizione della v.c. X è *non decrescente*. Questa proprietà è vera qualsiasi sia la variabile casuale X (e non soltanto nel caso di una variabile casuale uniforme).

Dalla Figura 2.1 si può anche notare un'altra cosa. Consideriamo il lancio di un dado. I segmenti verticali relativi alla funzione di probabilità sono disegnati in corrispondenza dei valori di x uguali a 1, 2, 3, 4, 5, 6. Per tutti gli altri valori (ad esempio 2.3 oppure 0), l'altezza (la probabilità) è pari a zero. Quindi, $f(2.3) = 0$. Nel caso della funzione di ripartizione ci sono dei "salti" (i gradini) in corrispondenza dei valori 1, 2, 3, 4, 5, 6, mentre tra un salto e l'altro la funzione rimane costante. Questo vuol dire quindi che se $F(2) = 2/6$ e $F(3) = 3/6$, $F(2.3)$ non è uguale a zero. Infatti, $F(2.3)$ è la probabilità che lanciando un dado regolare si abbia come risultato un va-

lore minore o uguale a 2.3 (cioè 0 o 1 o 2); quindi $F(2.3) = 2/6$. Anche $F(2.9) = 2/6$ o $F(2.99) = 2/6$. La probabilità cambia solo quando si arriva a 3. Questo vuol anche dire che per tutti i valori di x maggiori di 6, la probabilità cumulativa rimane costante e pari a 1, mentre per tutti i valori di x minori di 1, la probabilità cumulativa rimane costante e pari a 0. Pertanto, la funzione di ripartizione $F(x)$ di una qualsiasi variabile casuale X (discreta o continua) è definita *per tutti i valori reali* di x . Qualsiasi sia la variabile casuale X (discreta o continua) si ha che $F(-\infty) = 0$ e $F(+\infty) = 1$. Inoltre, come abbiamo già detto, se $a < b$, $F(a) \leq F(b)$, ovvero la funzione di ripartizione è *monotona non decrescente*.

Conoscendo la funzione di ripartizione di una variabile casuale X , è possibile calcolare la probabilità che X cada in un intervallo $(x_1, x_2]$:

$$P(x_1 < X \leq x_2) = F(x_2) - F(x_1).$$

2.3 La variabile casuale triangolare discreta

Supponiamo di lanciare due dadi regolari e di considerare come esito del lancio la *somma* dei due punteggi osservati su ciascun dado. Formalmente abbiamo due variabili casuali X_1 e X_2 uniformi discrete e *indipendenti*, ma quello che ci interessa è definire una nuova variabile casuale X data dalla somma di X_1 e X_2 : $X = X_1 + X_2$. Calcolare la media e la varianza di X è davvero un “gioco da ragazzi”, perché un teorema ci dice che il valore atteso di X è la somma dei valori attesi di X_1 e X_2 e che la varianza di X è la somma delle varianze di X_1 e X_2 (dal momento che X_1 e X_2 sono indipendenti).

Più in generale se $X_1, X_2, \dots, X_n$ sono n variabili casuali *indipendenti e identicamente distribuite* ciascuna con media μ e varianza σ^2 , allora la variabile casuale $X = X_1 + X_2 + \dots + X_n$ ha valore atteso $n\mu$ e varianza $n\sigma^2$.

Ma come sarà la funzione di probabilità della somma del lancio di due dadi? La risposta non è difficile; basta considerare quali sono gli esiti possibili. Possiamo farlo molto rapidamente con R, sfruttando la funzione `outer`:

```
> x <- c(1:6)
> (tbl <- outer(x,x,"+"))
      [,1] [,2] [,3] [,4] [,5] [,6]
[1,]    2    3    4    5    6    7
[2,]    3    4    5    6    7    8
[3,]    4    5    6    7    8    9
[4,]    5    6    7    8    9   10
[5,]    6    7    8    9   10   11
[6,]    7    8    9   10   11   12
```

I risultati possibili vanno da 2 a 12, ma non hanno tutti la stessa probabilità di realizzarsi. Infatti 2 (così come 12) può uscire in un solo modo su 36, mentre 4, ad esempio, ha più di una possibilità di realizzarsi (3, per la precisione). Facciamo una distribuzione di frequenza dei risultati possibili:


```
> table(tbl)
tbl
  2  3  4  5  6  7  8  9 10 11 12
1  2  3  4  5  6  5  4  3  2  1
```

Il risultato al quale è associato il maggior numero di modalità è il 7, con 6 possibilità. La distribuzione di probabilità f si ottiene rapportando i valori precedenti al loro totale (cioè 36), ovvero, con R, impiegando la funzione `prop.table`:

```
> f <- prop.table(table(tbl))
> x <- c(2:12)
> data.frame(x,f=as.numeric(f),F=cumsum(f))
```

	x	f	F
2	2	0.02777778	0.02777778
3	3	0.05555556	0.08333333
4	4	0.08333333	0.16666667
5	5	0.11111111	0.27777778
6	6	0.13888889	0.41666667
7	7	0.16666667	0.58333333
8	8	0.13888889	0.72222222
9	9	0.11111111	0.83333333
10	10	0.08333333	0.91666667
11	11	0.05555556	0.97222222
12	12	0.02777778	1.00000000

Come sempre è più efficace la rappresentazione grafica del risultato (Figura 2.2). Guardando il grafico della funzione di probabilità f risulta immediato il perché del nome




Figura 2.2: Distribuzione di probabilità (f) e distribuzione di ripartizione (F) della variabile casuale “somma del lancio di due dadi”.

“triangolare” assegnato a questa variabile casuale. Il grafico della funzione di ripartizione F è sempre a gradini, ma questa volta l’altezza dei gradini non è costante. Quando $x < 2$, $F(x) = 0$; quando $x \geq 12$, $F(x) = 1$.

La distribuzione triangolare è *simmetrica*; infatti a valori di x equidistanti dal valore centrale (che in questo caso è anche la media) corrispondono le stesse probabilità (ad esempio, $f(2) = f(12)$, $f(3) = f(11)$ e così via). Anche la distribuzione uniforme discreta è simmetrica (in un certo senso è la distribuzione che gode della “maggior” simmetria).

Possiamo infine verificare che la media della distribuzione riportata in Figura 2.2 è proprio 7 (vale a dire $3.5 + 3.5$) e che la varianza è proprio $35/6$ (vale a dire $35/12 + 35/12$):

```
> (mu <- sum(x*f))
[1] 7
> (sigma2 <- sum((x-mu)^2*f))
[1] 5.833333
```

(naturalmente R ci dà un risultato approssimato).

E se invece di lanciare 2 dadi ne lanciassimo 3, 4 o ancora di più? Il numero di possibilità da considerare crescerebbe esponenzialmente. Se infatti con 2 dadi abbiamo 6^2 risultati possibili, con 3 ne abbiamo 6^3 , con 4 diventano 6^4 e così via. Se lanciassimo 12 dadi avremmo un totale di $6^{12} = 2176782336$ possibilità (oltre 2 miliardi), anche se i valori distinti che potrebbe assumere il totale (cioè la variabile casuale X che stiamo considerando) sarebbero soltanto i numeri interi compresi fra 12 e 72 (inclusi). I due estremi non si verificherebbero praticamente mai, dal momento che la probabilità associata a ciascuno di questi due risultati è $1/2176782336$, vale a dire meno di un miliardesimo. Tuttavia è molto semplice calcolare la media $\mu = (3.5 \times 12 = 42)$ e la varianza $\sigma^2 = (35/12 \times 12 = 35)$. E la forma della distribuzione f come sarebbe? Possiamo dare una risposta approssimata mediante una simulazione:

```
> dado <- c(1:6)
> nrep <- 100000
> ndad <- 12
> set.seed(123456)
> y <- sample(dado, ndad*nrep, replace=TRUE)
> Y <- matrix(y, ncol=ndad)
> x <- rowSums(Y)
> f <- prop.table(table(x))
> x <- dimnames(f); x <- as.numeric(unlist(x))
```

Abbiamo lanciato un dado (dado) per 12 (ndad) volte (ovvero 12 dadi per una volta) e abbiamo ripetuto questo “esperimento” 100000 (nrep) volte. I risultati sono stati organizzati nella matrice Y che ha 12 colonne (il risultato osservato su ciascun dado) e 100000 righe. La funzione `rowSums` calcola la somma osservata in ciascuno dei 100000 lanci di 12 dadi e i singoli risultati sono gli elementi del vettore x . Non

abbiamo riportato l'*output* in quanto troppo “oneroso” (sono 100000 valori), ma il lettore può visualizzarlo (con cautela) perché è contenuto nel vettore *f*. Vediamo invece la rappresentazione grafica della *stima* della funzione *f* e della sua cumulata *F* (Figura 2.3).




Figura 2.3: Distribuzione di probabilità (*f*) e distribuzione di ripartizione (*F*) della variabile casuale “somma del lancio di 12 dadi” risultante dalla simulazione.

La funzione di probabilità *f* appare sostanzialmente simmetrica e di forma piuttosto “regolare” (vedremo più avanti il significato di questo aggettivo); anche i “salti” osservati nella funzione di ripartizione *F* si sono fatti meno accentuati. Verifichiamo, per finire, la media e la varianza associata alla nostra simulazione, che coincidono quasi esattamente con i valori che ci aspettavamo.

```
> (mu <- sum(x*f))
[1] 41.97972
> (sigma2 <- sum((x-mu)^2*f))
[1] 34.94549
```

Lasciamo al lettore verificare come si modifica il grafico di $f(x)$ e di $F(x)$ aumentando nello *script* precedente il numero di dadi lanciati (modificando il valore assegnato a *ndad*).

Cosa succederebbe se nell’esempio precedente (lancio di 12 dadi) dividessimo la somma ottenuta per 12 (calcolando così non il punteggio totale, ma il *punteggio medio*)? La Figura 2.3 non cambierebbe a parte il fatto che l’asse delle ascisse riporterebbe i valori da 1 a 6 invece che da 12 a 72. Se indichiamo con S_{12} la variabile casuale che rappresenta la somma dei punteggi osservati sui 12 dadi, allora, ricordando le proprietà del valore atteso e della varianza, avremmo:

$$E\left[\frac{S_{12}}{12}\right] = \frac{1}{12}E(S_{12}) = \frac{42}{12} = 3.5$$

$$Var\left[\frac{S_{12}}{12}\right] = \frac{1}{12^2}Var(S_{12}) = \frac{35}{144}.$$

Quindi, il valore atteso di $S_{12}/12$ coincide con il valore atteso del lancio di un dado, ma la varianza è molto più piccola. Lanciando un dado, la varianza del punteggio è $35/12$, cioè circa 2.92, mentre lanciando 12 dadi, la varianza del punteggio medio è circa 0.24 (12 volte più piccola). Il punteggio medio (basato sulla somma di 12 lanci) è quindi molto meno variabile del punteggio relativo ad un singolo lancio.

Prendiamo in esame l'intervallo $(\mu \pm 2\sigma)$ nelle due situazioni. Quando consideriamo un singolo lancio, l'intervallo è (circa) $(0.1, 6.9)$, mentre quando consideriamo la media di 12 lanci, l'intervallo è (circa) $(2.51, 4.49)$. Il primo intervallo è estremamente ampio e di fatto copre tutti i risultati possibili (che vanno da 1 a 6). L'ampiezza del secondo intervallo è invece molto più contenuta (meno di due unità); nella simulazione relativa al lancio di 12 dadi, in questo intervallo sono caduti quasi il 95% dei valori.

In generale, lanciando n dadi, il valore atteso di S_n/n sarà 3.5 e la varianza $35/12n$. La deviazione standard sarà quindi la radice quadrata del valore precedente, cioè $\sqrt{35/12n}$. Vediamo quindi (ri)comparire l'inverso della radice quadrata del numero delle "osservazioni". Questo è un risultato del tutto generale (che riprenderemo parlando di distribuzioni campionarie): al crescere del numero delle osservazioni (dei lanci, nel nostro esempio), la deviazione standard della media aritmetica delle osservazioni stesse si riduce in misura inversamente proporzionale non al numero delle osservazioni, ma alla loro radice quadrata.

2.4 La variabile casuale di Bernoulli

Consideriamo un variabile casuale X che può assumere solo due valori, 0 e 1, rispettivamente denominati "insuccesso" e "successo" (senza attribuire alcun significato letterale ai due termini, che possono essere scambiati). Indichiamo la probabilità di successo con p ; quindi, la probabilità di insuccesso sarà, necessariamente $1 - p$. Abbiamo pertanto $f(0) = 1 - p$ e $f(1) = p$. Un esempio "classico" riguarda l'estrazione di una pallina da un'urna che contiene palline bianche e palline nere in proporzione, rispettivamente, p e $1 - p$ indicando con "successo" l'estrazione di una pallina bianca. La variabile casuale così definita prende il nome di *variabile casuale di Bernoulli*; il suo valore atteso è

$$E(X) = 0 \times (1 - p) + 1 \times p = p$$

e la sua varianza è

$$Var(X) = (0 - p)^2 \times (1 - p) + (1 - p)^2 \times p = p(1 - p).$$

Facciamo notare che $p(1 - p)$ si può scrivere anche $p - p^2$. Quindi il grafico della varianza in funzione di p è quello di una parabola che volge la concavità verso il basso (il coefficiente del termine al quadrato è negativo) il cui massimo si ha quando $p = 0.5$. Pertanto, la varianza di una variabile casuale di Bernoulli è massima quando $p = 0.5$; in questo caso $\sigma^2 = 0.25$.

Vedremo nel prosieguo alcune variabili casuali “imparentate” con questo semplice *modello bernoulliano*

2.5 La variabile casuale geometrica

Consideriamo un’urna che contiene palline bianche e palline nere in proporzione, rispettivamente, p e $1 - p$ e indichiamo con “successo” l’estrazione di una pallina bianca. Il nostro “esperimento” consiste nell’estrarre palline dall’urna, rimettendo ogni volta nell’urna quella estratta (estrazioni di questo tipo si dicono *bernoulliane ovvero con rimessa*)⁸ finché non si estrae (per la prima volta) una pallina bianca.

Possiamo allora definire una variabile casuale X che descrive quante estrazioni (bernoulliane) dobbiamo fare *prima* di estrarre una pallina bianca. Una variabile casuale così definita è una variabile casuale discreta che ha come valore minimo 0 (se si estrae subito una pallina bianca) e come massimo “infinito” (ovvero non c’è un numero naturale che possiamo considerare a priori come il massimo raggiungibile). Qual è la distribuzione di probabilità f di questa variabile casuale? Facciamo qualche esempio.

La probabilità di estrarre subito una pallina bianca è $f(0) = p$. La probabilità di estrarre una pallina bianca alla seconda estrazione (avendo, quindi estratto una pallina nera alla prima) si calcola considerando che l’evento che ci interessa corrisponde alla sequenza (*NB*); dato che gli eventi (le estrazioni) sono fra loro indipendenti, applicando il principio del prodotto, abbiamo $f(1) = (1 - p) \times p$. La probabilità di estrarre una pallina bianca alla terza estrazione (avendo, quindi estratto una pallina nera alla prima e alla seconda) si calcola considerando che l’evento che ci interessa corrisponde alla sequenza (*NNB*); per il principio del prodotto abbiamo, quindi, $f(2) = (1 - p)^2 \times p$.

Continuando a ragionare in questo modo, la probabilità che siano necessarie x estrazioni bernoulliane prima di osservare la prima pallina bianca sarà

$$f(x) = (1 - p)^x \times p.$$

La variabile casuale così definita prende il nome di *variabile casuale geometrica*. È facile capire il perché di questo nome se osserviamo che il rapporto fra $f(x + 1)$ e $f(x)$ è costante; abbiamo quindi a che fare, dal punto di vista matematico, con una *successione geometrica* di ragione $1 - p$. Ad esempio, se $p = 0.6$ i primi 6 valori di $f(x)$ sono:

```
> x <- c(0:5)
> p <- 0.6
> f <- (1-p)^x * p
```

⁸In questo modo la proporzione di palline bianche è sempre p e le estrazioni sono fra loro indipendenti.

```
> f
```

```
[1] 0.600000 0.240000 0.096000 0.038400 0.015360 0.006144
```

e il rapporto fra ogni termine (a partire dal secondo) e il precedente è

```
> exp(diff(log(f)))
```

```
[1] 0.4 0.4 0.4 0.4 0.4
```

cioè $1 - p$ (per calcolare il rapporto $f(x+1)/f(x)$ abbiamo sfruttato la funzione `diff` e il fatto che il logaritmo di un rapporto è la differenza fra i logaritmi).

Ricordando quanto vale la somma dei primi $x + 1$ termini di una *successione geometrica* (nel nostro caso la somma parte da zero), possiamo calcolare in forma esplicita la funzione di ripartizione:

$$F(x) = 1 - (1 - p)^{x+1}.$$

Osservando questa formula, è facile vedere che quando x tende ad infinito, $F(x)$ tende a 1, come deve fare qualsiasi funzione di ripartizione per essere considerata tale.

Come sarà il grafico della funzione di probabilità di una variabile casuale geometrica? Non è difficile immaginarlo se prendiamo in esame la formula corrispondente: $f(x) = (1 - p)^x \times p$. Ricordando che il parametro p deve essere compreso fra 0 e 1, estremi esclusi se vogliamo avere una variabile casuale “sensata”, allora il massimo della distribuzione dei valori $f(x)$ sarà proprio p e questo massimo sarà assunto quando $x = 0$. Dopodiché, i valori decresceranno, più o meno rapidamente, a seconda di quanto vale p . Se p è molto vicino ad 1, il salto fra $f(0)$ e $f(1)$ sarà “grande” (ad esempio, se $p = 0.99$, allora $f(0) = 0.99$ e $f(1) = 0.0099$), mentre se p è molto vicino ad 0, il salto sarà “piccolo” (ad esempio, se $p = 0.01$, allora $f(0) = 0.01$ e $f(1) = 0.0099$, cioè un valore molto vicino a $f(0)$).

La Figura 2.4 mostra il grafico della funzione di probabilità di due variabili casuali geometriche con differenti valori del parametro p .

L'esempio dell'urna e delle palline bianche e nere può sembrare pretestuoso (e, forse, anche un po' “noioso”), ma la variabile casuale geometrica può essere pensata come un modello che descrive un *tempo di attesa* discreto.⁹ Potremmo, ad esempio, chiederci quanto tempo (misurato in unità discrete) dovremmo aspettare per osservare il primo pezzo difettoso di una macchina. Il *modello dell'urna* ha il vantaggio di definire in modo chiaro gli assunti alla base del modello geometrico: un esito *binario* (successo/insuccesso) e l'indipendenza fra gli eventi considerati (la probabilità di successo rimane sempre p , indipendentemente dal numero delle estrazioni eseguite)¹⁰.

Quanto valgono il valore atteso μ e la varianza σ^2 di questa variabile casuale? Iniziamo con il valore atteso.

$$E(X) = \sum_{x=0}^{\infty} x \times p \times (1 - p)^x.$$

⁹Vedremo nel prossimo capitolo come si può modellare un *tempo di attesa* continuo.

¹⁰Con buona pace di chi si ostina a scommettere al lotto sui numeri “ritardatari”.




Figura 2.4: Distribuzione di probabilità di due variabili casuali geometriche con diverso valore del parametro p . Le scale dei due grafici sono diverse (nel pannello di sinistra il valore massimo sull'ordinata è 0.8, mentre nel pannello di destra il valore massimo sull'ordinata è 0.2). In entrambi i grafici le probabilità decrescono al crescere del numero delle estrazioni. Quando $p = 0.8$ la discesa iniziale è molto “ripida” per poi livellarsi, mentre quando $p = 0.2$, la discesa è molto più “lenta”.

Si tratta di fare una “somma infinita”; naturalmente non è possibile fare materialmente una somma di infiniti addendi, ma ricorrendo ai concetti di *somme parziali* e di *limite* è possibile calcolare la somma precedente, ottenendo un risultato finito:¹¹

$$E(X) = \sum_{x=0}^{\infty} x \times p \times (1-p)^x = \frac{1-p}{p}. \quad (2.7)$$

Analogamente, indicando con μ il valore atteso appena trovato, la varianza è

$$\text{Var}(X) = \sum_{x=0}^{\infty} (x - \mu)^2 \times p \times (1-p)^x = \frac{1-p}{p^2}. \quad (2.8)$$

La variabile casuale geometrica prende in considerazione il primo successo. Quale sarebbe la funzione di probabilità di una variabile casuale che descrive il numero di prove bernoulliane da eseguire prima di osservare il secondo (o il terzo, il quarto, ...) successo? Risponderemo a questa domanda alla fine di questo capitolo. Prima, però, dobbiamo introdurre il *modello binomiale*.

¹¹Nell'appendice *online* daremo una dimostrazione di questo risultato e dei successivi.

2.6 La variabile casuale binomiale

L'esempio dei "tiri di rigore" con il quale avevamo aperto il capitolo è solo uno dei tanti possibili esempi di una *prova bernoulliana*, una prova cioè che può esitare con solo due risultati possibili (il rigore viene segnato oppure no), risultati che vengono convenzionalmente chiamati "successo" e "insuccesso". Indichiamo con p la probabilità di successo. Vediamo qualche altro esempio di *prova bernoulliana*:

- La nascita di un bambino (che può essere o maschio o femmina);
- la somministrazione di un vaccino (che può far acquisire o meno l'immunità desiderata);
- la semina di un seme (che può germogliare o meno);
- la domanda di immatricolazione ad un corso di laurea (che può essere o non essere accolta);
- l'esito di un esame universitario (superato o non superato);
- il lancio di una moneta (il cui esito può essere o testa o croce);
- il lancio di un dado (il cui risultato può essere un numero pari o un numero dispari);
- l'estrazione di una pallina da un'urna che contiene soltanto palline bianche e palline nere.

In ciascuno di questi casi possiamo definire una variabile casuale X di Bernoulli. Questa variabile casuale svolge un ruolo fondamentale nel campo della ricerca empirica, perché i risultati di diverse indagini possono essere pensati come *somma* di un certo numero n di prove bernoulliane (indipendenti e ciascuna con la stessa probabilità p di successo). Vediamo un esempio schematico, ma che dovrebbe aiutare a specificare le condizioni alle quali facevamo riferimento.

Consideriamo un'urna contenente 10 palline delle quali 6 sono bianche e 4 sono nere. Chiamiamo "successo" l'estrazione di una pallina bianca e "insuccesso" l'estrazione di una pallina nera. Sia $p = 0.6$ la probabilità di successo. Se estraia una sola pallina dall'urna abbiamo una prova bernoulliana. Decidiamo invece di estrarre $n = 3$ palline dall'urna ma *con reimmissione* (vale a dire inserendo ogni volta nell'urna la pallina appena estratta); in questo modo la probabilità di successo rimane sempre costante e le prove possono essere considerate indipendenti. Se indichiamo con X_1, X_2, X_3 le tre variabili casuali di Bernoulli, la variabile casuale X che ci interessa è data da $X = X_1 + X_2 + X_3$ (il numero di palline bianche osservate facendo 3 estrazioni) e, quindi, possiamo calcolare immediatamente la sua media e la sua varianza che saranno date da $\mu = 3 \times 0.6 = 1.8$ e da $\sigma^2 = 3 \times 0.6 \times 0.4 = 0.72$.

Più in generale se le prove bernoulliane sono n e la probabilità di successo è p in ogni prova, la variabile casuale *numero di successi in n prove bernoulliane indipendenti* è detta *variabile casuale binomiale*; la sua media è $\mu = np$ e la sua varianza è $\sigma^2 = np(1 - p)$.

Rimane da definire la sua funzione di probabilità. Per fare questo continuiamo a prendere in esame il nostro esempio.

Con tre estrazioni, il numero di palline bianche può essere 0, 1, 2 o 3. Pertanto questi sono gli unici valori per cui $f(x) > 0$. È facile calcolare le probabilità associate ai due casi estremi. Infatti, per il principio del prodotto nel caso di eventi indipendenti, la probabilità dell'evento (*BBB*) (3 palline bianche) è data dal prodotto delle probabilità associate a ciascuno di essi: $p \times p \times p = p^3$. Analogamente, nell'altro caso estremo, avremo che la probabilità dell'evento (*NNN*) (3 palline nere) è data da: $(1-p) \times (1-p) \times (1-p) = (1-p)^3$. Abbiamo quindi che $f(0) = (1-p)^3$ e $f(3) = p^3$.

Ragionando in modo analogo possiamo calcolare la probabilità associata all'evento (*BNN*); essa sarà data da $p \times (1-p) \times (1-p)$. Questa è però soltanto una parte della risposta. Infatti quella che abbiamo appena calcolato è la probabilità associata alla *sequenza* (*BNN*). Se vogliamo trovare la probabilità di ottenere 1 pallina bianca, allora dobbiamo considerare anche le sequenze (*NBN*) e (*NNB*). Vale a dire che ci sono tre modi possibili in cui si può ottenere 1 pallina bianca e 2 nere. A ciascuna sequenza è associata sempre la stessa probabilità $p \times (1-p) \times (1-p)$ (la moltiplicazione è commutativa) e quindi possiamo scrivere $f(1) = 3p \times (1-p)^2$.

Il caso “simmetrico” è dato dall'estrazione di 2 palline bianche. Le sequenze “utili” sono date da (*BBN*), (*BNB*) e da (*NBB*) (sono cioè anch'esse 3 come nel caso precedente). A ciascuna di esse è associata (per il principio del prodotto) una probabilità pari a $p \times p \times (1-p)$, motivo per cui avremo che $f(2) = 3p^2 \times (1-p)$.

Abbiamo quindi ottenuto la distribuzione di probabilità che cercavamo e, sostituendo a p il valore 0.6, abbiamo $f(0) = 0.4^3 = 0.064$, $f(1) = 3 \times 0.4^2 \times 0.6 = 0.288$, $f(2) = 3 \times 0.4 \times 0.6^2 = 0.432$, $f(3) = 0.6^3 = 0.216$ (il lettore verifichi che la somma è uguale a 1).

Noi però cerchiamo la risposta al caso più generale: “quale è la probabilità $f(x)$ di osservare x successi in n prove bernoulliane indipendenti, ciascuna con la stessa probabilità di successo p ?”

Estendendo il ragionamento precedente, possiamo considerare, per semplicità, una sequenza di x successi, seguita da una sequenza di $n-x$ insuccessi. A questa particolare sequenza è associata una probabilità pari a $p^x \times (1-p)^{n-x}$. Come sappiamo, questa però non è la risposta che cerchiamo (vale a dire non è $f(x)$), dal momento che in generale c'è più di una sequenza formata complessivamente da x successi e da $n-x$ insuccessi. Quante sono? Come abbiamo visto nel capitolo precedente la risposta è il numero delle possibili *combinazioni* (semplici) di n oggetti distinti di classe x :

$$\binom{n}{x} = \frac{n!}{x!(n-x)!}. \quad (2.9)$$

A questo punto possiamo scrivere in modo esplicito la funzione di probabilità della variabile casuale binomiale di parametri n e p :

$$f(x) = \binom{n}{x} p^x (1-p)^{n-x}. \quad (2.10)$$

Facciamo notare che la formula precedente va bene anche nel caso in cui $n = 1$, vale a dire nel caso della variabile casuale di Bernoulli.

La funzione `dbinom` di R implementa la (2.10). Gli argomenti di questa funzione sono, nell'ordine, i valori di x per i quali si desidera calcolare le probabilità, il numero n di prove e la probabilità p di successo. Le probabilità dell'esempio con il quale abbiamo introdotto la variabile casuale binomiale si possono quindi calcolare nel modo seguente:

```
> dbinom(c(0:3), 3, 0.6)
[1] 0.064 0.288 0.432 0.216
```

La funzione `Binomiale` di `rmf` produce un *output* con maggiori dettagli (insieme ad un grafico che qui non mostriamo).

```
> Binomiale(n=3, p=0.6)
-----
Distribuzione Binomiale
-----
Numero delle prove      : 3
Probabilita' di successo: 0.6
Valore atteso (media)   : 1.8
Varianza                 : 0.72
Somma delle probabilita': 1
  x  f(x)  F(x)
[1,] 0 0.064 0.064
[2,] 1 0.288 0.352
[3,] 2 0.432 0.784
[4,] 3 0.216 1.000
```

La variabile casuale binomiale, definita dalla (2.10), ha, come detto, due parametri: n e p . La Figura 2.5 mostra come varia il grafico della distribuzione di probabilità al variare di p per un valore di n fissato (pari a 10).

Esaminando la Figura 2.5 si può notare come tutte le distribuzioni siano asimmetriche a parte il caso in cui $p = 0.5$. Notiamo inoltre che il livello di asimmetria è tanto più elevato quanto più il valore di p è lontano da 0.5; quando $p < 0.5$ la distribuzione presenta una *asimmetria positiva*, mentre quando $p > 0.5$ la distribuzione presenta una *asimmetria negativa*. Possiamo infine notare che le distribuzioni dove $p = 0.1$ e $p = 0.9$ sono, per così dire, “speculari”. Lo stesso vale per tutte le altre distribuzioni in cui la probabilità di successo e quella di insuccesso sono state scambiate (0.2 e 0.8, 0.3 e 0.7, 0.4 e 0.6).

Al crescere del valore di n la distribuzione si “infittisce”, fino quasi a riempire completamente il grafico. Possiamo vederlo nel pannello di sinistra della Figura 2.6. La forma del grafico ricorda quella vista nella Figura 2.3.

Abbiamo detto che quando $p \neq 0.5$ la distribuzione binomiale è asimmetrica. Tuttavia, per valori di n (molto) grandi, anche quando $p < 0.5$ (come nel caso del




Figura 2.5: Grafico della funzione di probabilità (f) della variabile casuale binomiale con parametro $n = 10$ e per diversi valori del parametro p .

pannello di destra della Figura 2.6, dove p è davvero piuttosto piccolo), esiste una zona intorno alla media dove il grafico sembra essere alquanto simmetrico e “regolare”, con una forma davvero simile a quella presentata nel pannello di sinistra della stessa figura e a quella vista nella Figura 2.3.

Se X è una variabile casuale binomiale con parametri $n = 10$ e $p = 0.5$, allora la probabilità che X cada nell’intervallo $(\mu \pm 2\sigma)^{12}$ è circa 0.98, mentre se i parametri sono $n = 1000$ e $p = 0.5$, allora la probabilità che X cada nell’intervallo $(\mu \pm 2\sigma)^{13}$ è circa 0.95.

¹²Circa (1.8, 8.2).

¹³Circa (468.4, 531.6).




Figura 2.6: A sinistra: distribuzione di probabilità della variabile casuale binomiale con parametri $n = 1000$ e $p = 0.5$ nel range di valori compresi fra 430 e 570. A destra: distribuzione di probabilità della variabile casuale binomiale con parametri $n = 1000$ e $p = 0.1$ nel range di valori compresi fra 60 e 140.

Se X è una variabile casuale binomiale con parametri $n = 10$ e $p = 0.1$, allora la probabilità che X cada nell'intervallo $(\mu \pm 2\sigma)^{14}$ è circa 0.93, mentre se i parametri sono $n = 1000$ e $p = 0.1$, allora la probabilità che X cada nell'intervallo $(\mu \pm 2\sigma)^{15}$ è circa 0.95.

Vedremo nel prossimo capitolo che se X è una variabile casuale binomiale con parametri n e p tali che np e $n(1-p)$ sono entrambi “grandi”, allora la probabilità che X cada nell'intervallo $(\mu \pm 2\sigma)$ è (sempre) circa 0.95.

La passeggiata casuale

La *passeggiata casuale* (*random walk* in inglese) è un processo stocastico generalmente associato ai numeri interi. Può essere impiegato per simulare il percorso di una molecola in un liquido o in un gas (moto Browniano), ma trova applicazioni anche nei campi scientifici più disparati (biologia, economia, psicologia, sociologia, ecc.). Esistono vari tipi di “passeggiata casuale”, ma noi prenderemo in esame solo quella più “semplice”, consistente nel seguire un “percorso” che parte dall’origine, facendo un passo “in avanti” oppure un passo “indietro” (oppure verso destra o verso sinistra) a seconda del risultato ottenuto lanciando, ad esempio, una moneta non truccata. Tanto per fissare le idee, possiamo pensare che se esce testa si avanza di un metro in una direzione (+1), mentre se viene croce si avanza di un metro nella direzione opposta (−1). Nella Figura 2.7 sono visualizzate le “traiettorie” di quattro passeggiate casua-

¹⁴Circa $(-0.9, 2.9)$.

¹⁵Circa $(81.03, 118.97)$.




Figura 2.7: A sinistra: Due passeggiate casuali ciascuna di 10 passi. A destra: Due passeggiate casuali ciascuna di 100 passi.

li, due costituite da 10 *passi*¹⁶ (pannello di sinistra) e due da 100 *passi* (pannello di destra).

Questo lo *script* per le due passeggiate di 10 passi:

```
> plot(c(1,10),c(-4,3),type="n",xlab="Numero di passi",ylab="Distanza dall'origine")
> abline(h=0)
> n <- 10; x <- c(1:n)
> set.seed(123)
> y <- sample(c(-1,1),n,replace=TRUE); y
[1] -1 1 -1 1 1 -1 1 1 1 -1
> yy <- cumsum(y); lines(x,yy)
> set.seed(456)
> y <- sample(c(-1,1),n,replace=TRUE); y
[1] -1 -1 1 1 1 -1 -1 -1 -1 -1
> yy <- cumsum(y); lines(x,yy,lty=2)
```

Come si può vedere dall'*output*, nella prima passeggiata casuale (linea continua nel pannello di sinistra della Figura 2.7) complessivamente i passi avanti sono stati 6 e i passi indietro 4. Per questo la “distanza” complessivamente percorsa è stata di due metri nella direzione “positiva” (+2). Nella seconda passeggiata casuale (linea tratteggiata nel pannello di sinistra della Figura 2.7) complessivamente i passi avanti sono stati 3 e i passi indietro 7. Per questo la “distanza” complessivamente percorsa è stata di quattro metri nella direzione “negativa” (−4). Con un maggior numero di passi l’andamento appare più “barcollante” (la “passeggiata casuale” è a volte nota anche come la “passeggiata dell’ubriaco”) e la distanza percorsa, almeno nei due casi descritti nel pannello di destra della Figura 2.7, è stata un po’ maggiore (−6 e +8). Questo lo *script* impiegato:

¹⁶Ogni *passo* deriva dall’esito del lancio di una moneta equilibrata.

```

> plot(c(1,100),c(-10,15),type="n",xlab="Numero di passi",ylab="Distanza dall'origine")
> abline(h=0)
> n <- 100; x <- c(1:n)
> set.seed(123)
> y <- sample(c(-1,1),n,replace=TRUE); sum(y)
[1] -6
> yy <- cumsum(y); lines(x,yy)
> set.seed(456)
> y <- sample(c(-1,1),n,replace=TRUE); sum(y)
[1] 8
> yy <- cumsum(y); lines(x,yy,lty=2)

```

Sono numerose le domande che si possono porre in relazione ad una passeggiata casuale, ma, forse, la più “naturale” riguarda la distanza D_n percorsa dopo n passi. Questa distanza è una variabile casuale, risultato della *somma* dei passi fatti in una direzione (+1) e in quella opposta (−1), ovvero della differenza (con il segno) fra il numero di teste e il numero di croci. Questo ci fa intuire che la distribuzione binomiale sia coinvolta nella “generazione” di una passeggiata casuale. In effetti, fissato n (il numero di passi), la distanza D_n corrisponde, come detto, alla differenza fra il numero di teste e il numero di croci e la distribuzione di probabilità di D_n è analoga alla distribuzione di probabilità di una variabile casuale binomiale X con n uguale al numero dei passi e $p = 0.5$. In effetti D_n si ricava da X mediante la seguente *trasformazione lineare*: $D_n = 2X - n$. Ad esempio, la passeggiata casuale descritta dalla linea continua nel pannello di sinistra della Figura 2.7 deriva dal fatto di avere osservato 6 teste (ovvero 6 successi $X = 6$) e 4 croci; quindi $D_{10} = 2 \times 6 - 10 = 2$.

A questo punto possiamo applicare le proprietà del valore atteso e della varianza, per trovare il valore atteso e la varianza di D_n (ricordando che nella passeggiata casuale $p = 0.5$):

$$E(D_n) = E(2X - n) = 2E(X) - n = 2n \frac{1}{2} - n = n - n = 0$$

$$Var(D_n) = Var(2X - n) = 4Var(X) = 4n \frac{1}{4} = n.$$

Come ci si poteva aspettare, in media, dopo aver percorso n passi ci si ritrova nell’origine, anche se la variabilità aumenta all’aumentare di n . Potremmo però voler ignorare il segno associato a D_n e calcolare, ad esempio, il valore atteso del valore assoluto di D_n , cioè $E(|D_n|)$: in media, dopo n passi, a quanti metri ci troviamo dall’origine (indipendentemente dalla direzione)? Come spesso accade, non è agevole “gestire” un valore assoluto. Possiamo allora cambiare domanda e chiederci quanto vale $E(D_n^2)$. Lo abbiamo già calcolato! Quando? Dove?

Ricordiamo¹⁷ che $Var(D_n) = E(D_n^2) - [E(D_n)]^2$, ma, dal momento che $E(D_n) = 0$, in questo caso $E(D_n^2) = Var(D_n) = n$.

Controlliamo questo risultato mediante una simulazione calcolando non solo la media di D_n^2 , ma anche la media di $|D_n|$.

¹⁷Facciamo riferimento alla (2.3).

```

> set.seed(654321)
> n <- c(seq(10,100,10),seq(200,1000,100))
> out <- matrix(nrow=length(n),ncol=2)
> k <- 0
> for (i in n){
+   x <- rbinom(100000,i,0.5)
+   d <- 2*x - i
+   k <- k + 1
+   out[k,] <- c(mean(d^2),mean(abs(d)))
+ }

```

Abbiamo considerato 19 valori distinti di n (da 10 a 100 con passo 10 e da 100 a 1000 con passo 100; seconda riga dello *script*). Per ciascuno di questi valori di n abbiamo estratto 100000 valori di una variabile casuale binomiale con parametri n e $p = 0.5$; sesta riga dello *script*), trasformandoli poi (settima riga) nella distanza D_n dall'origine percorsa alla fine degli n passi. Infine, nel vettore `out` abbiamo inserito le medie di D_n^2 (prima colonna) e di $|D_n|$ (seconda colonna) per i diversi valori di n presi in esame. Possiamo vedere il risultato della simulazione (per brevità proponiamo soltanto i primi 10 valori di n):

```

> r1 <- round(out[1:10,1],0)
> r2 <- round(out[1:10,2],2)
> rbind(n=n[1:10],r1,r2)

```

n	10	20	30	40	50	60	70	80	90	100
r1	10.00	20.00	30.00	40.00	50.00	60.00	70.00	80.00	90.00	100.00
r2	2.46	3.54	4.34	5.01	5.62	6.15	6.63	7.12	7.53	7.98

I valori medi di D_n^2 ottenuti dalla simulazione (riportati nella riga intestata `r1`) sono sostanzialmente identici a quanto ci aspettavamo (cioè a n); invitiamo il lettore a verificarlo personalmente guardando tutti i valori presenti nella prima colonna della matrice `out` mediante l'istruzione `out[,1]`. Quindi, dopo n passi, in media ci troviamo a una distanza dall'origine il cui quadrato è n metri²; estraendo la radice quadrata di $E(D_n^2)$, per riportare la distanza in metri, vediamo come il risultato sia (direttamente) proporzionale a $\sqrt{n}$.

Passiamo ora a considerare i valori medi di $|D_n|$. Possiamo guardare quelli ottenuti dalla simulazione visualizzando il contenuto della seconda colonna della matrice `out` (`out[,2]`). I primi 10 valori sono anche riportati nella riga intestata `r2` dell'*output*, ma non sembra emergere in modo evidente la relazione che intercorre fra n e il valore atteso di $|D_n|$. È certamente più efficace visualizzare questa relazione graficamente (pannello di sinistra della Figura 2.8).

La relazione fra il valore atteso di $|D_n|$ e n è evidentemente non lineare; tuttavia il grafico ricorda moltissimo quello della radice quadrata. Per questo abbiamo voluto visualizzare nel pannello di destra della Figura 2.8 come variano le medie di $|D_n|$ in relazione alla radice quadrata del numero dei passi. In questo caso la relazione




Figura 2.8: Andamento dei valori medi di $|D_n|$ ottenuti mediante simulazione in relazione al numero n dei passi (a sinistra) e alla radice quadrata del numero n dei passi (a destra).

sembra essere perfettamente lineare e, mediante la funzione `lm`, possiamo calcolare la pendenza e l'intercetta della retta interpolante:

```
> fit <- lm(out[,2] ~ sqrt(n))
> (b <- fit$coefficients)
(Intercept)      sqrt(n)
-0.04054425  0.79901582
```

Spiegare cosa fa la funzione `lm` è al di fuori degli scopi di questo libro; il lettore interessato potrà consultare il Capitolo 4 del testo di Espa e Micciolo (2012). Quello che qui ci interessa osservare è che l'intercetta non sembra scostarsi sostanzialmente da zero (se non si fa nessun passo si resta nell'origine) e che la pendenza della retta è circa 0.8. Ma a cosa corrisponde 0.8?

Prima di rispondere a questa domanda osserviamo che per calcolare $E(|D_n|)$ per un particolare valore numerico di n non è necessario ricorrere alla simulazione. Basta ricordarsi la definizione di valore atteso.

Poniamo, ad esempio, $n = 10$. Se X è una variabile casuale binomiale con parametri $n = 10$ e $p = 0.5$, i valori che può assumere X sono $X = \{0, 1, 2, \dots, 10\}$, mentre i valori che può assumere D_{10} sono $D_{10} = \{-10, -8, -6, \dots, 6, 8, 10\}$ con la stessa probabilità dei corrispondenti valori di X . Eccoli qui di seguito:

```
> n <- 10
> x <- c(0:n)
> d <- 2*x - n
> f <- dbinom(x,n,0.5)
> rbind(x,d,f=round(f,3))
```

x	0	1	2	3	4	5	6	7	8	9	10
d	-10	-8	-6	-4	-2	0	2	4	6	8	10
f	0.001	0.01	0.044	0.117	0.205	0.246	0.205	0.117	0.044	0.01	0.001

Quindi, per calcolare $E(|D_{10}|)$ basta moltiplicare i valori presenti nella riga intestata *d* (dopo aver tolto il segno) per i valori (le probabilità) corrispondenti riportati nella riga intestata *f* (e ottenute impiegando la formula (2.10) per una variabile casuale binomiale):

```
> sum(abs(d)*f)
[1] 2.460937
```

Considerando i primi due decimali, il risultato coincide con quello ottenuto dalla nostra simulazione.

Possiamo allora calcolare $E(|D_n|)$ facendo variare n fra 1 e 1000 eseguendo lo *script* che segue:

```
> n <- c(1:1000)
> out <- numeric(length(n))
> k <- 0
> for (i in n){
+   x <- c(0:i)
+   f <- dbinom(x,i,0.5)
+   d <- 2*x - i
+   k <- k + 1
+   out[k] <- sum(abs(d)*f)
+ }
```

Questa volta il vettore *out* contiene i valori attesi esatti $E(|D_n|)$ e non quelli approssimati mediante simulazione. Tuttavia il grafico (che non riportiamo) è del tutto analogo a quello del pannello di destra della Figura 2.8. Eseguendo la funzione *fit* la retta interpolante ha i seguenti coefficienti:

```
> fit <- lm(out ~ sqrt(n))
> (b <- fit$coefficients)
(Intercept)      sqrt(n)
0.00139216   0.79782621
```

L'intercetta è ancora più vicina a zero, mentre la pendenza è molto vicina al valore trovato con la simulazione. Tuttavia c'è qualcosa su cui dobbiamo riflettere prima di concludere che $E(|D_n|) = 0.79782621\sqrt{n}$.

Calcoliamo i *residui* del modello di regressione appena interpolato facendo la differenza fra i valori osservati (cioè quelli contenuti nel vettore *out*) e quelli “previsti”, calcolati in base alla retta di equazione $y = 0.79782621\sqrt{x}$. Se l'adattamento fosse davvero perfetto, tutti questi residui dovrebbero essere uguali a zero. La Figura 2.9 mostra il grafico dei residui in relazione al valore di n separatamente per i valori di n pari (pannello di sinistra) e dispari (pannello di destra). Non solo i residui non sono tutti uguali a zero, ma c'è un evidente *pattern*. I residui “pari” sono tutti minori di zero e vanno crescendo (cioè si avvicinano a zero) al crescere di n . I residui “dispari” sono




Figura 2.9: Le due figure mostrano i residui (le differenze tra i valori veri di $E(|D_n|)$ e quelli calcolati impiegando la formula $E(|D_n|) = 0.79782621\sqrt{n}$, separatamente per i valori di n pari (a sinistra) e dispari (a destra).

tutti maggiori di zero e vanno diminuendo al crescere di n . L'andamento congiunto sembra far vedere che i residui “pari” e quelli “dispari” *tendano* a zero asintoticamente. In altri termini, la formula $E(|D_n|) = 0.79782621\sqrt{n}$ sembra essere quella corretta quando n tende a infinito.

Fatta questa osservazione, rimane da rispondere alla domanda relativa al valore numerico della pendenza (0.79782621). Si potrebbe far vedere (ma noi non lo facciamo) che il valore “vero” è $\sqrt{2/\pi}$, di modo che

$$E(|D_n|) \simeq \sqrt{\frac{2n}{\pi}}$$

al tendere di n all'infinito.

Sottolineiamo ancora una volta che la relazione fra il valore atteso di $|D_n|$ e n non è lineare, perché n compare sotto il segno di radice quadrata. Questo vuol dire che per raddoppiare la distanza media percorsa (il valore atteso di $|D_n|$) non è sufficiente raddoppiare il numero dei passi, ma bisogna *quadruplicarli*. La relazione non è aritmeticamente “esatta”, perché la formula $E(|D_n|) = \sqrt{\frac{2n}{\pi}}$ vale solo asintoticamente, ma possiamo considerarla tale (ovvero sufficientemente approssimata) nella sostanza. Ad esempio $E(|D_{10}|) = 2.46$ e $E(|D_{40}|) = 4.92$; $E(|D_{100}|) = 7.96$ e $E(|D_{400}|) = 15.95$.

Infine, una curiosità “matematica”. Sono moltissimi i metodi che si possono usare per ottenere una stima di π (per lo meno dei primi decimali). Ebbene, la passeggiata casuale può essere impiegata a questo proposito. Infatti, possiamo calcolare $E(|D_n|)$ per un valore di n molto grande (ad esempio, 1000000) e ricavare poi (una stima di) π nel modo seguente:

```
> n <- 1000000
> x <- c(0:n)
```

```
> f <- dbinom(x,n,0.5)
> d <- 2*x - n
> (m <- sum(abs(d)*f))
[1] 797.8844
> 2*n/m^2
[1] 3.141594
```

In generale, se μ è il valore atteso di $|D_n|$, allora π è stimato dal rapporto $2n/\mu^2$. Abbiamo appena visto come con $n = 10^6$, la stima che si ottiene differisce dal valore vero di circa 1.6×10^{-6} .

Fluttuazioni

Consideriamo una scatola riempita da n molecole di gas e divisa in due metà A, B da un setto permeabile alle molecole che quindi possono muoversi indisturbate. Immaginiamo di poter rendere (momentaneamente) impermeabile il setto, in modo da poter contare il numero di molecole che si trovano nella metà sinistra (n_A) e nella metà destra (n_B) della scatola. Quello che ci aspettiamo è che n_A e n_B non siano identici (almeno se n , la loro somma, è abbastanza grande), ma comunque siano molto vicini fra loro in modo che si realizzi una condizione di equilibrio. Possiamo pensare che in ogni istante ogni molecola abbia la stessa probabilità di trovarsi in una delle due metà della scatola e che ognuna si comporti indipendentemente dall'altra. Una situazione come questa può essere analizzata ricorrendo alla distribuzione binomiale, con parametri n (il numero delle molecole) e $p = 0.5$, definendo, ad esempio, “successo” il trovarsi nella metà sinistra della scatola, di modo che n_A è il numero dei successi in n prove, con probabilità di successo uguale a 0.5 (ovviamente, il numero degli insuccessi è n_B).

Una situazione di perfetto equilibrio si ha quando il numero n_A di molecole nella metà sinistra è uguale a $n/2$; ad esempio, se $n = 1000$, l'equilibrio perfetto si realizza quando $n_A = 500$. Definiamo ora un intervallo centrato sulla media e la cui semi-ampiezza è una frazione “trascurabile” di n ; ad esempio, questa frazione f potrebbe essere l'1%. Nel nostro esempio la semi-ampiezza sarebbe quindi 10 (l'1% di 1000) e l'intervallo andrebbe da 490 a 510. Diciamo che se n_A è in questo intervallo di valori si è in una condizione di equilibrio, mentre se n_A è al di fuori di questo intervallo si è realizzata una “fluttuazione”. Vediamo come varia la probabilità che si realizzi una fluttuazione al variare di n .

Nel caso che abbiamo appena illustrato, basta prima calcolare la probabilità che n_A sia compreso fra 490 e 510:

```
> sum(dbinom(c(490:510), 1000, 0.5))
[1] 0.49334
```

per poi prendere il complemento a 1 di questo valore. Quindi la probabilità di una fluttuazione è circa del 51%. Può sembrare un valore elevato (capita circa una volta su due), ma si realizza considerando un intervallo piuttosto limitato (di ampiezza $2nf$). Se però $n = 10000$, allora l'intervallo di valori che individua una situazione di

equilibrio va da 4900 a 5100 e la probabilità di una fluttuazione scende drasticamente, diventando meno del 5%:

```
> 1 - sum(dbinom(c(4900:5100), 10000, 0.5))
[1] 0.0444258
```

Il pannello di sinistra della Figura 2.10 mostra la probabilità associata ad una fluttuazione per valori di n compresi fra 100 e 20000, assegnando alla frazione f che individua la situazione di equilibrio il valore di 0.01. È del tutto evidente come la probabilità di una fluttuazione si riduca molto velocemente all'aumentare di n .




Figura 2.10: Probabilità di osservare una “fluttuazione” nel numero di molecole di gas contenute in una scatola in funzione del numero n di molecole. La fluttuazione è individuata sulla base di una frazione $f = 0.01$ (pannello di sinistra) oppure $f = 0.001$ (pannello di destra).

Il pannello di destra della Figura 2.10 mostra la probabilità associata ad una fluttuazione per valori di n compresi fra 10000 e 2000000, assegnando alla frazione f che individua la situazione di equilibrio il valore 0.001 (dieci volte più piccolo del precedente). Anche in questo caso la probabilità di una fluttuazione assume valori molto vicini a zero quando n è grande (ad esempio, quando $n = 2 \times 10^6$, la probabilità di una fluttuazione è 0.0047).

Naturalmente in una scatola “macroscopica” (come potrebbe essere un stanza) il numero di molecole di gas (per esempio, di O_2) è molto più grande (enormemente più grande) di 2×10^6 ; se, ad esempio, fosse dell’ordine di 10^{23} , anche assegnando alla frazione f un valore enormemente più piccolo di quelli considerati, la probabilità che si realizzi una fluttuazione (cioè una macroscopica differenza nel numero di molecole di O_2 nelle due metà in cui è divisa la stanza) è, a tutti gli effetti pratici, zero.

2.7 La variabile casuale ipergeometrica

Riprendiamo (modificandolo) l’esempio proposto per introdurre la variabile casuale binomiale.

Consideriamo un'urna contenente 10 palline delle quali 6 sono bianche e 4 sono nere. Chiamiamo “successo” l'estrazione di una pallina bianca e “insuccesso” l'estrazione di una pallina nera. Decidiamo di estrarre $n = 3$ palline dall'urna ma questa volta *senza reimmissione* (vale a dire senza reinserire la pallina estratta). In questo caso la probabilità di successo non è più costante (come nel caso della variabile casuale binomiale) e dipende dall'esito delle estrazioni precedenti. La variabile casuale X “numero di palline bianche osservate facendo 3 estrazioni senza reimmissione” è un esempio di *variabile casuale ipergeometrica*.

Con tre estrazioni, il numero di palline bianche può essere 0, 1, 2 o 3. Cominciamo, ancora una volta, calcolando le probabilità associate ai casi estremi, vale a dire $f(0)$ e $f(3)$. Il primo caso, $f(0)$, fa riferimento all'evento (NNN) (3 palline nere). Per trovare la probabilità cercata dobbiamo impiegare la regola del prodotto per eventi dipendenti. Infatti, se alla prima estrazione le palline nere sono 4 su 10, alla seconda sono 3 su 9 e alla terza sono 2 su 8. Abbiamo quindi che $f(0) = 4/10 \times 3/9 \times 2/8 = 1/30$ (circa 0.0333).

Il secondo caso estremo, $f(3)$, fa riferimento all'evento (BBB) (3 palline bianche). In questo caso, alla prima estrazione le palline bianche sono 6 su 10, alla seconda sono 5 su 9 e alla terza sono 4 su 8. Abbiamo quindi che $f(3) = 6/10 \times 5/9 \times 4/8 = 1/6$ (circa 0.167).

Passiamo ora a calcolare $f(1)$ considerando dapprima la sequenza (BNN) . Alla prima estrazione ci sono 6 palline bianche su un totale di 10, alla seconda le palline nere sono 4 su un totale di 9, mentre alla terza le palline nere sono 3 su un totale di 8. Quindi la probabilità associata alla sequenza (BNN) è data da $6/10 \times 4/9 \times 3/8$. Se la sequenza è invece (NBN) , la probabilità è data da $4/10 \times 6/9 \times 3/8$. Infine, se la sequenza è (NNB) , la probabilità è data da $4/10 \times 3/9 \times 4/8$. In altre parole, le tre probabilità sono tutte uguali fra loro (valgono tutte $1/10$) e, quindi, $f(1) = 3/10$.

Consideriamo ora l'estrazione di 2 palline bianche. Le sequenze “utili” sono date da (BBN) , (BNB) e da (NBB) . Si può far vedere che a ciascuna di esse è associata una probabilità pari a $6/10 \times 5/9 \times 4/8$, cioè $1/6$. Pertanto, $f(2) = 3/6 = 1/2$.

Abbiamo quindi

$$f(0) = \frac{1}{30}, f(1) = \frac{3}{10}, f(2) = \frac{1}{2}, f(3) = \frac{1}{6}$$

e $f(0) + f(1) + f(2) + f(3) = 1$.

Notiamo subito quanto sia più “complicato” (meno immediato) calcolare le probabilità quando non vale l'indipendenza. L'assunto di indipendenza è impiegato comunemente nell'ambito della ricerca scientifica, in particolare negli esperimenti che prevedono la *randomizzazione*.

Noi però vogliamo una formula generale per la funzione di probabilità della variabile casuale ipergeometrica, formula che possiamo ottenere nel modo seguente. Sia X il numero di successi che si presentano in un campione di n oggetti estratti senza reimmissione da un gruppo di N oggetti dei quali il numero totale di successi è S . Allora la distribuzione di probabilità della v.c. X (che è detta variabile casuale ipergeometrica)

è data da:

$$f(x) = \frac{\binom{S}{x} \binom{N-S}{n-x}}{\binom{N}{n}} \quad (2.11)$$

dove x può assumere valori tali che $\max[0, n - (N - S)] \leq x \leq \min[n, S]$.

Nel nostro esempio $N = 10$ è il numero di palline totali nell'urna, $S = 6$ è il numero di palline bianche e $n = 3$ è il numero di palline estratte. Possiamo calcolare la distribuzione di probabilità ricorrendo alla funzione `dhyper` di R. Gli argomenti sono, nell'ordine,

1. i valori x per i quali si vuole calcolare $f(x)$;
2. il numero S di palline bianche nell'urna (cioè il numero di successi);
3. il numero $N - S$ di palline nere nell'urna (cioè il numero di insuccessi);
4. il numero n di palline estratte dall'urna.

Pertanto, nel nostro esempio, avremo

```
> dhyper(c(0:3), 6, 4, 3)
[1] 0.03333333 0.30000000 0.50000000 0.16666667
```

valori che coincidono con quelli trovati in precedenza.

La media μ di una variabile casuale ipergeometrica è data da

$$E(X) = \mu = n \times \frac{S}{N}, \quad (2.12)$$

mentre la varianza σ^2 è data da

$$Var(X) = \sigma^2 = \frac{n(N-n)S(N-S)}{N^2(N-1)}. \quad (2.13)$$

Se indichiamo con $p = S/N$ la proporzione iniziale di palline bianche nell'urna e con $1 - p = (N - S)/N$ la proporzione iniziale di palline nere, la media μ può essere scritta nel modo seguente:

$$\mu = np$$

e la varianza

$$\sigma^2 = np(1-p) \frac{N-n}{N-1}.$$

In altre parole, la media della variabile casuale ipergeometrica coincide con quella della variabile casuale binomiale di parametri n e p , mentre la varianza è ancora quella della binomiale, ma moltiplicata per un *fattore di correzione per popolazioni finite*¹⁸

¹⁸Per approfondimenti, teorici e applicativi (sempre mediante l'utilizzo di R!), connessi alla selezione di campioni da popolazioni finite si rimanda al manuale di Tillé *et al.* (2020).

pari a $(N - n)/(N - 1)$; dal momento che questo fattore è sempre inferiore a 1 (a parte il caso in cui $n = 1$), la varianza della ipergeometrica è sempre inferiore a quella della binomiale. Notiamo ancora che, qualora il valore di N sia molto grande in confronto al valore di n (la popolazione sia molto più grande del campione estratto), il fattore di correzione sarà molto vicino a 1 e, quindi, sarà possibile approssimare la varianza della ipergeometrica con quella della binomiale.

La variabile casuale ipergeometrica trova impiego nel calcolo di test e di intervalli di confidenza “esatti” per proporzioni, come descritto ampiamente nel nostro *Ricerca con R*.

2.8 La variabile casuale di Poisson

Con la sola eccezione della variabile casuale geometrica, le variabili casuali considerate fino ad ora ammettevano tutte un insieme finito di valori (i numeri interi da 1 a 6 nel caso di un dado o da 2 a 12 nel caso di due; i numeri interi da 0 a n nel caso della variabile casuale binomiale). Accade di frequente che il risultato di una ricerca empirica sia rappresentato da un “conteggio” come, ad esempio, il numero di eventi che si registrano in un ambito circoscritto, sia esso temporale o spaziale. Esempi classici¹⁹ sono rappresentati dal numero di meteoriti che cadono ogni giorno sul suolo lunare, dal numero di bombe cadute sui quartieri di Londra durante la seconda guerra mondiale,²⁰ dal numero di morti per calcio di cavallo nelle armate prussiane,²¹ dal numero di eritrociti presenti in un quadrato di un emocitometro, dal numero di persone che si ammalano di una determinata patologia (non contagiosa) in un anno e/o in un’area geografica, dal numero di guasti giornalieri dei macchinari di un’officina, dal numero di disintegrazioni che si registrano in un minuto in un grammo di una sostanza radioattiva e così via.

In tutti questi esempi l’estremo inferiore è rappresentato da zero (nessun evento osservato), mentre l’estremo superiore dipende dal periodo di osservazione e/o dall’ampiezza dell’area geografica presa in considerazione. Ecco perché in questo caso non risulta opportuno limitare superiormente il valore che può essere osservato. In altre parole la variabile casuale X che stiamo considerando può assumere *tutti* i valori interi da zero fino a *infinito*: $X = \{0, 1, 2, \dots\}$.

In situazioni di questo tipo il modello probabilistico più semplice che si possa prendere in esame è rappresentato dalla *variabile casuale di Poisson* (ovvero dal *modello poissoniano*). La funzione di probabilità di una variabile casuale X di Poisson è

¹⁹ Ancora una volta non possiamo non citare Feller (1968), rimandando alla lettura della sezione *Observations fitting the Poisson distribution*, pagg. 159–164.

²⁰ Si veda l’articolo originale di Clarke (1946).

²¹ Per una approfondita discussione di questo esempio “classico” rimandiamo all’articolo di Quine e Seneta (1987).

data da²²

$$f(x) = \frac{e^{-\mu} \mu^x}{x!} \quad (2.14)$$

Facciamo notare che nel caso della variabile casuale di Poisson il rapporto fra $f(x+1)$ e $f(x)$ è dato da

$$\frac{f(x+1)}{f(x)} = \frac{e^{-\mu} \mu^{x+1}}{(x+1)!} \times \frac{x!}{e^{-\mu} \mu^x} = \frac{\mu}{x+1},$$

per cui

$$f(x+1) = f(x) \frac{\mu}{x+1},$$

e $f(0) = e^{-\mu}$. La variabile casuale di Poisson ha un solo parametro: μ . Questo parametro rappresenta sia la media, sia la varianza della variabile casuale di Poisson.²³ Quindi una variabile casuale di Poisson ha media e varianza uguali. Naturalmente, essendo μ la media di un conteggio dovrà essere necessariamente maggiore di zero; da qui la condizione $\mu > 0$. La Figura 2.11 fa vedere il grafico della funzione di probabilità della variabile casuale poissoniana al variare di μ .

La distribuzione di Poisson è sempre asimmetrica (con asimmetria positiva); tuttavia il grado di asimmetria si riduce al crescere della media μ (Figura 2.11). Sempre dalla Figura 2.11 si può notare come per valori di $\mu < 1$ la distribuzione abbia un massimo in corrispondenza dello zero (la probabilità più elevata corrisponde a non osservare alcun evento). Quando $\mu = 1$ la distribuzione presenta due massimi in corrispondenza di $x = 0$ e di $x = 1$. Per valori di $\mu > 1$, il massimo è sempre maggiore di zero.²⁴

La funzione `dpois` di R permette di calcolare le probabilità associate ad una determinata distribuzione di Poisson. Gli argomenti principali della funzione sono due: il primo è rappresentato dai valori di x per i quali si vuole calcolare $f(x)$; il secondo è rappresentato dal parametro μ . Ad esempio, per ottenere i valori riportati nella Figura 2.11 quando $\mu = 0.5$, basta scrivere

```
> round(dpois(c(0:5),0.5),6)
[1] 0.606531 0.303265 0.075816 0.012636 0.001580 0.000158
```

La funzione `Poisson` di `rmf` produce un *output* più dettagliato (oltre a un grafico che non riportiamo):

²² e è un numero irrazionale (impiegato come base dei logaritmi naturali) che vale 2.718...

²³La deviazione standard è quindi $\sqrt{\mu}$.

²⁴In molti testi la distribuzione di Poisson è anche indicata come la *legge dei piccoli numeri o degli eventi rari*. Noi non lo facciamo; facciamo invece nostro il commento di Feller (1968) "The Poisson distribution has become known as the law of small numbers or of rare events. These are misnomers which proved detrimental to the realization of the fundamental role of the Poisson distribution." con il quale siamo in completo accordo.




Figura 2.11: Grafico della funzione di probabilità (f) della variabile casuale di Poisson per diversi valori del parametro μ .

```
> Poisson(mu=0.5)
-----
Distribuzione di Poisson
-----
mu: 0.5
Valore atteso (media) : 0.5
Varianza : 0.5
Somma delle probabilita': 1
      x\index[funr]{x}      f(x)      F(x)
[1,] 0 6.065307e-01 0.6065307
[2,] 1 3.032653e-01 0.9097960
[3,] 2 7.581633e-02 0.9856123
[4,] 3 1.263606e-02 0.9982484
```

[5,]	4	1.579507e-03	0.9998279
[6,]	5	1.579507e-04	0.9999858
[7,]	6	1.316256e-05	0.9999990
[8,]	7	9.401827e-07	0.9999999
[9,]	8	5.876142e-08	1.0000000
[10,]	9	3.264523e-09	1.0000000
[11,]	10	1.632262e-10	1.0000000

Anche per la variabile casuale di Poisson al crescere del valore di μ la distribuzione si infittisce, assumendo un andamento “regolare” e alquanto simmetrico, come si può osservare guardando il pannello di destra della Figura 2.12.




Figura 2.12: A sinistra: distribuzione di probabilità della variabile casuale di Poisson con parametri $\mu = 10$ nel range di valori compresi fra 0 e 30. A destra: distribuzione di probabilità della variabile casuale di Poisson con parametri $\mu = 100$ nel range di valori compresi fra 60 e 140.

Se X è una variabile casuale di Poisson con parametro $\mu = 10$, allora la probabilità che X cada nell’intervallo $(\mu \pm 2\sigma)^{25}$ è circa 0.96, mentre se $\mu = 100$, allora la probabilità che X cada nell’intervallo $(\mu \pm 2\sigma)^{26}$ è circa 0.95.

Una caratteristica del modello poissoniano è la seguente. Se X_1 e X_2 sono due variabili casuali di Poisson indipendenti con media μ_1 e μ_2 , rispettivamente, allora la variabile casuale $X = X_1 + X_2$ è anch’essa una variabile casuale di Poisson con media $\mu = \mu_1 + \mu_2$. Questa proprietà si estende al caso della somma di n variabili casuali di Poisson indipendenti.

²⁵Circa (3.7, 16.3).

²⁶(80, 120).

La distribuzione di Poisson troncata sullo zero

In alcune circostanze può accadere che uno strumento costruito per conteggiare certi “eventi”, per vari motivi, non sia in grado di evidenziare le situazioni in cui l’evento in parola non si è verificato e/o le situazioni in cui il numero di eventi ha superato una certa soglia s . Se la vera distribuzione della variabile casuale X è una Poisson, allora la variabile casuale Y effettivamente “misurata” è una *Poisson troncata* (con troncamento a sinistra e a destra, rispettivamente). Consideriamo il primo caso, cioè quello in cui non si conosce quante volte $X = 0$, di modo che Y è una variabile casuale di *Poisson troncata sullo zero* (*zero-truncated Poisson distribution*). Se X è una variabile casuale di Poisson con valore atteso μ , allora la distribuzione di probabilità di Y è data da

$$f(y) = \frac{e^{-\mu} \mu^y}{(1 - e^{-\mu})y!} = \frac{\mu^y}{(e^\mu - 1)y!},$$

dove $Y = \{1, 2, \dots\}$. Il valore atteso della variabile casuale così definita è

$$E(Y) = \frac{\mu}{(1 - e^{-\mu})}. \quad (2.15)$$

Per vedere un esempio concreto, eseguiamo una simulazione.

```
> set.seed(654321)
> x <- rpois(100000,1)
> c(mean(x),var(x))
[1] 1.001350 1.002498
```

Impiegando la funzione `rpois` abbiamo estratto un campione di 100000 osservazioni distribuite come una Poisson con valore atteso $\mu = 1$ e verificato che la media e la varianza calcolate sui dati campionari sono sostanzialmente uguali fra loro (e uguali al valore vero). Anche la distribuzione di frequenza dei valori osservati (la riga intestata `fo`) coincide, nella sostanza, con quanto atteso nel caso di una Poisson con $\mu = 1$ (la riga intestata `fa`); ci si aspetterebbe solo una ulteriore osservazione con un valore maggiore di 7, una differenza del tutto trascurabile.

```
> fo <- table(x)
> f <- dpois(c(0:7),1)
> fa <- round(f*100000,0)
> rbind(fo,fa)
      0      1      2      3      4      5      6      7
fo 36792 36673 18484 6165 1501 322 56 7
fa 36788 36788 18394 6131 1533 307 51 7
> sum(fa)
[1] 99999
```

Eliminiamo ora i 36792 valori uguali a zero, ottenendo così una Poisson troncata (sullo zero).

```
> y <- x[x > 0]
> length(y)
[1] 63208
> c(mean(y), var(y))
[1] 1.5842140 0.6626438
```

La media delle 63208 osservazioni così rimaste è evidentemente superiore al valore vero, mentre la varianza si è ridotta notevolmente (si parla di “sottodispersione”).

Naturalmente lo scopo (principale) del ricercatore in questa circostanza è stimare μ . Nel caso di X basta calcolare la media aritmetica $\bar{x}$ delle 100000 osservazioni, ovvero calcolare la media ponderata dei dati presentati nell’*output* di R, di modo che $\hat{\mu} = \bar{x}$. Questo però non è più vero nel caso dei dati troncati: $\hat{\mu} \neq \bar{y}$ (nella nostra simulazione $\bar{y} = 1.58$, mentre $\mu = 1$).

Una possibile strategia, suggerita da Johnson, Kemp e Kotz (2005) consiste nel trovare quel valore $\hat{\mu}$ che fa sì che il valore atteso di Y sia uguale alla media $\bar{y}$ calcolata sul campione, ovvero trovare quel valore $\hat{\mu}$ che soddisfa l’equazione

$$\bar{y} = \frac{\hat{\mu}}{(1 - e^{-\hat{\mu}})}. \quad (2.16)$$

Questa non è una equazione lineare, per la quale si possa trovare una soluzione esplicita. Quindi sarà necessario risolverla iterativamente in modo “manuale”; ecco il passo iniziale:

```
> g <- function(l,m) 1/(1-exp(-l)) - m
> (m <- mean(y))
[1] 1.584214
> l <- seq(0.8,1.6,0.1)
> cbind(l,g(l,m))
l
[1,] 0.8 -0.131441047
[2,] 0.9 -0.067608048
[3,] 1.0 -0.002237317
[4,] 1.1 0.064642701
[5,] 1.2 0.133001289
[6,] 1.3 0.202805653
[7,] 1.4 0.274021122
[8,] 1.5 0.346611352
[9,] 1.6 0.420538538
```

Abbiamo definito una (nuova) funzione di R, che abbiamo chiamato g , che calcola la differenza fra il valore atteso di Y dato dalla (2.15) per un valore specifico dell’argomento l e la media m del campione. Abbiamo definito una serie di valori l per l’argomento principale di g per i quali calcolare la differenza fra $E(Y)$ e $\bar{y}$. Dall’*output* risultante vediamo che la funzione vale zero per un valore di l compreso fra 1 e 1.1.

Possiamo a questo punto eseguire una nuova iterazione, facendo uno *zoom* sui valori 1, ad esempio

```
l <- seq(1,1.1,0.01)
cbind(l,g(l,m))
```

e procedere in questo modo fino a quando non siamo soddisfatti del risultato.

In alternativa, possiamo impiegare la funzione `uniroot` di R. Questa funzione, si legge nell'*help*, “searches the interval from lower to upper for a root (i.e., zero) of the function *f* with respect to its first argument”, quindi fa proprio al caso nostro. Bisogna solo essere molto attenti a definire i primi due/tre argomenti in modo appropriato:

- Il primo argomento (*f*) è la funzione della quale si vuole trovare lo (uno) zero; l'*help* ci ricorda che il *primo* argomento di questa funzione deve essere quello rispetto al quale vogliamo trovare lo zero.
- Il secondo argomento (*interval*) è un vettore di due elementi che individuano gli estremi dell'intervallo entro il quale siamo “certi” che la funzione assuma il valore zero (se dovesse valere zero in più punti dell'intervallo viene individuata una soltanto delle soluzioni).
- Il terzo argomento è . . . e, nel nostro caso, è fondamentale perché la funzione relativamente alla quale vogliamo trovare lo zero ha l'argomento *m* (la media di *Y* calcolata sui dati del campione) in aggiunta a quello “principale” (che è il primo) e questo argomento deve essere necessariamente passato a `uniroot` perché questa possa “funzionare”.

Per il significato degli altri argomenti, che “controllano” il comportamento di `uniroot`, rimandiamo all'*help* della funzione; ricordiamo soltanto che, quando chiamiamo questa funzione (o altre analoghe), siamo noi responsabili nel definire un *interval* “sensato” entro il quale la funzione assume il valore zero *solo una volta*. Siamo ora pronti a chiamare `uniroot` e a vederne il risultato:

```
> g <- function(l,m) 1/(1-exp(-l)) - m
> (m <- mean(y))
[1] 1.584214
> uniroot(g,c(0.5,1.6),m)
$`root`
[1] 1.003381
$f.root
[1] -8.523267e-07
$iter
[1] 4
$init.it
[1] NA
$estim.prec
[1] 6.103516e-05
```

Notiamo come il primo argomento di `uniroot` sia la nostra funzione g (e che il primo argomento di questa, 1, è proprio il valore rispetto al quale cerchiamo lo zero); il secondo argomento è l'intervallo entro il quale cercare/trovare la soluzione e il terzo argomento è la media del campione. Nel definire l'intervallo di valori siamo stati piuttosto “larghi”, soprattutto per l'estremo superiore. Infatti, dato che la media del campione è 1.58, la stima del parametro μ che cerchiamo deve essere necessariamente inferiore, dal momento che dalla distribuzione originale sono stati tolti gli zeri.

L'*output* di `uniroot` ci dice che $\hat{\mu} = 1.003381$ (`$root`) e che quando diamo a μ questo valore, l'uguaglianza riportata nella (2.16) non è rispettata esattamente, ma ci va davvero vicino (`$f.root`). Sono bastate 4 iterazioni (`$iter`) per raggiungere la convergenza (cioè per trovare lo zero). Per il significato dei due “valori” rimanenti, rimandiamo all'*help* della funzione.

Vediamo molto rapidamente altri due esempi analoghi al precedente. Nel primo la simulazione ha riguardato una Poisson con media $\mu = 0.5$, un valore decisamente inferiore al precedente e con un numero decisamente superiore di zeri (oltre il 60%).

```
> dpois(0,0.5)
[1] 0.6065307
> set.seed(654321)
> x <- rpois(100000,0.5)
> c(mean(x),var(x))
[1] 0.501730 0.500602
> sum(x==0)
[1] 60508
```

Dopo aver rimosso gli zeri, la media si è più che raddoppiata, mentre la varianza si è ridotta del 60%. La funzione `uniroot` trova la stima di μ (che coincide con il valore vero) in 4 iterazioni.

```
> y <- x[x > 0]
> c(mean(y),var(y))
[1] 1.2704598 0.2909579
> uniroot(g,c(0.1,1.3),mean(y))
$`root`
[1] 0.4995039
$f.root
[1] -1.83253e-06
$iter
[1] 4
```

Nel terzo esempio abbiamo scelto un valore “elevato” per il parametro μ ($\mu = 3$) che comporta un numero di zeri alquanto ridotto (il 5%). Questo comporta che la media del campione complessivo e quella del campione “troncato” siano molto simili. Anche in questo caso la funzione `uniroot` converge rapidamente alla stima $\hat{\mu}$ che è sostanzialmente coincidente con il valore vero.

```

> dpois(0,3)
[1] 0.04978707
> set.seed(654321)
> x <- rpois(100000,3)
> c(mean(x),var(x))
[1] 3.002550 3.005254
> sum(x==0)
[1] 4917
> y <- x[x > 0]
> c(mean(y),var(y))
[1] 3.157820 2.670345
> uniroot(g,c(1.5,3.5),mean(y))
$`root`
[1] 3.000714
$f.root
[1] 1.156831e-07
$iter
[1] 4

```

2.9 La variabile casuale binomiale negativa

Abbiamo definito la variabile casuale geometrica come quella che descrive il numero di estrazioni bernoulliane necessarie *prima* di osservare il *primo* successo (estrarre una pallina bianca, nell'esempio che avevamo proposto). Vogliamo generalizzare questo risultato, partendo ancora una volta da un esempio particolare. Troviamo la funzione di probabilità della variabile casuale X che descrive quante estrazioni bernoulliane dobbiamo fare *prima* di osservare il terzo successo, vale a dire estrarre la terza pallina bianca.

È evidente che il numero minimo di estrazioni in questo caso è 3; quindi $f(x) = 0$ quando $x < 2$. È altrettanto evidente che per estrarre la terza pallina bianca alla terza estrazione, anche le due precedenti devono aver dato pallina bianca. Abbiamo quindi la sequenza (*BBB*), la cui probabilità è (per l'indipendenza fra le estrazioni) p^3 (essendo p la probabilità di successo). Quindi $f(2) = p^3$ (ricordiamo che X è il numero di estrazioni bernoulliane che *precedono* il terzo successo, cioè la terza pallina bianca; questo è il motivo per cui abbiamo scritto $f(2)$ e non $f(3)$).

Calcoliamo ora $f(3)$; una possibile sequenza è, in questo caso, (*BBNB*), e la probabilità di questa sequenza è $p^3 \times (1 - p)$; un'altra possibile sequenza è (*BBNB*), che ha la stessa probabilità della precedente. Se riflettiamo, tutte le sequenze relative a questo caso devono avere *B* come evento associato all'ultima estrazione (la quarta), mentre nelle tre precedenti estrazioni *B* deve comparire due volte e *N* una sola volta. Sappiamo che ci sono 3 modi per estrarre due palline bianche e una nera eseguendo

tre estrazioni, quindi la probabilità cercata è

$$f(3) = \binom{3}{2} \times p^3 \times (1-p).$$

Ragionando in modo analogo, calcoliamo $f(4)$, vale a dire la probabilità che prima di estrarre la terza pallina bianca siano necessarie 4 estrazioni. Una possibile sequenza è $(BBNNB)$, e la probabilità di questa sequenza è $p^3 \times (1-p)^2$. Tutte le sequenze relative a questo caso devono avere B come evento associato all'ultima estrazione (la quinta), mentre nelle quattro ($x = 4$) precedenti estrazioni B deve comparire due volte e N due volte. Ci sono 6 modi per estrarre due palline bianche e 2 nere eseguendo quattro estrazioni, quindi la probabilità cercata è

$$f(4) = \binom{4}{2} \times p^3 \times (1-p)^2.$$

Come per la variabile casuale geometrica, il valore di x non è limitato superiormente (può arrivare a "infinito"). Quanto varrà allora $f(x)$ nel caso generale? Dal momento che stiamo trattando come esempio l'estrazione della terza pallina bianca, una particolare sequenza potrebbe iniziare con (BB) , proseguire con un numero di palline nere pari a $x-2$ e terminare con B . La probabilità di questa sequenza è quindi $p^3 \times (1-p)^{x-2}$. Tenendo conto del numero di modi in cui si possono estrarre 2 palline bianche in x estrazioni, abbiamo che

$$f(x) = \binom{x}{2} \times p^3 \times (1-p)^{x-2}$$

(osserviamo che quando $x = (2, 3, 4)$, la formula precedente ci dà i tre risultati già ottenuti). Possiamo calcolare i valori numerici scrivendo in R la funzione corrispondente al nostro esempio:

```
> f <- function(x,p) choose(x,2) * p^3 * (1-p)^(x-2)
```

e chiedendo di calcolare i valori per $x = (2, 3, 4)$ nel caso in cui la probabilità di successo è $p = 0.6$:

```
> x <- c(2:4)
> f(x, 0.6)
[1] 0.21600 0.25920 0.20736
```

Siamo ora pronti a generalizzare il nostro esempio considerando un numero qualsiasi k di successi ($k = 1, 2, 3, \dots$). Ragionando come abbiamo fatto in precedenza (quando abbiamo preso in esame il caso in cui $k = 3$), possiamo dire che per osservare k successi (essendo il risultato della k -esima prova necessariamente un successo), è necessario che nelle x prove *che precedono* il k -esimo successo si osservino $k-1$ successi e $x - (k-1)$ insuccessi. Allora la funzione di probabilità sarà data da

$$f(x) = \binom{x}{k-1} \times p^k \times (1-p)^{x-k+1}. \quad (2.17)$$

Se nella formula precedente poniamo $k = 1$ abbiamo la variabile casuale geometrica. Dal momento che in questo caso $k - 1$ è uguale a zero, il coefficiente binomiale vale 1, qualsiasi sia il valore di x . Analogamente, l'esponente $x - k + 1$ vale x e la funzione di probabilità corrispondente è $f(x) = p \times (1 - p)^x$, che è la funzione di probabilità della variabile casuale geometrica. Se invece $k = 3$ (l'esempio proposto all'inizio di questa sezione), avremo

$$f(x) = \binom{x}{2} \times p^3 \times (1 - p)^{x-2}$$

che coincide con la funzione di probabilità che avevamo ricavato analiticamente nell'esempio introduttivo.

Non è difficile scrivere con R una funzione che calcola i valori che assume la funzione di probabilità della variabile casuale binomiale negativa così come l'abbiamo appena definita:

```
> bn <- function(x,k,p) choose(x,(k-1)) * p^k * (1-p)^(x-k+1)
```

La funzione che abbiamo appena definita è molto “grezza” e presume che noi passiamo dei valori “corretti”, dal momento che non esegue alcuna verifica di “conformità” (ad esempio, il parametro p deve essere compreso fra zero e uno e il parametro k non deve essere zero o negativo; se così non fosse, dobbiamo aspettarci un messaggio di errore). Verifichiamo con la nostra funzione `bn` i valori che abbiamo calcolato in precedenza:

```
> x <- c(0:4)
> cbind(x,"f(x)"=bn(x,k=3,p=0.6))
      x      f(x)
[1,] 0 0.00000
[2,] 1 0.00000
[3,] 2 0.21600
[4,] 3 0.25920
[5,] 4 0.20736
```

Abbiamo fatto partire di proposito x da zero per far vedere come R, correttamente, assegni probabilità uguale a zero quando $x = 0$ oppure quando $x = 1$.²⁷

R ha la funzione `dnbinom` che permette di calcolare i valori assunti dalla funzione di probabilità della variabile casuale binomiale negativa. Questa funzione ha tre argomenti principali:

1. il primo argomento (x) è, come sempre, il valore o l'insieme di valori della variabile casuale per i quali si chiede di calcolare la probabilità;

²⁷Però darebbe un valore palesemente sbagliato (una probabilità negativa!) se ponessimo, ad esempio, $x = 0.5$; verificatelo.

2. il secondo argomento (*size*) corrisponde a quello che noi abbiamo chiamato k , cioè il numero finale di successi;
3. il terzo argomento (*prob*) rappresenta la probabilità p di successo.

C'è però da fare presente che un punto importante differenzia la funzione `dnbinom` da quella che abbiamo definito in precedenza. Considerazioni che sono al di là degli scopi di questo libro, “consigliano” di far partire i valori della variabile casuale binomiale negativa comunque da zero (indipendentemente dal valore di k , ovvero di *size*). Confrontiamo i risultati della nostra funzione `bn` con quelli della funzione `dnbinom`:

```
> x <- c(2,3,4); bn(x,k=3,p=0.6)
[1] 0.21600 0.25920 0.20736
> x <- c(2,3,4); dnbinom(x,3,0.6)
[1] 0.207360 0.138240 0.082944
```

I risultati sono palesemente diversi, come se una delle due funzioni fosse sbagliata! Tuttavia definendo opportunamente i valori di x quando si chiama `dnbinom` i risultati coincidono:

```
> x <- c(2,3,4); bn(x,k=3,p=0.6)
[1] 0.21600 0.25920 0.20736
> x <- c(0,1,2); dnbinom(x,3,0.6)
[1] 0.21600 0.25920 0.20736
```

Abbiamo quindi due (apparentemente) diverse definizioni per la “stessa” variabile casuale. La “nostra” definizione prevede che la variabile casuale X assuma valori per i quali la funzione di probabilità è diversa da zero che dipendono da k . Ad esempio, se $k = 1$ (la variabile casuale geometrica), allora x può partire da zero; se invece $k = 3$ allora x deve partire da 2. In generale, il primo valore al quale è associata una probabilità diversa da zero è $k - 1$.

La definizione impiegata da R (che è anche quella impiegata più in generale) fa invece riferimento ad una variabile casuale Y i cui valori partono sempre da zero, indipendentemente dal valore assunto dal parametro k . Di fatto queste due definizioni si possono considerare “equivalenti” se teniamo conto del fatto che $Y = X - (k - 1)$. Infatti, se $k = 1$ (la variabile casuale geometrica), allora $Y = X$ e le due definizioni coincidono. Se, invece, $k = 3$ (come nel nostro esempio), allora $Y = X - 2$. Abbiamo visto che, adottando la nostra definizione, il primo valore “valido” per la variabile casuale X (il primo valore per il quale $f(x) > 0$) era proprio 2; in questo caso, quindi, adottando la definizione impiegata da R si ha $Y = 0, 1, 2, \dots$. La probabilità restituita da `dnbinom` è la probabilità che siano necessarie $x - (k - 1)$ estrazioni prima di osservare il k -esimo successo.

In altre parole, la funzione di probabilità della variabile casuale binomiale negativa impiegando la definizione di R della variabile casuale Y è:

$$f(y) = \binom{k+y-1}{y} \times p^k \times (1-p)^y$$

dove i valori di y partono da zero e sono definiti come abbiamo detto in precedenza.

Può sembrare un modo piuttosto “contorto” di definire i valori della variabile casuale binomiale negativa. Tuttavia, come già accennato, in questo modo la variabile casuale binomiale negativa (e la funzione `dnbinom`) può essere impiegata come modello alternativo alla variabile casuale di Poisson per modellare dei conteggi in presenza di *sovradisersione* (vedi più avanti per il significato di questo termine). Inoltre, così facendo, una variabile casuale binomiale negativa con parametri k e p può essere vista come la somma di k variabili casuali geometriche indipendenti, ciascuna con lo stesso valore di p . Trovare valore atteso e varianza della variabile casuale binomiale negativa così definita è allora immediato:

$$E(X) = k \times \frac{1-p}{p}$$

$$Var(X) = k \times \frac{1-p}{p^2}.$$

Verifichiamolo in modo empirico riprendendo in esame l'esempio che ci ha accompagnato in questa sezione $k = 3, p = 0.6$. Se impieghiamo la “nostra” definizione (facendo cioè partire x da 2), abbiamo

```
> x <- c(2:999)
> f <- bn(x,k=3,p=0.6)
> sum(f)
[1] 1
> (m <- sum(x*f))
[1] 4
> sum((x-m)^2*f)
[1] 3.333333
```

Se impieghiamo la definizione di R (facendo cioè partire x da 0), abbiamo

```
> y <- c(0:999)
> f <- dnbinom(y,size=3,p=0.6)
> sum(f)
[1] 1
> (m <- sum(y*f))
[1] 2
> sum((y-m)^2*f)
[1] 3.333333
```

Quindi, le due medie sono diverse, mentre le due varianze sono uguali e non dipendono dalla definizione (nostra o di R). Questo perché, come abbiamo visto, le due definizioni sono uguali, a meno di una costante e si può passare dall'una all'altra mediante una *trasformazione lineare*: $Y = X - (k - 1)$ e $X = Y + (k - 1)$.

I valori teorici (basati sulla definizione “più generale” di R) sono

$$E(X) = 3 \times \frac{0.4}{0.6} = 3 \times \frac{2}{3} = 2$$

$$Var(X) = 3 \times \frac{0.4}{0.6^2} = 3 \times \frac{40}{36} = 3 \times \frac{10}{9} = \frac{10}{3}$$

Applicando le proprietà del valore atteso e della varianza, abbiamo quindi

$$E(X) = E(Y + (k - 1)) = E(Y) + (k - 1)$$

$$Var(X) = Var(Y + (k - 1)) = Var(Y).$$

Pertanto, nel nostro esempio in cui $k = 3$, $E(Y) = 2$ e, quindi, $E(X) = 2 + (3 - 1) = 4$, mentre $Var(X)$ e $Var(Y)$ coincidono.

Se indichiamo con μ il valore atteso di una variabile casuale binomiale negativa,

$$\mu = k \times \frac{1-p}{p}$$

allora possiamo scrivere la varianza σ^2 nel modo seguente

$$\sigma^2 = \mu \times \frac{1}{p}.$$

Se, ad esempio, $k = 99$ e p fosse molto vicino ad uno (ad esempio, $p = 0.99$), allora media e varianza sarebbero quasi uguali e la variabile casuale binomiale negativa sarebbe molto “simile” a quella di Poisson. Per valori di p lontani da 1, la varianza della variabile casuale binomiale negativa è (molto) *maggiore* della variabile casuale di Poisson con la stessa media. Si dice che nel caso della variabile casuale binomiale negativa si osserva *sovradispersione* (la varianza della binomiale negativa è maggiore della varianza di una Poisson con la stessa media). Pertanto, in una situazione reale nella quale devono essere analizzati dei conteggi, se la loro varianza (empirica) è (molto) superiore alla media, allora il modello poissoniano non è un buon modello e si può provare ad impiegare il modello binomiale negativo.

Infine rispondiamo alla domanda: perché l’aggettivo “negativa” associato al termine “binomiale”?

La definizione del coefficiente binomiale è

$$\binom{n}{x} = \frac{n!}{x!(n-x)!}.$$

L’espressione precedente può essere semplificata dividendo numeratore e denominatore per $(n-x)!$ ottenendo

$$\binom{n}{x} = \frac{n(n-1)(n-2) \cdots (n-x+1)}{x!}.$$

Si può allora generalizzare il coefficiente binomiale nel modo seguente:

$$\binom{-n}{x} = \frac{-n(-n-1)(-n-2)\cdots(-n-x+1)}{x!} = (-1)^x \binom{n+x-1}{x}.$$

Con questa generalizzazione la funzione di probabilità della variabile casuale binomiale negativa è

$$f(x) = \binom{-k}{x} \times p^k \times (p-1)^x$$

e il perché del nome *binomiale negativa* dovrebbe risultare evidente.

3 Variabili casuali continue

Le variabili casuali descritte nel capitolo precedente avevano tutte la caratteristica di essere *discrete*. In altre parole il numero di valori distinti che poteva assumere la variabile casuale era o finito (uniforme discreta, binomiale, ipergeometrica) o un' *infinità numerabile* (geometrica, Poisson, binomiale negativa).

Una seconda classe di variabili casuali è rappresentata dalle *variabili casuali continue*, le cui realizzazioni si possono pensare come il risultato di un processo di *misura*, in altre parole come un *numero reale*. Come ha fatto vedere Cantor, i numeri reali sono “molti di più” dei numeri interi e dei numeri razionali; per trattare con questi numeri diventano necessari gli strumenti del calcolo infinitesimale, in particolare le *derivate* e gli *integrali*.

Esiste una fondamentale differenza fra variabili casuali discrete e variabili casuali continue. Infatti per le prime la funzione di probabilità $f(x)$ rappresenta la (massa di) probabilità che la variabile casuale X assuma un valore *esattamente uguale* a x e la funzione di ripartizione $F(x)$, così come la media e la varianza, sono definiti come *somme*. Come vedremo concretamente fra poco, se X è una variabile casuale continua, allora la funzione di probabilità $f(x)$ non rappresenta più la probabilità che la variabile casuale X assuma un valore *esattamente uguale* a x e, proprio per marcare la differenza con il caso discreto, prende il nome di *funzione di densità di probabilità*; come faremo vedere fra poco, $f(x)$ non può essere interpretata come una probabilità. Abbiamo pertanto:

$$\begin{cases} f(x) = P(X = x) & \text{se } X \text{ è una variabile casuale discreta} \\ f(x) \neq P(X = x) & \text{se } X \text{ è una variabile casuale continua.} \end{cases}$$

La funzione di ripartizione $F(x)$ mantiene nel caso continuo lo stesso significato che aveva nel caso discreto, ma è definita mediante un *integrale*:

$$F(x) = P(X \leq x) = \int_{-\infty}^x f(u) du. \quad (3.1)$$

In analogia con quanto detto a proposito delle variabili casuali discrete, il valore atteso e la varianza di X sono

$$E(X) = \mu = \int_{-\infty}^{+\infty} xf(x)dx \quad (3.2)$$

$$\text{Var}(X) = \sigma^2 = \int_{-\infty}^{+\infty} (x - \mu)^2 f(x)dx. \quad (3.3)$$

Dalla (3.1) si ricava che $P(X = x) = 0^1$ qualsiasi sia il valore di x e qualsiasi sia la variabile casuale continua X e che $P(X \leq x) = P(X < x) = F(x)$. In generale i risultati associati ai segni $\leq$ e $<$, così come quelli associati ai segni $\geq$ e $>$ sono numericamente identici (a differenza di quanto avviene per le variabili casuali discrete).

Sempre dalla (3.1) si ricava che la funzione di densità di probabilità $f(x)$ di una variabile casuale continua X è la *derivata* della funzione di ripartizione (e quindi non è più una probabilità):²

$$f(x) = \lim_{\Delta x \rightarrow 0} \frac{F(x + \Delta x) - F(x)}{\Delta x}. \quad (3.4)$$

Una variabile casuale X continua deve soddisfare due condizioni. La prima,

$$f(x) \geq 0,$$

richiede che la funzione di densità di probabilità non sia mai negativa. La seconda,

$$\int_{-\infty}^{+\infty} f(x)dx = 1,$$

richiede che l'area sotto tutta la curva descritta dalla $f(x)$ sia esattamente uguale a 1.

Prima di prendere in esame le principali variabili casuali continue, vediamo due esempi a scopo illustrativo.

Consideriamo la funzione $f(x) = 5x - x^2$. Se ci limitiamo a considerare l'intervallo $[0, 5]$, allora $f(x)$ *potrebbe* rappresentare la funzione di densità di probabilità di una variabile casuale X , dal momento che nell'intervallo $[0, 5]$ assume soltanto valori positivi (o uguali a 0). Tuttavia l'area sotto la curva non è uguale a 1:

$$\int_0^5 (5x - x^2)dx = \frac{125}{6}.$$

Se però definiamo $f(x)$ nel modo seguente:

$$f(x) = \frac{6}{25}x - \frac{6}{125}x^2 \quad x \in [0, 5],$$

¹Secondo alcuni Autori, la probabilità che la variabile casuale X assuma un dato valore x non è tanto zero, quanto *infinitesima* (se $f(x) \neq 0$). Noi non adotteremo questo punto di vista.

²La probabilità che la variabile casuale X cada in un intervallo *infinitesimo* di estremi x e $x + dx$ è data da $P(x < X \leq x + dx) = f(x)dx$.

mentre $f(x) = 0$ al di fuori di questo intervallo, allora $f(x)$ può essere considerata la funzione di densità di probabilità di una variabile casuale X . Infatti, l'area sotto la curva della parabola descritta dalla $f(x)$ quando $x \in [0, 5]$ vale esattamente 1:

$$\int_0^5 \left(\frac{6}{25}x - \frac{6}{125}x^2 \right) dx = 1.$$

La funzione di ripartizione di X è quindi

$$F(x) = \int_0^x \left(\frac{6}{25}u - \frac{6}{125}u^2 \right) du = \frac{3}{25}x^2 - \frac{2}{125}x^3.$$

Osserviamo che $F(0) = 0$ e che $F(5) = 1$. Naturalmente la formula precedente non può essere impiegata per valori di $x < 0$ o per valori di $x > 5$, dal momento che $f(x) = 0$ al di fuori dell'intervallo $[0, 5]$.

La funzione di ripartizione nell'intervallo $[0, 5]$ assume tutti i valori compresi nell'intervallo $[0, 1]$. In particolare ci sarà un valore di x tale che $F(x) = 1/2$. Il valore di x che verifica questa uguaglianza prende il nome di *mediana* della variabile casuale X . Nel nostro esempio sarà necessario risolvere l'equazione

$$\frac{3}{25}x^2 - \frac{2}{125}x^3 = \frac{1}{2}.$$

C'è una sola soluzione all'interno dell'intervallo $[0, 5]$ ed è $x = 2.5$. In effetti la variabile casuale X che abbiamo definito è simmetrica e, quindi, la mediana corrisponde al valore centrale dell'intervallo $[0, 5]$. Osserviamo inoltre che 2.5 è anche la *moda* della variabile casuale X , cioè è il valore di x in corrispondenza del quale la funzione di densità di probabilità assume il suo valore *massimo*.

Il valore di x che soddisfa la relazione $F(x) = 1/4$ prende il nome di *primo quartile* (Q_1) della variabile casuale X , mentre quello che soddisfa la relazione $F(x) = 3/4$ prende il nome di *terzo quartile* (Q_3) della variabile casuale X ; il *secondo quartile* (Q_2) soddisfa la relazione $F(x) = 2/4$ e corrisponde, quindi, alla mediana. Pertanto, ad ogni variabile casuale X continua possiamo associare i valori dei tre quartili (i quartili sono 3 e non 4, dal momento che sono i valori della variabile casuale X all'interno dei quali l'area, cioè la probabilità, è uguale a $1/4$). Nel nostro esempio i tre quartili sono, rispettivamente, 1.631759, 2.5 e 3.368241.

Oltre ai quartili, si possono calcolare i *quintili* (cioè i valori ai quali sono associate probabilità $F(x)$ uguali a $1/5, 2/5, 3/5, 4/5$), i *decili* (probabilità uguale a $1/10, 2/10, \dots, 9/10$), i *centili* (probabilità uguale a $1/100, 2/100, \dots, 99/100$) e, più in generale, i *quantili*.

Il valore atteso di X è

$$E(X) = \int_{-\infty}^{+\infty} x \left(\frac{6}{25}x - \frac{6}{125}x^2 \right) dx = \frac{5}{2}.$$

Ci aspettavamo questo risultato, dal momento che, essendo la funzione di densità di probabilità simmetrica, media, moda e mediana coincidono. La varianza di X è

$$\text{Var}(X) = \int_{-\infty}^{+\infty} (x - 2.5)^2 \left(\frac{6}{25}x - \frac{6}{125}x^2 \right) dx = \frac{5}{4}.$$

Questo risultato si poteva ricavare più facilmente calcolando il valore atteso del quadrato di X :

$$E(X^2) = \int_{-\infty}^{+\infty} x^2 \left(\frac{6}{25}x - \frac{6}{125}x^2 \right) dx = \frac{15}{2}$$

e ricorrendo poi alla relazione

$$\text{Var}(X) = E(X^2) - (E(X))^2$$

che vale sia per le variabili casuali discrete sia per le variabili casuali continue

$$\frac{15}{2} - \left(\frac{5}{2} \right)^2 = \frac{5}{4}.$$

Come secondo esempio possiamo considerare la funzione $f(x) = x$. Se limitiamo i valori di x nell'intervallo $[0, \sqrt{2}]$, allora $f(x)$ può essere considerata una funzione di densità di probabilità dal momento che l'area sotto la retta $f(x) = x$ nell'intervallo $[0, \sqrt{2}]$ vale 1 (non è necessario calcolare l'integrale; basta saper calcolare l'area di un triangolo). La funzione di ripartizione è quindi

$$F(x) = \int_0^x u du = \frac{x^2}{2}.$$

In questo caso è facile calcolare il valore dei tre quartili ($1/\sqrt{2}$, 1 e $\sqrt{3}/\sqrt{2}$).

Il valore atteso di X , del quadrato di X e la varianza sono, rispettivamente, $2\sqrt{2}/3$, 1 e $2\sqrt{2}/9$.


3.1 La variabile casuale uniforme continua

Il caso forse più “semplice” da trattare di variabile casuale continua è rappresentato dalla *variabile casuale uniforme continua* (o *rettangolare*). Questa è una variabile casuale che può assumere valori reali in un intervallo limitato $[a, b]$, con a e b numeri reali tali che $a < b$; la sua funzione di densità di probabilità è data da:

$$f(x) = \frac{1}{b-a} \tag{3.5}$$

quando $a \leq x \leq b$; per valori di x esterni all'intervallo $[a, b]$, si ha $f(x) = 0$.

Questa variabile casuale soddisfa evidentemente la prima richiesta, $f(x) \geq 0$. Per verificare che anche la seconda richiesta è rispettata, basta calcolare l'area del rettangolo



che ha per base il segmento di lunghezza $b - a$ e per altezza il segmento $1/(b - a)$, area che, evidentemente, è esattamente uguale a 1.

La figura a fianco mostra il grafico della funzione di densità di probabilità di una variabile casuale X uniforme continua in cui $a = 120$ e $b = 140$.

In questo intervallo abbiamo $f(x) = \frac{1}{20}$ e l'area in grigio è uguale a $\frac{140-120}{20} = 1$.

La funzione di ripartizione di X è l'area del rettangolo che ha per altezza $1/(b - a)$ e per base la distanza $x - a$:

$$F(x) = \frac{x - a}{b - a}. \quad (3.6)$$

Dalla (3.6) si ricava immediatamente $F(a) = 0$ e $F(b) = 1$. Inoltre, abbiamo che $F(x) = 0 \forall x \leq a$ e che $F(x) = 1 \forall x \geq b$.

Sempre la (3.6) permette di calcolare agevolmente qualsiasi *quantile* di X . Ad esempio, se vogliamo trovare il primo quartile Q_1 di X basta risolvere (rispetto a x)

$$\frac{x - a}{b - a} = 0.25,$$

da cui si ricava

$$Q_1 = \frac{3a + b}{4}.$$

Analogamente, la *mediana* (cioè il secondo quartile Q_2) è uguale a

$$Q_2 = \frac{a + b}{2}$$

e il terzo quartile Q_3 è uguale a


$$Q_3 = \frac{a + 3b}{4}.$$

Proviamo ora a considerare i seguenti valori per a e b : $a = 0.1$; $b = 0.2$. In questo caso la variabile casuale uniforme continua X può assumere qualsiasi valore nell'intervallo $[0.1, 0.2]$. La sua funzione di densità di probabilità è data da

$$f(x) = \frac{1}{0.2 - 0.1} = 10,$$

ma, evidentemente, questo valore (10) non può certo essere una probabilità. Eppure l'area del rettangolo di base 0.1 (cioè $0.2 - 0.1$) e altezza 10 è esattamente uguale a 1 e l'area corrispondente a qualsiasi intervallo risulta compresa fra gli estremi 0 e 1.

Calcolare le probabilità associate ad intervalli di una variabile casuale uniforme continua è facile come calcolare l'area di un rettangolo, perché di questo si tratta.



Sia X una variabile casuale uniforme continua sull'intervallo $[5, 15]$ con funzione di densità di probabilità $f(x) = 1/10$.

Vogliamo trovare $P(7.5 < X \leq 12.5)$.

Dalla figura a fianco è immediato vedere che la risposta alla domanda è l'area del rettangolo di altezza $1/10$ e base $12.5 - 7.5 = 5$, cioè $P(7.5 < X \leq 12.5) = 0.5$.

Mostriamo ora una procedura apparentemente più complicata, ma che è valida per qualsiasi variabile casuale continua (e non solo per la uniforme). La risposta

alla domanda precedente si può dare anche calcolando la differenza fra i valori che assume la funzione di ripartizione nei due punti considerati, vale a dire $F(12.5) - F(7.5)$.

Infatti, dalla (3.6) si ricava che, nel caso in parola, $F(x) = (x - 5)/10$ e, quindi, $F(12.5) = 0.75$ e $F(7.5) = 0.25$. Quindi $P(7.5 < X \leq 12.5) = F(12.5) - F(7.5) = 0.75 - 0.25 = 0.5$.³

Questo è il modo con cui possiamo chiedere a R di calcolare $P(x_1 \leq X \leq x_2)$ per una variabile casuale uniforme con parametri a e b . La funzione di ripartizione $F(q)$ è data da `punif`; il primo argomento è q , cioè l'estremo superiore dell'intervallo di integrazione e i due successivi (`min` e `max`) corrispondono ai parametri che abbiamo chiamato a e b . Calcoliamo quindi i valori richiesti nel nostro esempio: $F(7.5)$, $F(12.5)$ e $P(7.5 < X \leq 12.5)$.

```
> punif(7.5, 5, 15)
[1] 0.25
> punif(12.5, 5, 15)
[1] 0.75
> punif(12.5, 5, 15) - punif(7.5, 5, 15)
[1] 0.5
```

Non è difficile dimostrare⁴ che, se X è una variabile casuale uniforme continua fra a e b , la sua media è

$$E(X) = \mu = \frac{a+b}{2}$$

e la sua varianza è

$$\text{Var}(X) = \sigma^2 = \frac{(b-a)^2}{12}.$$

³In generale, quando X è una variabile casuale continua, si ha $P(a < X \leq b) = F(b) - F(a)$.

⁴Lo facciamo nell'appendice *online*.

Fra gli infiniti valori che possono essere assegnati ai parametri a e b , ve ne sono due “privilegiati”: $a = 0$ e $b = 1$. Le funzioni di R legate alla variabile casuale uniforme continua assegnano questi due valori di *default* ai parametri a e b . In particolare, la funzione `runif` estrae un *numero pseudo-casuale* distribuito uniformemente fra 0 e 1 (a meno di non assegnare esplicitamente altri valori agli argomenti `min` e `max` della funzione `runif`). La possibilità di generare numeri pseudo-casuali distribuiti uniformemente fra 0 e 1 è una richiesta che qualsiasi linguaggio che voglia permettere di fare simulazioni deve soddisfare. R offre più di una possibilità a questo proposito; il libro *Problemi ed esperimenti di statistica con R* dedica alcune pagine (in particolare le pagine 19, 20 e 21) a questo proposito.

A titolo di esempio, generiamo 100000 valori uniformemente distribuiti tra 5 e 15 e calcoliamone la media e la varianza:

```
> set.seed(123456)
> x <- runif(100000,5,15)
> c(mean(x),var(x))
[1] 9.991027 8.359658
```

che risultano sostanzialmente uguali ai valori teorici (10 e 25/3).

Potremmo voler visualizzare la distribuzione di frequenza dei valori simulati mediante un istogramma, per valutare visivamente la *bontà di adattamento* ad una uniforme. Il risultato è presentato nel pannello di sinistra della Figura 3.1; il grafico è stato prodotto con le seguenti istruzioni:

```
> tmp <- hist(x,main="",xlab="",prob=TRUE)
> box()
> abline(h=0.1,lty=3,lwd=2)
```




Figura 3.1: Istogramma relativo all'estrazione di 100000 valori uniformemente distribuiti fra 5 e 15 (a sinistra) e corrispondente grafico quantile–quantile per valutare l'adattamento alla distribuzione teorica.

Abbiamo assegnato il valore TRUE all'argomento `prob` in modo che l'istogramma abbia un'area totale uguale a 1 e i valori sull'asse delle ordinate corrispondano a densità di probabilità. L'ultima istruzione disegna un segmento orizzontale in corrispondenza dell'ordinata 0.1, che è la densità teorica per una uniforme tra 5 e 15 ($1/(15 - 5)$).

L'adattamento è senz'altro più che soddisfacente (del resto il numero delle osservazioni è molto elevato e tale da eliminare quasi del tutto le fluttuazioni campionarie). Vogliamo tuttavia esporre un metodo grafico del tutto generale per valutare l'adattamento di un campione di n osservazioni ad una distribuzione data; si tratta del *grafico quantile-quantile* o *Q-Q plot*. Una illustrazione estesa si trova in Espa e Micciolo (2012). Qui ne ricorderemo solo gli aspetti principali.

Il *Q-Q plot* è un metodo grafico per confrontare le distribuzioni di due variabili X e Y . La lettera Q è acronimo di *quantile* e il *Q-Q plot* si costruisce appunto presentando in un grafico i quantili di X e di Y , permettendo così il confronto fra le loro distribuzioni. Se queste sono simili, i punti del *Q-Q plot* si disporranno approssimativamente lungo la retta $x = y$. Se le due distribuzioni sono linearmente correlate, i punti che compongono il *Q-Q plot* saranno ancora disposti approssimativamente lungo una retta che non necessariamente sarà $x = y$.

Nel nostro caso vogliamo confrontare i quantili osservati sul campione con quelli attesi sulla base di una distribuzione uniforme fra 5 e 15 di modo che il generico punto del *Q-Q plot* ha per coordinate il p -mo quantile della distribuzione teorica (asse delle ascisse) ed il corrispondente quantile della distribuzione osservata (asse delle ordinate).⁵

Possiamo, ad esempio, calcolare i decili del campione simulato ricorrendo alla funzione `quantile` di R (specificando, come secondo argomento, i valori delle probabilità corrispondenti):

```
> p <- seq(0.1,0.9,0.1)
> qc <- quantile(x,p)
> round(qc,0)
10% 20% 30% 40% 50% 60% 70% 80% 90%
  6   7   8   9  10  11  12  13  14
```

e confrontarli con i corrispondenti decili teorici, ricorrendo alla funzione `qunif` (specificando i valori di a e b):

```
> qt <- (qunif(p,5,15))
> round(qt,0)
[1]  6  7  8  9 10 11 12 13 14
```

I risultati appaiono identici (non considerando i decimali).

Il campione simulato è così numeroso che possiamo calcolare i centili e andare anche oltre. Il risultato dello *script* che segue è riportato nel pannello di destra della

⁵Naturalmente, il ruolo degli assi può essere scambiato.

Figura 3.1. Il grafico corrisponde alla bisettrice, ad indicare la perfetta aderenza dei dati del campione alla distribuzione teorica.

```
> p <- seq(0.001,0.999,0.001)
> qc <- quantile(x,p)
> qt <- (qunif(p,5,15))
> plot(qt,qc,xlab="Quantili teorici",ylab="Quantili campionari")
```

La distribuzione triangolare

Prendiamo due variabili casuali uniformi X_1 e X_2 fra loro indipendenti e con gli stessi parametri a e b ; diciamo che X_1 e X_2 sono *indipendenti e identicamente distribuite*, impiegando d'ora in avanti l'acronimo *i.i.d.*. Consideriamo ora la variabile casuale $X = X_1 + X_2$. Sappiamo calcolare immediatamente il valore atteso e la varianza (sono entrambi il doppio dei valori "originali"). Quale sarà la distribuzione di X ? Vediamolo con una simulazione (impiegando, come in precedenza, i valori 5 e 15 come parametri della uniforme).

```
> set.seed(654321)
> x1 <- runif(100000,5,15)
> x2 <- runif(100000,5,15)
> x <- x1 + x2
> c(mean(x),var(x))
[1] 20.01592 16.68382
```

Il valore atteso e la varianza sono del tutto sovrapponibili ai valori teorici (20 e 50/3). L'istogramma prodotto da `hist(x,prob=TRUE)` è visualizzato (sotto forma di densità di probabilità) nel pannello di sinistra della Figura 3.2. Le due linee scure sono state prodotte dalle istruzioni `lines(c(10,20),c(0,0.1))` e `lines(c(20,30),c(0.1,0))` e rendono del tutto evidente il perché del termine "triangolare". Analogamente al caso discreto (ad esempio la somma risultante dal lancio di due dadi), la distribuzione è simmetrica e si estende da $2a$ a $2b$; il valore centrale (cioè la mediana, che corrisponde anche alla moda e alla media della distribuzione) è quindi $(a+b)$. La funzione di densità di probabilità cresce linearmente partendo dal punto di coordinate $(2a,0)$ fino al punto di coordinate $(a+b,y_M)$ per poi decrescere linearmente fino al punto di coordinate $(2b,0)$. Il valore di y_M (il massimo della distribuzione) si può ottenere ricordando la formula per calcolare l'area di un triangolo. Infatti, considerando il triangolo rettangolo che ha per base $b-a$ e per altezza y_M , avremo $\frac{(b-a)y_M}{2} = \frac{1}{2}$ e, quindi, $y_M = \frac{1}{b-a}$ (la densità della variabile casuale uniforme che ha "generato" la distribuzione triangolare).

Anche in questo caso l'adattamento appare ottimo. Possiamo confrontare i quantili osservati con quelli teorici facendo ricorso al *package* `triangle`. I decili osservati e quelli teorici coincidono (se non consideriamo i decimali)

```
> p <- seq(0.1,0.9,0.1)
> qc <- quantile(x,p)
```




Figura 3.2: Istogramma relativo all'estrazione di 100000 valori distribuiti come un variabile casuale triangolare fra 10 e 30 (a sinistra) e corrispondente grafico *quantile-quantile* per valutare l'adattamento alla distribuzione teorica.

```
> round(qc,0)
10% 20% 30% 40% 50% 60% 70% 80% 90%
 14  16  18  19  20  21  22  24  26
> qt <- (qtriangle(p,10,30,20))
> round(qt,0)
[1] 14 16 18 19 20 21 22 24 26
```

e anche il *Q-Q plot* (riportato nel pannello di destra della Figura 3.2) rivela una concordanza quasi assoluta.

Scrivere la funzione di densità di probabilità della variabile casuale triangolare come l'abbiamo considerata (somma di due uniformi i.i.d fra a e b) è piuttosto “laborioso”. Si tratta di scrivere l'equazione di due rette con coefficiente angolare di segno opposto, ma uguale in valore assoluto⁶ che si intersecano in un punto noto⁷

$$f(x) = \begin{cases} 0, & x < 2a, \\ \frac{x-2a}{(b-a)^2}, & 2a \leq x < (a+b), \\ \frac{1}{b-a}, & x = (a+b), \\ \frac{2b-x}{(b-a)^2}, & (a+b) < x \leq 2b, \\ 0, & x > 2b. \end{cases}$$

⁶ $\frac{1}{(b-a)^2}$.

⁷ Le coordinate sono $(a+b, \frac{1}{a+b})$.

In realtà potremmo considerare una definizione più generale di variabile casuale triangolare X come derivante dalla somma di due variabili casuali uniformi X_1 e X_2 indipendenti, distribuite, rispettivamente, fra a_1 e b_1 e fra a_2 e b_2 . In questo caso la variabile casuale risultante non sarebbe più (necessariamente) simmetrica. Per ricavare la funzione di densità di probabilità di X si può ricorrere ad un procedimento noto sotto il nome di *convoluzione* che presenteremo nell'appendice *online*. Ricordiamo che il *package* `triangle` è in grado di gestire una variabile casuale triangolare in tutta generalità.

Può essere interessante vedere come si modifica la distribuzione di probabilità se sommiamo, ad esempio, 18 uniformi i.i.d., come abbiamo fatto in questo *script*:

```
> set.seed(135246)
> X <- runif(100000*18,5,15)
> Y <- matrix(X,ncol=18)
> x <- rowSums(Y)
> c(mean(x),var(x))
[1] 180.0314 149.6782
```

Lo *script* è molto compatto, in quanto genera 1800000 valori (100000×18) che vengono poi organizzati in una matrice con 18 colonne. I 100000 valori del campione si ottengono mediante la funzione `rowSums`. Valore atteso e varianza sono corrispondenti a quelli teorici (180 e 150). La Figura 3.3 mostra gli istogrammi che si ottengono con 20 e 100 classi. In questo secondo caso è ben evidente come la variabile casuale risultante dalla somma di 18 uniformi i.i.d. abbia un andamento molto “regolare”, a forma di “campana” (*bell shaped*).




Figura 3.3: Istogramma relativo all'estrazione di 100000 valori derivanti dalla somma di 18 variabili casuali uniformi i.i.d. (ciascuna con parametri $a = 5$ e $b = 15$). A sinistra il numero delle classi è 20. A destra il numero delle classi è 100.

3.2 La variabile casuale esponenziale

Quando la variabile casuale oggetto di studio può assumere solo valori positivi e, in particolare, quando si possa assimilare ad un *tempo di accadimento* (*failure time*) ovvero a un *tempo di sopravvivenza*, la variabile casuale esponenziale può essere considerata la variabile casuale più “semplice” da prendere in considerazione. Dovremmo chiamarla variabile casuale *esponenziale negativa*, ma ometteremo sempre il termine “negativa”, dal momento che una variabile casuale esponenziale positiva non è di impiego comune.

Una variabile casuale esponenziale è una variabile casuale T continua che può assumere valori reali positivi ($T \geq 0$) e che ha la seguente funzione di densità di probabilità:

$$f(t) = \lambda e^{-\lambda t}. \quad (3.7)$$

La variabile casuale esponenziale ha un solo parametro ($\lambda > 0$), che è il reciproco del valore atteso di T :

$$E(T) = \frac{1}{\lambda},$$

mentre la varianza è data da

$$Var(T) = \frac{1}{\lambda^2}.$$

La funzione di ripartizione è:

$$F(t) = 1 - e^{-\lambda t}, \quad (3.8)$$

mentre il suo complemento a 1 prende il nome di *funzione di sopravvivenza*

$$S(t) = e^{-\lambda t}.$$

In effetti potremmo definire più in generale la *funzione di sopravvivenza* di una variabile casuale T :


$$P(T > t) = 1 - P(T \leq t) = 1 - F(t) = S(t).$$

Se si moltiplica la media di una variabile casuale esponenziale per il logaritmo naturale di $1/2$ e si cambia il segno (cioè, approssimando, se si moltiplica per 0.693), si ottiene la mediana di T . Più precisamente:

$$Q_2 = -\frac{\log(1/2)}{\lambda}$$

(dove il logaritmo è in base e). Se T è un *tempo*, talvolta Q_2 è detto *tempo di dimezzamento* o *emivita*.

Dalla (3.7) osserviamo che $f(0) = \lambda$.



La figura mostra un esempio di variabile casuale esponenziale per la quale $\lambda = 0.068$. Possiamo calcolare agevolmente le aree indicate ricorrendo alla (3.8). Infatti:

$$P(T \leq 6) = F(6) = 1 - e^{-0.068 \times 6} \simeq 0.335$$

$$P(6 \leq T \leq 18) = F(18) - F(6) \simeq 0.371.$$

Possiamo verificare i risultati precedenti ricorrendo alla funzione `pexp` di R che fornisce il valore della funzione di ripartizione $F(t)$ corrispondente all'argomento `q`. Il secondo argomento (`rate`) è il nostro λ . Quindi $F(6)$, $F(18)$ e $P(6 \leq X \leq 18)$ sono:

```
> pexp(6,0.068)
[1] 0.3350211
> pexp(18,0.068)
[1] 0.7059484
> pexp(18,0.068) - pexp(6,0.068)
[1] 0.3709273
```

La variabile casuale esponenziale trova impiego in varie discipline, tra le quali la fisica e l'ingegneria. Il tempo impiegato da un pezzo meccanico per rompersi è spesso distribuito in modo esponenziale. In fisica, il tempo che impiega un atomo di una sostanza radioattiva per subire una disintegrazione è distribuito in modo esponenziale. Analogamente, un neutrone *libero* (cioè al di fuori del nucleo) è instabile e ha un'emivita di circa 15 minuti (e decade emettendo un elettrone e un antineutrino, secondo quello che è chiamato decadimento beta); il valore atteso del tempo di decadimento è (circa) 21.64 minuti. La media è (molto) più grande della mediana; infatti, la variabile casuale esponenziale è molto asimmetrica.

Eseguiamo una simulazione estraendo 100000 osservazioni da una variabile casuale esponenziale con $\lambda = 0.0462$ (di modo che il valore atteso sia circa 22 minuti e la mediana 15 minuti). Impieghiamo a questo scopo la funzione `rexp`, il cui secondo argomento è il valore di λ .

```
> set.seed(123456)
> x <- rexp(100000,0.0462)
> c(median(x),mean(x))
[1] 15.03604 21.71019
```

Osserviamo che mediana e media sono molto vicine ai valori teorici. La distribuzione di frequenza dei valori simulati è riportata nel pannello di sinistra della Figura 3.4 insieme alla funzione di densità di probabilità teorica ottenuta con l'istruzione `curve(dexp(x,0.0462),add=TRUE)`, mentre in quello di destra è riportato il *Q-Q plot*, ottenuto in modo analogo a quanto fatto a proposito della uniforme e della triangolare (impiegando la funzione `qexp`).




Figura 3.4: Istogramma relativo all'estrazione di 100000 valori distribuiti come una variabile casuale esponenziale ($\lambda = 0.0462$) e corrispondente grafico *quantile-quantile* per valutare l'adattamento alla distribuzione teorica.

Esiste un interessantissimo legame fra la variabile casuale esponenziale e la variabile casuale di Poisson.⁸ Abbiamo detto che il tempo necessario per osservare una disintegrazione radioattiva è distribuito in modo esponenziale. Ebbene, se contiamo il numero di disintegrazioni in un periodo fissato, allora tale numero è distribuito come una Poisson. Possiamo verificare questa relazione mediante la simulazione proposta di seguito.

Il “cuore” della simulazione consiste nell'estrarre un campione di n tempi $t_1, t_2, \dots, t_n$ da una esponenziale e nel calcolarne i valori cumulati: $T_1 = t_1$, $T_2 = t_1 + t_2$, $T_3 = t_1 + t_2 + t_3$, ... Ecco un esempio:

```
> lambda=5
> t <- rexp(10,lambda)
> T <- cumsum(t)
> round(rbind(t,T),2)
t 0.15 0.24 0.03 0.03 0.09 0.58 0.25 0.11 0.19 0.03
T 0.15 0.39 0.42 0.44 0.53 1.11 1.36 1.46 1.66 1.69
```

L' i -esimo elemento del vettore T è il tempo di attesa che è stato necessario per osservare l' i -esimo evento. Contiamo quanti eventi sono stati osservati in un intervallo di tempo *unitario*, ovvero contiamo il numero X di tempi T minori o uguali a 1; questo numero è la realizzazione della variabile casuale X di Poisson associata. Nel nostro esempio $X = 5$.⁹ Questo processo va ripetuto un numero molto grande di volte, in

⁸Per ulteriori dettagli, si veda l'appendice *online*.

⁹Infatti, se il tempo è misurato in minuti, abbiamo dovuto aspettare 1.11 minuti per osservare il sesto evento; quindi allo scadere di 1 minuto erano stati osservati 5 eventi.

modo da avere un gran numero di realizzazioni di X . Nella simulazione che segue abbiamo ripetuto il processo 10000 volte (`nrep`), fissando $\lambda = 1.5$ e estraendo ogni volta 20 (`nexp`) tempi distribuiti come una esponenziale (il numero 20 è sufficiente a garantire che, nel nostro caso, ogni volta il totale dei tempi sia almeno uguale a 1; abbiamo comunque voluto aggiungere un *check* che interromperebbe la simulazione nel caso in cui questo non si verifici).

```
> lambda <- 1.5
> nrep <- 10000
> nexp <- 20
> ris <- numeric(nrep)
> tot <- matrix(nrow=nrep,ncol=nexp)
> set.seed(123456)
> for (i in 1:nrep){
+   t <- rexp(nexp,lambda)
+   T <- cumsum(t)
+   if\index[funr]{if} (sum(t) < 1) stop("Numero di tempi insufficiente.")
+   tot[i,] <- t
+   x <- length(which(T <= 1))
+   ris[i] <- x
+ }
```

La mediana di tutti i tempi estratti è molto vicina al valore teorico:

```
> c(median(tot),-log(0.5)/lambda)
[1] 0.4621570 0.4620981
```

così come la media è del tutto sovrapponibile a $1/\lambda$:

```
> m <- mean(tot)
> c(m,1/m)
[1] 0.6678989 1.4972326
```

Anche la media delle realizzazioni della variabile casuale X di Poisson è molto vicina al parametro λ :

```
> mean(ris)
[1] 1.4878
```

Noi però vogliamo vedere le frequenze osservate e confrontarle con quelle teoriche di una variabile casuale di Poisson con $\lambda = 1.5$:

```
> fo <- table(ris)
> fa <- dpois(c(0:8),lambda)*nrep
> rbind(fo,fa=round(fa,1))
```

	0	1	2	3	4	5	6	7	8
fo	2266.0	3380	2471.0	1236.0	453.0	144.0	36.0	12.0	2.0
fa	2231.3	3347	2510.2	1255.1	470.7	141.2	35.3	7.6	1.4

Le frequenze osservate sono state ottenute con la funzione `table`, mentre per ottenere quelle teoriche abbiamo prima calcolato le probabilità poissoniane corrispondenti ai valori di X da 0 a 8,¹⁰ e poi le abbiamo moltiplicate per il numero di repliche. L'adattamento si può considerare davvero soddisfacente.

La variabile casuale Gamma

Abbiamo visto che la somma di due uniformi è una distribuzione triangolare. Se sommiamo due esponenziali i.i.d. quale sarà la distribuzione risultante? Lo vediamo con una simulazione.

```
> lambda <- 0.0462
> n <- 2
> set.seed(123456)
> u <- rexp(100000*n,lambda)
> v <- matrix(u, ncol=n)
> x <- rowSums(v)
> c(mean(x),var(x))
[1] 43.37006 934.43809
> c(n/lambda,n/lambda^2)
[1] 43.29004 937.01392
> median(x)
[1] 36.3984
```

Riprendendo un esempio discusso in precedenza, abbiamo preso in esame due variabili casuali esponenziali T_1 e T_2 i.i.d. con $\lambda = 0.0462$. Per ciascuna di esse abbiamo generato 100000 valori, che poi sono stati sommati per ottenere quelli relativi alla variabile casuale $T = T_1 + T_2$ che vogliamo studiare. La media e la varianza di T sono il doppio della media e della varianza di T_1 (ovvero di T_2) e le stime calcolate sulle 100000 osservazioni sono in perfetto accordo con quanto ci si aspettava. La mediana di T è alquanto inferiore alla media, per cui la distribuzione di T sarà asimmetrica “positiva” (cioè con una coda più lunga a destra).

Per quanto riguarda la funzione di densità di probabilità di T , la si può ottenere mediante la *convoluzione* delle densità di T_1 e T_2 ; il risultato è il seguente (naturalmente $t > 0$)

$$f(t) = \lambda^2 t e^{-\lambda t} \quad (3.9)$$

Il pannello di sinistra della Figura 3.5 mostra l'istogramma relativo ai valori ottenuti mediante la simulazione con la funzione di densità di probabilità teorica sovrapposta. Nel pannello di destra della stessa figura è riportato l'istogramma relativo ai valori ottenuti mediante una seconda simulazione nella quale abbiamo considerato la somma

¹⁰La somma di queste probabilità è uguale a 0.9999723, per cui possiamo trascurare i valori maggiori di 8.




Figura 3.5: Istogramma relativo all'estrazione di 100000 valori distribuiti come la somma di 2 variabili casuali esponenziali i.i.d. con parametro $\lambda = 0.0462$ (a sinistra) e come la somma di 10 variabili casuali esponenziali i.i.d. con parametro $\lambda = 0.0462$ (a destra). La linea continua sovrapposta è la funzione di densità di probabilità teorica.

di 10 esponenziali i.i.d. (con $\lambda = 0.0462$). Non riportiamo lo *script* che è uguale al precedente, con l'unica variante `n <- 10` nella seconda riga. Media e varianza sono sostanzialmente equivalenti a quelle teoriche e la mediana conferma l'asimmetria della distribuzione risultante.

```
> c(mean(x), var(x))
[1] 216.5552 4681.8321
> c(n/lambda, n/lambda^2)
[1] 216.4502 4685.0696
> median(x)
[1] 209.3423
```

La funzione di densità di probabilità teorica della somma di n variabili casuali esponenziali i.i.d. con lo stesso parametro λ è un caso particolare di una importante variabile casuale detta *Gamma*:

$$f(t) = \frac{\lambda e^{-\lambda t} (\lambda t)^{n-1}}{\Gamma(n)}; \quad (3.10)$$

(anche in questo caso $t > 0$). Il denominatore $\Gamma(n)$ è la *funzione Gamma* e fa sì che l'integrale della (3.10) fra 0 e $+\infty$ sia uguale a 1. Rimandiamo all'appendice *online* per ulteriori considerazioni sulla funzione Gamma.¹¹

¹¹Ricordiamo che quando l'argomento della funzione Gamma è un numero naturale n maggiore di zero (come nel caso che stiamo trattando), $\Gamma(n) = (n-1)!$.

La variabile casuale Gamma come l'abbiamo definita (somma di n variabili casuali esponenziali i.i.d. con lo stesso valore di λ) può essere vista come un modello probabilistico relativo al tempo di attesa per osservare l' n -esimo evento.

Per disegnare la funzione di densità di probabilità teorica nella Figura 3.5 abbiamo impiegato la funzione `dgamma` assegnando all'argomento `shape` il valore 2 nella prima simulazione e 10 nella seconda e all'argomento `rate` il valore 0.0462 (vale a dire λ).

```
curve(dgamma(x, shape=2, rate=0.0462), add=TRUE, lwd=2)
curve(dgamma(x, shape=10, rate=0.0462), add=TRUE, lwd=2)
```

Il lettore interessato potrà verificare che, mantenendo fisso il valore di λ , al crescere di n (cioè del numero di esponenziali sommate) la funzione di densità di probabilità tende ad assumere una forma “a campana”, come abbiamo già visto in altre circostanze.

3.2.1 La funzione azzardo

La funzione di densità di probabilità di una variabile casuale continua X descrive la forma del grafico di X , mentre l'area sotto il grafico tra due punti x_1 e x_2 rappresenta la probabilità che X assuma un valore compreso nell'intervallo $[x_1, x_2]$. Tuttavia, quando la variabile casuale è un tempo di sopravvivenza si può porre una seconda domanda dal contenuto informativo (forse più) rilevante. Consideriamo il seguente esempio.

Il tempo di vita T (in migliaia di ore) di un componente elettronico segue una legge esponenziale con parametro $\lambda = 0.02$. Qual è la probabilità che quel componente elettronico abbia un tempo di vita compreso fra 1 e 2 (cioè fra 1000 e 2000 ore)? Qual è la probabilità che quel componente elettronico abbia un tempo di vita compreso fra 1 e 2, sapendo che il suo tempo di vita è superiore a 1?

La prima è una domanda *standard*, che ha una risposta immediata, facendo ricorso alla funzione di ripartizione $F(t): F(2) - F(1)$. La funzione di densità di probabilità della variabile casuale T in parola è data da $f(t) = 0.02e^{-0.02t}$ e, quindi, la funzione di ripartizione è $F(t) = 1 - e^{-0.02t}$. Abbiamo quindi $P(1 \leq T \leq 2) = F(2) - F(1) = 0.0392 - 0.0198 = 0.0194$.

La seconda domanda è più interessante, dal momento che chiede di calcolare una probabilità *condizionata*. In simboli la richiesta è $P(1 \leq T \leq 2 | T > 1)$ e, trattandosi di un tempo di sopravvivenza, in generale l'interesse consiste nel calcolare la probabilità di osservare l'evento (cioè che il componente elettronico si guasti) in un certo intervallo di tempo, limitatamente al caso in cui sia ancora funzionante (cioè “vivo”) all'inizio dell'intervallo.

Se indichiamo con A l'evento $(1 \leq T \leq 2)$ e con B l'evento $(T > 1)$, allora, in base alla definizione di probabilità condizionata,

$$P(A|B) = \frac{P(A \cap B)}{P(B)}.$$

Al numeratore dobbiamo calcolare la probabilità associata all'intersezione fra gli eventi A e B , cioè $(1 \leq T \leq 2) \cap (T > 1)$; l'evento risultante è $(1 < T \leq 2)$, cioè, in sostanza,

l'evento A la cui probabilità è $F(2) - F(1)$ (calcolata in risposta alla prima domanda). Al denominatore dobbiamo calcolare la probabilità di sopravvivenza associata al tempo $T = 1$, quindi $S(1)$. Ricordando che $F(t) = 1 - e^{-0.02t}$ e che $S(t) = e^{-0.02t}$ abbiamo

$$P(A|B) = \frac{F(2) - F(1)}{S(1)} = \frac{0.0194}{0.9802} = 0.0198.$$

Rispondiamo ora alla seguente domanda di carattere più "generale". Sia T un "tempo di sopravvivenza" che si distribuisce come una variabile casuale esponenziale con parametro λ . Qual è la probabilità che la variabile casuale T assuma un valore compreso fra t e $t + \Delta t$, sapendo che il tempo di sopravvivenza è superiore a t ? Ragionando come nel caso precedente, troveremo che la risposta è data da

$$P(A|B) = \frac{F(t + \Delta t) - F(t)}{S(t)} = \frac{e^{-\lambda t} - e^{-\lambda(t + \Delta t)}}{e^{-\lambda t}}.$$

Naturalmente se $\Delta t = 0$ avremo che $P(A|B) = 0$, dal momento che il numeratore (ma non il denominatore) sarà uguale a zero. Ricordando però la (3.4) possiamo ricavare, in termini del tutto generali, la *densità di probabilità* associata all'evento A , che sarà

$$\lim_{\Delta t \rightarrow 0} \frac{F(t + \Delta t) - F(t)}{\Delta t},$$

quindi proprio $f(t)$.

Ecco allora che possiamo definire una nuova funzione $\lambda(t)$, che rappresenta una sorta di *densità di probabilità condizionata*, nel modo seguente:

$$\lambda(t) = \lim_{\Delta t \rightarrow 0} \frac{F(t + \Delta t) - F(t)}{\Delta t S(t)} = \frac{f(t)}{S(t)}. \quad (3.11)$$

La (3.11) prende il nome di *funzione azzardo* (*hazard function* o, anche *hazard rate* in inglese) o *forza di mortalità* (in particolare quando impiegata in demografia).

In un certo senso $\lambda(t)dt$ è la probabilità di osservare l'evento nell'intervallo infinitesimo dt dato che (condizionatamente al fatto che) l'evento non era accaduto fino al tempo t ($T > t$).

La (3.11) si può esprimere in un modo equivalente se ricordiamo la regola di derivazione di una funzione composta; infatti, se consideriamo non tanto la funzione di sopravvivenza $S(t) = 1 - F(t)$, quanto piuttosto il suo logaritmo naturale $\log(S(t)) = \log(1 - F(t))$ abbiamo

$$\lambda(t) = -\frac{d}{dt} \log(S(t)) = \frac{f(t)}{S(t)}. \quad (3.12)$$

Guardando questa formulazione, possiamo definire la *funzione azzardo cumulativo*, che è l'integrale della funzione azzardo:

$$\Lambda(t) = \int_0^t \lambda(u) du = \int_0^t -\frac{d}{du} \log(S(t)) du = -\log(S(t)). \quad (3.13)$$

Ricordando che $\lambda(t) \geq 0$ (basta vedere la (3.11) per convincersene), abbiamo le seguenti relazioni:¹².

$$\Lambda(0) = 0; \Lambda(+\infty) = +\infty; S(t) = e^{-\Lambda(t)}; F(t) = 1 - e^{-\Lambda(t)}.$$

La seconda relazione è particolarmente importante: $\Lambda(+\infty) = +\infty$; in parole, l'integrale della funzione azzardo (di qualunque funzione azzardo) deve divergere, in modo da garantire che $F(+\infty) = 1 - e^{-\Lambda(+\infty)} = 1$.

Le relazioni che intercorrono fra le funzioni $f(t), F(t), S(t), \lambda(t), \Lambda(t)$ permettono di definire la variabile casuale esponenziale in un modo estremamente elegante (e compatto). Infatti, ricordando la (3.11), abbiamo che, nel caso di una variabile casuale esponenziale, la funzione azzardo è costante nel tempo:

$$\lambda(t) = \frac{f(t)}{S(t)} = \frac{\lambda e^{-\lambda t}}{e^{-\lambda t}} = \lambda. \quad (3.14)$$

Se si parte da questa condizione per definire una variabile casuale esponenziale, tutto il resto segue immediatamente. Infatti,

$$\begin{aligned} \Lambda(t) &= \int_0^t \lambda du = \lambda t \\ S(t) &= e^{-\lambda t} \\ F(t) &= 1 - e^{-\lambda t} \\ f(t) &= F'(t) = \lambda e^{-\lambda t}. \end{aligned}$$

Nei modelli di sopravvivenza è spesso più “comodo” partire definendo prima la forma della funzione azzardo, per poi ricavare da questa le altre funzioni.

La distribuzione Weibull

Ad esempio, la *distribuzione Weibull* può essere definita come quella associata all'azzardo dato da

$$\lambda(t) = kh(ht)^{k-1} \quad (3.15)$$

dove k e h sono due parametri, entrambi strettamente positivi, definiti, rispettivamente, di *forma* e di *scala* (e, naturalmente, $t \geq 0$, trattandosi di un tempo di sopravvivenza).

L'azzardo cumulativo ha una forma piuttosto “semplice”, essendo dato da

$$\Lambda(t) = (ht)^k. \quad (3.16)$$

¹²La maggior parte di queste relazioni dovrebbero essere espresse sotto forma di limiti, ma il lettore (se non il matematico) ci perdonerà se adottiamo una simbologia, per così dire, “compatta”.

A partire dalla (3.16) si ricava immediatamente la funzione di sopravvivenza

$$S(t) = e^{-(ht)^k} \quad (3.17)$$

e da questa la funzione di ripartizione, la cui derivata ci dà la funzione di densità di probabilità della Weibull (che qui non riportiamo).

Possiamo disegnare il grafico della funzione azzardo per diversi valori dei parametri h e k . Nel pannello di sinistra della Figura 3.6 è possibile vedere l'andamento della funzione azzardo in relazione ad alcuni valori di k , quando $h = 1$; nel pannello di destra della stessa figura è possibile vedere l'andamento dell'azzardo in relazione agli stessi valori di k , quando $h = 0.5$.




Figura 3.6: Grafico della funzione azzardo di una Weibull per diversi valori di k quando $h = 1$ (a sinistra) e quando $h = 0.5$ (a destra).

Dalla Figura 3.6 e, ancora meglio, dalla (3.15), si ricava subito che, se $k = 1$, l'azzardo è costante ($\lambda(t) = h$) e, quindi, la Weibull si riduce all'esponenziale. Se $k < 1$ l'azzardo si riduce con il tempo, mentre se $k > 1$ l'azzardo aumenta con il tempo. Quando $k = 2$ abbiamo $\lambda(t) = 2h^2t$, per cui l'azzardo aumenta in modo lineare (con una pendenza data da $2h^2$).

Una caratteristica del modello Weibull, impiegata quando si vuole valutare se questo modello si “adatta” a dati reali, è la seguente. Sappiamo che, in generale, $\Lambda(t) = -\log(S(t))$. Nel caso del modello Weibull, ricordando la (3.16), abbiamo quindi

$$-\log(S(t)) = (ht)^k.$$

Prendendo il logaritmo di entrambi i membri e sfruttando le proprietà dei logaritmi otteniamo, dopo alcuni passaggi,

$$\log[-\log(S(t))] = k \log(h) + k \log(t)$$

e, quindi, uno *scatterplot* del logaritmo dei tempi (in ascissa) *vs* il logaritmo del logaritmo cambiato di segno di una stima di $S(t)$ dovrebbe esibire un andamento sostanzialmente lineare. La pendenza della retta ci darebbe una stima del parametro k , mentre a partire dall'intercetta e dal valore di k potremmo ricavare una stima di h . Possiamo fare una verifica empirica mediante una simulazione.

Impiegando la funzione `rweibull` estraiamo da una Weibull con parametri $k = 0.8$ e $h = 0.5$ un campione di 10000 osservazioni. Per fare questo dobbiamo però sapere che nella funzione `rweibull` i parametri `shape` e `scale` hanno il seguente significato: il parametro `shape` corrisponde al nostro k , mentre il parametro `scale` corrisponde al reciproco del nostro h . Quindi, se vogliamo che $h = 0.5$, dovremo assegnare valore 2 all'argomento `scale`. Ecco lo *script* che estrae il campione:

```
> set.seed(135246)
> n <- 10000
> x <- rweibull(n, shape=0.8, scale=2)
```

Lasciamo al lettore verificare con un grafico *quantile-quantile* la bontà di adattamento ad una Weibull. Noi procediamo stimando la funzione di sopravvivenza in modo cosiddetto *non parametrico* nel modo seguente.

- Ordiniamo in modo crescente gli n tempi.
- Calcoliamo una stima $\hat{F}(t)$ della funzione di ripartizione sotto forma di distribuzione di frequenze cumulate (si può ragionevolmente escludere il caso di esistenza di valori *ex aequo*): $1/n, 2/n, 3/n, \dots, (n-1)/n, 1$.
- Calcoliamo una stima $\hat{S}(t)$ della funzione di sopravvivenza prendendo il complemento a 1 della $\hat{F}(t)$.

```
> t <- sort(x)
> F <- c(1:n)/n
> S <- 1 - F
```

Il pannello di sinistra della Figura 3.7 mostra il grafico della $\hat{S}(t)$ con i dati della simulazione.

A questo punto è opportuno togliere l'ultimo valore del vettore `S`, dal momento che è uguale a 0 (stiamo per fare il logaritmo ...), e quello corrispondente del vettore `t` dei tempi. Possiamo ora calcolare il "*log minus log*", cioè il logaritmo del logaritmo (cambiato di segno) di $\hat{S}(t)$.

```
> S <- S[1:(n-1)]
> t <- t[1:(n-1)]
> lml <- log(-log(S))
```

Il pannello di destra della Figura 3.7 rappresenta lo *scatterplot* che riporta in ascissa il logaritmo dei tempi e in ordinata i corrispondenti valori del logaritmo del logaritmo cambiato di segno di $\hat{S}(t)$. La relazione è quasi perfettamente lineare. Impiegando ancora una volta la funzione `lm`, possiamo stimare i parametri della retta.




Figura 3.7: A sinistra: Stima $\hat{S}(t)$ della funzione di sopravvivenza relativa alla simulazione illustrata nel testo. A destra: Grafico *log minus log*. In ordinata è riportato il logaritmo del logaritmo cambiato di segno di $\hat{S}(t)$; in ascissa il logaritmo del tempo. L'andamento lineare di questo grafico rivela che la distribuzione dei tempi è una Weibull.

```
> fit <- lm(lml ~ log(t))
> (b <- fit$coefficients)
(Intercept)      log(t)
  -0.5645628    0.8073092
```

L'equazione della retta è quindi (arrotondando) $y = -0.56 + 0.81 \log(t)$. Osserviamo come la stima della pendenza della retta sia molto vicina al valore vero assegnato al parametro k . Dal momento che l'intercetta è uguale a $k \log(h)$, per ottenere la stima di h prendiamo il rapporto fra intercetta e pendenza (che ci dà il logaritmo di h) e ne facciamo l'esponenziale. Il valore ottenuto è molto vicino a quello vero.

```
> exp(b[1]/b[2])
(Intercept)
  0.496926
```

3.3 La variabile casuale normale

La variabile casuale *normale* o *gaussiana* (dal nome del grande matematico tedesco C.F. Gauss) e la distribuzione di probabilità ad essa associata occupano un ruolo assolutamente centrale nella Statistica in generale e, in particolare, in quella branca (l'*inferenza*) che costituisce la base logica del linguaggio quantitativo della ricerca empirica. Proprio all'*inferenza*, e in particolare ai test di significatività e agli intervalli di confidenza, è dedicato il volume *Ricerca con R*.

Abbiamo in qualche modo già visto nelle pagine precedenti la distribuzione normale, adombrata nella Figura 2.3, nella Figura 2.6 e nella Figura 2.12.

La funzione di densità di probabilità della variabile casuale normale è data da

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2}, \quad (3.18)$$

mentre non è assolutamente possibile scrivere in forma “chiusa” (cioè in una forma analoga a quanto visto per la variabile casuale uniforme o per la variabile casuale esponenziale) la funzione di ripartizione $F(x)$:

$$F(x) = \int_{-\infty}^x \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{1}{2}\left(\frac{u-\mu}{\sigma}\right)^2} du \quad (3.19)$$

(in alcuni testi la funzione di ripartizione della normale è indicata con la lettera greca maiuscola Φ).

La Figura 3.8 mostra nel pannello di sinistra il grafico di una distribuzione normale per la quale $\mu = 90$ e $\sigma = 5$. Dal grafico si può notare come la distribuzione normale sia continua, abbia una forma a campana e sia simmetrica (quindi media, moda e mediana coincidono). La media (μ) e la varianza (σ^2) rappresentano i due *parametri* della distribuzione. La curva è unimodale con un massimo in corrispondenza della media (evidenziata nella Figura 3.8 con un pallino vuoto); in corrispondenza dei due punti simmetrici rispetto alla media (evidenziati nella Figura 3.8 con due pallini pieni) essa cambia di concavità (cioè presenta due *flessi*): la distanza fra la media μ e l'ascissa di ciascun punto di flesso è pari a σ (la deviazione standard). Presenta inoltre due “code” che non intersecano mai l'asse delle ascisse; questo significa che una variabile casuale X normalmente distribuita si estende illimitatamente a sinistra e a destra di μ , potendo assumere tutti i valori compresi tra *meno infinito* e *più infinito*. È




Figura 3.8: Grafico della funzione di densità di probabilità (a sinistra) e della funzione di ripartizione (a destra) di una distribuzione normale con media 90 e deviazione standard 5.

possibile dimostrare (anche se non è assolutamente elementare) che l'area sotto tutta la curva è esattamente uguale a 1. Come per qualsiasi altra variabile casuale continua si può trovare la probabilità che la variabile casuale assuma valori compresi in un determinato intervallo calcolando l'area della curva compresa tra i due valori considerati (ovvero calcolando la differenza fra i corrispondenti valori assunti dalla funzione di ripartizione).

Nel pannello di destra della Figura 3.8 è riportato il grafico della funzione di ripartizione della stessa normale considerata in precedenza ($\mu = 90$, $\sigma = 5$). Il grafico è a forma di “esse italiana”. Non arriva mai a toccare l'asse delle ascisse (cioè $F(x) > 0$ per qualsiasi valore di x), così come non arriva mai a toccare la retta $y = 1$ (cioè $F(x) < 1$ per qualsiasi valore di x). Sul grafico si può notare come $F(x) = 0.5$ quando $x = 90$, cioè quando x è uguale alla media μ della distribuzione.

La media μ determina la posizione “centrale” dove si colloca il massimo della distribuzione. Questo risulta evidente guardando il pannello di sinistra della Figura 3.9, dove sono disegnate tre distribuzioni normali con la stessa varianza, ma media diversa. Le tre distribuzioni sono sostanzialmente identiche, essendo soltanto traslate una rispetto all'altra.




Figura 3.9: A sinistra: Tre distribuzioni normali con media diversa (segnata dal pallino pieno) e uguale varianza. A destra: Tre distribuzioni normali con media uguale, ma diversa varianza.

Il secondo parametro (σ o σ^2) determina invece quanto la distribuzione è “appuntita”. Nel pannello di destra della Figura 3.9 sono rappresentate tre distribuzioni normali con la stessa media, ma varianza diversa. La distribuzione più “appuntita”, disegnata con il tratto continuo, è quella con la varianza più piccola e risulta più “concentrata” intorno alla media. La distribuzione più “appiattita”, disegnata con il tratto punteggiato, è quella con la varianza più grande e risulta più “dispersa” intorno alla media. La varianza è, appunto, una misura della variabilità con cui i valori sono distribuiti intorno alla media.

La Figura 3.10 mostra la forma che assume il grafico della funzione di ripartizione al variare della media (pannello di sinistra) e della deviazione standard (pannello di destra). Nel primo caso, al crescere della media la funzione si “sposta” verso destra. Nel secondo caso, invece, dal momento che la media non cambia, tutti e tre i grafici devono passare per il punto di coordinate $(170, 0.5)$. Al crescere della deviazione standard è la “pendenza” della curva che tende a ridursi.




Figura 3.10: A sinistra: Grafico della funzione di ripartizione di una distribuzione normale con media 160 (linea punteggiata), 170 (linea continua) e 180 (linea tratteggiata); la deviazione standard è sempre uguale a 10. A destra: Grafico della funzione di ripartizione di una distribuzione normale con deviazione standard 10 (linea continua), 15 (linea tratteggiata) e 20 (linea punteggiata); la media è sempre uguale a 170.

Un aspetto notevole della distribuzione normale è rappresentato dal fatto che la forma generale della distribuzione non cambia modificando il valore dei parametri μ e σ . Questo ha fatto sì che, storicamente, una particolare distribuzione normale acquisisse importanza fondamentale: la *distribuzione normale standard* (o standardizzata). In un certo senso, questa è la più “semplice” fra le distribuzioni normali, in quanto sembra che i due parametri μ e σ siano “spariti” dalla funzione di densità di probabilità:

$$f(z) = \frac{1}{\sqrt{2\pi}} e^{-\frac{z^2}{2}}. \quad (3.20)$$

Naturalmente i due parametri ci sono sempre, solo che non si vedono, dal momento che nella distribuzione normale standard $\mu = 0$ e $\sigma^2 = 1$.

Il lettore avrà notato che nella (3.20) abbiamo usato la lettera z al posto della x generalmente impiegata fino ad ora. È una “tradizione” adottata in moltissimi testi quella di indicare la variabile casuale normale standard con la lettera Z (e le sue realizzazioni con la lettera z).

Come abbiamo detto in precedenza, non è possibile scrivere la funzione di ripartizione $F(x)$ di una normale in forma “chiusa”. D’altro canto è fondamentale poter

calcolare le probabilità corrispondenti a qualsiasi intervallo. Oggi tutti i *software* statistici possiedono una funzione per calcolare numericamente il valore di $F(x)$ (R ha la funzione `pnorm`) per una variabile casuale normale con media μ e deviazione standard σ . Ma questo non era possibile agli inizi del secolo scorso, motivo per cui sono state “tabulate” alcune aree relative alla distribuzione normale standard.

Esistono vari “tipi” di tavole della distribuzione normale standard. Quasi tutte sfruttano la simmetria della distribuzione per tabulare soltanto i valori $z \geq 0$. Alcune tavole riportano l’area nella “coda” destra della distribuzione ($P(Z > z)$), mentre altre riportano o l’area da 0 a z ($P(0 \leq Z \leq z)$) oppure il valore della funzione di ripartizione $F(z)$. A scopo illustrativo useremo anche noi una tavola, che ci “costruiremo” impiegando R. Come da tradizione, considereremo soltanto valori positivi di z , impiegando due decimali. In questo modo la tavola sarà sotto forma di una matrice che riporta nella prima colonna i valori di z fino al primo decimale e nella prima riga il valore relativo al secondo decimale. All’incrocio di ciascuna riga e ciascuna colonna si leggerà il valore della funzione di ripartizione $F(z)$. Lo *script* è il seguente:

```
> z <- c(0:399)/100
> p <- pnorm(z)
> tbl <- matrix(p,ncol=10,byrow=TRUE)
> nr <- nrow(tbl)+1
> nc <- ncol(tbl)+1
> out <- matrix(NA,nr,nc)
> out[2:nr,2:nc] <- round(tbl,5)
> out[2:nr,1] <- c(0:39)/10
> out[1,2:nc] <- round(c(0:9)/100,2)
```

e la tavola è riportata nella Tabella 3.1.

In questo *script* vengono calcolati i valori di $F(z)$ per valori di z compresi fra 0.00 e 3.99. Vediamo alcuni esempi.

1. Vogliamo calcolare la probabilità che la variabile casuale Z normale standard assuma un valore minore o uguale a 1.96: $P(Z \leq 1.96)$. Questa domanda equivale a chiedere quanto vale l’area colorata nella Figura 3.11a, ovvero quanto vale $F(1.96)$; troveremo la risposta direttamente sulle tavole. Prendiamo la riga che comincia con 1.90 e la colonna che comincia con 0.06 (di modo che $1.90 + 0.06 = 1.96$) e leggiamo all’incrocio il valore 0.975, che è la risposta alla nostra domanda: $P(Z \leq 1.96) = 0.975$.
2. Vogliamo calcolare la probabilità che la variabile casuale Z normale standard assuma un valore maggiore di 1.96: $P(Z > 1.96)$. Questa domanda equivale a chiedere quanto vale l’area colorata nella Figura 3.11b. La risposta a questa domanda è il complemento a 1 della risposta alla domanda (1): $P(Z > 1.96) = 1 - F(1.96) = 1 - 0.975 = 0.025$.
3. Vogliamo calcolare la probabilità che la variabile casuale Z normale standard assuma un valore minore o uguale a -1.96 : $P(Z \leq -1.96)$. Questa domanda equivale a chiedere quanto vale l’area colorata nella Figura 3.11c, cioè quanto vale

Tabella 3.1: Valori della funzione di ripartizione della normale standard per $0 \leq Z \leq 3.99$.

z	0.00	0.01	0.02	0.03	0.04	0.05	0.06	0.07	0.08	0.09
0.00	0.50000	0.50399	0.50798	0.51197	0.51595	0.51994	0.52392	0.52790	0.53188	0.53586
0.10	0.53983	0.54380	0.54776	0.55172	0.55567	0.55962	0.56356	0.56749	0.57142	0.57535
0.20	0.57926	0.58317	0.58706	0.59095	0.59483	0.59871	0.60257	0.60642	0.61026	0.61409
0.30	0.61791	0.62172	0.62552	0.62930	0.63307	0.63683	0.64058	0.64431	0.64803	0.65173
0.40	0.65542	0.65910	0.66276	0.66640	0.67003	0.67364	0.67724	0.68082	0.68439	0.68793
0.50	0.69146	0.69497	0.69847	0.70194	0.70540	0.70884	0.71226	0.71566	0.71904	0.72240
0.60	0.72575	0.72907	0.73237	0.73565	0.73891	0.74215	0.74537	0.74857	0.75175	0.75490
0.70	0.75804	0.76115	0.76424	0.76730	0.77035	0.77337	0.77637	0.77935	0.78230	0.78524
0.80	0.78814	0.79103	0.79389	0.79673	0.79955	0.80234	0.80511	0.80785	0.81057	0.81327
0.90	0.81594	0.81859	0.82121	0.82381	0.82639	0.82894	0.83147	0.83398	0.83646	0.83891
1.00	0.84134	0.84375	0.84614	0.84849	0.85083	0.85314	0.85543	0.85769	0.85993	0.86214
1.10	0.86433	0.86650	0.86864	0.87076	0.87286	0.87493	0.87698	0.87900	0.88100	0.88298
1.20	0.88493	0.88686	0.88877	0.89065	0.89251	0.89435	0.89617	0.89796	0.89973	0.90147
1.30	0.90320	0.90490	0.90658	0.90824	0.90988	0.91149	0.91309	0.91466	0.91621	0.91774
1.40	0.91924	0.92073	0.92220	0.92364	0.92507	0.92647	0.92785	0.92922	0.93056	0.93189
1.50	0.93319	0.93448	0.93574	0.93699	0.93822	0.93943	0.94062	0.94179	0.94295	0.94408
1.60	0.94520	0.94630	0.94738	0.94845	0.94950	0.95053	0.95154	0.95254	0.95352	0.95449
1.70	0.95543	0.95637	0.95728	0.95818	0.95907	0.95994	0.96080	0.96164	0.96246	0.96327
1.80	0.96407	0.96485	0.96562	0.96638	0.96712	0.96784	0.96856	0.96926	0.96995	0.97062
1.90	0.97128	0.97193	0.97257	0.97320	0.97381	0.97441	0.97500	0.97558	0.97615	0.97670
2.00	0.97725	0.97778	0.97831	0.97882	0.97932	0.97982	0.98030	0.98077	0.98124	0.98169
2.10	0.98214	0.98257	0.98300	0.98341	0.98382	0.98422	0.98461	0.98500	0.98537	0.98574
2.20	0.98610	0.98645	0.98679	0.98713	0.98745	0.98778	0.98809	0.98840	0.98870	0.98899
2.30	0.98928	0.98956	0.98983	0.99010	0.99036	0.99061	0.99086	0.99111	0.99134	0.99158
2.40	0.99180	0.99202	0.99224	0.99245	0.99266	0.99286	0.99305	0.99324	0.99343	0.99361
2.50	0.99379	0.99396	0.99413	0.99430	0.99446	0.99461	0.99477	0.99492	0.99506	0.99520
2.60	0.99534	0.99547	0.99560	0.99573	0.99585	0.99598	0.99609	0.99621	0.99632	0.99643
2.70	0.99653	0.99664	0.99674	0.99683	0.99693	0.99702	0.99711	0.99720	0.99728	0.99736
2.80	0.99744	0.99752	0.99760	0.99767	0.99774	0.99781	0.99788	0.99795	0.99801	0.99807
2.90	0.99813	0.99819	0.99825	0.99831	0.99836	0.99841	0.99846	0.99851	0.99856	0.99861
3.00	0.99865	0.99869	0.99874	0.99878	0.99882	0.99886	0.99889	0.99893	0.99896	0.99900
3.10	0.99903	0.99906	0.99910	0.99913	0.99916	0.99918	0.99921	0.99924	0.99926	0.99929
3.20	0.99931	0.99934	0.99936	0.99938	0.99940	0.99942	0.99944	0.99946	0.99948	0.99950
3.30	0.99952	0.99953	0.99955	0.99957	0.99958	0.99960	0.99961	0.99962	0.99964	0.99965
3.40	0.99966	0.99968	0.99969	0.99970	0.99971	0.99972	0.99973	0.99974	0.99975	0.99976
3.50	0.99977	0.99978	0.99978	0.99979	0.99980	0.99981	0.99981	0.99982	0.99983	0.99983
3.60	0.99984	0.99985	0.99985	0.99986	0.99986	0.99987	0.99987	0.99988	0.99988	0.99989
3.70	0.99989	0.99990	0.99990	0.99990	0.99991	0.99991	0.99992	0.99992	0.99992	0.99992
3.80	0.99993	0.99993	0.99993	0.99994	0.99994	0.99994	0.99994	0.99995	0.99995	0.99995
3.90	0.99995	0.99995	0.99996	0.99996	0.99996	0.99996	0.99996	0.99996	0.99997	0.99997

$F(-1.96)$. Sulle tavole sono riportati soltanto i valori positivi di z . Tuttavia, per la simmetria della distribuzione normale, avremo che, se $z > 0$, $F(-z) = 1 - F(z)$, ovvero che $P(Z \leq -1.96) = P(Z \geq 1.96)$ (l'area colorata nella Figura 3.11c è uguale all'area colorata nella Figura 3.11b). La risposta sarà quindi $1 - 0.975 = 0.025$, come nel caso (2).

- Vogliamo calcolare la probabilità che la variabile casuale Z normale standard assuma un valore maggiore di -1.96 : $P(Z > -1.96)$. Questa domanda equivale a chiedere quanto vale l'area colorata nella Figura 3.11d. La risposta è il complemento a 1 della risposta alla domanda precedente: $1 - 0.025 = 0.975$. Facciamo osservare che l'area colorata nella Figura 3.11d è uguale all'area colorata nella Figura 3.11a.
- Vogliamo calcolare la probabilità che la variabile casuale Z normale standard assuma un valore compreso fra -1.96 e $+1.96$: $P(-1.96 \leq Z \leq 1.96)$. Questa do-




Figura 3.11: Le distribuzioni rappresentate nei pannelli (a)–(f) sono normali standard. Quelle rappresentate nei pannelli (g)–(i) sono normali con media $\mu = 170$ e deviazione standard $\sigma = 10$. Le aree in grigio corrispondono alle probabilità richieste nel testo.

manda equivale a chiedere quanto vale l'area colorata nella Figura 3.11e. Per rispondere a questa domanda basta calcolare la differenza fra i valori che assume la funzione di ripartizione in corrispondenza dei due valori considerati: $F(1.96) - F(-1.96) = 0.975 - 0.025 = 0.95$. In altre parole, l'area colorata nella Figura 3.11e è uguale alla differenza fra l'area colorata nella Figura 3.11a e l'area colorata nella Figura 3.11c

6. Vogliamo calcolare la probabilità che la variabile casuale Z normale standard assuma un valore esterno all'intervallo $(-1.96, +1.96)$: $P(Z < -1.96 \cup Z > +1.96)$. Questa domanda equivale a chiedere quanto vale l'area colorata nella Figura 3.11f. La risposta è il complemento a 1 della risposta alla domanda precedente: $1 - 0.95 = 0.05$, ovvero è la somma delle aree colorate nelle figure 3.11b (0.025) e 3.11c (0.025).

Con R è possibile ottenere queste risposte ricorrendo alla funzione `pnorm` (eventualmente impiegando l'argomento `lower.tail` che fornisce il complemento a 1 della funzione di ripartizione se il suo valore è FALSE):

```
> pnorm(1.96)
[1] 0.9750021
> pnorm(1.96,lower.tail=FALSE)
[1] 0.0249979
> pnorm(-1.96)
[1] 0.0249979
> pnorm(-1.96,lower.tail=FALSE)
[1] 0.9750021
> pnorm(1.96)-pnorm(-1.96)
[1] 0.9500042
> pnorm(-1.96)+pnorm(1.96,lower.tail=FALSE)
[1] 0.04999579
```

La funzione `ProbNorm` di `rmf` produce anche un *output* grafico:

```
> ProbNorm(a=1.96,color="red")
La probabilita' di osservare un valore minore di 1.96
e' uguale a 0.97500210485178
> ProbNorm(da=1.96,color="red")
La probabilita' di osservare un valore maggiore di 1.96
e' uguale a 0.0249978951482205
> ProbNorm(a=-1.96,color="red")
La probabilita' di osservare un valore minore di -1.96
e' uguale a 0.0249978951482204
> ProbNorm(da=-1.96,color="red")
La probabilita' di osservare un valore maggiore di -1.96
e' uguale a 0.97500210485178
> ProbNorm(da=-1.96,a=1.96,color="red")
La probabilita' di osservare un valore compreso fra -1.96 e 1.96
e' uguale a 0.950004209703559
```

Disponendo delle tavole della distribuzione normale standard, è possibile calcolare le probabilità relative a una distribuzione normale con media μ e deviazione standard σ ricorrendo alla procedura di *standardizzazione*:

$$z = \frac{x - \mu}{\sigma}. \quad (3.21)$$

Ad esempio, data una variabile casuale X che segue una distribuzione normale con media $\mu = 170$ e deviazione standard $\sigma = 10$, si vuole calcolare la probabilità che la variabile casuale X assuma un valore minore o uguale a 189.6: $P(X \leq 189.6)$. L'area

corrispondente è quella colorata nella Figura 3.11g che è (non solo visivamente) esattamente uguale all'area colorata nella Figura 3.11a.

Standardizziamo il valore richiesto per la variabile casuale X applicando la (3.21):

$$\frac{189.6 - 170}{10} = 1.96.$$

In altre parole la probabilità dell'evento $(X \leq 189.6)$ per una variabile casuale X normale con media $\mu = 170$ e deviazione standard $\sigma = 10$ è esattamente uguale alla probabilità dell'evento $(Z \leq 1.96)$ per una variabile casuale Z normale standard e, quindi, $F_X(189.6) = F_Z(1.96)$.

Lasciamo al lettore verificare che, con riferimento alla stessa variabile casuale X ,

- la probabilità dell'evento $(X > 189.6)$ è equivalente alla probabilità dell'evento $(Z > 1.96)$;
- la probabilità dell'evento $(X \leq 150.4)$ è equivalente alla probabilità dell'evento $(Z \leq -1.96)$;
- la probabilità dell'evento $(X > 150.4)$ è equivalente alla probabilità dell'evento $(Z > -1.96)$;
- la probabilità dell'evento $(150.4 < X < 189.6)$ è equivalente alla probabilità dell'evento $(-1.96 < Z < 1.96)$ (l'area colorata nella Figura 3.11h è infatti uguale all'area colorata nella Figura 3.11e);
- la probabilità dell'evento $(X < 150.4 \cup X > 189.6)$ è equivalente alla probabilità dell'evento $(Z < -1.96 \cup Z > 1.96)$ (l'area colorata nella Figura 3.11i è infatti uguale all'area colorata nella Figura 3.11f).

I valori ± 1.96 sono largamente impiegati nell'*inferenza statistica*, dal momento che, come abbiamo visto, all'intervallo $(-1.96, +1.96)$ è associata una probabilità del 95% (figura 3.11e) e l'area esterna a questo intervallo vale il 5% (figura 3.11f).

Dalla procedura di standardizzazione si evince che, se X è una variabile casuale normalmente distribuita, con media μ e deviazione standard σ , allora la probabilità che la variabile casuale X assuma un valore compreso nell'intervallo $(\mu - 1.96\sigma, \mu + 1.96\sigma)$ è pari al 95%, qualsiasi sia la media μ e la deviazione standard σ .

Esistono altri intervalli “tipici” cui si fa frequentemente ricorso quando si lavora con una variabile casuale normale. In aggiunta al precedente, gli intervalli più usati hanno come estremi la media ± 1 , 2 o 3 deviazioni standard; questi intervalli comprendono, rispettivamente, circa il 68.3%, il 95.4%, il 99.7% delle osservazioni.

È possibile usare le tavole della distribuzione normale standard per risolvere problemi “inversi”, nei quali è nota la probabilità e si vuole risalire al valore corrispondente (cioè al *quantile*) della variabile casuale X . Per fare un esempio, del quale conosciamo già la risposta, potremmo chiederci quale è quel valore z tale che $P(Z \leq z) = 0.975$. Ovvero, dato che $F(z) = 0.975$ vogliamo risalire al valore di z . Dal momento che la domanda è posta in termini di funzione di ripartizione la risposta la troviamo direttamente cercando *all'interno* della tavola un valore uguale a 0.975 (o vicino ad esso).

Una volta trovato il valore, basta leggere il numero che si trova all'inizio della riga (1.90) e all'inizio della colonna (0.06). La risposta è data dalla somma dei due valori: $1.90 + 0.06 = 1.96$.

Consideriamo un secondo esempio. Vogliamo trovare quel valore z tale che $P(Z \leq z) = 0.95$. Ovvero, dato che $F(z) = 0.95$, vogliamo risalire al valore di z . Anche in questo caso troviamo la risposta cercando *all'interno* della tavola un valore uguale a 0.95. Dal momento che questo valore non è presente prendiamo quello immediatamente più piccolo (0.9495) e quello immediatamente più grande (0.9505). Il numero che si trova all'inizio della riga è 1.60 in entrambi i casi, mentre all'inizio delle colonne corrispondenti leggiamo 0.04 e 0.05. La risposta (approssimata) può quindi essere sia 1.64, sia 1.65, oppure, interpolando, 1.645.

Analogamente, se volessimo trovare i *quartili* della normale standard, dovremmo cercare all'interno delle tavole i valori di probabilità pari a 0.25, 0.5, 0.75 per risalire ai corrispondenti valori Q_1 , Q_2 , Q_3 . Per quanto riguarda il secondo (Q_2), essendo il valore al quale corrisponde una probabilità esattamente uguale a 0.5 ($F(Q_2) = 0.5$), sarà la *mediana* della distribuzione e, quindi, possiamo rispondere immediatamente $Q_2 = \mu = 0$ (media e mediana coincidono). Troviamo ora Q_3 , sapendo che ($F(Q_3) = 0.75$). Guardando all'interno delle tavole, troviamo i due valori più vicini: 0.7486 e 0.7517. Ad essi corrispondono i valori di z pari a 0.67 e 0.68. Possiamo scegliere indifferentemente uno dei due come valore da assegnare a Q_3 . Infine, dovremo cercare una probabilità p pari a 0.25. Tuttavia le nostre tavole riportano soltanto valori $p \geq 0.5$. Sfruttando però la simmetria della distribuzione normale, possiamo dire che, se $p > 0.5$ e $F(z) = p$, allora $F(-z) = 1 - p$. Applicando questa regola al nostro caso, sappiamo che $F(0.67) = 0.75$; quindi, $F(-0.67) = 1 - 0.75 = 0.25$. In altre parole, se Z è una variabile casuale normale standard, $Q_1 = -Q_3$.

Consideriamo ora una variabile casuale X normale con media $\mu = 170$ e deviazione standard $\sigma = 10$. Quali sono i quartili di questa distribuzione conoscendo che i quartili di una normale standard sono $(-0.67, 0, 0.67)$? Dobbiamo “invertire” l'operazione di standardizzazione (3.21), per risalire dal valore di z a quello di x :

$$x = \mu + z\sigma. \quad (3.22)$$

Pertanto, avremo che

- $Q_1 = 170 - 0.67 \times 10 = 163.3$,
- $Q_2 = 170 + 0 \times 10 = 170$,
- $Q_3 = 170 + 0.67 \times 10 = 176.7$.

In altre parole, il 50% “centrale” dei valori di X cade nell'intervallo $(163.3, 176.7)$ e, più in generale, se X è una variabile casuale normale con media μ e deviazione standard σ , il 50% “centrale” dei valori di X cade nell'intervallo $(\mu - 0.67\sigma, \mu + 0.67\sigma)$.

La funzione `qnorm` di R risolve immediatamente questo tipo di problemi inversi. Passiamo come primo argomento un vettore contenente le probabilità note (0.25, 0.5 e 0.75 nel nostro caso) e come argomenti successivi μ e σ :

```
> qnorm(c(0.25,0.5,0.75),mean=0,sd=1)
[1] -0.6744898  0.0000000  0.6744898
> qnorm(c(0.25,0.5,0.75),mean=170,sd=10)
[1] 163.2551 170.0000 176.7449
```

Altri esercizi riguardanti la distribuzione normale si possono trovare sul libro *Problemi ed esperimenti di statistica con R*.

3.3.1 Approssimazioni alla normale e “correzione per la continuità”

Abbiamo visto in precedenza che molte variabili casuali discrete (in particolare la binomiale e la Poisson) possono produrre un grafico molto vicino a quello di una distribuzione normale. In effetti possiamo dire che

- una variabile casuale binomiale con parametri n e p può essere approssimata da una normale con media $\mu = np$ e varianza $\sigma^2 = np(1 - p)$. L'approssimazione è tanto migliore quanto più sono grandi sia np , sia $n(1 - p)$;
- una variabile casuale di Poisson con parametro λ può essere approssimata da una normale con media $\mu = \lambda$ e varianza $\sigma^2 = \lambda$. L'approssimazione è tanto migliore quanto più è grande λ .

Disponendo di un programma come R è possibile in generale ricorrere sempre al calcolo della distribuzione “esatta”, tralasciando l'approssimazione che, a volte, non è soddisfacente (si veda al riguardo *Ricerca con R*). Tuttavia, storicamente, si è cercato di migliorare l'approssimazione introdotta impiegando la distribuzione normale (che è una distribuzione continua) apportando una correzione, nota sotto il nome di *correzione per la continuità*, che qui trattiamo brevemente con riferimento alla distribuzione binomiale (ma lo stesso vale per la Poisson e per l'ipergeometrica).

Una differenza sostanziale fra la variabile casuale binomiale e la variabile casuale normale è che la prima è discreta, mentre la seconda è continua. Pertanto, come già detto, mentre nel primo caso (variabile casuale binomiale) è perfettamente lecito chiedersi quanto vale $P(X = x)$, nel secondo caso (variabile casuale normale) sappiamo già che $P(X = x) = 0$. Come possiamo fare, quindi, se vogliamo rispondere a questa domanda nel caso di una binomiale impiegando l'approssimazione normale? L'idea è quella di considerare un conteggio come l'approssimazione di una “misura”. In altre parole, se ho osservato, ad esempio, 20 successi, per impiegare l'approssimazione normale dovrò prendere in considerazione l'intervallo (19.5, 20.5). In generale, se sono stati osservati x successi, l'intervallo sarà dato da $(x - 0.5, x + 0.5)$. Vediamo un esempio concreto.

Sia X una variabile casuale binomiale con parametri $n = 50$ e $p = 0.5$; vogliamo calcolare $P(X = 20)$. La risposta “esatta” (ottenuta impiegando la distribuzione binomiale) è

```
> dbinom(20,size=50,prob=0.5)
[1] 0.04185915
```

Trattiamo ora X come se fosse una variabile casuale normale con media $\mu = 50 \times 0.5 = 25$ e varianza $\sigma^2 = 50 \times 0.5 \times (1 - 0.5) = 12.5$. Vogliamo trovare $P(19.5 \leq X \leq 20.5)$. Lasciamo come esercizio al lettore trovare la risposta impiegando le tavole della normale standard. Noi utilizzeremo direttamente R:

```
> pnorm(20.5,25,sqrt(12.5))-pnorm(19.5,25,sqrt(12.5))
[1] 0.04164843
```

Come si può vedere le due risposte, quella esatta (0.04186) e quella approssimata ottenuta impiegando la correzione per la continuità (0.04165) sono abbastanza vicine fra loro.

Vediamo ora come comportarci nel caso in cui si chieda di calcolare la probabilità relativa ad un intervallo di valori. Ad esempio, calcoliamo la probabilità di osservare meno di 15 successi (cioè $P(X < 15)$); impiegando la binomiale avremo

```
> (p <- sum(dbinom(c(0:14),size=50,prob=0.5)))
[1] 0.001301086
```

Infatti, *meno di 15* vuol dire *fino a 14*, cioè tutti i valori di X da 0 a 14 devono essere considerati nella somma, mentre il valore 15 non va considerato.

Come ci comportiamo se vogliamo impiegare la distribuzione normale? Cosa vuol dire, in questo caso, *meno di 15*? Possiamo pensare che voglia dire *fino a 14*, come abbiamo appena scritto e, quindi, la probabilità (approssimata) sarà

```
> (pa <- pnorm(14,25,sqrt(12.5))); (pa-p)/p
[1] 0.0009314231
[1] -0.2841185
```

con una sottostima del valore vero del 28%; oppure possiamo ricordare che, nel caso della normale (ovvero di una variabile casuale continua) $P(X < 15) = P(X \leq 15)$ e, quindi, la probabilità (approssimata) sarà in questo caso

```
> (pa <- pnorm(15,25,sqrt(12.5))); (pa-p)/p
[1] 0.002338867
[1] 0.7976275
```

con una sovrastima del valore vero che sfiora l'80%.

Ripetendo le considerazioni fatte poco sopra, però possiamo dire che il valore 15 su scala discreta equivale all'intervallo da 14.5 a 15.5 su scala continua (15 ± 0.5). Allora la probabilità di osservare un valore *minore di 15* su scala discreta equivale (approssimativamente) alla probabilità di osservare un valore *minore di 14.5* (o, anche, *minore o uguale a 14.5*) su scala continua. Pertanto, la probabilità (approssimata) sarà (applicando la correzione per la continuità)


```
> (pa <- pnorm(14.5,25,sqrt(12.5))); (pa-p)/p
[1] 0.001489733
[1] 0.1449924
```

La sovrastima è del 14%, ma la probabilità trovata è quella che si avvicina di più al valore vero. Ripetiamo adesso l'esempio, chiedendo, però, di calcolare la probabilità di osservare *fino a* 15 successi (cioè $P(X \leq 15)$); impiegando la binomiale avremo

```
> (p <- sum(dbinom(c(0:15),size=50,prob=0.5)))
[1] 0.003300224
```

A differenza del caso precedente, questa volta nella somma vanno considerati tutti i valori da 0 a 15 compreso.

Se vogliamo impiegare la distribuzione normale possiamo calcolare $P(X \leq 15)$ mediante la funzione di ripartizione assegnando il valore 15 al primo argomento di `pnorm`; la probabilità (approssimata) sarà quindi

```
> (pa <- pnorm(15,25,sqrt(12.5))); (pa-p)/p
[1] 0.002338867
[1] -0.2913004
```

con una sottostima del valore vero del 29%.

Se vogliamo applicare la correzione per la continuità, possiamo ripetere quanto appena scritto: il valore 15 su scala discreta equivale all'intervallo da 14.5 a 15.5 su scala continua. Quindi la probabilità di osservare un valore *minore o uguale a* 15 su scala discreta equivale (approssimativamente) alla probabilità di osservare un valore *minore o uguale a* 15.5 (o, anche, *minore di* 15.5) su scala continua. Pertanto, la probabilità (approssimata) sarà

```
> (pa <- pnorm((15.5),25,sqrt(12.5))); (pa-p)/p
[1] 0.003604785
[1] 0.09228507
```

con una sovrastima del 9%, ottenendo un risultato più vicino al valore vero.

Senza ripetere tutti i passaggi, calcoliamo la probabilità esatta di osservare *più di* 30 successi e quella approssimata impiegando la correzione per la continuità:

```
> (p <- sum(dbinom(c(31:50),size=50,prob=0.5)))
[1] 0.05946023
> (pa <- pnorm(30.5,25,sqrt(12.5),lower.tail=FALSE)); (pa-p)/p
[1] 0.05989747
[1] 0.007353469
```

e la probabilità esatta e quella approssimata di osservare *almeno* 30 successi:

```
> (p <- sum(dbinom(c(30:50),size=50,prob=0.5)))
[1] 0.1013194
> (pa <- pnorm(29.5,25,sqrt(12.5),lower.tail=FALSE)); (pa-p)/p
[1] 0.1015459
[1] 0.002235685
```

Ancora sulle fluttuazioni

La Figura 3.12 mostra la distribuzione di probabilità di due binomiali, entrambe con parametro $p = 1/2$; il valore del parametro n è 100 nel caso della binomiale rappresentata nel pannello di sinistra e 1000 nel caso della binomiale rappresentata nel pannello di destra. È ben evidente come le probabilità nel caso della binomiale a destra siano più “addensate” intorno alla media.




Figura 3.12: Distribuzione di probabilità di due variabili casuali binomiali, entrambe con parametro $p = 1/2$. Il parametro n vale 100 nel caso della figura a sinistra e 1000 nel caso della figura a destra.

Ad esempio, quando $n = 100$ l’intervallo dei valori della variabile casuale X ai quali corrisponde una probabilità “centrale” del 99% è compreso fra 37 e 63 ed ha una ampiezza, rapportata al valore di n , del 26%:

```
> n <- 2; x <- qbinom(c(0.005,0.995),10^n,0.5); x
[1] 37 63
> (x[2] - x[1])/10^n
[1] 0.26
```

Quando invece $n = 1000$ l’intervallo dei valori di X ai quali corrisponde la medesima probabilità “centrale” è compreso fra 459 e 541 ed ha una ampiezza, rapportata al valore di n dell’8.2%:

```
> n <- 3; x <- qbinom(c(0.005,0.995),10^n,0.5); x
[1] 459 541
> (x[2] - x[1])/10^n
[1] 0.082
```

Nel caso in cui $n = 10000$, l’intervallo dei valori di X ai quali corrisponde una probabilità “centrale” del 99% è compreso fra 4871 e 5129 ed ha una ampiezza, rapportata al valore di n , del 2.58%:

```
> n <- 4; x <- qbinom(c(0.005,0.995),10^n,0.5); x
[1] 4871 5129
> (x[2] - x[1])/10^n
[1] 0.0258
```

Vediamo quindi come aumentando n di 100 volte (da 10^2 a 10^4), l'ampiezza dell'intervallo in percentuale si riduca di 10 volte. Che questo non sia un caso lo possiamo verificare subito considerando $n = 10^6$:

```
> n <- 6; x <- qbinom(c(0.005,0.995),10^n,0.5); x
[1] 498712 501288
> (x[2] - x[1])/10^n
[1] 0.002576
```

Vediamo come passando da 10^4 a 10^6 l'ampiezza percentuale si sia ridotta di 10 volte.

Sfruttando l'approssimazione normale possiamo calcolare l'ampiezza percentuale per diversi esponenti k (di modo che $n = 10^k$) considerando non più un intervallo dei valori di X al quale sia associata una probabilità del 99%, ma una probabilità molto più alta, ad esempio del 99.9999%, in modo tale che complessivamente la probabilità rimanente sia 10^{-6} , suddivisa in modo uguale nelle due “code”. Illustriamo il calcolo nel caso in cui $k = 9$, per cui $n = 10^9$.

- La media è $\mu = \frac{10^9}{2}$.
- La varianza è $\sigma^2 = \frac{10^9}{4}$.
- La deviazione standard è $\sigma = \frac{\sqrt{10^9}}{2}$.
- Impiegando la funzione `qnorm` calcoliamo i quantili q_1 e q_2 per i quali $p_1 = \frac{10^{-6}}{2}$ e $p_2 = 1 - \frac{10^{-6}}{2}$ di una normale con media μ e deviazione standard σ .
- Calcoliamo l'ampiezza percentuale: $\frac{q_2 - q_1}{n}$.

```
> n <- 10^9; m <- n/2; s <- sqrt(n)/2
> p <- 10^(-6)
> q <- qnorm(c(p/2,1-p/2),m,s)
> (q[2]-q[1])/n
[1] 0.0001546872
```

Quindi, in un intervallo centrato sulla media la cui ampiezza percentuale (riferita a n) è circa 0.015%, è contenuta la quasi totalità (99.9999%) delle realizzazioni della variabile casuale X .

Abbiamo calcolato l'ampiezza percentuale dell'intervallo centrato sulla media che comprende il 99.9999% delle realizzazioni della variabile casuale X binomiale con parametro $p = 1/2$ per i valori interi di k da 10 a 28 (di modo che $n = 10^k$). Dal grafico presente nel pannello di sinistra della Figura 3.13 si vede come questa ampiezza percentuale “precipiti” a valori prossimi a zero al crescere dell'esponente k . Molto

più informativo è il grafico nel pannello di destra della Figura 3.13, dove l'ampiezza percentuale è riportata su una scala logaritmica (in questo caso, per comodità, il logaritmo è in base 10); è del tutto evidente come esista una relazione (inversa) perfettamente lineare fra il valore dell'esponente k e il logaritmo in base 10 dell'ampiezza.




Figura 3.13: Andamento dell'ampiezza percentuale dell'intervallo che contiene il 99.9999% delle realizzazioni di una variabile casuale X binomiale con parametro $p = 1/2$ e $n = 10^k$. (Nella figura a destra l'ampiezza è riportata su scala logaritmica).

Impiegando ancora una volta la funzione `lm` troviamo che l'equazione della retta che si vede nel grafico del pannello di destra della Figura 3.13 è $y = 0.6897 - 0.5x$, dove $x = \log_{10}(n)$ e $y = \log_{10}(\delta)$ (δ è l'ampiezza percentuale). Prendendo l'antilogaritmo di entrambi i membri abbiamo quindi:

$$10^{\log_{10}(\delta)} = 10^{0.6897} \times 10^{-0.5 \log_{10}(n)},$$

cioè $\delta = 4.89/\sqrt{n}$. Vediamo comparire ancora una volta una relazione che coinvolge la radice quadrata di n (il “numero delle osservazioni”). Possiamo chiederci cosa rappresenti il valore (che abbiamo arrotondato) 4.89; ecco cos'è:

```
> qnorm(10^(-6)/2, lower.tail=FALSE)
[1] 4.891638
```

È quel valore di z che in una normale standard lascia alla sua destra un'area pari a $10^{-6}/2$, ovvero, in una normale standard l'area compresa fra -4.89 e $+4.89$ è (circa) uguale a 0.999999.

Quello che abbiamo appena trovato è estremamente importante. Prendiamo una “scatola” e riempiamola con una mole di un gas (ad esempio, O_2); il numero di molecole è quindi dell'ordine di 10^{24} . Consideriamo ora la metà destra e la metà sinistra della scatola. Se le molecole si comportano in modo indipendente, ciascuna di esse ha la stessa probabilità ($1/2$) di trovarsi nella metà sinistra o nella metà destra. Con un valore di 10^{24} siamo sostanzialmente certi che in qualsiasi momento un numero a tutti gli

effetti “uguale” di molecole si troveranno in ciascuna delle due metà. L’uguaglianza non sarà ovviamente esatta, ma quando $n = 10^{24}$ aggiungere (o togliere), ad esempio, un miliardo di molecole non fa nessuna differenza pratica: $10^{24} \pm 10^9 \simeq 10^{24}$, perché la differenza fra i due numeri è di 15 *ordini di grandezza*. È come se una persona possedesse 100 miliardi (10^{11}) di euro; espressi in centesimi di euro, sono 10^{13} ; se si aggiungesse (o si togliesse) a questa cifra 1 centesimo di euro, la cifra non si modificherebbe nella sostanza.¹³

3.3.2 La variabile casuale log-normale

Consideriamo la seguente simulazione. Prendiamo un campione (molto numeroso) da una variabile casuale Y normale standard:

```
> mu <- 0; sigma <- 1
> set.seed(123456)
> y <- rnorm(100000,mu,sigma)
> c(mean(y),sd(y))
[1] 0.003276657 1.000769891
```

e facciamo l’esponenziale di ciascun valore $x = \exp(y)$. Come sarà la distribuzione della variabile casuale $X = e^Y$ risultante? La risposta (grafica) si può vedere nel pannello di sinistra della Figura 3.14. Dato che l’esponenziale è sempre positivo, la distribuzione partirà da zero ($X > 0$); inoltre non sarà più simmetrica, dal momento che al crescere di x , e^x cresce più rapidamente, per cui avremo una asimmetria positiva, con la media più grande della mediana:

```
> c(mean(x),median(x))
[1] 3.085607 2.725890
```

La distribuzione risultante prende il nome di *distribuzione log-normale*, dal momento che, prendendo il logaritmo dei valori di x , otterremmo una distribuzione normale (standard nel nostro esempio). Sul grafico è stata sovrainposta la funzione di densità di probabilità teorica ottenuta ricorrendo alla funzione `dlnorm` con parametri `meanlog` uguale a 0 e `sdlog` uguale a 1 (in generale `meanlog` è la media aritmetica del logaritmo delle osservazioni e, analogamente, `sdlog` è la deviazione standard del logaritmo delle osservazioni).

La distribuzione log-normale può essere impiegata quando i dati sono tutti positivi e la loro distribuzione empirica non è simmetrica, ma presenta un coda (più o meno pronunciata) a destra. La funzione di densità di probabilità è la seguente

$$f(x) = \frac{1}{x\sigma\sqrt{2\pi}} e^{-\frac{1}{2}\left(\frac{\log(x)-\mu}{\sigma}\right)^2}, \quad (3.23)$$

¹³In questo esempio la variazione è di 13 ordini di grandezza (da 10^{13} a 10^0), quindi più piccola di quella considerata nel testo.




Figura 3.14: Istogrammi dei risultati delle due simulazioni descritte nel testo. La curva sovrainposta su ciascun istogramma è la funzione di densità di probabilità della distribuzione log-normale pertinente. I valori della media e della deviazione standard impiegati per generare i dati sono $(\mu = 0, \sigma = 1)$ (pannello di sinistra) e $(\mu = 1, \sigma = 0.5)$ (pannello di destra).

dove i parametri μ e σ sono la media e la deviazione standard del logaritmo della variabile casuale X .

Il valore atteso è $E(X) = e^{\mu + \frac{\sigma^2}{2}}$, la mediana è e^μ e la varianza è $Var(X) = e^{2\mu + \sigma^2} (e^{\sigma^2} - 1)$. I risultati della simulazione sono molto vicini ai valori teorici.

```
> c(mean(x), exp(mu+sigma^2/2))
[1] 1.653480 1.648721
> c(median(x), exp(mu))
[1] 1.005606 1.000000
> v <- exp(2*mu+sigma^2) * (exp(sigma^2)-1)
> c(var(x), v)
[1] 4.582490 4.670774
```

Nel pannello di destra della Figura 3.14 è riportato il risultato di una seconda simulazione, in tutto analoga alla precedente, fatti salvi i valori assegnati ai parametri della distribuzione normale di partenza che sono stati $\mu = 1$ e $\sigma = 0.5$.

```
> c(mean(x), exp(mu+sigma^2/2))
[1] 3.085607 3.080217
> c(median(x), exp(mu))
[1] 2.725890 2.718282
> v <- exp(2*mu+sigma^2) * (exp(sigma^2)-1)
> c(var(x), v)
[1] 2.696716 2.694758
```

Vediamo un modo (forse) alternativo di pensare ad una distribuzione log-normale. Abbiamo già visto che la somma di n uniformi i.i.d. ha una distribuzione di probabilità

molto simile a quella di una normale (per lo meno se n è “sufficientemente grande”). Nel pannello di sinistra della Figura 3.15 ne vediamo un ulteriore esempio, essendo visualizzato l’istogramma di una simulazione in cui abbiamo sommato 10 uniformi i.i.d. fra 0.5 e 1.5 (ripetendo il tutto 100000 volte). Abbiamo anche sovrapposto sull’istogramma la funzione di densità di probabilità di una normale con media $\mu = 10$ (la somma dei valori attesi delle 10 uniformi) e varianza $\sigma^2 = 10/12$ (la somma delle varianze delle 10 uniformi). Fino a qui nulla di nuovo.

```
> set.seed(654321)
> n <- 10
> y <- runif(100000*n,0.5,1.5)
> Y <- matrix(y,ncol=n)
> x <- rowSums(Y)
> c(mean(x),var(x))
[1] 10.0011826 0.8294685
```

Adesso, invece di considerare la *somma*, calcoliamo il *prodotto* dei 10 valori estratti (impiegando la funzione `prod`) e guardiamo l’istogramma delle 100000 realizzazioni (pannello di destra della Figura 3.15).

```
> x <- apply(Y,1,prod)
> hist(x,breaks=200,xlim=c(0,4),prob=TRUE)
> box()
```




Figura 3.15: A sinistra: Distribuzione di frequenza della *somma* di 10 uniformi i.i.d. fra 0.5 e 1.5. La curva continua sovrapposta è la funzione di densità di probabilità di una distribuzione normale con media $\mu = 10$ e varianza $\sigma^2 = 10/12$. A destra: Distribuzione di frequenza del *prodotto* di 10 uniformi i.i.d. fra 0.5 e 1.5. La curva continua sovrapposta è la funzione di densità di probabilità di una distribuzione log-normale i cui parametri sono stati ricavati a partire dai dati della simulazione.

Evidentemente la distribuzione del prodotto di n uniformi i.i.d. non è normale. Assomiglia però molto al grafico di una distribuzione log-normale. Abbiamo sovrapposto sull'istogramma la funzione di densità di probabilità di una variabile casuale log-normale mediante la funzione `dlnorm` con parametri `meanlog` uguale alla media aritmetica del logaritmo delle osservazioni e `sdlog` uguale alla deviazione standard del logaritmo delle osservazioni;

```
m <- mean(log(x))
s <- sd(log(x))
curve(dlnorm(x,m,s),0,4,add=TRUE,xlab="",main="")
```

e l'adattamento sembra essere davvero buono. Lasciamo al lettore costruire un grafico *quantile-quantile* sfruttando la funzione `qlnorm` che restituisce i quantili associati ad una distribuzione log-normale. Quello che ci interessa far notare è che il modello sottostante ad una distribuzione log-normale è un *modello moltiplicativo*, mentre il modello sottostante ad una distribuzione normale è un *modello additivo*. Spetta al ricercatore capire qual è il modello che meglio si adatta ai dati che vuole analizzare.

La distribuzione log-normale è importante nella descrizione di molti fenomeni naturali e trova impiego in vari ambiti scientifici, quali, ad esempio, la biologia e la geologia.¹⁴ Spesso i processi naturali di crescita sono dovuti all'accumularsi di molti piccoli cambiamenti percentuali e la distribuzione delle dimensioni risultanti tendono a seguire una distribuzione log-normale, in particolare quando la velocità con cui si accumulano i (piccoli) cambiamenti è costante nel tempo.

Il lettore può consultare¹⁵ la pagina di *Wikipedia* dedicata alla distribuzione log-normale.¹⁶ Troverà un elenco molto interessante di campi in cui una distribuzione log-normale sembra essere un buon modello per analizzare i dati: comportamenti umani, biologia e medicina, chimica dei colloidi e dei polimeri, idrologia, scienze demografiche e sociali, tecnologia. Fra i diversi esempi segnalati, uno in particolare poteva essere oggetto di analisi immediata. Abbiamo quindi voluto verificare se davvero, come era segnalato sulla pagina consultata, la dimensione della popolazione residente dei vari Comuni (italiani, nel nostro caso) poteva essere descritta da una distribuzione log-normale.

Dal sito dell'ISTAT¹⁷ abbiamo scaricato il *file* della popolazione residente (Femmine + Maschi) al 1° gennaio 2019 nei diversi Comuni italiani (sono 7979 su un totale di 8365 quelli per i quali era disponibile il dato). L'istogramma relativo è riportato

¹⁴Ad esempio, la distribuzione di molti elementi nelle rocce ignee segue una legge di probabilità di tipo log-normale. Si veda al riguardo Latham *et al.* (1989).

¹⁵Come abbiamo fatto noi il 10/1/2021.

¹⁶La pagina in inglese è molto più ricca di informazioni. L'indirizzo è https://en.wikipedia.org/wiki/Log-normal_distribution

¹⁷<http://dati.istat.it/>




Figura 3.16: A sinistra: Distribuzione di frequenza della popolazione (F+M) residente al 1° gennaio 2019 nei Comuni italiani. La curva continua rappresenta la funzione di densità di probabilità della distribuzione log-normale interpolata. A destra: Grafico *quantile-quantile* per valutare la bontà di adattamento dei dati osservati al modello teorico log-normale.

nel pannello di sinistra della Figura 3.16. Sullo stesso grafico abbiamo disegnato la funzione di densità di probabilità di una distribuzione log-normale, assegnando agli argomenti della funzione `dlnorm` i valori 7.83 e 1.36 (cioè, rispettivamente, la media e la deviazione standard del logaritmo dei valori della popolazione residente). Questa volta non si tratta di una simulazione per la quale si conosce il modello reale; in questo caso si tratta di dati empirici. Ebbene, l’adattamento si direbbe davvero estremamente buono.

Abbiamo anche calcolato i decili “campionari” e i decili attesi sulla base di una distribuzione log-normale; anche in questo caso i valori sono molto simili.

```
> p <- c(1:9)/10
> (qo <- round(quantile(x,p),0))
10%  20%  30%  40%  50%  60%  70%  80%  90%
468  808 1224 1730 2443 3441 5025 7803 14088
> (qa <- round(qlnorm(p,m,s),0))
439  799 1232 1783 2519 3559 5150 7938 14465
```

Infine, nel pannello di destra della Figura 3.16, si può osservare il grafico *quantile-quantile* ed apprezzare una volta di più come i valori osservati siano ben riprodotti dal modello teorico. Si può quindi dire che impiegando soltanto due numeri (la media e la deviazione standard del logaritmo della popolazione residente nei diversi Comuni) si può “riprodurre” in modo abbastanza fedele la distribuzione di frequenza della popolazione residente nei quasi 8000 Comuni italiani.

3.4 Altre variabili casuali continue

La variabile casuale normale è, in un certo senso, la più “importante” fra le variabili casuali continue. Oltre a quelle viste in questo capitolo ve ne sono, ovviamente, molte altre che qui non affrontiamo in dettaglio. Vogliamo soltanto ricordare alcune variabili casuali importanti per quanto riguarda l’inferenza e che sono descritte nel libro *Ricerca con R*: la variabile casuale *chi quadrato*, la variabile casuale *t* di Student, la variabile casuale *F*. Queste tre variabili casuali si possono tutte pensare “derivate” dalla variabile casuale normale standard.

3.4.1 La variabile casuale chi quadrato

La variabile casuale *chi quadrato* con n gradi di libertà è la somma di n variabili casuali normali standard al quadrato fra loro indipendenti.

$$\chi_n^2 = \sum_{i=1}^n Z_i^2,$$

dove Z è una variabile casuale normale standard. Le funzioni di R relative a questa variabile casuale sono `dchisq`, `pchisq`, `qchisq`, `rchisq`.

Il valore atteso di una variabile casuale chi quadrato con n gradi di libertà è uguale a n , mentre la varianza è uguale a $2n$ (il doppio dei gradi di libertà).

Possiamo sfruttare R e la funzione `dchisq` per vedere quale è la forma di una variabile casuale chi quadrato con n gradi di libertà. Nella Figura 3.17 osserviamo come si modifichi la forma passando da 1 a 3 gradi di libertà; inoltre se indichiamo con $f_n(x)$ la funzione di densità di probabilità di una variabile casuale chi quadrato con n gradi di libertà, allora si ha che $f_1(0) = \infty$, $f_2(0) = 0.5$, $f_3(0) = 0$. L’ultimo grafico della Figura 3.17 fa intuire che quando i gradi di libertà sono numerosi, la variabile casuale chi quadrato tende alla normale con media n e varianza $2n$.

3.4.2 La variabile casuale t di Student

La variabile casuale t di Student con n gradi di libertà è il rapporto fra una variabile casuale normale standard al numeratore e, al denominatore, la radice quadrata di una variabile casuale chi quadrato con n gradi di libertà divisa per n , fra loro indipendenti. In simboli:

$$t \sim \frac{Z}{\sqrt{\chi_n^2/n}}$$

Le funzioni di R relative a questa variabile casuale sono `dt`, `pt`, `qt`, `rt`.

Il grafico della funzione di densità di probabilità di una variabile casuale t di Student è in generale molto simile a quello di una variabile casuale normale standard, con un massimo in corrispondenza dello zero, che è anche la mediana della distribuzione.




Figura 3.17: Densità di probabilità della variabile casuale chi quadrato con 1, 2, 3, 100 gradi di libertà. Nell'ultimo grafico (in basso a destra) è riportata (tratteggiata) la funzione di densità di probabilità di una variabile casuale normale con media 100 e varianza 200.

La media è sempre zero tranne che nel caso in cui $n = 1$, valore per il quale non è definita; proviamo con R:

```
> set.seed(123456)
> x <- rt(1000000,1); mean(x)
[1] 5.972237
> x <- rt(1000000,1); mean(x)
[1] -3.036316
> x <- rt(1000000,1); mean(x)
[1] 1.116677
> x <- rt(1000000,1); mean(x)
[1] 0.002662667
> x <- rt(1000000,1); mean(x)
[1] -1.024635
```

La media delle repliche non è assolutamente stabile, cosa che non succede, ad esempio, quando $n = 2$:

```
> set.seed(123456)
> x <- rt(1000000,2); mean(x)
```

```
[1] 0.003464133
> x <- rt(1000000,2); mean(x)
[1] 0.009340373
> x <- rt(1000000,2); mean(x)
[1] -0.002040492
> x <- rt(1000000,2); mean(x)
[1] -0.00657685
> x <- rt(1000000,2); mean(x)
[1] -0.00609931
```

Per quanto riguarda la varianza, questa è infinita quando $n = 1$ o $n = 2$:

```
> set.seed(123456)
> x <- rt(1000000,2); var(x)
[1] 17.13951
> x <- rt(1000000,2); var(x)
[1] 47.17742
> x <- rt(1000000,2); var(x)
[1] 12.68094
> x <- rt(1000000,2); var(x)
[1] 38.30628
> x <- rt(1000000,2); var(x)
[1] 11.70582
```

Quando $n > 2$, la varianza è $\frac{n}{n-2}$; osserviamo che questo valore è sempre più grande di 1, anche se si avvicina sempre di più a 1 al crescere dei gradi di libertà n :

```
> set.seed(123456)
> x <- rt(1000000,3); var(x)
[1] 2.960171
> x <- rt(1000000,12); var(x)
[1] 1.200185
> x <- rt(1000000,102); var(x)
[1] 1.021714
> x <- rt(1000000,1002); var(x)
[1] 1.000446
```

Possiamo sfruttare R e la funzione `dt` per vedere quale è la forma di una variabile casuale t di Student con n gradi di libertà e confrontarla con quella di una variabile casuale normale standard. Nella Figura 3.18 osserviamo come la forma sia sempre fondamentalmente la stessa: una curva unimodale simmetrica, con il picco in corrispondenza del valore zero. Visivamente già con 5 gradi di libertà la curva della t sembra quasi sovrapposta a quella della normale standard e, ovviamente, ancora di più quando i gradi di libertà sono 10.




Figura 3.18: Densità di probabilità della variabile casuale t di Student con 1, 2, 5, 10 gradi di libertà. Per confronto, in ogni grafico è riportata (tratteggiata) la funzione di densità di probabilità di una variabile casuale normale standard.

3.4.3 La variabile casuale F

Abbiamo detto che la variabile casuale t di Student con n gradi di libertà è

$$t \sim \frac{Z}{\sqrt{\frac{\chi^2}{n}}}.$$

Se eleviamo tutto al quadrato, ricordando che $Z^2 = \chi_1^2$ (una normale standard al quadrato è un chi quadrato con 1 grado di libertà), abbiamo

$$t^2 \sim \frac{\chi_1^2/1}{\chi_n^2/n},$$

cioè il rapporto fra due variabili casuali chi quadrato indipendenti, ciascuna divisa per i suoi gradi di libertà, ovvero una variabile casuale F con 1 grado di libertà al numeratore e n gradi di libertà al denominatore.

In generale il rapporto fra una variabile casuale chi quadrato con n_1 gradi di libertà al numeratore e una variabile casuale chi quadrato con n_2 gradi di libertà al

denominatore, fra loro indipendenti, ciascuna divisa per i rispettivi gradi di libertà è una variabile casuale F (di Fisher-Snedecor) con n_1 gradi di libertà al numeratore e n_2 gradi di libertà al denominatore:

$$F_{n_1, n_2} \sim \frac{\chi_{n_1}^2 / n_1}{\chi_{n_2}^2 / n_2}.$$

Le funzioni di R relative a questa variabile casuale sono `df`, `pf`, `qf`, `rf`.

Come accenneremo nel prossimo capitolo, la distribuzione F è importante quando si vuole fare inferenza su varianze stimate a partire da campioni casuali.

3.5 La “famiglia esponenziale” e i modelli lineari generalizzati

Cosa hanno in comune variabili casuali discrete come la binomiale o la Poisson e variabili casuali continue come la normale? Possono tutte essere viste come appartenenti ad una *classe di funzioni* $f(y; \theta, \phi)$, detta *famiglia di funzioni esponenziali*.¹⁸

$$f(y; \theta, \phi) = \exp \left\{ \frac{y\theta - b(\theta)}{a(\phi)} + c(y, \phi) \right\}, \quad (3.24)$$

dove $a(\cdot)$, $b(\cdot)$ e $c(\cdot)$ sono funzioni specifiche. Se il parametro ϕ è noto, allora la (3.24) descrive un modello di famiglia esponenziale di cui θ rappresenta il *parametro canonico*.

Quando la densità di Y è specificata come nella (3.24), la media e la varianza di Y possono essere espresse in termini di θ e ϕ come segue:

$$\begin{aligned} E(Y) &= b'(\theta) \\ \text{Var}(Y) &= b''(\theta)a(\phi), \end{aligned}$$

dove l'apice (') indica la differenziazione rispetto a θ .

La varianza di Y è quindi il prodotto di due funzioni, una delle quali ($b''(\theta)$) dipende dal solo parametro canonico ed è detta *funzione di varianza*, mentre l'altra dipende soltanto da ϕ .

Normale. Per ottenere la distribuzione Normale, poniamo $\phi = \sigma^2$, $a(\phi) = \phi$, $b(\theta) = \theta^2/2$ e

$$c(y, \phi) = -\frac{1}{2} \left(\frac{y^2}{\phi} + \log(2\pi\phi) \right).$$

¹⁸Seguiremo la simbologia di McCullagh e Nelder, 1989.

Il parametro θ è la media μ della normale (come si può verificare facilmente tenendo presente le relazioni appena definite), mentre il parametro ϕ è la varianza σ^2 .

Binomiale. È necessario in questo caso considerare il parametro n come fissato e definire la variabile casuale Y non come il numero S di successi, ma come la proporzione di successi ($Y = S/n$). Possiamo allora porre $\phi = 1/n$, $a(\phi) = \phi$, $b(\theta) = \log(1 + e^\theta)$ e

$$c(y, \phi) = \log \left[\binom{n}{ny} \right],$$

dove ny è il numero dei successi. In questo modo la media di Y è p ed è data da $e^\theta / (1 + e^\theta)$; il parametro θ rappresenta l'*odds* di successo.

Poisson. Per ottenere la distribuzione di Poisson, poniamo $\phi = 1$, $a(\phi) = \phi$, $b(\theta) = e^\theta$ e $c(y, \phi) = -\log y!$. La media della Poisson (così come la varianza) è quindi e^θ (ovvero, il parametro θ è il logaritmo della media).

Cosa ci “guadagniamo” a complicare in questo modo la rappresentazione della funzione di densità di probabilità di una variabile casuale Y ? In effetti in questo modo variabili casuali (in apparenza) differenti possono essere viste tutte come appartenenti ad una stessa classe, la *famiglia esponenziale*. È stato così possibile introdurre, nel lavoro “seminale” di Nelder e Wedderburn (1972), i *modelli lineari generalizzati* estendendo in modo del tutto naturale la teoria del *modello lineare classico*. La teoria dei modelli lineari generalizzati è il fondamento di gran parte dei metodi statistici maggiormente impiegati nel campo della ricerca empirica.

Il modello lineare classico

Il modello lineare classico, così come i modelli lineari generalizzati, sono al di là degli scopi di questo libro. Tuttavia da un lato abbiamo già fatto riferimento più di una volta al modello lineare e, dall'altro, potendo impiegare le potenzialità di R possiamo fare un accenno molto concreto (di tipo “operativo”) a questo fondamentale capitolo della Statistica.

Accade molto spesso che il ricercatore sia interessato a valutare in che misura una *variabile dipendente* y sia “influenzata” da una o più *variabili indipendenti* (o *covariate*) $x_1, x_2, \dots, x_k$. Limitandoci d'ora in avanti al caso più semplice (una sola variabile indipendente) abbiamo quindi $y = f(x)$. Naturalmente $f(x)$ rappresenta una qualsiasi funzione che va però definita in modo esplicito per poter proseguire nell'analisi. Il caso più semplice (ma anche quello più frequente) è una relazione di tipo *lineare*:¹⁹ $y = b_0 + b_1x$. Nel linguaggio statistico, b_0 prende il nome di *intercetta* (o, anche, *ordinata all'origine*), mentre b_1 prende il nome di *coefficiente di regressione lineare* (e ci dice di quanto varia y quando x varia di una unità).

¹⁹Abbiamo trattato questo argomento dal punto di vista descrittivo in Espa, Micciolo (2012). Per ulteriori approfondimenti si rimanda ad Agresti e Franklin (2016), in particolare ai *Laboratori* con R.

Esempio 3.1 Supponiamo ad esempio che la variabile dipendente y sia il peso (in kg) di una persona (di genere maschile e di età compresa fra 20 e 50 anni) e che la variabile indipendente x sia l'altezza (in cm) di quella stessa persona. Supponiamo inoltre che *in media* il peso di una persona alta x cm sia dato dalla seguente relazione: $y = -85 + 0.88x$. In questo modo, ad esempio, il peso medio delle persone alte 170 cm è 64.77 kg, mentre quello delle persone alte 171 cm è 65.48 kg e la differenza fra i due pesi è proprio b_1 (0.88 kg, ovvero 880 g). Naturalmente l'altezza non è (non può essere) l'unica “determinante” del peso di un uomo in età adulta. Ci sono altri fattori (genetici ed ambientali) che concorrono alla “realizzazione” del peso. Supponiamo allora che, a parità di altezza x , la distribuzione del peso sia normale con media $\mu_x = -85 + 0.88x$ e deviazione standard $\sigma = 10$. Eseguiamo una simulazione i cui risultati, sotto forma di *scatterplot*, sono rappresentati nel pannello (a) della Figura 3.19.

```
> set.seed(654321)
> a <- -85
> b <- 0.88
> x <- seq(150,190,5)
> n <- length(x)
> m <- a + b*x
> e <- rnorm(5*n,0,10)
> e <- matrix(e,nrow=n)
> y <- m + e
```

Sono state simulate 5 osservazioni per ciascuno dei 9 valori di altezza considerati (150, 155, 160, ..., 190). Ciascuna osservazione (ciascun elemento del vettore y) è costituita da una parte *sistematica* (riga 6 dello *script*) e da una parte *casuale* (un valore estratto da una normale con media zero e deviazione standard 10). I 45 valori così ottenuti sono visibili nel pannello (a) della Figura 3.19. L'equazione della retta rappresentata nella stessa figura con un tratto continuo è $y = -85 + 0.88x$.

Quando si interpola un modello lineare, il primo scopo è *stimare* i parametri sconosciuti (b_0 e b_1 nel nostro caso). Abbiamo visto²⁰ che queste stime si ottengono impiegando il metodo dei *minimi quadrati*. In realtà nel caso in esame questo metodo risulta equivalente ad un metodo più generale, la *massima verosimiglianza* (*maximum likelihood*), più “adatto” quando i dati provengono da un campione casuale estratto da una distribuzione di probabilità (normale, nel nostro esempio).

In R, come abbiamo già visto, la funzione deputata a trovare queste stime è `lm` (che sta appunto per *linear model*). L'argomento principale di questa funzione è una *formula*, consistente di una parte sinistra (la variabile dipendente) e una parte destra

²⁰Espa, Micciolo (2012).




Figura 3.19: (a) Modello lineare. (b) Modello logistico. (c) Modello *complementary log log*. (d) Modello di Poisson. In tutti i pannelli la linea continua è relativa al modello “vero” (nel quale i parametri b_0 e b_1 sono noti), mentre quella punteggiata è relativa al modello in cui i parametri b_0 e b_1 sono stimati con il metodo della massima verosimiglianza. Nel pannello (c) la linea tratteggiata è relativa ad un modello logistico che, però, non è il modello corretto.

(la variabile indipendente o le variabili indipendenti, se sono più d’una) separate dal simbolo della “tilde”:

```
> Y <- as.vector(y)
> X <- rep(x,5)
> fit <- lm(Y ~ X)
> fit$coefficients
(Intercept)          X
-76.1947631    0.8422818
```

L'output della funzione `lm` (che abbiamo “raccolto” nell'oggetto `fit`) è molto “ricco” e complesso. Per quanto riguarda il nostro esempio, è sufficiente conoscere le stime dei parametri b_0 e b_1 (`fit$coefficients`). L'equazione della retta così stimata ($y = -76 + 0.842x$) non coincide con quella della retta “vera” ($y = -85 + 0.88x$), ma è molto vicina ad essa. Un intervallo di confidenza al 95%,²¹ ottenuto mediante la funzione `confint`, include il valore vero (0.88) all'interno dell'intervallo.

```
> confint(fit)[2,]
      2.5 %      97.5 %
0.6182776 1.0662859
```

La retta stimata è rappresentata nel pannello (a) della Figura 3.19 con un tratto punteggiato.

Vogliamo far notare come, nel modello lineare classico, la variabile dipendente è rappresentata da una variabile casuale Y , normalmente distribuita, la cui media dipende, secondo una relazione lineare, dalla variabile indipendente (i cui valori si considerano “fissati”): $E(Y) = \mu_x = b_0 + b_1x$.

I modelli lineari generalizzati

Possiamo pensare ad un modello lineare classico come costituito da due componenti: una componente casuale, rappresentata dalla variabile casuale Y , la cui distribuzione di probabilità è normale, e una componente sistematica che definisce come varia il valore atteso (la media) di Y al variare di x ; in un modello lineare la relazione fra il valore atteso di Y e x è, appunto, lineare: $E(Y) = \mu_x = b_0 + b_1x$.

Possiamo definire un modello lineare generalizzato in un modo molto simile. Anch'esso si può considerare costituito da due componenti: una componente casuale, rappresentata da una variabile casuale Y , la cui distribuzione di probabilità appartiene alla famiglia esponenziale, e una componente sistematica che definisce come varia il valore atteso (la media) di Y al variare di x ; in un modello lineare generalizzato non è detto che la relazione fra il valore atteso di Y e x debba essere lineare; quello che deve essere lineare è la relazione fra una trasformazione T (una funzione) del valore atteso di Y e x : $T(E(Y)) = T(\mu_x) = b_0 + b_1x$. Questa trasformazione (questa funzione) è detta *funzione di link* (*link function*), in quanto fa da collegamento fra la componente sistematica e quella casuale, e $b_0 + b_1x$ è detto *predittore lineare* (*linear predictor*).

I modelli lineari generalizzati rappresentano quindi una classe di modelli statistici della quale il modello lineare classico rappresenta un caso particolare per il quale la distribuzione di probabilità di Y è normale e la funzione di *link* è la *funzione identità*: $T(\mu_x) = \mu_x$. Al tempo stesso, un modello lineare generalizzato può contemplare

²¹In questo intervallo “quasi certamente” (ovvero con una confidenza del 95%) è contenuto il valore vero che, generalmente, non è noto. Per ulteriori dettagli e approfondimenti si veda *Ricerca con R*.

il caso in cui, ad esempio, la variabile casuale Y sia una “proporzione di successi” (che sottende una distribuzione di probabilità binomiale), oppure un “conteggio” (con una distribuzione di probabilità di tipo Poisson). Non abbiamo fatto questi due esempi a caso, dal momento che si tratta delle due situazioni in cui un modello lineare generalizzato è più frequentemente impiegato nell’ambito della ricerca empirica.

Prima di passare a vedere alcuni esempi è opportuno ricordare che l’introduzione dei modelli lineari generalizzati (avvenuta poco meno di 50 anni fa) ha permesso di estendere le procedure di inferenza, che fino ad allora erano sostanzialmente limitate al caso normale, a situazioni molto comuni nell’ambito della ricerca empirica (quali l’analisi delle proporzioni e dei conteggi). Inoltre, dal momento che qualsiasi distribuzione di probabilità appartenente alla famiglia esponenziale può essere espressa come abbiamo fatto nella (3.24), è stato possibile impiegare un metodo comune (il metodo della “massima verosimiglianza”) per stimare i parametri del modello e fare inferenza su di essi, mettendo a punto un unico algoritmo di applicazione generale in varie discipline e in grado di affrontare diversi problemi. Un *software* ormai storico, sviluppato pochissimi anni dopo l’articolo di Nelder e Wedderburn (1972), che ha implementato questo tipo di approccio è stato il *GLIM*.²² Sia pure con una filosofia molto diversa, derivante dal progresso dei linguaggi di programmazione, una buona parte dei “comandi” del *GLIM* si ritrovano tradotti in R, un *software* che, come il *GLIM*, mantiene l’impostazione a “riga di comando” (*Command Line Interface*).

Analisi di proporzioni: il modello logistico

Accade spesso che il ricercatore debba analizzare delle “proporzioni”, avendo conteggiato il numero y di successi in n prove indipendenti, e che, in particolare, sia interessato a valutare come queste proporzioni si modifichino al variare di una covariata x . Per illustrare questa situazione, prenderemo lo spunto da un esempio “storico” descritto da Dobson (2002) e relativo ad un lavoro di Bliss (1935). Tuttavia, dal momento che il nostro scopo è illustrare operativamente la procedura, la nostra analisi si baserà su dati simulati.

Esempio 3.2 Supponiamo che il numero di coleotteri (*beetles*) morti dopo cinque ore di esposizione a solfuro di carbonio alla concentrazione x sia modellato da una distribuzione di probabilità binomiale con parametro n fissato dal ricercatore (può essere lo stesso per tutte le concentrazioni prese in esame o, invece, variare a seconda della concentrazione) e parametro p_x (il valore atteso della Bernoulli sottostante alla binomiale) che dipende da x secondo la seguente relazione

$$p_x = \frac{e^{b_0 + b_1 x}}{1 + e^{b_0 + b_1 x}} \quad (3.25)$$

(questo è il *modello logistico*.)

²² Acronimo di *Generalized Linear Interactive Modelling*.

Applichiamo ora a p_x la *trasformazione logit* mediante due passaggi:

1. passiamo dalla probabilità p_x all'*odds* corrispondente $p_x/(1 - p_x) = e^{b_0 + b_1 x}$;
2. facciamo il logaritmo naturale dell'*odds* : $b_0 + b_1 x$.

Ecco quindi che, in questo caso, la trasformazione *logit* rappresenta la funzione di *link* che rende lineare la relazione di dipendenza dalla covariata x e permette di stimare i parametri b_0 e b_1 del modello lineare generalizzato corrispondente (nel nostro caso, il modello logistico).

Nella simulazione che proponiamo, abbiamo preso in esame 13 diverse concentrazioni di solfuro di carbonio (1.7, 1.75, 1.8, ..., 2.3).²³ Per ciascuna concentrazione x calcoliamo il predittore lineare (p_l), ovvero $f(x) = -40 + 20x$ e, da questo, ricaviamo il parametro p_x della binomiale (terza riga dello *script*). A questo punto, per ciascuna delle concentrazioni, estraiamo, mediante la funzione `rbinom`, un numero casuale di successi a partire da una binomiale con $n = 100$ fissato e probabilità data da p_x (riga 8). I dati da elaborare sono riportati nell'ultima riga dello *script*.

```
> x <- seq(1.7,2.3,0.05)
> pl <- -40 + 20*x
> p <- exp(pl)/(1+exp(pl))
> k <- length(p)
> y <- numeric(k)
> n <- rep(100,k)
> set.seed(135246)
> for (i in 1:k) y [i] <- rbinom(1,n[i],p[i])
> rbind(x,y)
x 1.7 1.75 1.8 1.85 1.9 1.95 2 2.05 2.1 2.15 2.2 2.25 2.3
y 1.0 1.00 3.0 6.00 16.0 20.00 48 76.00 88.0 97.00 97.0 100.00 99.0
```

Possiamo ora stimare i parametri b_0 e b_1 di questo modello lineare generalizzato impiegando la funzione `glm`.

```
> fit <- glm(y/n ~ x, family=binomial("logit"), weights=n)
> fit$coefficients
(Intercept)          x
-38.28882      19.15403
```

Come si può vedere le stime di b_0 e b_1 (-38.3 e 19.15) sono molto vicine ai valori veri (-40 e 20). Vediamo come si interpola con R un modello logistico.

- La funzione da chiamare è `glm` (che sostituisce `lm`).
- La variabile dipendente (a sinistra della tilde) è la proporzione di successi ottenuta come rapporto fra il numero dei successi (inseriti nel vettore y) e il numero delle prove (inserite nel vettore n).

²³Per non appesantire la trattazione, non è importante specificare l'unità di misura della concentrazione.

- A destra della tilde si trova la covariata, ovvero il vettore x , i cui elementi contengono le concentrazioni di solfuro di carbonio.
- Assegniamo all'argomento `family` il “valore” `binomial` per indicare il tipo di distribuzione di probabilità (all'interno della famiglia esponenziale) che vogliamo impiegare per analizzare i dati.
- La funzione di *link* (`logit`) è specificata sotto forma di stringa che completa le indicazioni date attraverso l'argomento `family`.
- Infine, l'argomento `weights` identifica il numero delle prove associate a ciascuna proporzione.

Nel pannello (b) della Figura 3.19 troviamo rappresentati:

- lo *scatterplot* dei dati che abbiamo analizzato;
- la curva logistica $p_x = \frac{e^{-40+20x}}{1+e^{-40+20x}}$ relativa al vero modello con il quale sono stati generati i dati (disegnata con una linea continua);
- la curva logistica $\hat{p}_x = \frac{e^{-38+19x}}{1+e^{-38+19x}}$ relativa al modello stimato (disegnata con una linea punteggiata).

Cosa rappresentano i parametri b_0 e b_1 di un modello logistico? Facendo riferimento alla (3.25), possiamo dire che b_0 è associato all'*odds* di “successo” quando $x = 0$, mentre b_1 è associato all'*odds ratio*. Il nostro esempio, nel quale la covariata x è quantitativa, non si presta molto bene a discuterne il significato. Prendiamo invece il seguente esempio tristemente reale.

Esempio 3.3 Consultando il sito dell'Istituto Superiore di Sanità è possibile scaricare²⁴ un file con i dati aggiornati sulla mortalità per fascia di età in Italia relativi all'epidemia da COVID-19. Alla data del 5 febbraio 2021 i casi totali di COVID-19 (femmine + maschi) nella fascia di età 20 – 69 anni erano complessivamente 1788800, mentre quelli nella fascia di età 70 – 89 anni erano 402516. Alla stessa data i decessi totali nella fascia di età 20 – 69 anni erano 12196, mentre quelli nella fascia di età 70 – 89 anni erano 58535. Possiamo analizzare questi dati interpolando un modello logistico in questo modo:

```
> y <- c(12196, 58535)
> n <- c(1788800, 402516)
> x <- c(0, 1)
> fit <- glm(y/n ~ x, family=binomial("logit"), weights=n)
> fit$coefficients
(Intercept)          x
-4.981351      3.210389
```

²⁴<https://www.epicentro.iss.it/coronavirus/sars-cov-2-dashboard>

Il vettore y contiene il numero di decessi nelle due fasce di età considerate e il vettore n il numero di casi corrispondenti. Infine abbiamo definito una covariata x che assume valore 0 quando la fascia di età è 20 – 69 anni e valore 1 quando la fascia di età è 70 – 89 anni. Per interpretare il significato delle stime dei parametri b_0 e b_1 facciamone l'esponenziale.

```
> exp(fit$coefficients)
(Intercept)          x
0.006864782 24.788736320
```

Iniziamo da b_0 . Quando $x = 0$ (quindi quando la fascia di età è 20 – 69 anni), il predittore lineare assume il valore -4.981351 (la stima di b_0). Il suo esponenziale produce il corrispondente *odds* di mortalità, che risulta proprio quello che possiamo calcolare direttamente dai dati:

```
> p <- y/n
> p[1]/(1 - p[1])
[1] 0.006864782
> b <- fit$coefficients
> exp(b[1])
(Intercept)
0.006864782
```

Non si tratta di una coincidenza numerica; i due valori devono essere uguali. La corrispondente proporzione di decessi è circa 0.00686.

Quando $x = 1$, (quindi quando la fascia di età è 70 – 89 anni), il predittore lineare assume il valore $-4.981351 + 3.210389$ (la stima di $b_0 + b_1$). Il suo esponenziale produce il corrispondente *odds* di mortalità; anche questo risulta esattamente uguale a quello che si può calcolare direttamente dai dati:

```
> p <- y/n
> p[2]/(1 - p[2])
[1] 0.1701693
> b <- fit$coefficients
> exp(b[1] + b[2])
0.1701693
```

La corrispondente proporzione di decessi è circa 0.145.

Il rapporto fra i due *odds* di mortalità (70 – 89 anni vs 20 – 69 anni), cioè l'*odds ratio*, coincide con l'esponenziale della stima di b_1

```
> odds <- p/(1-p)
> odds[2]/odds[1]
[1] 24.78874
> exp(b[2])
x
24.78874
```

e ci dice che l'*odds* di mortalità dei casi di COVID-19 diagnosticati in Italia nella fascia di età 70 – 89 anni è quasi 25 volte quello dei casi corrispondenti appartenenti alla fascia di età 20 – 69 anni.

Potrebbe sembrare a questo punto inutile interpolare un modello logistico per ottenere informazioni (come gli *odds* di mortalità e l'*odds ratio*) che è davvero più facile ricavare “a mano” (con una calcolatrice che faccia le sole 4 operazioni).

Non è così. La forza di un modello lineare generalizzato è che a questo punto abbiamo sostanzialmente “gratis” tutta la parte di inferenza (l'argomento di *Ricerca con R*). Infatti, se ad esempio volessimo costruire un intervallo di confidenza al 95% per l'*odds* di mortalità nella fascia di età 20 – 69 anni e (soprattutto) per l'*odds ratio*, basterebbe solo chiederlo chiamando la funzione `confint`:

```
> exp(confint(fit))
Waiting for profiling to be done...
                2.5 %          97.5 %
(Intercept) 0.006743261 0.006987764
x           24.302560226 25.286674769
```

La trasformazione *logit* non è l'unica che possa essere impiegata come funzione di *link* quando la famiglia (*family*) è binomiale. Ad esempio si può usare la trasformazione *probit* $T(p) = \Phi^{-1}(p)$, dove Φ^{-1} è l'inversa della funzione di ripartizione di una normale; tuttavia la trasformazione *probit* produce in generale risultati molto simili a quelli che si ottengono impiegando la trasformazione *logit* senza che i suoi parametri possano però essere interpretati come *odds* oppure *odds ratio*.

Analisi di proporzioni: il modello “cloglog”

Vogliamo accennare brevemente ad una particolare funzione di *link* (`cloglog`) che ha delle caratteristiche davvero particolari. Lo facciamo riprendendo l'esempio della simulazione vista in precedenza.

Esempio 3.4 Supponiamo che il numero di coleotteri morti dopo cinque ore di esposizione a solfuro di carbonio alla concentrazione x sia modellato da una distribuzione di probabilità binomiale con parametro n fissato dal ricercatore e parametro p_x che dipende da x secondo la seguente relazione

$$p_x = 1 - \exp[-\exp(b_0 + b_1x)]. \quad (3.26)$$

Per linearizzare questo modello dobbiamo innanzitutto considerare il complemento a 1 di p_x (quindi la probabilità di insuccesso):

$$1 - p_x = \exp[-\exp(b_0 + b_1x)]$$

e poi applicare due volte in successione il logaritmo naturale, facendo attenzione anche al segno “meno”:

$$\begin{aligned}\log(1 - p_x) &= -\exp(b_0 + b_1x), \\ -\log(1 - p_x) &= \exp(b_0 + b_1x), \\ \log(-\log(1 - p_x)) &= b_0 + b_1x.\end{aligned}$$

In questo caso, la trasformazione (la funzione di *link*) che rende lineare la relazione di dipendenza dalla covariata x si chiama *complementary log log* (ovvero, *cloglog*). Nella simulazione che proponiamo, abbiamo preso in esame 14 diverse concentrazioni di solfuro di carbonio (1.8, 1.82, ..., 2.06). Per ciascuna concentrazione x calcoliamo il *predittore lineare* in analogia al caso precedente $f(x) = -40 + 20x$ e, da questo, ricaviamo il parametro p_x della binomiale (terza riga dello *script*). A questo punto, per ciascuna delle concentrazioni, estraiamo, mediante la funzione *rbinom*, un numero casuale di successi a partire da una binomiale con $n = 100$ fissato e probabilità data da p_x (riga 8). I dati da elaborare sono riportati nell'ultima riga dello *script*.

```
> x <- seq(1.8,2.06,0.02)
> pl <- -40 + 20*x
> p <- 1 - exp(-exp(pl))
> k <- length(p)
> y <- numeric(k)
> n <- rep(100,k)
> set.seed(246135)
> for (i in 1:k) y [i] <- rbinom(1,n[i],p[i])
> rbind(x,y)
  [,1] [,2] [,3] [,4] [,5] [,6] [,7] [,8] [,9] [,10] [,11] [,12] [,13] [,14]
x 1.8 1.82 1.84 1.86 1.88 1.9 1.92 1.94 1.96 1.98 2 2.02 2.04 2.06
y 1.0 4.00 6.00 7.00 6.00 10.0 18.00 23.00 31.00 45.00 59 76.00 88.00 99.00
```

Per stimare i parametri b_0 e b_1 di questo modello chiamiamo la funzione *glm* specificando opportunamente la funzione di *link*

```
> fit <- glm(y/n ~ x, family=binomial("cloglog"), weights=n)
> fit$coefficients
(Intercept)          x
-41.56557      20.75885
```

Come si può vedere le stime di b_0 e b_1 (-41.6 e 20.76) sono molto vicine ai valori veri (-40 e 20). Nel pannello (c) della Figura 3.19 troviamo rappresentati:

- lo *scatterplot* dei dati che abbiamo analizzato;
- la curva corrispondente al vero modello $p_x = 1 - \exp[-\exp(-40 + 20x)]$ con il quale sono stati generati i dati (disegnata con una linea continua);
- la curva $\hat{p}_x = 1 - \exp[-\exp(-42 + 21x)]$ relativa al modello stimato (disegnata con una linea punteggiata);

- la curva logistica ottenuta stimando i parametri impiegando la funzione di *link* $\text{logit}(\hat{p}_x) = \frac{e^{-53+27x}}{1+e^{-53+27x}}$ (disegnata con una linea tratteggiata).

La curva punteggiata (ottenuta stimando il modello corretto) e quella tratteggiata (relativa ad un modello sbagliato) sono estremamente vicine fra loro e si distaccano solo quando la dose è “elevata” (superiore a 2); in altre parole quando la probabilità stimata è vicina ad uno. Vediamo “in pratica” come questa sia una caratteristica peculiare che differenzia i due modelli.

Ripetiamo la simulazione relativa al modello logistico, eseguendo anche l’analisi sulla probabilità di “insuccesso”:

```
> x <- seq(1.7,2.3,0.05)
> pl <- -40 + 20*x
> p <- exp(pl)/(1+exp(pl))
> k <- length(p)
> y <- numeric(k)
> n <- rep(100,k)
> set.seed(135246)
> for (i in 1:k) y[i] <- rbinom(1,n[i],p[i])
> fit <- glm(y/n ~ x, family=binomial("logit"), weights=n)
> fit$coefficients
(Intercept)          x
-38.28882      19.15403
> fit <- glm((n-y)/n ~ x, family=binomial("logit"), weights=n)
> fit$coefficients
(Intercept)          x
 38.28882     -19.15403
```

I risultati ottenuti sono gli stessi in valore assoluto; è cambiato soltanto il segno sia di b_0 , sia di b_1 . Da questo punto di vista analizzare i successi o gli insuccessi porta agli stessi risultati numerici (a parte il segno).

Vediamo cosa succede quando la funzione di *link* è *cloglog*:


```
> x <- seq(1.8,2.06,0.02)
> pl <- -40 + 20*x
> p <- 1 - exp(-exp(pl))
> k <- length(p)
> y <- numeric(k)
> n <- rep(100,k)
> set.seed(246135)
> for (i in 1:k) y [i] <- rbinom(1,n[i],p[i])
> fit <- glm(y/n ~ x, family=binomial("cloglog"), weights=n)
> fit$coefficients
(Intercept)          x
-41.56557      20.75885
```

```
> fit <- glm((n-y)/n ~ x, family=binomial("cloglog"), weights=n)
> fit$coefficients
(Intercept)          x
  25.46159    -13.09441
```

Anche in questo caso i segni dei coefficienti risultano opposti nelle due analisi, ma i risultati numerici sono del tutto diversi.

In effetti in un modello logistico la curva risulta simmetrica per valori di $p = 0.5$ e si “avvicina” a 0 e a 1 con la stessa velocità. Se questo non risulta “verificato” nei dati che si stanno analizzando, allora il modello logistico non è un buon modello e si potrebbe provare a modificare l’analisi cambiando la funzione di *link* in *cloglog*, in particolare quando la probabilità di un evento è molto piccola o molto grande. La curva del modello *cloglog* si avvicina a 0 abbastanza lentamente, mentre si avvicina a 1 abbastanza rapidamente; in questo caso è quindi fondamentale definire in modo appropriato qual è l’evento la cui probabilità si vuole stimare con il modello *cloglog*.

La figura qui sotto mostra in modo efficace come con lo stesso predittore lineare ($-40 + 20x$), il modello *complementary log log* (linea punteggiata) si avvicina ad 1 in maniera più “decisa” rispetto ad un modello logistico (linea continua).



Qualche lettore attento potrebbe avere avuto un *déjà-vu* quando abbiamo introdotto la trasformazione *complementary log log*: $\log(-\log(1 - p_x)) = b_0 + b_1x$. L’abbiamo in effetti già vista (l’avevamo chiamata *log minus log*) descrivendo la distribuzione Weibull e un modo grafico per verificare l’adattamento di questa funzione ad una serie di dati empirici:

$$\log(-\log(1 - F(t))) = k \log(h) + k \log(t).$$

In effetti il modello *complementary log log* è strettamente legato ai modelli di analisi della sopravvivenza in tempo continuo.

Analisi di conteggi: il modello di Poisson

Quando la variabile dipendente è un conteggio per il quale non si può proporre un preciso limite superiore ($Y = 0, 1, 2, \dots$), la distribuzione di Poisson (che fa parte della famiglia esponenziale) è verosimilmente quella di più comune impiego. L’unico parametro che specifica questa distribuzione di probabilità (μ) rappresenta il valore atteso (oltre che la varianza) della distribuzione. Il solo vincolo posto su μ è che deve essere

strettamente positivo ($\mu > 0$), essendo la media di un insieme di conteggi, ovvero di quantità positive e non tutte nulle.

Per analizzare l’andamento dei conteggi in relazione ad una covariata x un modello del tipo $\mu_x = b_0 + b_1x$ non va bene, dal momento che questa relazione non garantisce $\mu > 0$ per qualsiasi valore di x . È molto più “naturale” una relazione del tipo $\mu_x = e^{b_0+b_1x}$. In questo caso è del tutto evidente che la funzione di *link* logaritmo naturale, applicata a μ_x , rende lineare la dipendenza dalla covariata x . Abbiamo così la *regressione di Poisson*.

Per illustrare questo particolare tipo di modello lineare generalizzato, prenderemo lo spunto da un esempio trovato in rete²⁵ relativo al numero di ciclisti transitati giornalmente (dal 1/4/2017 al 31/10/2017) su diversi ponti della città di New York in relazione, in particolare, alla temperatura massima di ciascun giorno. Ancora una volta non analizzeremo i dati reali, ma prenderemo lo spunto per illustrare la regressione di Poisson mediante una simulazione.

Esempio 3.5 Supponiamo che il numero di ciclisti che passano su un certo ponte in un giorno in cui la temperatura massima è x gradi centigradi sia modellato da una distribuzione di Poisson con parametro μ_x che dipende da x secondo la seguente relazione:

$$\mu_x = e^{b_0+b_1x}. \quad (3.27)$$

Come detto poco sopra, prendendo il logaritmo naturale di ambo i membri della (3.27), si riesce a linearizzare la dipendenza dalla covariata x . In questo caso, quindi, la trasformazione (la funzione di *link*) è il logaritmo naturale (ovvero, $\log$). Nella simulazione che proponiamo, abbiamo preso in esame una serie di temperature (da 5 a 35 gradi) e, per ciascuna temperatura x , è stato calcolato il predittore lineare $f(x) = 5.83 + 0.077x$, ricavando da questo il valore da dare al parametro μ_x della Poisson (terza riga dello *script*). A questo punto, per ciascuna delle temperature, è stato estratto, mediante la funzione `rpois`, un numero casuale di ciclisti a partire da una Poisson con media data da μ_x (riga 7). I dati da elaborare sono riportati nelle ultime righe dello *script*.

```
> x <- c(5:35)
> pl <- 5.83 + 0.077*x
> mu <- exp(pl)
> k <- length(mu)
> y <- numeric(k)
> set.seed(246135)
> for (i in 1:k) y[i] <- rpois(1,mu[i])
> rbind(x,y)
  [,1] [,2] [,3] [,4] [,5] [,6] [,7] [,8] [,9] [,10] [,11] [,12]
x    5    6    7    8    9   10   11   12   13   14   15   16
```

²⁵<https://tinyurl.com/y2tnrjnn>

```

y 483 552 564 628 683 712 803 866 942 1039 1100 1178
  [,13] [,14] [,15] [,16] [,17] [,18] [,19] [,20] [,21] [,22]
x  17   18   19   20   21   22   23   24   25   26
y 1199 1402 1420 1605 1657 1807 2048 2178 2346 2514
  [,23] [,24] [,25] [,26] [,27] [,28] [,29] [,30] [,31]
x  27   28   29   30   31   32   33   34   35
y 2711 2925 3119 3460 3651 3943 4364 4711 5042

```

Per stimare i parametri b_0 e b_1 di questo modello chiamiamo la funzione `glm` specificando opportunamente l'argomento `family` e la funzione di `link`

```

> fit <- glm(y ~ x, family=poisson("log"))
> fit$coefficients
(Intercept)          x
 5.82623019  0.07708711

```

Anche in questo esempio le stime di b_0 e b_1 (5.826 e 0.07709) sono molto vicine ai valori veri (5.83 e 0.077). Nel pannello (d) della Figura 3.19 troviamo rappresentati:

- lo *scatterplot* dei dati che abbiamo analizzato;
- la curva corrispondente al vero modello $\mu_x = \exp(5.83 + 0.077x)$ con il quale sono stati generati i dati (disegnata con una linea continua);
- la curva $\hat{\mu}_x = \exp(5.826 + 0.07709x)$ relativa al modello stimato (disegnata con una linea punteggiata).

Le due curve sono sostanzialmente sovrapposte ed interpolano in modo estremamente soddisfacente i dati empirici (simulati).

Per interpretare il significato dei parametri b_0 e b_1 del modello poissoniano, possiamo ancora una volta fare riferimento ai dati pubblicati dall'Istituto Superiore di Sanità relativi questa volta al numero di casi di COVID-19 diagnosticati in Italia dall'inizio della pandemia.

Esempio 3.6 Il documento “Epidemia COVID-19. Aggiornamento nazionale 3 febbraio 2021”, scaricato dal sito EpiCentro²⁶ riporta nella Tabella 3 a pagina 7 il numero di casi di COVID-19 diagnosticati in Italia dall'inizio della pandemia fino al 31 gennaio 2021 suddivisi per Regione. Nell'analisi che proporremo, i dati relativi alle regioni del Nord²⁷ da un lato e quelli relativi alle rimanenti regioni²⁸ dall'altro sono stati aggregati.

²⁶<https://tinyurl.com/y53xbt6d>

²⁷Liguria, Lombardia, Piemonte, Valle d'Aosta, Emilia-Romagna, Friuli-Venezia Giulia, Veneto, province autonome di Trento e di Bolzano.

²⁸Lazio, Marche, Toscana, Umbria, Abruzzo, Basilicata, Calabria, Campania, Molise, Puglia, Sardegna, Sicilia.

Alla data del 31 gennaio 2021 i casi totali di COVID-19 (femmine + maschi) diagnosticati fra i residenti nelle regioni del Nord Italia erano 1510463, mentre quelli relativi ai residenti nelle altre regioni erano 1058684. Questi due numeri rappresentano i valori assunti dalla variabile dipendente. Definiamo poi una covariata x che assume valore 0 nel caso delle regioni appartenenti al Centro-Sud-Isole e valore 1 nel caso delle regioni del Nord Italia.

Dovrebbe essere evidente che fino ad ora è stata tralasciata una informazione importante. Infatti, i dati relativi alle due aggregazioni regionali non possono essere confrontati direttamente, dal momento che il numero di residenti non è lo stesso. I residenti nelle regioni del Nord Italia sono 27616213, mentre i residenti nelle rimanenti regioni sono 32025275.

Possiamo ora analizzare questi dati interpolando un modello poissoniano come segue:

```
> y <- c(1510463, 1058684)
> n <- c(27616213, 32025275)/1000
> x <- c(1, 0)
> fit <- glm(y ~ x + offset(log(n)), family=poisson("log"))
> fit$coefficients
(Intercept)          x
  3.498256    0.503512
```

Il vettore y contiene il numero di casi nelle due aggregazioni geografiche e il vettore n la corrispondente popolazione residente espressa in migliaia di abitanti (questo è il significato della divisione per 1000 nella seconda riga dello *script*). La covariata x assume valore 1 nelle regioni del Nord e valore 0 nelle rimanenti.

Dobbiamo a questo punto osservare una particolarità nella chiamata della funzione `glm` (la presenza di un `offset`) che deriva dal significato assunto dal parametro μ della Poisson nel caso che stiamo considerando. Questo parametro ha una sua unità di misura. Facendo riferimento alle regioni del Nord, possiamo dire che il rapporto fra 1510463 (il numero di casi) e 27616.21 (la popolazione residente in migliaia di abitanti) è 54.695, ovvero circa 55 casi ogni 1000 residenti. In epidemiologia un rapporto di questo tipo viene chiamato *tasso di incidenza* (*incidence rate*) ed è, a tutti gli effetti, una *velocità*; la velocità (media) con la quale si sviluppa l'epidemia. Allo stesso modo possiamo dire che nelle rimanenti regioni il tasso di incidenza è pari a circa 33 casi ogni 1000 abitanti. Il rapporto fra due tassi di incidenza è quello che si chiama *rischio relativo* (*relative risk*); nel caso che stiamo trattando il rischio relativo è circa 1.65 e sta ad indicare una maggiore intensità dell'epidemia nelle regioni del Nord.

In una regressione di Poisson la variabile dipendente è il numero di “eventi” osservati. Quando questo numero di eventi si riferisce ad un ambito spaziale e/o temporale diventa fondamentale prendere in considerazione la dimensione di tale ambito. Questa è la funzione dell'`offset`, il quale definisce una sorta di “denominatore” da associare agli eventi osservati. Nel nostro caso l'`offset` è il logaritmo naturale della popolazione residente nelle due aggregazioni regionali.

Siamo pronti ora ad interpretare il significato delle stime dei parametri b_0 e b_1 o, meglio, del loro esponenziale.

```
> exp(fit$coefficients)
(Intercept)          x
  33.057765    1.654522
```

Iniziamo da b_0 . Quando $x = 0$ (Centro-Sud-Isole), il predittore lineare assume il valore 3.498256 (la stima di b_0). Il suo esponenziale produce il corrispondente tasso di incidenza (per mille abitanti), che risulta proprio quello che abbiamo calcolato direttamente dai dati:

```
> inc <- y/n
> inc[2]
[1] 33.05776
```

Quando $x = 1$, (regioni del Nord), il predittore lineare assume il valore $3.498256 + 0.503512$ (la stima di $b_0 + b_1$). Il suo esponenziale produce il corrispondente tasso di incidenza (per mille abitanti); anche questo risulta esattamente uguale a quello calcolato direttamente dai dati:

```
> inc <- y/n
> inc[1]
[1] 54.69479
> b <- fit$coefficients
> exp(b[1] + b[2])
(Intercept)
  54.69479
```

Il rapporto fra i due tassi di incidenza (regioni del Nord vs altre regioni), cioè il rischio relativo, coincide con l'esponenziale della stima di b_1

```
> inc[1]/inc[2]
[1] 1.654522
> exp(b[2])
      x
1.654522
```

Possiamo costruire un intervallo di confidenza al 95% per il rischio relativo chiamando la funzione `confint`:

```
> exp(confint(fit)[2,])
Waiting for profiling to be done...
      2.5 %    97.5 %
1.650417 1.658638
```

Un'altra situazione in cui la distribuzione di Poisson gioca un ruolo chiave si ha nell'analisi di *tabelle di contingenza multidimensionali*, dove i conteggi sono rappresentati dalle frequenze assolute associate alle combinazioni dei livelli delle variabili considerate. In questo caso l'analisi viene eseguita impiegando un *modello log-lineare*, un argomento estremamente interessante che, però, non è possibile davvero affrontare, nemmeno superficialmente, in questo libro. Al lettore interessato non possiamo che consigliare un testo a nostro avviso irrinunciabile, quello di Alan Agresti (2019).

4 Distribuzioni campionarie

In questo capitolo cambieremo completamente “punto di vista”, spostando il nostro interesse dalla singola osservazione ad un indice opportunamente calcolato su un *insieme* di n osservazioni ricavate a partire da un campione estratto in modo appropriato. Questo cambio di prospettiva è del tutto comune nel mondo della ricerca empirica, quando è necessario presentare in modo sintetico i risultati di uno studio scientifico.

Da un punto di vista generale, il ricercatore vuole *stimare un parametro* (ad esempio, la media μ o la proporzione p di “successi”) mediante una *statistica* calcolata sulle n osservazioni. Questa statistica prende il nome di *stimatore*.

4.1 La media campionaria

Riprendiamo in esame l’esempio proposto nel secondo capitolo di un’urna contenente 10 palline contrassegnate con i numeri 0, 1, 2, 3, 4, 5, 6, 7, 8, 9. Assimiliamo il risultato dell’estrazione di una pallina alla realizzazione x di una variabile casuale X distribuita come una uniforme discreta con media $\mu = 4.5$ e varianza $\sigma^2 = 8.25$. Consideriamo ora il seguente “esperimento”:

1. estraiamo una pallina dall’urna;
2. annotiamo il numero x_1 riportato sulla pallina;
3. reinseriamo la pallina nell’urna (mescolando bene il contenuto);
4. estraiamo una seconda pallina dall’urna;
5. annotiamo il numero x_2 riportato sulla pallina;
6. calcoliamo la media aritmetica dei due valori $\bar{x} = (x_1 + x_2)/2$;
7. annotiamo il risultato ottenuto (la media dei due valori estratti);
8. ripetiamo i punti 1 – 7 un numero molto grande di volte.

È immediato eseguire questo “esperimento” con R ; ecco lo *script* relativo ai primi 7 punti:

```
> set.seed(654321)
> (x <- sample(c(0:9),size=2,replace=TRUE))
```

```
[1] 0 5
> mean(x)
[1] 2.5
```

Iteriamo ora tutto il procedimento 10000 volte (in modo compatto, senza usare un ciclo for) e vediamo quale è la distribuzione di frequenza delle medie ottenute:

```
> set.seed(654321)
> x <- sample(c(0:9),size=2*10000,replace=TRUE)
> X <- matrix(x, ncol=2)
> xm <- rowMeans(X)
> frq(xm)
```

```
xm
      x      n      f
+-----+-----+-----+
| 0    |   115 |   1.15 |
| 0.5  |   203 |   2.03 |
| 1    |   301 |   3.01 |
| 1.5  |   424 |   4.24 |
| 2    |   470 |   4.70 |
| 2.5  |   612 |   6.12 |
| 3    |   698 |   6.98 |
| 3.5  |   784 |   7.84 |
| 4    |   864 |   8.64 |
| 4.5  |  1011 |  10.11 |
| 5    |   928 |   9.28 |
| 5.5  |   796 |   7.96 |
| 6    |   710 |   7.10 |
| 6.5  |   592 |   5.92 |
| 7    |   496 |   4.96 |
| 7.5  |   384 |   3.84 |
| 8    |   318 |   3.18 |
| 8.5  |   199 |   1.99 |
| 9    |    95 |   0.95 |
+-----+-----+-----+
      10000   100.00
Osservazioni mancanti: 0
```

(il grafico della distribuzione di frequenza è riportato nel pannello di sinistra della Figura 4.1). La forma del grafico è del tutto simile a quello della distribuzione triangolare che avevamo ottenuto nel caso del lancio di due dadi.

In effetti nel nostro “esperimento” il risultato osservato su ciascuna coppia di estrazioni è il rapporto fra la somma S di due variabili casuali X_1 e X_2 indipendenti e identicamente distribuite (in modo uniforme discreto fra 0 e 9) e il numero 2 (per




Figura 4.1: A sinistra: Distribuzione di frequenza empirica della media di un campione casuale di due osservazioni estratto da una distribuzione uniforme discreta fra 0 e 9. A destra: Distribuzione di probabilità (esatta) della media di un campione casuale di due osservazioni estratto da una distribuzione uniforme discreta fra 0 e 9.

ottenere la media aritmetica): $\bar{X} = S/2$. Sfruttando ancora una volta la funzione `outer` possiamo ottenere la distribuzione “esatta” di $\bar{X}$:

```
> x <- c(0:9)
> tbl <- outer(x,x,"+")
> (tbl <- tbl/2)
      [,1] [,2] [,3] [,4] [,5] [,6] [,7] [,8] [,9] [,10]
[1,]  0.0  0.5  1.0  1.5  2.0  2.5  3.0  3.5  4.0  4.5
[2,]  0.5  1.0  1.5  2.0  2.5  3.0  3.5  4.0  4.5  5.0
[3,]  1.0  1.5  2.0  2.5  3.0  3.5  4.0  4.5  5.0  5.5
[4,]  1.5  2.0  2.5  3.0  3.5  4.0  4.5  5.0  5.5  6.0
[5,]  2.0  2.5  3.0  3.5  4.0  4.5  5.0  5.5  6.0  6.5
[6,]  2.5  3.0  3.5  4.0  4.5  5.0  5.5  6.0  6.5  7.0
[7,]  3.0  3.5  4.0  4.5  5.0  5.5  6.0  6.5  7.0  7.5
[8,]  3.5  4.0  4.5  5.0  5.5  6.0  6.5  7.0  7.5  8.0
[9,]  4.0  4.5  5.0  5.5  6.0  6.5  7.0  7.5  8.0  8.5
[10,] 4.5  5.0  5.5  6.0  6.5  7.0  7.5  8.0  8.5  9.0
> f <- prop.table(table(tbl))
> x <- dimnames(f); x <- as.numeric(unlist(x))
> rbind(x,f)
x 0.00 0.50 1.00 1.50 2.00 2.50 3.00 3.50 4.00 4.5
f 0.01 0.02 0.03 0.04 0.05 0.06 0.07 0.08 0.09 0.1
x 5.00 5.50 6.00 6.50 7.00 7.50 8.00 8.50 9.00
f 0.09 0.08 0.07 0.06 0.05 0.04 0.03 0.02 0.01
```

Le due distribuzioni (quella empirica e quella esatta) sono del tutto sovrapponibili, come emerge anche dal confronto delle corrispondenti rappresentazioni grafiche riportate nella Figura 4.1.

Come si può osservare guardando la Figura 4.1, per quanto la probabilità più elevata sia in corrispondenza della media μ della distribuzione della variabile casuale di partenza (cioè 4.5), è relativamente frequente osservare risultati “estremi”, cioè molto lontani dalla media vera (circa 2 volte su 100 otterremo una media $\bar{X}$ uguale a 0 o uguale a 9). Ripetiamo l’esperimento estraendo non 2, ma 10 palline (ovviamente con rimessa):

```
> set.seed(654321)
> x <- sample(c(0:9),size=10*10000,replace=TRUE)
> X <- matrix(x, ncol=10)
> xm <- rowMeans(X)
> c(min(xm),max(xm))
[1] 1 8
```

Osserviamo che in nessuno dei 10000 campioni la media è risultata uguale a 0 o uguale a 9; in effetti non è mai risultata nè minore di 1, nè maggiore di 8). Estraiamo 100 palline (ripetendo l’estrazione 10000 volte):

```
> set.seed(654321)
> x <- sample(c(0:9),size=100*10000,replace=TRUE)
> X <- matrix(x, ncol=100)
> xm <- rowMeans(X)
> c(min(xm),max(xm))
[1] 3.40 5.59
```

Adesso in nessuno dei 10000 campioni la media è risultata inferiore a 3.4 o superiore a 5.6. Ripetiamo la simulazione estraendo questa volta 1000 palline (per 10000 volte):

```
> set.seed(654321)
> x <- sample(c(0:9),size=1000*10000,replace=TRUE)
> X <- matrix(x, ncol=1000)
> xm <- rowMeans(X)
> c(min(xm),max(xm))
[1] 4.142 4.807
```

Tutti i risultati (tutte le medie) sono comprese fra 4 e 5.

Quindi, questo primo gruppo di simulazioni ci ha fatto vedere come al crescere della *dimensione del campione* (il numero di palline estratte ogni volta: 2, 10, 100, 1000) i risultati (le *medie campionarie*) tendono a “concentrarsi” intorno alla media vera $\mu = 4.5$, di modo che risultati “estremi” divengono via via meno probabili. In

altre parole, la variabilità del risultato (la variabilità delle medie campionarie) tende a ridursi all'aumentare della dimensione del campione. Vogliamo andare un po' più a fondo con il seguente esperimento:

1. estraiamo (con reinserimento) n palline dall'urna;
2. calcoliamo il valore della *media campionaria* $\bar{X}_n$;
3. ripetiamo i punti precedenti 10000 volte;
4. calcoliamo la media e la varianza delle 10000 medie così ottenute;
5. ripetiamo i passi 1 – 4 facendo variare il valore di n (la *dimensione del campione*) fra 1 e 128.

Ecco lo *script* che esegue la simulazione:

```
set.seed(123456)
out <- matrix(nrow=128,ncol=3)
for (n in 1:128)
{
  x <- sample(c(0:9),size=n*10000,replace=TRUE)
  X <- matrix(x, ncol=n)
  xm <- rowMeans(X)
  out[n,1] <- n
  out[n,2] <- mean(xm)
  out[n,3] <- var(xm)
}
```

I risultati sono conservati nella matrice `out`. La prima colonna contiene la dimensione n del campione, la seconda colonna contiene le medie, la terza colonna le varianze. Può essere utile vedere i valori ottenuti raddoppiando la dimensione del campione (a partire da un campione in cui $n = 1$):

```
> n <- c(1,2,4,8,16,32,64,128)
> colnames(out) <- c("n","Media","Varianza")
> out[n,]
```

	n	Media	Varianza
[1,]	1	4.495000	8.23239824
[2,]	2	4.532950	4.09884918
[3,]	4	4.473900	2.05559935
[4,]	8	4.510662	1.04508926
[5,]	16	4.500100	0.50875008
[6,]	32	4.494078	0.25817737
[7,]	64	4.500578	0.12984161
[8,]	128	4.497319	0.06489837

Osserviamo che, per qualsiasi valore di n , la media delle 10000 medie ottenute è sostanzialmente uguale alla media vera $\mu = 4.5$.

Osserviamo che, al raddoppiare di n , la varianza delle 10000 medie ottenute si riduce in modo regolare (dimezzandosi).

Se moltiplichiamo fra loro la prima e la terza colonna (la dimensione del campione e la varianza) il prodotto è approssimativamente costante

```
> k <- out[,1]*out[,3]
```

```
> round(k[n],3)
```

```
[1] 8.232 8.198 8.222 8.361 8.140 8.262 8.310 8.307
```

e sostanzialmente uguale alla varianza $\sigma^2 = 8.25$ della variabile casuale X di partenza. Questi risultati sono riassunti graficamente nella Figura 4.2.




Figura 4.2: (a) La media delle medie campionarie è approssimativamente uguale a 4.5 qualsiasi sia la dimensione n del campione. (b) e (c) La varianza delle medie campionarie di campioni di dimensione n è inversamente proporzionale a n . (d) La costante di proporzionalità è σ^2 (cioè 8.25).

La relazione che lega fra loro la varianza delle medie campionarie e la dimensione del campione è quella di una *proporzionalità inversa*, del tipo $xy = k$. Infatti, i grafici riprodotti in Figura 4.2b e 4.2c rappresentano due iperboli equilateri.

I risultati ottenuti sono assolutamente generalizzabili sotto questa forma:

Siano $X_1, X_2, \dots, X_n$ n variabili casuali *indipendenti e identicamente distribuite* (i.i.d.) ciascuna con media μ e varianza σ^2 . Sia $\bar{X}_n$ la media campionaria calcolata su un campione casuale di dimensione n .

Allora

$$E(\bar{X}_n) = \mu \quad (4.1)$$

e

$$Var(\bar{X}_n) = \frac{\sigma^2}{n}. \quad (4.2)$$

La radice quadrata della varianza della media campionaria è la deviazione standard della media campionaria. Tuttavia, in particolare nel mondo anglosassone, essa è indicata con il nome di *errore standard* della media campionaria e, come vedremo fra poco, è una misura della *precisione* con cui è stata *stimata* la media campionaria.

Questi due risultati fondamentali si potevano facilmente ricavare dalle regole che ci eravamo dati introducendo le variabili casuali. Infatti, se indichiamo con $S_n = X_1 + X_2 + \dots + X_n$ la somma delle n variabili casuali i.i.d., sappiamo che il valore atteso della somma è la somma dei valori attesi

$$E(S_n) = n\mu$$

e che la varianza della somma è (per l'indipendenza) la somma delle varianze

$$Var(S_n) = n\sigma^2.$$

Dal momento che $\bar{X}_n = \frac{S_n}{n}$, ricordando le proprietà del valore atteso e della varianza, abbiamo che

$$E(\bar{X}_n) = E\left(\frac{S_n}{n}\right) = \frac{1}{n}E(S_n) = \frac{1}{n} \times n\mu = \mu$$

e che

$$Var(\bar{X}_n) = Var\left(\frac{S_n}{n}\right) = \frac{1}{n^2}Var(S_n) = \frac{1}{n^2} \times n\sigma^2 = \frac{\sigma^2}{n}.$$

La (4.2) è l'espressione fondamentale che permette di *dimensionare* in modo adeguato un esperimento.

La (4.1) ci dice che il nostro esperimento, se adeguatamente condotto, produrrà un risultato *non distorto* (*unbiased*), mentre la (4.2) ci dice che il nostro esperimento, se adeguatamente dimensionato, produrrà un risultato *preciso* (cioè vicino al valore vero). Per poter però impiegare in pratica le precedenti relazioni dobbiamo conoscere la distribuzione di probabilità della variabile casuale $\bar{X}_n$.

La risposta "esatta" alla domanda precedente è che la distribuzione di $\bar{X}_n$ dipende dalla distribuzione delle variabili casuali che entrano nella sua definizione. In particolare, se queste sono normali, allora $\bar{X}_n$ sarà normale (qualsiasi sia il valore di n).

Esiste un teorema “centrale” (cioè fondamentale) della Statistica, che va sotto il nome di *central limit theorem* (tradotto in italiano con “teorema limite centrale” o “teorema del limite centrale” o, forse meglio, “teorema centrale asintotico”) il quale ci dice che, quando la dimensione del campione n è *sufficientemente grande*, possiamo pensare che la distribuzione di $\bar{X}_n$ sia *normale*, con media μ e varianza σ^2/n . La Figura 4.3 illustra il teorema con qualche esempio.




Figura 4.3: Illustrazione del teorema del limite centrale per tre diverse distribuzioni di partenza. I grafici presentati nelle righe 2, 3, 4 riportano la distribuzione della media campionaria per campioni casuali di dimensione $n = 2, 5, 20$ rispettivamente, estratti dalle distribuzioni (a), (b) e (c).

4.1.1 Alcune simulazioni sulla “bontà” del teorema centrale

Possiamo “mettere alla prova” il teorema centrale con alcune simulazioni relative ad alcune distribuzioni con diverso grado di asimmetria. Verificheremo, mediante un numero elevato (10000) di repliche, quanto sia “vicina” la distribuzione della media campionaria alla normale per alcuni valori di n . Naturalmente invitiamo il lettore a riprodurre ogni *script*, modificando a suo piacere il valore di n . Per rendere questo più agevole, abbiamo scritto ogni volta una funzione (alla quale abbiamo sempre dato lo stesso nome convenzionale, `simtc`), che campiona dalla distribuzione opportuna e che basta chiamare, in generale modificando soltanto il valore di n . La “bontà” dell’approssimazione della distribuzione delle medie campionarie verrà valutata mediante un opportuno grafico *quantile-quantile* confrontando i quantili empirici con quelli teorici di una distribuzione normale standard.

Il primo esempio riguarda l’estrazione di campioni da una variabile casuale uniforme continua realizzata tramite il seguente *script*:

```
> simtc <- function(n, nrep=10000)
+ {
+   x <- runif(n*nrep)
+   X <- matrix(x,ncol=n)
+   xm <- apply(X,1,mean)
+   qqn(xm)
+ }
>
> set.seed(654321)
> simtc(2)
> simtc(10)
```

Abbiamo visto come la distribuzione di questa variabile casuale sia simmetrica. Con campioni di dimensione $n = 2$, la distribuzione della media campionaria non è molto distante dalla normale, ma osservando il pannello di sinistra della Figura 4.4 si può notare come le “code” della distribuzione campionaria sia ben discoste dalla linea “ideale” che dovrebbero seguire i punti se la distribuzione fosse davvero normale. Tuttavia, basta portare la dimensione del campione a $n = 10$ osservazioni per avere un grafico del tutto sovrapponibile a quello atteso per una distribuzione normale (pannello di destra della Figura 4.4).

Consideriamo ora una distribuzione empirica, rappresentata dai valori assunti dal *Body Mass Index* di 24000 italiani (valori che si trovano nel *data-frame* `bmi` di `rmf`). La Figura 4.5 riporta questa distribuzione sia sotto forma di istogramma sia sotto forma di grafico *quantile-quantile*. La distribuzione presenta una ben evidente asimmetria positiva, che risalta maggiormente osservando il grafico *quantile-quantile*.

```
> data(bmi)
> hist(bmi$bmi)
> qqn(bmi$bmi)
```




Figura 4.4: Distribuzione delle medie campionarie $\bar{X}_n$ estratte da una variabile casuale uniforme continua quando $n = 2$ (pannello di sinistra) e quando $n = 10$ (pannello di destra).




Figura 4.5: Distribuzione di frequenza del *Body Mass Index* di un campione di 24000 italiani (pannello di sinistra) e corrispondente grafico *quantile-quantile* (pannello di destra). È ben evidente l'asimmetria positiva della distribuzione.

Andiamo ora a vedere come si comportano le medie campionarie estratte da questa distribuzione empirica, considerando valori di n pari a 10 e a 30 (Figura 4.6).

```
> simtc <- function(n, y, nrep=10000)
+ {
+   x <- sample(y,n*nrep,replace=TRUE)
+   X <- matrix(x,ncol=n)
+   xm <- apply(X,1,mean)
```




Figura 4.6: Distribuzione delle medie campionarie $\bar{X}_n$ estratte dalla distribuzione empirica del *Body Mass Index* di un campione di 24000 italiani quando $n = 10$ (pannello di sinistra) e quando $n = 30$ (pannello di destra). In questo caso l'asimmetria positiva presente nella distribuzione originale è sostanzialmente scomparsa.

```
+      qqn(xm)
+ }
>
> set.seed(654321)
> simtc(10, bmi$bmi)
> simtc(30, bmi$bmi)
```

Nonostante l'asimmetria della distribuzione di partenza, già con un campione di 10 osservazioni l'adattamento a una normale può essere considerato soddisfacente (pannello di sinistra della Figura 4.6). Le medie campionarie di campioni di 30 osservazioni producono un grafico *quantile-quantile* sostanzialmente indistinguibile da quello di una normale (pannello di destra della Figura 4.6).

Esistono tuttavia distribuzioni che presentano un grado di asimmetria molto più pronunciato. Questo è, ad esempio, il caso della distribuzione *log-normale*. Il grafico *quantile-quantile* di un campione estratto da questa distribuzione (mediante la funzione `rlnorm`) è riportato nel pannello di sinistra della Figura 4.7. La concavità è rivolta verso l'alto, come nel caso della Figura 4.5 (pannello di destra), ma è molto più pronunciata.

```
set.seed(123456)
x <- rlnorm(1000)
qqn(x)
```

Nel caso della distribuzione log-normale la “convergenza alla normale” non si osserva né quando la dimensione del campione è uguale a 100 (Figura 4.8, pannello di sinistra) e nemmeno quando le medie sono calcolate su campioni di 1000 osservazioni (Figura 4.8, pannello di destra).




Figura 4.7: A sinistra: grafico *quantile-quantile* di un campione di 1000 osservazioni estratte da una distribuzione log-normale. A destra: lo stesso grafico dopo trasformazione logaritmica dei dati originali.




Figura 4.8: Distribuzione delle medie campionarie $\bar{X}_n$ calcolate su osservazioni estratte da una variabile casuale log-normale quando $n = 100$ (pannello di sinistra) e quando $n = 1000$ (pannello di destra). In entrambi i casi è presente una evidente asimmetria positiva.

```
> simtc <- function(n, nrep=10000)
+ {
+   x <- rlnorm(n*nrep)
+   X <- matrix(x,ncol=n)
+   xm <- apply(X,1,mean)
+   qqn(xm)
+ }
```

```
>
> set.seed(654321)
> simtc(100)
> simtc(1000)
```

Naturalmente, proprio per come è definita la variabile casuale log-normale, se *trasformiamo* i dati originali facendone il logaritmo naturale, riusciamo a “normalizzare” i dati stessi (Figura 4.7, pannello di destra).

Anche la distribuzione esponenziale è caratterizzata da una elevatissima asimmetria (positiva), come si può notare guardando il pannello di sinistra della Figura 4.9. La trasformazione in logaritmo in questo caso non è in grado di normalizzare la distribuzione e trasforma la asimmetria da positiva in negativa (pannello di destra della Figura 4.9).

```
> set.seed(123456)
> x <- rexp(1000); qqn(x)
> qqn(log(x))
```




Figura 4.9: A sinistra: grafico *quantile-quantile* di un campione di 1000 osservazioni estratte da una distribuzione esponenziale. A destra: lo stesso grafico dopo trasformazione logaritmica dei dati originali. Entrambe le distribuzioni sono asimmetriche; quella di sinistra presenta asimmetria positiva, quella di destra presenta asimmetria negativa.

Anche in questo caso, le medie calcolate su campioni di 100 osservazioni estratte dalla distribuzione originale non sono distribuite normalmente (pannello di sinistra della Figura 4.10). Tuttavia, le medie di 100 osservazioni calcolate sui dati dopo trasformazione logaritmica presentano un adattamento alla normale estremamente buono (pannello di destra della Figura 4.10).




Figura 4.10: Distribuzione delle medie campionarie $\bar{X}_n$ calcolate su osservazioni estratte da una variabile casuale esponenziale quando $n = 100$ (pannello di sinistra). A destra è presentato il grafico relativo alle stesse osservazioni dopo trasformazione logaritmica.

```
> simtc <- function(n, nrep=10000)
+ {
+   x <- rexp(n*nrep)
+   X <- matrix(x,ncol=n)
+   xm <- apply(X,1,mean)
+   qqn(xm)
+ }
>
> set.seed(654321)
> simtc(100)
>
> simtc <- function(n, nrep=10000)
+ {
+   x <- rexp(n*nrep)
+   X <- matrix(log(x),ncol=n)
+   xm <- apply(X,1,mean)
+   qqn(xm)
+ }
>
> set.seed(654321)
> simtc(100)
```

Una breve precisazione a proposito del teorema centrale.

Abbiamo detto poche righe sopra che quando la dimensione del campione n è *sufficientemente grande*, possiamo pensare che la distribuzione di $\bar{X}_n$ sia *normale*, con

media μ e varianza σ^2/n . Se applicassimo pedissequamente questo teorema al nostro esempio della uniforme discreta fra 0 e 9, allora saremmo portati a dire che la media campionaria, quando n è sufficientemente grande, si distribuisce come una normale con media 4.5 e varianza $8.25/n$. Ma questo è palesemente falso! Infatti, per quanto possa essere grande il campione, la media campionaria non potrà mai essere minore di 0 o maggiore di 9, mentre una distribuzione normale va da meno infinito a più infinito.

In effetti il nostro enunciato è stato un po' troppo "sbrigativo" (anche se può andare tutto sommato bene a fini pratici). Il "vero" enunciato del teorema centrale fa infatti riferimento non alla media campionaria, ma ai corrispondenti *valori standardizzati*. Un enunciato più vicino a quello vero (che comporterebbe la conoscenza della *convergenza in legge di una successione di variabili casuali indipendenti e identicamente distribuite*, un argomento decisamente al di fuori della nostra portata) è quindi il seguente.

Siano $X_1, X_2, \dots, X_n$ n variabili casuali *indipendenti e identicamente distribuite* ciascuna con media μ e varianza σ^2 . Sia $\bar{X}_n$ la media campionaria calcolata su un campione casuale di dimensione n . Allora, al crescere di n , la distribuzione della variabile casuale

$$Z = \frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}}$$

è approssimativamente normale standard.

4.2 Precisione e accuratezza

I termini *precisione* e *accuratezza* hanno in Statistica un significato ben preciso, significato che spesso è travisato da coloro che non hanno le specifiche competenze. In particolare questi due termini sono impiegati nel mondo delle analisi di laboratorio ed è fondamentale chiarirne il significato (magari aiutandosi con la Figura 4.11).

La Figura 4.11 presenta i risultati di n misurazioni di un medesimo valore vero μ eseguite con 4 differenti metodiche. I pallini vuoti indicano i singoli risultati, mentre il pallino pieno indica la media aritmetica $\bar{x}_n$ delle n determinazioni. Il quadratino nero posto al centro del "bersaglio" indica il valore vero μ . Commentiamo i risultati ottenuti con le quattro metodiche:

1. il metodo 1 (in alto a sinistra nella Figura) presenta i pallini vuoti molto dispersi e lontani dal centro del "bersaglio"; l'elevata dispersione dei risultati è indice di elevata variabilità, quindi di bassa *precisione*, mentre il fatto che il pallino pieno (la media delle n determinazioni) sia distante dal quadratino nero (il valore vero) è indice di bassa *accuratezza*;
2. il metodo 2 (in alto a destra nella Figura) presenta i pallini vuoti molto dispersi intorno al centro del "bersaglio"; l'elevata dispersione dei risultati è indice di elevata variabilità, quindi di bassa *precisione*; tuttavia il fatto che il pallino pieno




Figura 4.11: Sono riportati i risultati di n misurazioni di un medesimo valore vero μ eseguite con 4 differenti metodiche. I pallini vuoti indicano i singoli risultati, mentre il pallino pieno indica la media aritmetica $\bar{x}_n$ delle n determinazioni. Il quadratino nero posto al centro del “bersaglio” indica il valore vero μ .

- (la media delle n determinazioni) sia molto vicino al quadratino nero (il valore vero) è indice di elevata *accuratezza*;
- il metodo 3 (in basso a sinistra nella Figura) presenta i pallini vuoti molto concentrati, ma lontani dal centro del “bersaglio”; la bassa dispersione dei risultati (cioè la bassa variabilità) è indice di elevata *precisione*, mentre il fatto che il pallino pieno (la media delle n determinazioni) sia distante dal quadratino nero (il valore vero) è indice di bassa *accuratezza*;
 - il metodo 4 (in basso a destra nella Figura) presenta tutti i pallini vuoti concentrati intorno al centro del “bersaglio”; la bassa dispersione dei risultati (cioè la bassa variabilità) è indice di elevata *precisione*, mentre il fatto che il pallino pieno (la

media delle n determinazioni) coincida con il quadratino nero (il valore vero) è indice di grandissima (totale) *accuratezza*.

Sintetizzando quanto appena visto, possiamo dire che il termine *precisione* ha a che fare con la *variabilità* della metodica. Un metodo preciso è un metodo al quale è associata una varianza piccola.

Il termine *accuratezza* ha invece a che fare con il livello di *distorsione* della metodica. Un metodo è accurato se, in media, riproduce il valore vero. In caso contrario un metodo si dice distorto. Spesso la distorsione si può correggere *tarando* opportunamente lo strumento di misura.

4.3 Errore standard e dimensione del campione

Riprendiamo l'esperimento relativo all'estrazione delle palline numerate da 0 a 9 da un'urna. Supponiamo di conoscere il valore della varianza ($\sigma^2 = 8.25$), ma non quello della media e di volerla *stimare* a partire da un campione adeguatamente dimensionato. Supponiamo inoltre di voler essere ragionevolmente "certi" (fissando una elevata probabilità, ad esempio 95%) che il risultato (la media campionaria $\bar{X}_n$) che otterremo a seguito dell'esperimento sarà "vicino" al valore vero μ (che non conosciamo). Naturalmente dobbiamo quantificare il termine "vicino" e diciamo, ad esempio, che saremo soddisfatti se il nostro risultato sarà entro una unità dal valore vero ($\mu \pm 1$). In altre parole l'*ampiezza* dell'intervallo *ampiezza* dell'intervallo nel quale ci aspettiamo cadrà $\bar{X}_n$ dovrà essere minore di (o al più uguale a) 2.

Supponendo che la distribuzione di $\bar{X}_n$ sia gaussiana (o approssimativamente tale), vogliamo trovare quel valore n tale che

$$P\left(\mu - 1.96\sqrt{\frac{8.25}{n}} \leq \bar{X}_n \leq \mu + 1.96\sqrt{\frac{8.25}{n}}\right) \geq 0.95.$$

L'ampiezza dell'intervallo precedente è data da

$$\left(\mu + 1.96\sqrt{\frac{8.25}{n}}\right) - \left(\mu - 1.96\sqrt{\frac{8.25}{n}}\right).$$

Semplificando l'espressione otteniamo

$$\mu + 1.96\sqrt{\frac{8.25}{n}} - \mu + 1.96\sqrt{\frac{8.25}{n}} = 2 \times 1.96\sqrt{\frac{8.25}{n}}.$$

Come si può notare, nella semplificazione μ è scomparsa. Possiamo ora "uguagliare" le due ampiezze:

$$2 \times 1.96\sqrt{\frac{8.25}{n}} \leq 2.$$

È facile vedere che il (più piccolo) valore di n che soddisfa la disuguaglianza precedente è dato da $n = 32$ (l'uguaglianza sarebbe soddisfatta con $n = 31.69$, ma dobbiamo sempre arrotondare per eccesso quando calcoliamo la dimensione campionaria). Una soluzione “per tentativi”, sfruttando la “forza bruta” di R è la seguente:

```
> n <- c(1:1000)
> a <- 2*1.96*sqrt(8.25/n)
> k <- first(2, a, type="LE")
> cbind(n[(k-1):k], a[(k-1):k])
      [,1]      [,2]
[1,]    31  2.022238
[2,]    32  1.990389
```

Con 31 osservazioni l'ampiezza è superiore a 2, mentre con 32 è inferiore a 2.

Possiamo verificare l'adeguatezza del risultato (e della bontà dell'approssimazione normale) controllando che con un campione di 32 osservazioni (32 palline estratte) nel 95% (in almeno il 95%) dei casi la media campionaria sarà compresa fra 3.5 e 5.5:

```
> set.seed(123456)
> x <- sample(c(0:9), size=32*10000, replace=TRUE)
> X <- matrix(x, ncol=32)
> xm <- rowMeans(X)
> aa <- xm < 3.5; sum(aa)
[1] 228
> bb <- xm > 5.5; sum(bb)
[1] 194
> length(xm)-sum(aa)-sum(bb)
[1] 9578
```

In questa simulazione, la media dei 10000 campioni estratti è risultata inferiore a 3.5 per 228 volte, mentre altre 194 volte è risultata superiore a 5.5. Quindi la probabilità stimata con il metodo Monte Carlo è del 95.8%. Quella basata sulla distribuzione normale è pari a

```
> ProbNorm(da=3.5, a=5.5, mu=4.5, sigma=sqrt(8.25/32))
La probabilita' di osservare un valore compreso
fra 3.5 e 5.5 e' uguale a 0.951100
```

rivelando un accordo che avremmo potuto anticipare in virtù del fatto che partendo da una distribuzione uniforme discreta un campione di 32 osservazioni produce una media campionaria la cui distribuzione è molto vicina alla normale.

Potremmo essere più esigenti e richiedere, mantenendo il grado di “certezza” al 95%, che la media campionaria cada entro mezza unità dal valore vero ($\mu \pm 0.5$). In altre parole l'ampiezza dell'intervallo dovrà essere minore di (o al più uguale a) 1.

Potremmo ripetere i passaggi precedenti. Tuttavia, conoscendo il risultato precedente, dal momento che vogliamo *dimezzare* l'ampiezza dell'intervallo (portandolo da 2 a 1), dovremo *quadruplicare* la dimensione del campione, ovvero dovremo calcolare $4 \times 31.6932 = 126.7728$ che arrotondiamo a $n = 127$. Raddoppiare la dimensione del campione non sarebbe sufficiente, dal momento che il termine n compare sotto il segno di radice quadrata.

In generale, se indichiamo con ε la *metà* dell'ampiezza dell'intervallo entro il quale vogliamo che cada la media campionaria, con $1 - \alpha$ il grado di “certezza” e con $z_{\alpha/2}$ il quantile della distribuzione normale standard che lascia *alla sua destra* un'area pari ad $\alpha/2$, allora la dimensione del campione è data da

$$n = \frac{z_{\alpha/2}^2 \sigma^2}{\varepsilon^2}. \quad (4.3)$$

4.4 La proporzione campionaria

Una proporzione campionaria $\hat{P}_n$ si può considerare a tutti gli effetti la media campionaria di n variabili casuali di Bernoulli indipendenti, ciascuna con media p e varianza $p(1-p)$. Pertanto, se vale l'approssimazione normale, avremo che $\hat{P}_n$ seguirà una distribuzione (approssimativamente) normale con media p ed errore standard $\sqrt{p(1-p)/n}$.

Impiegando R possiamo fare alcune verifiche empiriche per valutare la “bontà” dell'approssimazione gaussiana. Impiegheremo la funzione `simpc` per simulare il comportamento della proporzione campionaria al variare di n (la dimensione del campione) e di p (la probabilità di “successo”).

```
simpc <- function(n,p, nrep=10000)
{
  x <- rbinom(nrep,n,p)
  xm <- x/n
  z <- qnorm(0.05, lower.tail=FALSE) # 10%
  me <- z * sqrt(p*(1-p)/n)
  print(cbind(p-me, p+me))
  print(quantile(xm,probs=c(0.05,0.95),type=2))
  z <- qnorm(0.025, lower.tail=FALSE)
  me <- z * sqrt(p*(1-p)/n)
  print(cbind(p-me, p+me))
  print(quantile(xm,probs=c(0.025,0.975),type=2))
}
```

Impiegando la funzione `rbinom` (che simula il campionamento da una binomiale), otteniamo il numero di successi x osservati in un campione di n osservazioni quando la probabilità di successo è p . La funzione `rbinom` è vettoriale, per cui possiamo

chiedere con una sola istruzione di estrarre $nrep$ osservazioni (contenute nel vettore x). Dividendo per il numero n delle “prove”, otteniamo $nrep$ proporzioni campionarie (10000 negli esempi che presenteremo). La funzione calcola poi i quantili attesi (basati sulla distribuzione gaussiana) e quelli osservati che individuano un intervallo centrale che comprende il 90% e il 95% delle proporzioni campionarie e li propone come *output*.

Presentiamo di seguito il risultato di alcune simulazioni, lasciando al lettore lo svolgimento di ulteriori prove. Iniziamo considerando una distribuzione simmetrica ($p = 0.5$) e un numero di prove sostanzialmente basso ($n = 10$).

```
> n <- 10; p <- 0.5
> set.seed(654321)
> simpc(n,p)
      [,1]      [,2]
[1,] 0.2399258 0.7600742
 5% 95%
0.2 0.8
```

```
      [,1]      [,2]
[1,] 0.1901025 0.8098975
2.5% 97.5%
0.2 0.8
```

Il risultato non è del tutto soddisfacente, dal momento che n è piuttosto piccolo (e $np = 5$, il minimo richiesto, secondo la regola che avevamo visto nel capitolo precedente). Le cose però migliorano portando n a 50 ($np = 25$).

```
> n <- 50; p <- 0.5
> set.seed(654123)
> simpc(n,p)
      [,1]      [,2]
[1,] 0.3836913 0.6163087
 5% 95%
0.38 0.62
```

```
      [,1]      [,2]
[1,] 0.3614096 0.6385904
2.5% 97.5%
0.36 0.64
```

I valori empirici dei quantili non sono molto diversi da quelli teorici. E sono ancora più simili portando n a 100 ($np = 50$).

```
> n <- 100; p <- 0.5
> set.seed(456321)
```

```
> simpc(n,p)
      [,1]      [,2]
[1,] 0.4177573 0.5822427

      5%  95%
0.42 0.58

      [,1]      [,2]
[1,] 0.4020018 0.5979982
2.5% 97.5%
0.4   0.6
```

Passiamo ora a considerare una situazione in cui la distribuzione binomiale si presenta con una asimmetria abbastanza accentuata ($p = 0.1$) e vediamo come si comportano i quantili empirici rispetto a quelli teorici per tre diversi valori di n (50, 100 e 1000).

```
> n <- 50; p <- 0.1
> set.seed(654321)
> simpc(n,p)
      [,1]      [,2]
[1,] 0.03021477 0.1697852
      5%  95%
0.04 0.18

      [,1]      [,2]
[1,] 0.01684577 0.1831542
2.5% 97.5%
0.02 0.18
>
> n <- 100; p <- 0.1
> set.seed(654123)
> simpc(n,p)
      [,1]      [,2]
[1,] 0.05065439 0.1493456
      5%  95%
0.05 0.15

      [,1]      [,2]
[1,] 0.04120108 0.1587989
2.5% 97.5%
0.05 0.16
```

Come ci si aspettava, al crescere della dimensione del campione (e quindi al crescere di np) l'adattamento migliora.

Questo è anche vero se p è molto piccolo ($p = 0.01$), ma n è grande in modo che, nel nostro esempio, $np = 10$.

```

>
> n <- 1000; p <- 0.01
> set.seed(123321)
> simpc(n,p)
      [,1]      [,2]
[1,] 0.004824589 0.01517541
     5%    95%
0.005 0.015

      [,1]      [,2]
[1,] 0.003833117 0.01616688
     2.5% 97.5%
0.004 0.017

```

Non tratteremo ulteriormente il caso della proporzione campionaria, tanto frequente quanto “delicato”, al quale abbiamo dedicato grande spazio nel nostro *Ricerca con R*.

4.5 La varianza campionaria

Le due distribuzioni campionarie che abbiamo considerato, relative alla media e alla proporzione stimate su un campione casuale semplice, sono senza dubbio le più importanti per il ruolo che rivestono nell’ambito dell’*inferenza statistica*.

Esistono tuttavia moltissime altre distribuzioni campionarie; in effetti, ad ogni *stimatore* va affiancata la distribuzione campionaria corrispondente. In questo libro, facendo leva sulle possibilità che ci offre R di impiegare il metodo Monte Carlo per approssimare i risultati teorici, faremo qualche cenno alla distribuzione campionaria di altri stimatori, iniziando con quella della *varianza campionaria*.

Abbiamo definito la varianza di una variabile casuale X nel modo seguente:

$$\text{Var}(X) = E(X - E(X))^2,$$

cioè come la media (il valore atteso) dei quadrati delle differenze fra i valori che può assumere la variabile casuale X e la media della stessa variabile casuale X .

Prendiamo in considerazione ancora una volta l’esempio con cui abbiamo iniziato questo capitolo: un’urna contenente 10 palline contrassegnate con i numeri 0, 1, 2, 3, 4, 5, 6, 7, 8, 9 e una variabile casuale X (che rappresenta il valore associato ad una pallina estratta dall’urna) distribuita come una uniforme discreta con media $\mu = 4.5$ e varianza $\sigma^2 = 8.25$.

Se estraiamo, ad esempio, 3 palline dall’urna in modo bernoulliano (rimettendo, cioè, ogni volta nell’urna la pallina appena estratta), come possiamo *stimare* la varianza σ^2 ? Usando la definizione potremmo definire il seguente *stimatore*:

$$S_1^2 = \frac{(X_1 - 4.5)^2 + (X_2 - 4.5)^2 + (X_3 - 4.5)^2}{3}$$

dove X_1, X_2, X_3 rappresentano i risultati delle tre estrazioni eseguite. Verifichiamo la “bontà” di questo stimatore mediante una simulazione:

1. estraiamo (bernoullianamente) 3 palline dall’urna;
2. calcoliamo il valore s_1^2 dello stimatore S_1^2 usando la formula appena descritta;
3. annotiamo il risultato ottenuto;
4. ripetiamo i punti 1 – 3 un gran numero di volte.

Ecco lo *script* di R che esegue la simulazione precedente un milione di volte e restituisce come risultato finale la media del milione di varianze calcolate.

```
> X <- c(0:9)
> n <- 3
> nrep <- 1000000
> set.seed(654321)
> x <- sample(X,n*nrep,replace=TRUE)
> x <- matrix(x,ncol=3)
> job <- function(x) ((x[1]-4.5)^2+(x[2]-4.5)^2+(x[3]-4.5)^2)/3
> out <- apply(x,1,job)
> mean(out)
[1] 8.256961
```

Facendo la media di tutti i valori ottenuti mediante la simulazione osserviamo che il risultato è molto vicino al valore vero della varianza ($\sigma^2 = 8.25$).

Ora riflettiamo sullo stimatore S_1^2 che abbiamo proposto. Perché abbiamo sottratto da ciascuna osservazione il numero 4.5? Perché 4.5 è la media μ , quindi la *media vera* della variabile casuale X .

Se però vogliamo porci nelle condizioni in cui opera generalmente un ricercatore, questi non conosce il valore della media vera μ e deve stimare la varianza senza disporre di questa informazione. Modifichiamo allora la proposta nel modo seguente:

$$S_2^2 = \frac{(X_1 - \bar{X})^2 + (X_2 - \bar{X})^2 + (X_3 - \bar{X})^2}{3},$$

dove $\bar{X}$ è la media aritmetica delle tre osservazioni. Ripetiamo ora la simulazione, impiegando lo stesso innesco del generatore di numeri pseudo-casuali per avere esattamente lo stesso campione. Naturalmente dobbiamo modificare lo *script* per tener conto della definizione di S_2^2 .

```
> X <- c(0:9)
> n <- 3
> nrep <- 1000000
> set.seed(654321)
> x <- sample(X,n*nrep,replace=TRUE)
> x <- matrix(x,ncol=3)
```

```

> m <- mean(x)
> job <- function(x) ((x[1]-m)^2+(x[2]-m)^2+(x[3]-m)^2)/3
> out <- apply(x,1,job)
> mean(out)
[1] 5.505059

```

Questo risultato non può certo soddisfarci; dopo un milione di repliche la media delle varianze è molto, molto diversa da 8.25. Perché lo stimatore S_2^2 si comporta così male? La risposta sta nel fatto che mentre lo stimatore S_1^2 calcolava le differenze rispetto alla *media vera* (che non cambia da campione a campione), lo stimatore S_2^2 calcola le differenze rispetto alla *media del campione* che, appunto, varia da campione a campione.

Possiamo poi osservare un'altra cosa: se moltiplichiamo il valore finale ottenuto dalla simulazione per 3 e lo dividiamo per 2 il risultato è quasi uguale alla varianza vera 8.25:

```

> mean(out)*3/2
[1] 8.257588

```

Naturalmente messa così si potrebbe dire che stiamo facendo numerologia: perché moltiplicare per 3 e dividere per 2? Teniamo presente che per calcolare la varianza di ciascun campione abbiamo diviso per 3; moltiplicando per 3 annulliamo il risultato della divisione, riottenendo il numeratore che poi dividiamo per 2, cioè per $3 - 1$. In altre parole stiamo proponendo un nuovo stimatore (questo è quello definitivo):

$$S^2 = \frac{(X_1 - \bar{X})^2 + (X_2 - \bar{X})^2 + (X_3 - \bar{X})^2}{3 - 1}.$$

Lasciamo al lettore modificare lo *script*, sostituendo al valore 3 il valore 2 e verificare che la media finale è proprio 8.257588.

Usando un gergo formale diciamo che lo stimatore S_2^2 è *distorto* (*biased*), mentre lo stimatore S^2 è *non distorto* (*unbiased*); anche lo stimatore S_1^2 è *non distorto*, ma è anche “inutilizzabile” in pratica (a meno che non si conosca la media vera). Ecco quindi che per stimare la varianza campionaria impiegheremo sempre il seguente stimatore:

$$S^2 = \frac{\sum_{i=1}^n (X_i - \bar{X})^2}{n - 1} \quad (4.4)$$

Il denominatore della (4.4) è talmente importante da avere un nome: *gradi di libertà* (*degrees of freedom* in inglese). Possiamo dire che i gradi di libertà sono tra i “protagonisti” del nostro *Ricerca con R* e, più in generale, sono protagonisti quando si deve fare inferenza.

Abbiamo visto quindi come si può stimare, in modo non distorto, la varianza su di un campione. Ma a noi interessa anche conoscere la distribuzione di probabilità di questo stimatore. E qui le cose sono un po' meno “favorevoli” rispetto alla media campionaria, nel senso che non c'è un equivalente del teorema del limite centrale.

Vediamo allora come è fatta la distribuzione di probabilità di S^2 quando il campione è estratto da una distribuzione gaussiana con media μ e varianza σ^2 . Prima però prendiamo ancora in considerazione lo stimatore S_1^2 e guardiamo più attentamente la sua definizione nel caso generale

$$S_1^2 = \sum_{i=1}^n \frac{(X_i - \mu)^2}{n}$$

e mettiamola a confronto con la seguente

$$V = \sum_{i=1}^n \frac{(X_i - \mu)^2}{\sigma^2}.$$

La variabile casuale V segue (per definizione) una distribuzione chi quadrato con n gradi di libertà essendo la somma di n variabili casuali normali standardizzate al quadrato e indipendenti (ricordiamo che X è distribuita come una normale con media μ e varianza σ^2). Quindi anche la distribuzione di probabilità di S_1^2 sarà “imparentata” con la distribuzione chi quadrato. In effetti, è sufficiente moltiplicare il numeratore per σ^2 (in modo da semplificare il termine corrispondente al denominatore) e aggiungere n al denominatore per ottenere

$$S_1^2 \sim \frac{\sigma^2}{n} \chi_n^2.$$

Quindi il nostro stimatore “inutilizzabile” segue una distribuzione chi quadrato con n gradi di libertà moltiplicata per un fattore costante (σ^2/n).

Tenendo presente questo risultato, dedichiamoci alla ricerca della distribuzione di probabilità della varianza campionaria, stimata impiegando S^2 . Ancora una volta, prima di enunciare il risultato teorico vediamo di approssimarla con una simulazione molto semplice: estraiamo un campione di n osservazioni da una normale con media $\mu = 170$ e varianza $\sigma^2 = 100$, stimiamo impiegando lo stimatore S^2 la varianza, mettiamo da parte il risultato e ripetiamo il procedimento un numero molto grande di volte. Per provare con diversi valori di n abbiamo preparato la funzione `simvcnorm`:

```
simvcnorm <- function (n,m,s2,nrep){
x <- rnorm(n*nrep,m,sqrt(s2))
X <- matrix(x,ncol=n)
y <- apply(X,1,var)
u <- y*(n-1)/s2
print(c(mean(y),s2))
print(c(mean(u),var(u)))
out <- list(y=y,u=u)
}
```

I parametri della funzione sono, nell'ordine, la dimensione del campione, la media e la varianza della normale e il numero di repliche. La funzione non si limita a calcolare

il valore s^2 su ciascuno dei campioni estratti, ma calcola anche la seguente quantità

$$u = s^2 \times \frac{n-1}{\sigma^2}$$

che verrà utile fra poco.

La funzione restituisce una *lista* formata da due vettori (y e u) che contengono i valori di s^2 e di u ; inoltre propone come *output* la media dei valori di s^2 , il valore di σ^2 come confronto, la media e la varianza dei valori di u .

```
> set.seed(456456)
> ris <- simvcnorm(5,170,100,10000)
[1] 98.65351 100.00000
[1] 3.946141 8.052479
> ris <- simvcnorm(10,170,100,10000)
[1] 100.4267 100.0000
[1] 9.038407 17.896190
> ris <- simvcnorm(50,170,100,10000)
[1] 100.041 100.000
[1] 49.02009 98.11787
> ris <- simvcnorm(100,170,100,10000)
[1] 100.1061 100.0000
[1] 99.10499 200.63409
```

Sono state eseguite 4 simulazioni con diversi valori di n (5, 10, 50 e 100), impiegando sempre 10000 repliche. In tutte le simulazioni la media dei valori di s^2 è risultata sostanzialmente uguale a 100, che è il valore di σ^2 . Di estremo interesse, poi, il fatto che la media dei valori di u sia stata 4, 9, 49 e 99 quando n era, rispettivamente, 5, 10, 50 e 100. Quindi il valore atteso di u sembra proprio $n - 1$, i gradi di libertà associati alla stima della varianza. Non basta: la varianza di u è risultata 8, 18, 98, 201. I primi tre valori sono proprio il doppio dei gradi di libertà e l'ultimo è molto vicino al doppio di 99. Questo è un indizio estremamente importante (alla luce di quanto detto a proposito della distribuzione di S_1^2)!

Abbiamo visto nel capitolo precedente che la variabile casuale *chi quadrato* con v gradi di libertà ha valore atteso v e varianza $2v$. Come possiamo verificare questo nostro “sospetto” (cioè che u segua una distribuzione chi quadrato con $n - 1$ gradi di libertà)? Ma con un *plot* quantile-quantile analogo a quello visto per una normale, adattato a questo caso. Si tratta, cioè, di mettere a confronto i quantili osservati con quelli teorici di una distribuzione chi quadrato con v gradi di libertà. Ecco una funzione “minimale” che produce il grafico che vogliamo. Gli argomenti della funzione sono: il vettore con i dati osservati, i gradi di libertà, i quantili da mettere a confronto (con un *default* che non modificheremo).

```
qqchisq <- function (z,df,q=c(1:99)/100){
  thq <- qchisq(q,df)
```

```
obq <- quantile(z,q)
plot(thq,obq,xlab="Theoretical Quantiles",ylab="Sample Quantiles")
abline(0,1)
}
```




Figura 4.12: Grafico quantile-quantile per l'adattamento ad una distribuzione chi quadrato con $n - 1$ gradi di libertà.

La Figura 4.12 mostra i *plot* quantile-quantile relativi alle quattro simulazioni precedenti ottenuti con il seguente *script*:

```
> set.seed(456456)
> par(mfrow=c(2,2))
> ris <- simvcnorm(5,170,100,10000); qqchisq(ris$u,4)
> ris <- simvcnorm(10,170,100,10000); qqchisq(ris$u,9)
> ris <- simvcnorm(50,170,100,10000); qqchisq(ris$u,49)
```

```
> ris <- simvcnorm(100,170,100,10000); qqchisq(ris$u,99)
> par(mfrow=c(1,1))
```

I punti sono perfettamente allineati a “dimostrazione” che il nostro “sospetto” era corretto. Naturalmente quanto abbiamo fatto non può essere considerato una dimostrazione, ma la teoria ci dice effettivamente che la varianza campionaria stimata attraverso lo stimatore S^2 segue, se il campione di n osservazioni è estratto da una normale con varianza σ^2 , una distribuzione proporzionale a quella di una variabile casuale chi-quadrato con $n - 1$ gradi di libertà ovvero, in formula

$$S^2 \sim \frac{\sigma^2}{n-1} \chi_{n-1}^2.$$

4.6 Distribuzioni campionarie di differenze di medie e di rapporti di varianze

Per la loro importanza nelle applicazioni legate all’inferenza statistica dedichiamo alcune righe alla distribuzione campionaria della differenza fra le medie di due normali e alla distribuzione campionaria del rapporto fra le varianze di due normali.

Se $\bar{X}_1$ e $\bar{X}_2$ sono le medie stimate su due campioni casuali indipendenti di numerosità n_1 e n_2 , estratti da due normali con medie, rispettivamente, μ_1 e μ_2 e con varianze σ_1^2 e σ_2^2 , allora la distribuzione campionaria della differenza fra le due medie è

$$\bar{X}_1 - \bar{X}_2 \sim N\left(\mu_1 - \mu_2, \frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}\right),$$

cioè è normale, con media uguale alla differenza delle due medie e varianza uguale alla somma delle varianze delle medie campionarie.

La distribuzione di probabilità della differenza fra due medie campionarie è alla base dei metodi di inferenza volti, appunto, al confronto delle medie di due campioni indipendenti (si trovano trattati nel capitolo 2 del nostro *Ricerca con R*).

Se S_1^2 e S_2^2 sono le varianze stimate su due campioni indipendenti di numerosità n_1 e n_2 , estratti da due normali con medie, rispettivamente, μ_1 e μ_2 e con la stessa varianza σ^2 , allora la distribuzione campionaria del rapporto fra le due varianze è

$$\frac{S_1^2}{S_2^2} \sim \frac{\chi_{n_1-1}^2/(n_1-1)}{\chi_{n_2-1}^2/(n_2-1)},$$

cioè è una variabile casuale F con $n_1 - 1$ gradi di libertà al numeratore e $n_2 - 1$ gradi di libertà al denominatore.

La distribuzione di probabilità del rapporto fra due varianze campionarie è alla base dell’analisi della varianza (ANOVA), una procedura estremamente potente sviluppata per analizzare i risultati di disegni sperimentali anche molto complessi (una introduzione all’ANOVA si trova nel capitolo 3 del nostro *Ricerca con R*).

4.7 La mediana campionaria

Se X è una variabile casuale normalmente distribuita, il parametro μ rappresenta sia la media sia la mediana di X . Abbiamo visto come la variabile casuale media campionaria ($\bar{X}_n$) sia uno stimatore non distorto di μ . Perché non impiegare invece la *mediana campionaria* per stimare μ ? Rispondiamo con una simulazione.

La funzione `mc` estrae un campione di n osservazioni (il primo argomento di `mc`) da una normale con media `mu` e deviazione standard `sigma` e ne calcola la mediana. Il processo viene ripetuto `nrep` volte (il *default* è 100000) e alla fine la funzione propone come *output* la media e la varianza delle `nrep` mediane campionarie; propone inoltre la varianza della media campionaria.

```
> mc <- function(n,mu,sigma,nrep=100000,seed=123456) {
+   set.seed(seed)
+   x <- rnorm(n*nrep,mu,sigma)
+   X <- matrix(x,ncol=n)
+   y <- apply(X,1,median)
+   c(mean(y),var(y),sigma^2/n)
+ }
```

Anche con un campione di dimensioni alquanto ridotte ($n = 11$),¹ la mediana campionaria è uno stimatore non distorto del parametro μ di una normale (la media delle 100000 mediane campionarie è 170 a tutti gli effetti, cioè il valore vero di μ scelto per la simulazione) e la sua distribuzione di campionamento è normale. Tuttavia la varianza delle 100000 mediane campionarie (13.7) è alquanto maggiore della varianza della media campionaria (9.1) e, quindi, la mediana campionaria è uno stimatore di μ *meno preciso* della media campionaria.

```
> mc(11,170,10)
[1] 169.991304 13.710029 9.090909
```

La situazione non cambia nemmeno aumentando di quasi 10 volte la dimensione del campione ($n = 101$).

```
> mc(101,170,10)
[1] 169.999843 1.548311 0.990099
```

Se la distribuzione dei dati è normale è quindi *più conveniente* stimare μ attraverso la media campionaria.

Non esiste un equivalente del teorema centrale per la mediana campionaria. Vale a dire che ci sono situazioni in cui la distribuzione della mediana campionaria non è normale nemmeno asintoticamente. Basta considerare il seguente esempio.

¹ Abbiamo scelto un numero di osservazioni dispari in modo da avere un unico valore centrale e, quindi, un'unica mediana.

Sia X un variabile casuale che segue una distribuzione di Poisson con parametro $\mu = -\log(0.5)$ (circa 0.693). In questo modo $P(X = 0) = e^{-\mu} = 0.5$ e la mediana (vera) di questa variabile casuale è zero. Eseguiamo una simulazione, modificando opportunamente la funzione `mc` in modo che estragga (ripetutamente) un campione di $n = 11$ osservazioni da una Poisson con media μ e ne calcoli la mediana campionaria. La funzione restituisce le `nrep` mediane calcolate.

```
> mc <- function(n,mu,nrep=100000,seed=123456) {
+   set.seed(seed)
+   x <- rpois(n*nrep,mu)
+   X <- matrix(x,ncol=n)
+   y <- apply(X,1,median)
+   y
+ }
>
> z <- mc(11,-log(0.5))
> table(z)
z
      0      1      2
50187 49508   305
```

Non solo la distribuzione delle mediane campionarie non è normale, ma è anche “altamente discreta”. Circa metà delle volte la mediana campionaria è proprio zero e nei casi rimanenti è quasi sempre 1. La media delle mediane della simulazione è 0.50118, per cui in questo caso lo stimatore è distorto. Aumentare la dimensione del campione (portandola, ad esempio, a 101) non modifica nella sostanza il risultato.

```
> z <- mc(101,-log(0.5))
> table(z)
z
      0      1
49704 50296
```

La situazione non migliora se poniamo la vera mediana uguale a 1. In questo caso per trovare il valore del parametro μ della Poisson ricorriamo alla funzione `uniroot`, dal momento che dobbiamo risolvere l'equazione non lineare $e^{-\mu} + \mu e^{-\mu} = 0.5$:

```
> g <- function(l) exp(-l) + l*exp(-l) - 0.5
> (mu <- uniroot(g,c(1,2))$root)
[1] 1.678353
> ppois(1,mu)
[1] 0.499998
```

Chiamando la funzione `mc` con $\mu = 1.678353$, in circa la metà dei campioni (ciascuno di 101 osservazioni) la mediana è 1, mentre nell'altra metà è 2 (e la media delle 100000 mediane campionarie è circa 1.5).

```
> z <- mc(101,mu)
> table(z)
z
      1      2
49703 50297
```

Un risultato analogo si ha quando la mediana è 10 (in questo caso $\mu = 10.6685$):

```
> g <- function(l) ppois(10,l) - 0.5
> (mu <- uniroot(g,c(10,11))$root)
[1] 10.6685
> ppois(10,mu)
[1] 0.5000025
> z <- mc(101,mu)
> table(z)
z
      9      10      11      12
605 49438 49186   771
```

4.8 L'odds ratio campionario

Consideriamo due variabili casuali X_1 e X_2 fra loro indipendenti e distribuite entrambe come una binomiale con lo stesso parametro n e probabilità di successo, rispettivamente, p_1 e p_2 . Supponiamo inoltre che sia possibile in entrambi i casi approssimare adeguatamente la distribuzione vera (binomiale) mediante una normale. Allora, se indichiamo con $D = X_1/n - X_2/n$ la variabile casuale che descrive la differenza fra le due proporzioni (probabilità) di successo, essa seguirà una distribuzione (approssimativamente) normale con media $E(D) = \delta = p_1 - p_2$ e varianza

$$Var(D) = \frac{p_1(1-p_1)}{n} + \frac{p_2(1-p_2)}{n}.$$

In particolare, se $p_1 = p_2 = p$, avremo $\delta = 0$ e

$$Var(D) = \frac{2p(1-p)}{n}.$$

La Figura 4.13 mostra nel pannello di sinistra la distribuzione campionaria della differenza $\hat{\delta}$ fra due proporzioni ricavata dalla seguente simulazione:

```
> n <- 100; pa <- 0.5; pb <- 0.5
> nrep <- 100000
> set.seed(123456)
> xa <- rbinom(nrep,n,pa)
> xb <- rbinom(nrep,n,pb)
```




Figura 4.13: Distribuzione campionaria della differenza $\hat{\delta} = \hat{p}_1 - \hat{p}_2$ di due proporzioni campionarie. Pannello di sinistra $p_1 = p_2 = 0.5$ e $n_1 = n_2 = 100$. Pannello di destra $p_1 = 0.5$; $p_2 = 0.25$ e $n_1 = n_2 = 100$.

```
> p1 <- xa/n
> p2 <- xb/n
> y <- p1 - p2
> c(mean(y), var(y))
[1] -0.000009600 0.005004216
```

In questa simulazione $p_1 = p_2 = 0.5$ e $n_1 = n_2 = 100$. Avremo quindi che $\delta = 0$ e che $Var(\hat{\delta}) = 0.005$. Il risultato della simulazione è in perfetto accordo con la teoria e la distribuzione campionaria ottenuta per $\hat{\delta}$ è sostanzialmente normale.

La Figura 4.13 mostra nel pannello di destra la distribuzione campionaria della differenza $\hat{\delta}$ fra due proporzioni ricavata dalla seguente simulazione:

```
> n <- 100; pa <- 0.5; pb <- 0.25
> nrep <- 100000
> set.seed(123456)
> xa <- rbinom(nrep, n, pa)
> xb <- rbinom(nrep, n, pb)
> p1 <- xa/n
> p2 <- xb/n
> y <- p1 - p2
> c(mean(y), var(y))
[1] 0.249797600 0.004383561
```

In questa simulazione $p_1 = 0.5$ e $p_2 = 0.25$, mentre $n_1 = n_2 = 100$. In questo caso $\delta = 0.5 - 0.25$ e $Var(\hat{\delta}) = 0.004375$. Anche in questo caso il risultato è in perfetto accordo con la teoria e la distribuzione campionaria di $\hat{\delta}$ è sostanzialmente normale.

Una situazione come quella che abbiamo appena esplorato con le due simulazioni è estremamente frequente nel campo della ricerca empirica, quando si vogliono confrontare due proporzioni (ad esempio la proporzione di soggetti guariti con due diversi trattamenti farmacologici). In sostanza ci sono due proporzioni sconosciute (p_1 e p_2) e se ne vuole valutare la differenza $\delta = p_1 - p_2$. Con questa scelta, il ricercatore assume implicitamente un *modello additivo*.

Una alternativa potrebbe consistere nel confrontare le due proporzioni, facendone il rapporto: p_1/p_2 . In realtà considerazioni teoriche (che rimandano ai modelli lineari generalizzati) suggeriscono di fare il rapporto non delle due probabilità, ma degli *odds* corrispondenti, calcolando così l'*odds ratio*:

$$\psi = \frac{p_1}{(1-p_1)} \times \frac{(1-p_2)}{p_2}.$$

Una cosa da tenere ben presente è che l'*odds ratio* non è sempre calcolabile, dal momento che è un rapporto di due *odds* e che, quindi, il denominatore deve essere diverso da zero. Un *odds ratio* campionario potrebbe assumere valore zero, ma questo caso non sarebbe poi molto diverso dal precedente, dal momento che la scelta dell'*odds* da mettere al denominatore è arbitraria. In effetti due *odds ratio* che sono l'uno il reciproco dell'altro possono essere considerati “uguali”.² Se escludiamo questo caso, l'*odds ratio* (campionario) può assumere tutti i valori (razionali) maggiori di zero. In particolare, l'*odds ratio* vale uno *se e solo se* $p_1 = p_2$.

Proviamo a chiederci, prima di verificarlo con una simulazione, come potrebbe essere la distribuzione campionaria dell'*odds ratio* quando $\psi = 1$ (cioè quando $p_1 = p_2$). Dobbiamo pensare che (circa) la metà delle volte $\hat{\psi}$ (cioè l'*odds ratio* campionario) risulterà minore di 1 e circa metà delle volte risulterà maggiore di 1 (possiamo trascurare i casi in cui $\hat{\psi} = 1$). Però lo “spazio” disponibile fra 0 e 1 è minore di quello che c'è fra 1 e “infinito”. Ci aspettiamo quindi che la distribuzione campionaria sia asimmetrica, con una “coda” a destra (asimmetria positiva). Verifichiamo questa nostra ipotesi ripetendo esattamente (cioè con lo stesso “innesco” del generatore di numeri pseudo-casuali) la prima simulazione (calcolando però l'*odds ratio* dopo aver verificato che questo calcolo sia possibile in tutte le $nrep$ repliche).

```
> n <- 100; pa <- 0.5; pb <- 0.5
> nrep <- 100000
> set.seed(123456)
> xa <- rbinom(nrep,n,pa)
> xb <- rbinom(nrep,n,pb)
```

²Nello stesso senso in cui possono essere considerate “uguali” le due differenze $(\hat{p}_1 - \hat{p}_2)$ e $(\hat{p}_2 - \hat{p}_1)$.

```

> x <- cbind(xa,xb)
> nok <- which((xa == 0) | (xa == n))
> if\index[funr]{if} (length(nok) > 0) x <- x[-nok,]
> xb <- x[,2]
> nok <- which((xb == 0) | (xb == n))
> if (length(nok) > 0) x <- x[-nok,]
> nrow(x)
[1] 100000
> p1 <- x[,1]/n
> p2 <- x[,2]/n
> num <- p1/(1 - p1)
> den <- p2/(1 - p2)
> y <- num/den
> table(sign(y - 1))

    -1      0      1
47147  5566 47287

```

Osserviamo come l'*odds ratio* campionario sia risultato 47147 volte minore di 1 e 47287 volte maggiore di 1, due valori che possiamo considerare sostanzialmente uguali fra loro; inoltre, 5566 volte l'*odds ratio* campionario è risultato esattamente uguale a 1. La Figura 4.14 mostra nel pannello di sinistra la distribuzione campionaria risultante dalla simulazione; è ben evidente come questa distribuzione presenti una decisa asimmetria positiva.




Figura 4.14: Distribuzione campionaria dell'*odds ratio* $\hat{\psi}$ (pannello di sinistra) e del logaritmo naturale dell'*odds ratio* (pannello di destra) quando $\psi = 1$ ($p_1 = p_2 = 0.5$ e $n_1 = n_2 = 100$).

In circostanze come questa si può cercare di rendere la distribuzione meno asimmetrica facendo il logaritmo naturale³ dei valori ottenuti (quindi degli *odds ratio* campionari).

Nel pannello di destra della Figura 4.14 vediamo rappresentata la distribuzione campionaria (risultante dalla simulazione) del logaritmo naturale dell'*odds ratio*. Questa distribuzione appare sostanzialmente simmetrica. La media dei logaritmi dei 100000 *odds ratio* campionari può essere considerata uguale a zero e il suo esponenziale è quindi 1 (cioè il valore vero dell'*odds ratio* impiegato in questa simulazione).

```
> ly <- log(y)
> c(mean(ly), exp(mean(ly)))
[1] -3.645477e-05  9.999635e-01
```

La varianza dei logaritmi dei 100000 *odds ratio* campionari è circa 0.082 e nel pannello di destra della Figura 4.14 è sovrainposto all'istogramma il grafico di una distribuzione normale con media 0 e varianza 0.082. L'adattamento sembra molto buono.

```
> var(ly)
[1] 0.08172334
```

Abbiamo calcolato la varianza del logaritmo dell'*odds ratio* campionario $\hat{\psi}$ in modo empirico. In effetti, esiste una formula approssimata⁴ per calcolare la varianza di un *odds ratio* stimato sulla base dei successi e degli insuccessi osservati in due gruppi a confronto. Se indichiamo con

- a il numero di successi osservati nel gruppo 1,
- b il numero di successi osservati nel gruppo 2,
- c il numero di insuccessi osservati nel gruppo 1,
- d il numero di insuccessi osservati nel gruppo 2,

allora $\hat{\psi} = (ad)/(bc)$ e

$$Var(\hat{\psi}) = \frac{1}{a} + \frac{1}{b} + \frac{1}{c} + \frac{1}{d}. \quad (4.5)$$

Verifichiamo empiricamente questa formula con i risultati della nostra simulazione.

```
> ya <- n - x[,1]
> yb <- n - x[,2]
> X <- cbind(x, ya, yb)
> v <- 1/X[,1] + 1/X[,2] + 1/X[,3] + 1/X[,4]
```

³Può andare bene anche una base diversa da e , ma questa è la base preferita.

⁴Ne parliamo in *Ricerca con R*.

```
> mean(v)
[1] 0.08082637
```

Le quattro colonne della matrice X contengono rispettivamente i valori di a, b, c, d e gli elementi del vettore v sono le $nrep$ stime della varianze campionarie dei logaritmi degli *odds ratio*. La media di queste varianze è molto simile al valore trovato calcolando esplicitamente la varianza a partire dalle $nrep$ stime del logaritmo degli *odds ratio*.

La situazione non cambia nella sostanza anche se il vero *odds ratio* è maggiore di 1. Lo possiamo verificare con una simulazione in cui $p_1 = 0.5$ e $p_2 = 0.25$, così che $\psi = 3$. Ripetendo, con le opportune modifiche, la simulazione vista in precedenza otteniamo i seguenti risultati.

```
> n <- 100; pa <- 0.5; pb <- 0.25
> nrep <- 100000
> set.seed(123456)
> xa <- rbinom(nrep,n,pa)
> xb <- rbinom(nrep,n,pb)
> x <- cbind(xa,xb)
> nok <- which((xa == 0) | (xa == n))
> if(index[funr]){if (length(nok) > 0) x <- x[-nok,]
> xb <- x[,2]
> nok <- which((xb == 0) | (xb == n))
> if (length(nok) > 0) x <- x[-nok,]
> nrow(x)
[1] 100000
> p1 <- x[,1]/n
> p2 <- x[,2]/n
> num <- p1/(1 - p1)
> den <- p2/(1 - p2)
> y <- num/den
> table(sign(y - 1))

-1      0      1
 9      8 99983

> table(sign(y - 3))

-1      0      1
48733   757 50510
```

In questo caso solo 17 volte (su un totale di 100000 repliche) l'*odds ratio* campionario è risultato minore o uguale a 1, mentre circa metà delle volte è risultato superiore a 3. La distribuzione degli *odds ratio* campionari mantiene tuttavia un evidente grado di asimmetria positiva, come risulta osservando il pannello di sinistra della Figura 4.15.




Figura 4.15: Distribuzione campionaria dell'*odds ratio* $\hat{\psi}$ (pannello di sinistra) e del logaritmo naturale dell'*odds ratio* (pannello di destra) quando $\psi = 3$ ($p_1 = 0.5$, $p_2 = 0.25$ e $n_1 = n_2 = 100$).

Anche in questo caso la trasformazione logaritmica è in grado di rendere simmetrica la distribuzione campionaria e di “normalizzarla” (pannello di destra della Figura 4.15).

La media dei logaritmi dei 100000 *odds ratio* campionari può essere considerata molto vicina a $\log(3)$, così che il suo esponenziale è sovrapponibile al valore vero impiegato in questa simulazione ($\psi = 3$).

```
> ly <- log(y)
> c(mean(ly), exp(mean(ly)))
[1] 1.111375 3.038532
```

La varianza dei logaritmi dei 100000 *odds ratio* campionari è circa 0.097 e nel pannello di destra della Figura 4.15 è sovrapposto all'istogramma il grafico di una distribuzione normale con media $\log(3)$ e varianza 0.097. Anche in questo caso l'adattamento sembra buono.

```
> var(ly)
[1] 0.0966227
```

Per quanto riguarda la varianza, anche in questo caso la formula data in precedenza trova riscontro nei risultati della simulazione.

```
> ya <- n - x[,1]
> yb <- n - x[,2]
> X <- cbind(x, ya, yb)
> v <- 1/X[,1] + 1/X[,2] + 1/X[,3] + 1/X[,4]
> mean(v)
[1] 0.0950574
```

4.9 Il rischio relativo campionario

Una situazione analoga a quella appena descritta si ha quando si vogliono mettere a confronto le medie di due Poisson, che possono essere interpretate come due *tassi di incidenza*.

Consideriamo due variabili casuali X_1 e X_2 fra loro indipendenti e distribuite entrambe come una Poisson con parametri μ_1 e μ_2 , rispettivamente. Estraiamo un campione casuale di dimensione n da ciascuna delle due distribuzioni. Supponiamo inoltre che sia possibile in entrambi i casi approssimare adeguatamente la distribuzione vera (Poisson) mediante una normale. Allora, se indichiamo con $D = (X_1 - X_2)/n$ la variabile casuale che descrive la differenza fra le due medie (ovvero fra i due tassi di incidenza), essa seguirà una distribuzione (approssimativamente) normale con media $E(D) = \delta = \mu_1 - \mu_2$ e varianza

$$\text{Var}(D) = \frac{\mu_1}{n} + \frac{\mu_2}{n}.$$

In particolare, se $\mu_1 = \mu_2 = \mu$, avremo $\delta = 0$ e

$$\text{Var}(D) = \frac{2\mu}{n}.$$

La Figura 4.16 mostra nel pannello di sinistra la distribuzione campionaria della differenza $\hat{\delta}$ fra i due tassi di incidenza ricavata dalla seguente simulazione:

```
> n <- 10; ma <- 8; mb <- 8
> nrep <- 100000
```




Figura 4.16: Distribuzione campionaria della differenza $\hat{\delta} = \hat{\mu}_1 - \hat{\mu}_2$ di due tassi di incidenza. Pannello di sinistra $\mu_1 = \mu_2 = 8$ e $n_1 = n_2 = 10$. Pannello di destra $\mu_1 = 8; \mu_2 = 4$ e $n_1 = n_2 = 10$.

```
> set.seed(123456)
> xa <- rpois(nrep,ma*n)
> xb <- rpois(nrep,mb*n)
> x <- cbind(xa,xb)/n
> m1 <- x[,1]
> m2 <- x[,2]
> y <- m1 - m2
> c(mean(y),var(y))
[1] 0.002335 1.590619
```

In questa simulazione $\mu_1 = \mu_2 = 8$ e $n_1 = n_2 = 10$. Avremo quindi che $\delta = 0$ e che $Var(\hat{\delta}) = 1.6$. Il risultato della simulazione è in perfetto accordo con la teoria e la distribuzione campionaria ottenuta per $\hat{\delta}$ è sostanzialmente normale.

La Figura 4.16 mostra nel pannello di destra la distribuzione campionaria della differenza $\hat{\delta}$ fra due tassi di incidenza risultante dalla seguente simulazione:

```
> n <- 10; ma <- 8; mb <- 4
> nrep <- 100000
> set.seed(123456)
> xa <- rpois(nrep,ma*n)
> xb <- rpois(nrep,mb*n)
> x <- cbind(xa,xb)/n
> m1 <- x[,1]
> m2 <- x[,2]
> y <- m1 - m2
> c(mean(y),var(y))
[1] 3.998781 1.199216
```

In questa simulazione $\mu_1 = 8$ e $\mu_2 = 4$, mentre $n_1 = n_2 = 10$. In questo caso $\delta = 8 - 4$ e $Var(\hat{\delta}) = 1.2$. Anche in questo caso il risultato è in perfetto accordo con la teoria e la distribuzione campionaria di $\hat{\delta}$ è sostanzialmente normale.

Una alternativa al confronto attraverso il calcolo della differenza D consiste nel fare il rapporto fra i due tassi di incidenza, calcolando così il *rischio relativo* (o, più propriamente, il *rate ratio*): $\phi = \mu_1/\mu_2$.

La distribuzione campionaria del rischio relativo quando $\phi = 1$ (cioè quando $\mu_1 = \mu_2$) ha fondamentalmente la stessa caratteristica dell'*odds ratio* quando $\psi = 1$. Circa la metà delle volte $\hat{\phi}$ (cioè il rischio relativo campionario) risulterà minore di 1 e circa metà delle volte risulterà maggiore di 1. La distribuzione campionaria sarà quindi asimmetrica, con una asimmetria positiva. Verifichiamolo ripetendo esattamente la prima simulazione, calcolando però il rischio relativo.

```
> n <- 10; ma <- 8; mb <- 8
> nrep <- 100000
> set.seed(123456)
> xa <- rpois(nrep,ma*n)
```

```

> xb <- rpois(nrep,mb*n)
> x <- cbind(xa,xb)/n
> m1 <- x[,1]
> m2 <- x[,2]
> y <- m1/m2
> table(sign(y - 1))

```

```

-1      0      1
48294  3227 48479

```

Il rischio relativo campionario è risultato 48294 volte minore di 1 e 48479 volte maggiore di 1 (due valori sostanzialmente uguali fra loro); inoltre, 3227 volte il rischio relativo campionario è risultato esattamente uguale a 1. La Figura 4.17 mostra nel pannello di sinistra la distribuzione campionaria risultante dalla simulazione; è ben evidente come questa distribuzione presenti una decisa asimmetria positiva.




Figura 4.17: Distribuzione campionaria del rischio relativo $\hat{\phi}$ (pannello di sinistra) e del logaritmo naturale del rischio relativo (pannello di destra) quando $\phi = 1$ ($\mu_1 = \mu_2 = 8$ e $n_1 = n_2 = 10$).

Possiamo cercare di rendere la distribuzione meno asimmetrica facendo il logaritmo naturale del rischio relativo.

Nel pannello di destra della Figura 4.17 vediamo rappresentata la distribuzione campionaria (risultante dalla simulazione) del logaritmo naturale del rischio relativo. Questa distribuzione appare sostanzialmente simmetrica. La media dei logaritmi dei 100000 valori di rischio relativo può essere considerata uguale a zero e il suo esponenziale è quindi 1 (cioè il valore vero del rischio relativo impiegato in questa simulazione).


```
> ly <- log(y)
> c(mean(ly), exp(mean(ly)))
[1] 0.0002776623 1.0002777009
```

La varianza del logaritmo del rischio relativo è circa 0.0253 e nel pannello di destra della Figura 4.17 è sovrapposto all'istogramma il grafico di una distribuzione normale con media 0 e varianza 0.0253. L'adattamento sembra molto buono.

```
> var(ly)
[1] 0.02533428
```

Come per la varianza del logaritmo dell'*odds ratio* campionario esiste una formula approssimata⁵ per calcolare la varianza di un rischio relativo stimato sulla base dei “conteggi” (cioè del numero totale di eventi) osservati in due gruppi a confronto. Se indichiamo con T_1 e T_2 questi due totali, allora $\hat{\phi} = (T_1/n_1)/(T_2/n_2)$ e

$$Var(\hat{\phi}) = \frac{1}{T_1} + \frac{1}{T_2},$$

risultato che è verificato empiricamente nella nostra simulazione.

```
> ta <- ma*n
> tb <- mb*n
> v <- 1/ta + 1/tb
> mean(v)
[1] 0.025
```

Gli elementi del vettore v sono le $nrep$ stime della varianze campionarie del logaritmo del rischio relativo. La media di queste varianze è molto simile al valore trovato calcolando esplicitamente la varianza a partire dalle $nrep$ stime del logaritmo del rischio relativo.

La situazione non cambia nella sostanza anche se il vero rischio relativo è maggiore di 1. Lo possiamo verificare con una simulazione in cui $\mu_1 = 8$ e $\mu_2 = 4$, così che $\phi = 2$. Ripetendo, con le opportune modifiche, la simulazione vista in precedenza otteniamo i seguenti risultati.

```
> n <- 10; ma <- 8; mb <- 4
> nrep <- 100000
> set.seed(123456)
> xa <- rpois(nrep, ma*n)
> xb <- rpois(nrep, mb*n)
> x <- cbind(xa, xb)/n
```

⁵Ne parliamo in *Ricerca con R*.

```
> m1 <- x[,1]
> m2 <- x[,2]
> y <- m1/m2
> table(sign(y - 1))
```

```
-1      0      1
13      3 99984
```

In questo caso solo 16 volte (su un totale di 100000 repliche) il rischio relativo è risultato minore o uguale a 1, mentre circa metà delle volte è risultato superiore a 2. La distribuzione campionaria del rischio relativo mantiene tuttavia un evidente grado di asimmetria positiva, come risulta osservando il pannello di sinistra della Figura 4.18. Anche in questo caso la trasformazione logaritmica è in grado di rendere simmetrica la distribuzione campionaria e di “normalizzarla” (pannello di destra della Figura 4.18).




Figura 4.18: Distribuzione campionaria del rischio relativo $\hat{\phi}$ (pannello di sinistra) e del logaritmo naturale del rischio relativo (pannello di destra) quando $\phi = 2$ ($\mu_1 = 8$, $\mu_2 = 4$ e $n_1 = n_2 = 10$).

La media dei logaritmi dei 100000 valori ottenuti può essere considerata molto vicina a $\log(2)$, così che il suo esponenziale è sovrapponibile al valore vero impiegato in questa simulazione ($\phi = 2$).

```
> ly <- log(y)
> c(mean(ly), exp(mean(ly)))
[1] 0.6991809 2.0121039
```

La varianza del logaritmo dei 100000 valori ottenuti è circa 0.0386 e nel pannello di destra della Figura 4.18 è sovrainposto all’istogramma il grafico di una distribuzione normale con media $\log(2)$ e varianza 0.0386. Anche in questo caso l’adattamento sembra buono.

```
> var(ly)
[1] 0.03859326
```

Per quanto riguarda la varianza, anche in questo caso la formula data in precedenza trova un buon riscontro nei risultati della simulazione.

```
> ta <- ma*n
> tb <- mb*n
> v <- 1/ta + 1/tb
> mean(v)
[1] 0.0375
```

4.10 La distribuzione campionaria di un coefficiente di regressione

Prendiamo in esame la distribuzione campionaria del parametro b_1 di un modello lineare e di un modello lineare generalizzato.

Il modello lineare classico

In questo modello la relazione che lega la variabile dipendente y a quella indipendente x è una relazione lineare $y = b_0 + b_1x$, dove b_1 è detto *coefficiente di regressione lineare*. Disponendo di un campione casuale di n coppie di valori (x_i, y_i) , è possibile stimare (con il metodo dei minimi quadrati) il valore di b_1 . Analogamente ai casi visti in precedenza, anche lo stimatore $\hat{b}_1$ varia da campione a campione e, quindi, possiede una distribuzione campionaria. Per procedere è opportuno scrivere il modello di regressione lineare nel modo seguente:

$$y_i = b_0 + b_1x_i + e_i.$$

Se i *residui* e_i seguono una distribuzione normale con media zero e varianza σ^2 , allora i valori osservati y_i seguono una distribuzione normale con media $\mu_x = b_0 + b_1x$ e varianza σ^2 . In questo caso lo stimatore $\hat{b}_1$ del vero coefficiente di regressione lineare b_1 segue una distribuzione normale il cui valore atteso è proprio b_1 (quindi lo stimatore è non distorto) e varianza data da:

$$Var(\hat{b}_1) = \frac{\sigma^2}{\sum_{i=1}^n (x_i - \bar{x})^2}.$$

Vediamo una verifica empirica di questo risultato teorico mediante una simulazione che si basa sull'esempio impiegato per introdurre il modello lineare classico nel Capitolo 3 e che qui riprendiamo.

Supponiamo che il peso *medio* (in kg) delle persone la cui altezza è x cm sia dato dalla seguente relazione: $y = -85 + 0.88x$. Supponiamo inoltre che, a parità di altezza x , la distribuzione del peso sia normale con media $\mu_x = -85 + 0.88x$ e deviazione

standard $\sigma = 10$. In questo caso, quindi, $b_0 = -85$ e $b_1 = 0.88$. Consideriamo 9 valori distinti per l'altezza (150, 155, 160, ..., 190) e calcoliamo i corrispondenti valori osservati del peso facendo la somma di una parte sistematica ($-85 + 0.88x$) e di una parte casuale (sotto forma di 9 valori estratti da una distribuzione normale con media zero e deviazione standard $\sigma = 10$). Qui di seguito vediamo l'esempio di un campione casuale formato da 9 coppie di osservazioni (x_i, y_i) :

```
> x <- seq(150,190,5)
> m <- -85 + 0.88*x
> e <- rnorm(9,0,10)
> y <- m + e
> rbind(x,m,e=round(e,1),y=round(y,1))
  [,1] [,2] [,3] [,4] [,5] [,6] [,7] [,8] [,9]
x 150.0 155.0 160.0 165.0 170.0 175.0 180.0 185.0 190.0
m  47.0  51.4  55.8  60.2  64.6  69.0  73.4  77.8  82.2
e -19.2   0.1   6.7  -4.6  12.7  -3.4   8.7 -16.1  -9.3
y  27.8  51.5  62.5  55.6  77.3  65.6  82.1  61.7  72.9
```

Le righe 7–10 riportano, rispettivamente

- i 9 valori $x_1, x_2, \dots, x_9$ considerati per la variabile indipendente (definiti nella riga 1 dello *script*);
- i 9 valori $\mu_1, \mu_2, \dots, \mu_9$ corrispondenti del peso medio (calcolati nella riga 2 dello *script*);
- i 9 valori dei residui $e_1, e_2, \dots, e_9$ estratti da una normale con media zero e deviazione standard 10 (riga 3 dello *script*);
- i 9 valori $y_1, y_2, \dots, y_9$ osservati della variabile dipendente (calcolati nella riga 4 dello *script*).

Questo particolare campione produce, per il coefficiente di regressione lineare, una stima $\hat{b}_1 = 0.741$:

```
> fit <- lm(y ~ x)
> fit$coefficients
(Intercept)          x
-60.0955827   0.7412937
```

Ripetiamo questo procedimento 100000 volte e “costruiamo” la distribuzione campionaria empirica di $\hat{b}_1$:

```
> a <- -85
> b <- 0.880
> nrep <- 100000
> set.seed(654321)
> x <- seq(150,190,5)
```

```

> n <- length(x)
> m <- a + b*x
> e <- rnorm(nrep*n,0,10)
> e <- matrix(e,nrow=n)
> y <- m + e
> y <- t(y)
> fit <- function(y){
+   x <- seq(150,190,5)
+   fit <- lm(y ~ x)
+   b <- fit$coefficients
+   b[2]
+ }
> b <- apply(y,1,fit)
> c(mean(b),var(b))
[1] 0.87999640 0.06664259

```

Per rendere più “compatta” la simulazione, abbiamo definito una funzione `fit` che, applicata (`apply`) alle 100000 righe della matrice `y`, restituisce nel vettore `b` le 100000 stime di $\hat{b}_1$. La media di questi valori è sostanzialmente identica al valore vero ($b_1 = 0.88$); anche la varianza (0.0666) è equivalente al valore teorico ($100/1500 = 0.0667$). La Figura 4.19 mostra la distribuzione empirica ottenuta con la simulazione sia sotto forma di istogramma, sia sotto forma di grafico *quantile-quantile*.




Figura 4.19: Distribuzione campionaria del coefficiente di regressione lineare.

Il modello logistico

Nel Capitolo 3 abbiamo visto come l'*odds ratio* ψ sia un modo per valutare la “differenza” fra due proporzioni p_1 e p_2 e come la distribuzione campionaria dello stimatore $\hat{\psi}$ non possa essere considerata normale. Tuttavia, la distribuzione campionaria del suo logaritmo ($\log(\hat{\psi})$) è approssimativamente normale. È possibile dare un

fondamento teorico a questa affermazione ricorrendo alla teoria dei modelli lineari generalizzati.

Riprendiamo in esame l'esempio impiegato in questo capitolo per illustrare l'*odds ratio* campionario e la simulazione a pagina 222.

Ricordiamo brevemente che abbiamo estratto due campioni casuali, ciascuno composto da $n = 100$ osservazioni, da due binomiali con parametri $p_1 = 0.5$ e $p_2 = 0.25$ rispettivamente. In questo caso quindi, $\psi = 3$. Questo processo è stato ripetuto 100000 volte, ottenendo così 100000 *odds ratio* campionari ($\hat{\psi}$) dei quali è stato calcolato il logaritmo per poi ottenerne la media e la varianza.

Se consideriamo i primi due campioni estratti, il numero dei successi è stato $y_1 = 54$ e $y_2 = 31$, per cui l'*odds ratio* campionario è risultato $\hat{\psi} = (54/46)/(31/69) = 3726/1426$, cioè circa 2.61 e il suo logaritmo è circa 0.96.

Possiamo ottenere esattamente la stessa stima impiegando un modello lineare generalizzato in cui la variabile dipendente è la proporzione di successi nei due campioni (0.54 e 0.31) e la variabile indipendente assume i valori 1 e 0; la “famiglia” è la distribuzione binomiale e la funzione di *link* è *logit*.

```
> y <- c(54,31)
> x <- c(1,0)
> n <- c(100,100)
> fit <- glm(y/n ~ x, family=binomial("logit"), weights=n)
> c(fit$coefficients[2],log(3726/1426))
      x
0.960462 0.960462
```

L'ultima riga della *script* mostra che la stima $\hat{b}_1$ del coefficiente di regressione lineare coincide con il logaritmo del rapporto fra i due *odds* (cioè con l'*odds ratio*).

In un modello di questo tipo il predittore lineare $b_0 + b_1x$ può assumere soltanto due valori: b_0 quando $x = 0$ (cioè quando il gruppo è il secondo) e $b_0 + b_1$ quando $x = 1$ (cioè quando il gruppo è il primo). La probabilità di successo nel gruppo 2 è quindi $p_2 = \exp(b_0)/(1 + \exp(b_0))$, mentre la probabilità di successo nel gruppo 1 è $p_1 = \exp(b_0 + b_1)/(1 + \exp(b_0 + b_1))$. Gli *odds* corrispondenti sono $\exp(b_0)$ e $\exp(b_0 + b_1)$ e l'*odds ratio* (gruppo 1 vs gruppo 2) è $\exp(b_1)$. Ecco quindi che il coefficiente di regressione b_1 di un modello logistico non è altro che il logaritmo dell'*odds ratio*. E la teoria dei modelli lineari generalizzati ci dice che la distribuzione campionaria di un coefficiente di regressione (il logaritmo dell'*odds ratio* campionario nel nostro caso) è (asintoticamente) normale.

La regressione di Poisson

Possiamo ripetere quanto appena detto nel caso in cui siamo interessati a valutare la “differenza” fra due tassi di incidenza μ_1 e μ_2 attraverso il rischio relativo $\phi = \mu_1/\mu_2$. La distribuzione campionaria dello stimatore $\hat{\phi}$ non può essere considerata normale, ma quella del suo logaritmo ($\log(\hat{\phi})$) sì (almeno asintoticamente). Anche in questo caso la teoria dei modelli lineari generalizzati è in grado di dare un fondamento teorico a questo risultato empirico.

Riprendiamo in esame l'esempio impiegato in questo capitolo per illustrare il rischio relativo campionario e la simulazione a pagina 225.

Ricordiamo brevemente che abbiamo estratto due campioni casuali (ciascuno formato da $n = 10$ conteggi) da due distribuzioni di Poisson con parametri $\mu_1 = 8$ e $\mu_2 = 4$ rispettivamente. In questo caso quindi, $\phi = 2$. Questo processo è stato ripetuto 100000 volte, ottenendo così 100000 valori campionari ($\hat{\phi}$) dei quali è stato calcolato il logaritmo per poi ottenerne la media e la varianza.

Se consideriamo i primi due campioni estratti, i valori medi dei due conteggi sono stati $y_1 = 8.7$ e $y_2 = 4.4$, per cui il rischio relativo campionario è risultato $\hat{\phi} = 8.7/4.4$, cioè circa 1.98 e il suo logaritmo circa 0.682.

Possiamo ottenere esattamente la stessa stima impiegando un modello lineare generalizzato in cui la variabile dipendente è il numero totale dei conteggi nei due campioni (87 e 44) e la variabile indipendente assume i valori 1 e 0; la “famiglia” è la distribuzione di Poisson con funzione di *link* log e l'offset è il numero di conteggi in ciascun gruppo (10).

```
> y <- c(87,44)
> x <- c(1,0)
> n <- c(10,10)
> fit <- glm(y ~ x, family=poisson("log"), offset=n)
> c(fit$coefficients[2],log(8.7/4.4))
      x
0.6817185 0.6817185
```

In un modello di questo tipo il predittore lineare $b_0 + b_1x$ può assumere soltanto due valori: b_0 quando $x = 0$ (cioè quando il gruppo è il secondo) e $b_0 + b_1$ quando $x = 1$ (cioè quando il gruppo è il primo). Il numero medio di conteggi nel gruppo 2 è quindi $\mu_2 = \exp(b_0)$, mentre il numero medio di conteggi nel gruppo 1 è $\mu_1 = \exp(b_0 + b_1)$. Pertanto il rischio relativo (gruppo 1 vs gruppo 2) è $\exp(b_1)$. Il coefficiente di regressione b_1 di una regressione di Poisson non è quindi altro che il logaritmo del rischio relativo. Dal momento che la regressione di Poisson è un caso particolare di modello lineare generalizzato, la distribuzione campionaria del logaritmo del rischio relativo campionario sarà (asintoticamente) normale.

4.11 Il bootstrap

Concludiamo questo capitolo facendo un breve cenno al *bootstrap*, una tecnica basata sul ricampionamento, introdotta da Bradley Efron nel 1979 per valutare la distorsione (*bias*) e la varianza di uno stimatore; questo metodo sfrutta la potenza di calcolo dei moderni *personal computer*. Insieme ai test di permutazione e ai metodi di “apprendimento statistico” (*statistical learning*) fa parte dei cosiddetti *Computer Intensive Methods* entrati a far parte del bagaglio comune di tutti quelli che fanno analisi di dati.

In un articolo divulgativo, comparso su *Scientific American*, Diaconis e Efron (1983) concludevano scrivendo “Fisher was able to provide a statistical theory that took full advantage of the computational facilities of the 1920’s. The goal now is to do the same for the 1980’s”.⁶

Si può dire che questo ambizioso progetto è andato (molto) avanti. Il *bootstrap* è diventato ormai uno strumento standard di inferenza statistica, in particolare in quei campi in cui trovare risultati per via analitica è difficile.

R è un linguaggio che naturalmente si presta ad impiegare queste metodologie e, a proposito del *bootstrap*, va detto che quando si installa R, viene installato anche il *package boot*. Nel nostro *Ricerca con R* abbiamo dedicato varie pagine all’impiego del *bootstrap* per calcolare intervalli di confidenza ed eseguire test di significatività. In queste pagine vogliamo invece illustrare come si possa impiegare il *bootstrap* per ottenere una stima approssimata della varianza di uno stimatore. Questa era in un certo senso lo scopo originario del *bootstrap* proposto da Efron (1979a).

L’idea di fondo è davvero estremamente semplice: si tratta di estrarre ripetuti campioni, con rimessa, dai dati originari; in altre parole, si tratta di applicare il metodo Monte Carlo ai dati del proprio campione (e non per simulare nuovi dati come abbiamo fatto fino ad ora). Proprio da questo procedimento proviene il nome *bootstrap*, facendo riferimento alla frase idiomatica americana “*pull oneself over a fence by one’s bootstraps*”.⁷ In effetti inizialmente al *bootstrap* è stata mossa l’accusa di fare troppo affidamento sui dati campionari. Di fatto, però, i metodi di inferenza statistica si basano sulle informazioni presenti nel campione; se un campione, ancorché estratto seguendo tutti gli accorgimenti del caso, è “estremo” (ad esempio, lontano dal “centro” della distribuzione), i risultati che produrrà saranno verosimilmente distorti. Naturalmente questo rischio, sempre presente per via delle regole probabilistiche, si riduce all’aumentare della dimensione del campione ed è (anche) per questo che è estremamente importante dimensionare in modo accurato un esperimento o uno studio osservazionale.

Alla base del *bootstrap* c’è l’estrazione di un *campione bootstrap*. Se indichiamo con $x = \{x_1, x_2, \dots, x_n\}$ l’insieme dei valori osservati su un campione di dimensione n , allora un campione *bootstrap* si ottiene estraendo *con reimmissione* dal campione originale x un insieme di n osservazioni. Questo è un *campione bootstrap* e indichiamo

⁶Lo stesso articolo è comparso (sempre nel 1983), tradotto in italiano, sul numero 179 della rivista “Le Scienze” (l’edizione italiana di *Scientific American*) con il titolo “Statistica al calcolatore”.

⁷Il *bootstrap* è il “tirante” collocato sul bordo superiore di uno stivale allo scopo di calzarlo più facilmente. Secondo alcuni questo termine si troverebbe in una frase attribuita al barone von Münchhausen, che affermava di essere uscito dalle sabbie mobili “*picking himself up by his own bootstraps*”. Del resto lo stesso Efron (1979b) scrive “The name bootstrap is meant to be euphonic with jackknife, the two methods being closely related as we shall see, and also to convey the self-help nature of the bootstrap algorithm.” E una decina di anni fa, Efron (2010b) ha avvalorato l’ipotesi che il termine *bootstrap* derivi dal romanzo di Rudolph Erich Raspe, dichiarando “I always liked the Baron Munchhausen stories.”

con $x^* = \{x_1^*, x_2^*, \dots, x_n^*\}$ l'insieme dei valori entrati a far parte di questo campione. Vediamo come sia immediato ottenere con R un campione *bootstrap* (basta usare la funzione `sample` e assegnare all'argomento `replace` il valore `TRUE`). Consideriamo una distribuzione uniforme discreta fra 1 e 100 ed estraiamo un campione casuale semplice di 10 osservazioni:⁸

```
> u <- c(1:100)
> (x <- sample(u, 10, replace=TRUE))
[1] 67 54 100 49 97 62 51 38 62 83
```

Un (singolo) campione *bootstrap* si ottiene, in questo caso nel modo seguente:

```
> n <- length(x)
> (xb <- sample(x, n, replace=TRUE))
[1] 100 51 54 51 62 67 62 51 100 97
```

È del tutto evidente che un campione *bootstrap* x^* non è una permutazione del campione x di partenza, dal momento che l'estrazione è eseguita con rimessa. Quindi, in generale, in un campione *bootstrap* alcune osservazioni saranno ripetute più di una volta e altre (contenute nel campione originale) non compariranno affatto. Nel nostro esempio 51 si ripete 3 volte, mentre gli elementi di x che non sono stati estratti in x^* sono tre:

```
> setdiff(x, xb)
[1] 49 38 83
```

Naturalmente con un unico campione *bootstrap* non andremmo da nessuna parte. Il *bootstrap* consiste nell'estrarre un numero (molto) grande B di campioni *bootstrap* sui quali calcolare la statistica che ci interessa.⁹ Il valore di B dipende da diversi fattori. In particolare, per costruire intervalli di confidenza oppure eseguire test di significatività è necessario un numero più elevato di repliche *bootstrap*, mentre, se vogliamo avere un'idea di quale possa essere la varianza di uno stimatore (che è quanto vogliamo fare in queste pagine), allora il numero di campioni *bootstrap* da estrarre può essere più contenuto, ad esempio $B = 1000$ (anche se noi impiegheremo $B = 10000$).

Esempio 4.1 L'esempio classico con il quale si introduce generalmente il *bootstrap* è anche quello in cui non serve in realtà impiegarlo per ottenere la risposta esatta: qual è la varianza della media campionaria? Arrivati quasi alla fine di questo capitolo e di questo libro non possiamo non conoscere la risposta. Se σ^2 è la varianza della

⁸Nell'esempio che segue non impiegheremo un innesco predefinito, perché l'interesse non è riprodurre esattamente gli stessi risultati.

⁹Se il campione x di partenza è costituito da n elementi tutti distinti, allora il numero di possibili campioni *bootstrap* è n^n , vale a dire un numero tale che, nella grandissima maggioranza dei casi, non può essere gestito direttamente.

popolazione dalla quale estraiamo un campione casuale semplice di dimensione n , allora la varianza della media campionaria è σ^2/n .

Verifichiamo che la stima *bootstrap* della varianza della media campionaria è vicina al valore teorico prendendo in esame una distribuzione uniforme discreta fra 1 e 100 (la cui varianza è quindi $\sigma^2 = 833.25$) e un campione casuale semplice di $n = 10$ osservazioni estratto da questa distribuzione.

```
> u <- c(1:100)
> set.seed(123456)
> (x <- sample(u,10,replace=TRUE))
[1] 80 76 40 35 37 20 54 10 99 17
```

Estraiamo quindi 10000 campioni *bootstrap* a partire dagli elementi contenuti nel vettore x . Lo faremo senza ricorrere a cicli, sfruttando la vettorialità di R.

```
> B <- 10000
> n <- length(x)
> set.seed(987654)
> tmp <- sample(x,n*B,replace=TRUE)
> xb <- matrix(tmp, nrow = B)
> dim(xb)
[1] 10000    10
```

La matrice xb ha 10000 righe e 10 colonne. Ogni riga rappresenta un campione *bootstrap* di 10 osservazioni estratto, con rimessa, dal campione originario i cui valori sono gli elementi di x .

Calcoliamo ora la media aritmetica (cioè la statistica della quale vogliamo stimare la varianza) di ogni campione *bootstrap*.

```
> m <- apply(xb,1,mean)
```

e, per finire, la varianza dei 10000 valori contenuti in m sarà la nostra stima *bootstrap* della varianza della media campionaria:

```
> var(m)
[1] 81.1677
```

Il valore vero è $833.25/10 = 83.325$, ma è davvero “fantastico” come il *bootstrap* sia riuscito ad arrivare ad una stima non molto lontana dal vero basandosi solo sui dati del campione (e senza “conoscere” la teoria delle distribuzioni campionarie o le proprietà della varianza).

Il *bootstrap* della mediana. Possiamo usare lo stesso esempio e lo stesso *script* per dare risposta ad una domanda “meno facile” della precedente: qual è la varianza della *mediana campionaria*? Impieghiamo gli stessi 10000 campioni *bootstrap* e sostituiamo soltanto $m <- \text{apply}(xb,1,\text{mean})$ con $m <- \text{apply}(xb,1,\text{median})$. La risposta (la stima della varianza della mediana campionaria associata al nostro campione) è

```
> var(m)
[1] 173.6392
```

In questo caso non conosciamo però la risposta esatta, ma possiamo approssimarla con il metodo Monte Carlo:

```
> u <- c(1:100)
> n <- 10
> nrep <- 100000
> set.seed(123456)
> x <- sample(u, n*nrep, replace=TRUE)
> x <- matrix(x, nrow=nrep)
> m <- apply(x, 1, median)
> var(m)
[1] 189.0119
```

Abbiamo estratto 100000 campioni casuali semplici, ciascuno di dimensione $n = 10$ da una distribuzione uniforme discreta fra 1 e 100; su ciascuno di questi abbiamo trovato la mediana e, infine, ne abbiamo calcolato la varianza (che per noi sarà il risultato “vero”). La stima *bootstrap* della varianza della mediana campionaria, almeno nel nostro esempio, è assolutamente soddisfacente.

Esempio 4.2 Presentiamo un secondo esempio, un po’ più complesso del precedente, per il quale comunque si conosce la risposta esatta.

Se X è un variabile casuale normalmente distribuita con varianza σ^2 , sappiamo che la distribuzione della varianza campionaria S^2 stimata su un campione casuale di dimensione n è proporzionale ad una distribuzione χ^2 con $v = n - 1$ gradi di libertà e che il fattore di proporzionalità è σ^2/v . Allora la varianza della varianza campionaria è

$$\text{Var}(S^2) = \text{Var}\left(\frac{\sigma^2 \chi_v^2}{v}\right) = \frac{\sigma^4}{v^2} \text{Var}(\chi_v^2) = \left(\frac{\sigma^4 \times 2v}{v^2}\right) = \frac{2\sigma^4}{v}.$$

Prendiamo una normale con media $\mu = 60$ e varianza $\sigma^2 = 9$ ed estraiamo un campione casuale di dimensione $n = 101$ i cui elementi sono nel vettore x :

```
> m <- 60; s <- 3
> n <- 101
> set.seed(123456)
> x <- rnorm(n, m, s)
```

Estraiamo quindi 10000 campioni *bootstrap* a partire dagli elementi contenuti nel vettore x .

```
> B <- 10000
> n <- length(x)
> set.seed(654321)
```

```
> tmp <- sample(x,n*B,replace=TRUE)
> xb <- matrix(tmp, nrow = B)
> dim(xb)
[1] 10000 101
```

La matrice *xb* ha 10000 righe e 101 colonne. Ogni riga rappresenta un campione *bootstrap* di 101 osservazioni estratto, con rimessa, dal campione originario i cui valori sono gli elementi di *x*.

Calcoliamo ora la varianza (la statistica della quale vogliamo stimare la varianza) di ogni campione *bootstrap*.

```
> v <- apply(xb,1,var)
```

e, per finire, la varianza dei 10000 valori contenuti in *v* sarà la nostra stima *bootstrap* della varianza della varianza campionaria:

```
> var(v)
[1] 1.377145
```

Il valore vero è $2 \times 3^4 / (101 - 1)$, cioè 1.62, ma la stima *bootstrap* non è per nulla lontana da questo valore.

Esempio 4.3 Il terzo esempio è decisamente più complesso in quanto coinvolge due campioni indipendenti sui quali vogliamo calcolare l'*odds ratio* e stimarne, con il *bootstrap*, la varianza.

Siano X_A e X_B due variabili casuali di Bernoulli indipendenti con parametri $p_A = 0.5$ e $p_B = 0.25$ rispettivamente. In questo caso l'*odds ratio* A vs B è $\psi = 3$.

Se estraiamo un campione di dimensione $n = 400$ da ciascuna delle due distribuzioni e calcoliamo l'*odds ratio* campionario ($\hat{\psi}$) qual è la sua varianza? Cerchiamola mediante il metodo Monte Carlo.

```
> n <- 400; pa <- 0.5; pb <- 0.25
> nrep <- 100000
> set.seed(123456)
> xa <- rbinom(nrep,n,pa)
> xb <- rbinom(nrep,n,pb)
> p1 <- xa/n
> p2 <- xb/n
> num <- p1/(1 - p1)
> den <- p2/(1 - p2)
> y <- num/den
> var(y)
[1] 0.2228688
```

Possiamo quindi pensare che $Var(\hat{\psi}) = 0.223$, risultato che prenderemo come corretto.

Estraiamo ora due campioni di dimensione $n = 400$ dalle due distribuzioni e calcoliamo l'*odds ratio*.

```

> n <- 400; pa <- 0.5; pb <- 0.25
> set.seed(123456)
> xa <- rbinom(n,1,pa)
> xb <- rbinom(n,1,pb)
> p1 <- sum(xa)/n
> p2 <- sum(xb)/n
> num <- p1/(1 - p1)
> den <- p2/(1 - p2)
> y <- num/den
> c(sum(xa),sum(xb),y)
[1] 197 101 2.872897

```

Gli elementi dei vettori *xa* e *xb* sono 0 (ad indicare un insuccesso) e 1 (ad indicare un successo). Nel campione *A* abbiamo osservato 197 successi (su 400 prove); nel campione *B* abbiamo osservato 101 successi (su 400 prove); quindi $\hat{\psi} = 2.87$. Stimiamo la sua varianza con il *bootstrap*.

In questo caso dobbiamo estrarre (ripetutamente) due campioni *bootstrap*, uno dal vettore *xa* e uno dal vettore *xb* sui quali stimare l'*odds ratio* e, alla fine della procedura, calcolarne la varianza.

```

> B <- 10000
> set.seed(123456)
> na <- length(xa)
> y <- sample(xa,na*B, replace=TRUE)
> ya <- matrix(y,nrow=B)
> nb <- length(xb)
> y <- sample(xb,nb*B, replace=TRUE)
> yb <- matrix(y,nrow=B)
> dim(ya)
[1] 10000 400
> dim(yb)
[1] 10000 400

```

Le righe delle matrici *ya* e *yb* contengono gli elementi dei 10000 campioni *bootstrap* estratti. Calcoliamo, su ciascun campione *bootstrap*, la stima della probabilità di successo e, quindi, l'*odds ratio*.

```

> pa <- apply(ya,1,sum)/na
> pb <- apply(yb,1,sum)/nb
> num <- pa/(1 - pa)
> den <- pb/(1 - pb)
> y <- num/den

```

La varianza dei 10000 valori contenuti in *y* sarà la nostra stima *bootstrap* della varianza di $\hat{\psi}$:

```
> var(y)
[1] 0.2003361
```

Il valore “vero” (ovvero quello che riteniamo tale, trovato con il metodo Monte Carlo) è 0.223 e la stima *bootstrap* non è lontana da esso.

Esempio 4.4 L'esempio conclusivo è sostanzialmente simile al precedente dal momento che coinvolge due campioni indipendenti sui quali vogliamo calcolare il rischio relativo e stimarne, con il *bootstrap*, la varianza.

Siano X_A e X_B due variabili casuali di Poisson indipendenti con parametri $\mu_A = 8$ e $\mu_B = 4$ rispettivamente. In questo caso il rischio relativo A vs B è $\phi = 2$.

Se estraiamo un campione di dimensione $n = 100$ da ciascuna delle due distribuzioni e calcoliamo il rischio relativo campionario ($\hat{\phi}$) qual è la sua varianza? Cerchiamola anche in questo caso con il metodo Monte Carlo.

```
> n <- 100; ma <- 8; mb <- 4
> nrep <- 100000
> set.seed(123456)
> xa <- rpois(nrep,n*ma)
> xb <- rpois(nrep,n*mb)
> y <- xa/xb
> var(y)
[1] 0.01518891
```

Possiamo quindi pensare che $Var(\hat{\phi}) = 0.0152$, risultato che prenderemo come corretto.

Estraiamo ora due campioni di dimensione $n = 100$ dalle due distribuzioni e calcoliamo il rischio relativo.

```
> n <- 100; ma <- 8; mb <- 4
> set.seed(123456)
> xa <- rpois(n,ma)
> xb <- rpois(n,mb)
> y <- sum(xa)/sum(xb)
> c(sum(xa),sum(xb),y)
[1] 791 391 2.023018
```

Gli elementi dei vettori xa e xb sono i conteggi osservati nei due campioni. Nel campione A il numero complessivo di eventi osservati è stato 791 (quindi la media è 7.91); nel campione B il numero complessivo di eventi osservati è stato 391 (quindi la media è 3.91); pertanto $\hat{\psi} = 2.02$. Stimiamo la sua varianza con il *bootstrap*.

Come nell'esempio precedente, dobbiamo estrarre (ripetutamente) due campioni *bootstrap*, uno dal vettore xa e uno dal vettore xb sui quali stimare il rischio relativo e, alla fine della procedura, calcolarne la varianza.

```
> B <- 10000
> set.seed(45612)
> na <- length(xa)
> y <- sample(xa,na*B, replace=TRUE)
> ya <- matrix(y,nrow=B)
> nb <- length(xb)
> y <- sample(xb,nb*B, replace=TRUE)
> yb <- matrix(y,nrow=B)
> dim(ya)
[1] 10000 100
> dim(yb)
[1] 10000 100
```

Le righe delle matrici *ya* e *yb* contengono gli elementi dei 10000 campioni *bootstrap* estratti. Calcoliamo, su ciascun campione *bootstrap*, la media e, quindi, il rischio relativo.

```
> num <- apply(ya,1,mean)
> den <- apply(yb,1,mean)
> y <- num/den
```

La varianza dei 10000 valori contenuti in *y* sarà la nostra stima *bootstrap* della varianza di $\hat{\phi}$:

```
> var(y)
[1] 0.01528823
```

In questo caso la stima *bootstrap* è quasi identica al valore trovato con il metodo Monte Carlo (0.01518891).

Come abbiamo accennato in precedenza, l'installazione standard di R contiene il *pac-kage* *boot* e la funzione *boot* in grado di eseguire il *bootstrap* senza dover eseguire ogni volta uno *script* specifico, come invece abbiamo fatto in queste pagine. Nel libro *Ricerca con R* abbiamo dato alcuni dettagli operativi sull'impiego della funzione *boot* e ad esso rimandiamo.

Bibliografia

- Agresti A.** (2019) *An Introduction to Categorical Data Analysis*, 3rd ed. John Wiley & Sons, Inc., New York.
- Agresti A., Franklin C.** (2016) *Statistica – L'arte e la scienza d'imparare dai dati*. Pearson Italia, Milano (a cura di G. Espa, R. Micciolo, D. Giuliani, M.M. Dickson)
- Agresti A., Kateri M.** (2022) *Foundations of Statistical Science for Data Scientists*. CRC Press, Boca Raton.
- Baclawski K., Cerasoli M., Rota G.C.** (1990) *Introduzione alla probabilità*. Unione matematica italiana, Bologna.
- Bliss C.I.** (1935) *The calculation of the dosage-mortality curve*. *Annals of Applied Biology*, 22, 134–167.
- Clarke R.D.** (1946) *An application of the Poisson distribution*. *Journal of the Institute of Actuaries*, 72 (3), 481.
- David F.N.** (1955) *Studies in the History of Probability and Statistics I. Dicing and Gaming (A Note on the History of Probability)*. *Biometrika*, 42 (1/2), 1–15.
- David F.N.** (1962) *Games, Gods and Gambling*. Hafner Pub. Co., New York.
- Diaconis P., Efron B.** (1983) *Computer-Intensive Methods in Statistics*. *Scientific American*, 248 (5), 116–130.
- Dobson A.J.** (2002) *An introduction to generalized linear models*, 2nd ed. Chapman & Hall/CRC, Boca Raton.
- Efron B.** (1979a) *Bootstrap methods: Another look at the jackknife*. *The Annals of Statistics*, 7, 1–26.
- Efron B.** (1979b) *Computers and the theory of statistics: thinking the unthinkable*. *SIAM Review*, 21, 460–480.
- Efron B.** (1986) *Why Isn't Everyone a Bayesian?*. *The American Statistician*, 40 (1), 1–5.

- Efron B.** (2004) *Bayesians, Frequentists, and Scientists*. 164th ASA presidential address, Toronto, August 10.
- Efron B.** (2010a) *The Future of Indirect Evidence*. *Statistical Science*, 25 (2), 145–157.
- Efron B.** (2010b) *A Life in Statistics: Conversation with Julian Champkin*. *Significance*, 7 (4), 460–480.
- Efron B.** (2013) *A 250-year Argument: Belief, Behavior, and the Bootstrap*. *Bulletin (New Series) of the American Mathematical Society*, 50 (1), 129–146.
- Efron B.** (2013) *Bayes' Theorem in the 21st Century*. *Science*, 340 (6137), 1177–1178.
- Efron B.** (2019) *Bayes, Oracle Bayes and Empirical Bayes*. *Statistical Science*, 34 (2), 177–201.
- Espa G., Micciolo R.** (2008) *Problemi ed esperimenti di statistica con R*. Maggioli/Apogeo Education, Milano.
- Espa G., Micciolo R.** (2012) *Analisi esplorativa dei dati con R*. Maggioli/Apogeo Education, Milano.
- Feller W.** (1968) *An Introduction to Probability Theory and Its Applications*. Vol. 1, 3rd ed. John Wiley & Sons, Inc., New York.
- Gigerenzer G.** (2003) *Quando i numeri ingannano. Imparare a vivere con l'incertezza*. Raffaello Cortina Editore, Milano.
- Hacking I.** (2013) *The Emergence of Probability. A Philosophical Study of Early Ideas about Probability, Induction and Statistical Inference*. 2nd ed. Cambridge University Press, Cambridge.
- Johnson N.L., Kemp A.W., Kotz S.** (2005) *Univariate Discrete Distributions*, 3rd ed. Wiley-Interscience, Hoboken, New Jersey.
- Kahneman D., Slovic P., Tversky A.** (1982) *Judgment Under Uncertainty: Heuristics and Biases*. New York: Cambridge University Press.
- Kendall M.G.** (1956) *Studies in the history of probability and statistics II. The beginnings of a probability calculus*. *Biometrika*, 43 (1/2), 1–14.
- Latham A.G., Harding K.L., Lapointe P., Morris W.A., Balch S.J.** (1989) *On the lognormal distribution of oxides in igneous rocks, using magnetic susceptibility as a proxy for oxide mineral concentration*. *Geophysical Journal International*, 96 (1), 179–184.

- McCullagh P., Nelder J.A.** (1989) *Generalized Linear Models* (2nd ed.). Taylor & Francis Lt., London.
- Micciolo R., Espa G., Canal L.** (2013) *Ricerca con R*. Maggioli/Apogeo Education, Milano.
- Nelder J. A., Wedderburn R.W.M.** (1972) *Generalized Linear Models*. Journal of the Royal Statistical Society. Series A (General), 135 (3), 370–384.
- Pesarin F.** (1979) *Sulla necessità di mantenere una pluralità di approcci inferenziali*. Convegno Internazionale di Statistica Medica, Verona.
- Piccinato L.** (1979) *Le controversie sui fondamenti della statistica e la loro rilevanza per la statistica medica*. Convegno Internazionale di Statistica Medica, Verona.
- Quine M. P., Seneta E.** (1987) *Bortkiewicz's Data and the Law of Small Numbers*. International Statistical Review, 55 (2), 173–181.
- Stigler S.M.** (1988) *The Dark Ages of Probability in England: The Seventeenth Century Work of Richard Cumberland and Thomas Strode*. International Statistical Review, 56 (1), 75–88.
- Stigler S.M.** (1992) *A Historical View of Statistical Concepts in Psychology and Educational Research*. American Journal of Education, 101 (1), 60–70.
- Stigler S.M.** (2013) *The True Title of Bayes's Essay*. Statistical Science, 28 (3), 283–288.
- Tillé Y., Dickson M.M., Espa G.** (2020) *Elementi di campionamento e stima da popolazioni finite*. Pearson Italia, Milano.
- Tversky A., Kahneman D.** (1974) *Judgment under Uncertainty: Heuristics and Biases*. Science, 185 (4157), 1124–1131.
- Vulpiani A.** (2014) *Caso, probabilità e complessità*. Ediesse, Roma.

Indice analitico

- accuratezza, 201, 203
- albero degli eventi, 41
- ampiezza dell'intervallo, 157, 204, 205
- ANOVA, 214
- approssimazione
 - gaussiana, 205
 - normale, 157, 205
- asimmetria
 - negativa, 92
 - positiva, 92
- assioma
 - del limite inferiore, 38
 - del limite superiore, 38
 - della continuità, 38
 - della sommabilità completa, 38
 - della sommabilità finita, 38
- bias, 233
- big bang, 33
- Body Mass Index, 195–197
- bookmaker, 55, 60–62, 65, 67
- bootstrap, 233–238
- calcolo
 - combinatorio, 3, 25
 - infinitesimale, 121
- campione
 - con reimmissione, 90, 234
 - senza reimmissione, 103
- casi
 - favorevoli, 3, 16, 12
 - possibili, 3, 12, 16
- caso, 2
- coefficiente
 - binomiale, 115
 - di regressione, 229, 231
- combinazioni
 - con ripetizione, 10
 - semplici, 7, 15
- concavità, 86, 144, 197
- conteggio, 105, 173, 180
- convoluzione, 131, 136
- correzione per la continuità, 153, 155
- covariate, 169
- COVID-19, 175, 182
- curva logistica, 59, 175
- data-frame, 195
- decili, 123, 128, 129, 163
- deviazione standard, 76, 86, 106, 159, 193, 215
- differenze di medie, 214
- dimensionalità, 76
- dimensione del campione, 190, 191, 203
- dimezzamento, 132
- disegni sperimentali, 214
- dispersione, 201, 202
- disposizioni
 - con ripetizione, 9, 10
 - semplici, 6, 10
- distorsione, 203, 233
- distribuzione
 - campionaria, 195, 208, 214
 - campionaria empirica, 230
 - chi quadrato, 211
 - di probabilità, 29, 70
 - normale standard, 146, 147, 150, 195
 - simmetrica, 84, 206
 - Weibull, 140, 180
- disuguaglianza di Bienaymé-Čebyšëv, 76
- Divina Commedia, 71, 73
- emivita, 132
- epidemiologia, 183
- equiprobabilità, 28, 35
- errore standard, 193, 203
- esperimento
 - casuale, 2, 37

- estrazione
 - con rimessa, 10, 14, 15
 - senza rimessa, 14, 15
- eventi
 - congiunti, 40
 - disgiunti, 38, 48
 - incompatibili, 38
 - indipendenti, 40, 49
 - mutuamente esclusivi, 40
- evento
 - certo, 37, 38
 - complementare, 25, 55
 - elementare, 37, 69
 - impossibile, 37, 39
- falsi
 - negativi, 51
 - positivi, 51
- famiglia esponenziale, 168, 169, 172
- fattore di correzione, 104
- fattoriale discendente, 6
- fluttuazione, 101
- formula di Stirling, 13
- funzione
 - azzardo, 138, 139, 141
 - azzardo cumulativo, 139
 - di densità di probabilità, 72, 121, 124, 132, 137, 138, 144, 169
 - di link, 172, 175
 - di ripartizione, 121
 - di probabilità, 72, 91, 103, 105, 113, 121
 - di probabilità, 70
 - di ripartizione, 70, 79, 85, 132, 144, 148
 - di sopravvivenza, 132, 141, 143
 - di varianza, 168
 - Gamma, 137
- GLIM, 173
- gradi di libertà, 167, 168, 210
- grafico quantile-quantile, 195, 196
- incertezza, 2, 37
- indipendenza, 88, 103
- inferenza, 143, 151, 164, 208
- infinità numerabile, 38, 70, 121
- insieme
 - potenza, 38
 - vuoto, 37, 40
- intercetta, 98, 99, 142, 143, 169
- intersezione, 37, 40, 41, 138
- ISTAT, 162
- istogramma, 127, 136, 161, 162, 221, 231
- lista, 212
- logaritmo naturale, 59, 178, 181, 220
- logit, 57, 60, 177, 232
- lotteria, 71
- lotto, 2, 88
- massima verosimiglianza, 170, 173
- meccanica statistica, 1, 3, 11
- media
 - campionaria, 187, 191, 193, 203
 - ponderata, 110
- mediana campionaria, 215
- metodo
 - dei minimi quadrati, 170
 - della massima verosimiglianza, 171
 - Monte Carlo, 22, 24, 27, 204, 208, 234
- moda, 123
- modello
 - additivo, 162, 219
 - binomiale, 89
 - binomiale negativo, 118
 - di Poisson, 180
 - geometrico, 88
 - lineare classico, 169, 229
 - lineare generalizzato, 169, 172, 177, 181
 - logistico, 59, 173, 174, 231
 - moltiplicativo, 162
- Monte Carlo, 22, 24, 27
- moto Browniano, 34, 94
- normale standard, 146, 148, 167, 201
- numeri
 - pseudo-casuali, 36, 56, 209
 - ritardatari, 2
- numero di Avogadro, 29, 35
- odds, 55, 57, 58, 219
- odds ratio, 219
 - campionario, 217, 219
- ordine, 6, 7, 15
- parametro canonico, 168
- partizione, 48

- passaggiata casuale, 94
- permutazioni
 - con ripetizione, 8, 22
 - semplici, 4, 22
- plot quantile-quantile, 213
- popolazione, 14, 53, 162
- precisione, 193, 201, 202
- predittore lineare, 172, 174, 178
- principio
 - del prodotto, 49, 87, 91
 - della somma, 39
- probabilità
 - a posteriori, 47, 48, 54
 - a priori, 47, 48, 54
 - composte, 40
 - condizionata, 40, 41
 - cumulate, 79
 - di successo, 86, 88, 90
 - ontologica, 28
 - totale, 18, 49
- processo stocastico, 94
- proporzione campionaria, 205
- prova bernoulliana, 90
- quantili, 123, 129
- quartile, 123
- quota, 55, 60
- Q-Q plot, 128
- randomizzazione, 103
- range, 94, 108
- rapporti di varianze, 214
- rate ratio, 225
- regola del prodotto, 40, 103
- regressione di Poisson, 181, 183, 232
- rischio, 41, 75
 - relativo, 183
 - relativo campionario, 224
- roulette, 74, 78
- scala, 140, 154
- scarti dalla media, 75
- scarto quadratico medio, 76
- scatterplot, 142, 170
- scommessa equa, 55, 60
- scozzata perfetta, 4
- seme, 33, 41, 56, 90
- sensibilità, 51, 53
- simulazione, 17, 57, 96, 129, 134
- somma infinita, 89
- sopravvivenza, 132, 138
- sottodispersione, 110
- sovradi dispersione, 118
- spazio
 - campionario, 37
 - degli eventi, 38
- specificità, 51, 53
- standard deviation, 76
- standardizzazione, 150
- Statistica, 169, 194, 201
- stima, 18, 85, 100, 112, 142
- stimatore, 187, 208
- successo, 28, 36, 58, 86, 90, 175
- tabelle di contingenza, 185
- tasso di incidenza, 183
- teorema
 - del limite centrale, 195, 210
 - delle probabilità totali, 48
 - di Bayes, 48, 50, 54
- termodinamica, 29, 31
- test diagnostici, 50, 53
- trasformazione
 - complementary log log, 178
 - logaritmica, 198, 199
 - logit, 58, 174, 177
 - probit, 177
- troncamento, 109
- tunnel mentali, 44–46
- unbiased, 193
- universo, 37
- urna, 10, 30, 79, 80, 86, 87, 104, 187, 203
- valore
 - assoluto, 76, 96
 - atteso, 77, 164, 181, 208, 212
 - predittivo negativo, 51
 - predittivo positivo, 51
- valori standardizzati, 201
- variabile casuale, 69
 - binomiale, 90
 - binomiale negativa, 113, 116
 - chi quadrato, 164
 - continua, 121
 - di Bernoulli, 86
 - di Poisson, 105
 - discreta, 72
 - esponenziale, 132
 - F, 167
 - Gamma, 136

geometrica, 87
ipergeometrica, 102
log-normale, 159
normale, 143
 t di Student, 164
triangolare discreta, 82
uniforme continua, 124
uniforme discreta, 78

variabilità, 2, 75, 203
varianza campionaria, 208, 214
velocità, 29, 183
verifica d'ipotesi, 36
verosimiglianza, 47, 49
vincita, 56, 61

Wikipedia, 162

Indice delle funzioni e dei termini di R

abline, 57
apply, 27
as.numeric, 83

binomial, 175
Binomiale, 92
boot, 234
break, 17

cat, 32
cbind, 50
choose, 7
cloglog, 177
colnames, 191
confint, 184
cumsum, 80
curve, 57

data.frame, 80
dbinom, 21, 36, 92
dchisq, 164
dexp, 133
df, 168
dgamma, 138
dhyper, 104
diff, 88
dimnames, 84, 190
dlnorm, 159
dnbinom, 115--117
dpois, 106
dt, 164, 166
duplicated, 28

Ehr, 32, 34

factorial, 4, 26
family, 175
for, 21, 23
function, 69, 114, 115

glm, 174

hist, 127

if, 17
ifelse, 17
interval, 111

lchoose, 13
length, 97
lines, 95
lm, 98, 142, 158, 172
log, 13
logit, 174
lower.tail, 150
lty, 57

matrix, 28
max, 126
mc, 215
mean, 188
meanlog, 159
median, 133
min, 126

NaN, 13
ncol, 84
nrow, 28

offset, 183
outer, 82, 189

pbirthday, 28
pchisq, 164
pexp, 133
pf, 168
plot, 32
pnorm, 147
Poisson, 106
ppois, 216

- prob, 116
- ProbNorm, 150
- prod, 161
- prop.table, 83
- pt, 164
- punif, 126

- qbirthday, 27
- qchisq, 164
- qexp, 133
- qf, 168
- qlnorm, 162
- qnorm, 152
- qt, 164
- quantile, 128, 163
- qunif, 128

- rate, 133
- rbind, 12
- rbinom, 36, 205
- rchisq, 164
- readLines, 71
- rep, 31
- repeat, 17
- replace, 6, 14, 56, 235
- rexp, 133
- rf, 168
- rlnorm, 197
- rmf, 92, 106, 150, 195
- rnorm, 159
- round, 58
- rowMeans, 204

- rowSums, 64, 84, 131
- rpois, 216
- rt, 164
- runif, 127
- rweibull, 142

- sample, 6, 14, 17, 56, 235
- scale, 142
- sdlog, 159
- seq, 58
- set.seed, 36
- setdiff, 235
- shape, 138
- sign, 220
- simpc, 205
- simtc, 195
- simvcnorm, 211
- size, 6, 116
- sort, 142
- sum, 63

- table, 56, 83, 136
- triangle, 129, 131

- uniroot, 111, 112, 216
- unlist, 84, 190

- var, 109

- weights, 174
- which, 220

Indice dei nomi

- Agresti, A., 55, 169, 185
Avogadro, A., 29, 35
- Baclawski, K., 70
Bayes, T., 46–48, 50, 51, 54
Bernoulli, J., 3, 36, 86, 90, 92, 173, 205, 238
Bliss, C.I., 173
Bolt, U., 8
Boltzmann, L., 1, 3, 29
Brown, R., 34
- Campbell, L., 1
Canton, J., 46
Cantor, G., 121
Cardano, G., 2, 16
Cerasoli, M., 70
- Dante, 2, 71
David, F.N., 2, 22
de Fermat, P., 3, 22
De Grasse, A., 8
de Moivre, A., 3
de Montmort, P.R., 3
Diaconis, 234
Dobson, A.J., 173
- Efron, B., 55, 233, 234
Ehrenfest, P., 31
Einstein, A., 34, 35
Espa, G., 98, 128, 169, 170
- Feller, W., 11, 105, 106
Feynman, R., 1
Fisher, R.A., 37, 168, 234
Franklin, C., 169
- Galileo, 3, 21, 22
Garrett, W., 1
Gatlin, J., 8
Gauss, C.F., 143
- Gibbs, J.W., 1, 3
Gigerenzer, G., 51–54
- Hacking, I., 36
Huygens, C., 3
- Johnson, N.L., 110
- Kahneman, D., 1, 44
Kemp, A.W., 110
Kendall, M.G., 16, 22
Kolmogorov, A.N., 37
Kotz, S., 110
- Laplace, P.S., 3
- Mach, E., 31
Maxwell, J.C., 1, 29
McCullagh, P., 168
Micciolo, R., 98, 128, 169, 170
- Nelder, J.A., 168, 169, 173
Neyman, J., 37
- Pacioli, L., 16
Pascal, B., 3, 22
Pearson, E., 37
Pearson, K., 36
Pesarin, F., 55
Piccinato, L., 55
Poincaré, H., 31
Price, R., 46
- Raspe, R.E., 234
Rota, G.C., 70
- Slovic, P., 44
Snedecor, G.W., 168
Stigler, S., 1, 3, 46
Stirling, J., 13
- Tillé, Y., 104
Tversky, A., 1, 44

Vulpiani, A., 30, 34, 35

Zermelo, E., 31

Wedderburn, R.W.M., 169, 173